

UNIVERSIDAD
DE SANTIAGO
DE CHILE

Universidad de Santiago de Chile
Departamento de Matemática y Ciencia de la Computación

Modelamiento de Series de Tiempo Funcionales a través de Mezclas de Procesos Dirichlet Dependientes

Ingeniería Estadística

Profesor: Andres Iturriaga Jofre

Estudiante: Juan Francisco Ceballos González

Índice general

Secciones **Página**

Agradecimientos **7**

1. Introducción **9**
1.1. Contexto y motivación aplicada 9
1.2. Objetivo General 11
1.2.1. Objetivos Específicos 11

2. Marco Teórico **13**
2.1. Datos Funcionales 14
2.1.1. Representación Funcional de Dimensión Finita 14
2.1.1.1. Criterios para el truncamiento 16
2.1.2. Propiedades de las Funciones Base 17
2.1.2.1. Ortogonalidad y Ortonormalidad 18
2.1.2.2. Condiciones sobre el sistema de base 19
2.1.3. Función Base: B-splines 19
2.1.4. Análisis de Componentes Principales Funcional 20
2.1.4.1. Operador de covarianza y descomposición espectral . . 20
2.1.4.2. Representación de Karhunen–Loève y scores FPCA . . 21
2.1.4.3. Selección de componentes 22
2.2. Series de Tiempo Funcionales 23
2.2.1. Proceso Estocástico Funcional 23
2.2.2. Modelos Funcionales Clásicos 24
2.2.2.1. Limitaciones Estructurales 25
2.2.3. Criterios de Evaluación 26
2.2.3.1. Esquema de evaluación temporal con ventana móvil . . 26
2.2.3.2. Métricas de error 27
2.2.3.3. Evaluación de la intervalos de credibilidad 28
2.3. Fundamentos de Inferencia Bayesiana 29
2.3.1. Modelación Jerárquica Bayesiana 29
2.3.2. Inferencia Probabilística y Métodos MCMC 30
2.3.2.1. Algoritmo de Metropolis–Hastings 30
2.3.2.2. Muestreador de Gibbs 31
2.3.2.3. Slice Sampling 31
2.4. Procesos de Dirichlet 31
2.4.1. Definición y propiedades 32

2.4.2. Construcción Stick-Breaking 32
2.4.3. Distribución Posterior 33
2.5. Mezcla de Procesos de Dirichlet 34
2.5.1. Modelo Jerárquico con DP 34
2.5.2. Clusters y Asignación 34
2.5.3. Inferencia Posterior 35
2.5.4. Aleatorización de Hiperparámetros 35
2.6. Mezcla de Procesos Dirichlet Dependientes 36
2.6.1. Procesos de Dirichlet Dependientes 36
2.6.2. Procesos Stick-Breaking Dependientes 37
2.6.3. Modelos de Mezclas DDP 38
2.6.3.1. Modelos con Dependencia Temporal 38

3. Mezclas DDP para Series de Tiempo Funcionales 41
3.1. Motivación 41
3.2. Estado del Arte 42
3.2.1. Discusión y brecha de investigación 44
3.3. Probit Stick-Breaking Process Mixture 44
3.3.1. Especificación del modelo de mezclas 46
3.3.2. Esquema de inferencia bayesiana 47
3.3.3. Propiedades 49
3.4. Modelo PSBPM-FD 50
3.4.1. Esquema de inferencia 51
3.5. Reconstrucción Funcional 53
3.5.1. Esperanza predictiva 53
3.5.2. Varianza predictiva 54
3.5.3. Extracciones de la predictiva funcional 55
3.5.4. Predictores puntuales de la curva 56
3.5.4.1. Mediana puntual 56
3.5.4.2. Átomo más probable 56
3.5.5. Intervalos de credibilidad predictivos 57
3.5.5.1. Intervalo puntual equi-colas 57
3.5.5.2. Banda simultánea 57
3.5.5.3. Región de máxima densidad 57
3.6. Comportamientos predictivos 58
3.6.1. Agrupamiento de las extracciones 58
3.6.2. Número de comportamientos 59
3.6.3. Comportamientos como opciones de estimación 60
3.7. Diseño del Estudio de Simulación 60
3.7.1. Escenarios 61
3.8. Resultados 62
3.8.1. Error puntual 62
3.8.2. Intervalos de predicción 64
3.8.3. Comportamientos predictivos 66
3.8.4. Pronóstico por comportamiento 68
3.8.5. Síntesis 70

4. Aplicacion **73**

A. Algoritmos de Simulación **75**
A.1. Esquema común 75
A.2. Algoritmos basados en Scores de la Representación Funcional 76
A.2.1. Algoritmo C-1: Heterocedasticidad condicional en los scores . . 76
A.2.2. Algoritmo C-2: Cambio de régimen por umbral en los scores . . 77
A.2.3. Algoritmo C-3: Multimodalidad en los scores 79
A.3. Configuración del estudio de simulación 81

B. Resultados Complementarios del Estudio de Simulación **85**
B.1. Métricas completas por número de componentes 85
B.1.1. Escenario TAR 85
B.1.2. Escenario GARCH 85
B.1.3. Escenario de multimodalidad 85
B.2. Sensibilidad al ancho de la ventana 85
B.3. Desempeño a lo largo del período de prueba 85
B.3.1. Error de predicción 85
B.3.2. Intervalos de predicción 85
B.4. Calibración respecto de la representación truncada 85
B.5. Intervalos por componente 85
B.6. Predicciones curva a curva 85
B.6.1. Escenario TAR 85
B.6.2. Escenario GARCH 85
B.6.3. Escenario de multimodalidad 85

Agradecimientos

Este trabajo se realizó en el marco del proyecto FONDECYT 1251860.

Quiero expresar mi más sincero agradecimiento a mi profesor guía, Andrés Iturriaga Jofré, por su dedicación y compromiso constante a lo largo de todo el desarrollo de esta tesis. Sus observaciones críticas y su exigencia metodológica fueron fundamentales para dar forma y rigor al modelo propuesto en este trabajo. Agradezco especialmente su disposición para discutir extensamente cada decisión estructural, su paciencia frente a los múltiples ajustes que fue necesario realizar, y la confianza que depositó en mi capacidad de llevar adelante esta investigación de manera autónoma. Su guía no solo fue clave en lo académico, sino también en la forma en que aprendí a abordar problemas de investigación con mayor rigurosidad y sentido crítico.

Agradezco también a la Universidad de Santiago de Chile y al Departamento de Ingeniería Estadística, por brindarme el espacio académico, la infraestructura y los recursos necesarios para desarrollar esta investigación en condiciones adecuadas.

A mi familia, por su apoyo incondicional a lo largo de este proceso, por acompañarme en los momentos de mayor exigencia y por comprender el tiempo que este trabajo demandó.

A mis compañeros y compañeras de programa, por los intercambios de ideas, las discusiones metodológicas informales y el acompañamiento mutuo durante las etapas más desafiantes de esta investigación.

Finalmente, agradezco al proyecto FONDECYT 1251860, cuyo financiamiento hizo posible la realización de esta investigación.

Capítulo 1

Introducción

La presente tesis se organiza en cuatro capítulos. Este primer capítulo describe el contexto aplicado que motiva el problema de estudio desde la perspectiva de las aplicaciones, y formula los objetivos generales y específicos del trabajo.

El Capítulo 2 presenta los fundamentos teóricos y metodológicos sobre los que descansa el modelo propuesto. En él se desarrolla la representación de datos funcionales en bases de dimensión finita y el análisis de componentes principales funcional, el marco de las series de tiempo funcionales y sus criterios de evaluación, los fundamentos de la inferencia bayesiana y los métodos de simulación MCMC y por ultimo la construcción de los Procesos de Dirichlet, sus modelos de mezcla y sus extensiones dependientes.

El Capítulo 3 constituye el aporte metodológico de la tesis. Se presenta el Probit Stick-Breaking Process de Chung y Dunson (2009) y se deriva de él el modelo propuesto, PSBPM-FD, con su esquema de inferencia y la reconstrucción funcional de su predictiva, de la que se obtienen la curva predicha, sus intervalos de credibilidad y los comportamientos que la mezcla distingue. El capítulo cierra con el estudio de simulación y sus resultados.

Finalmente, el Capítulo 4 aplica la metodología propuesta mediante su aplicación a datos reales de series de tiempo funcionales.

1.1. Contexto y motivación aplicada

En diversos ámbitos aplicados, los procesos de interés se registran de forma intradiaria a intervalos regulares de una hora, treinta o quince minutos, e incluso a resoluciones mayores. Bajo una representación discreta tradicional, cada período queda descrito por un vector de dimensión elevada (por ejemplo, 24, 48 o 96 componentes por día), y la predicción del período siguiente se convierte en un problema de series de tiempo multivariadas de alta dimensión. En este escenario, la especificación de modelos clásicos se complejiza de manera considerable el número de parámetros de un modelo vectorial autorregresivo crece cuadráticamente con la dimensión, la estimación se vuelve inestable con muestras de tamaño moderado y la estructura de dependencia entre los distintos instantes del día resulta difícil de imponer de manera parsimoniosa, Aue, Norinho y Hörmann, 2015;

Bosq, 2000; Kokoszka y Reimherr, 2017.

Una alternativa conceptualmente más adecuada consiste en reconocer que estas observaciones densamente muestreadas son, en esencia, discretizaciones de una curva subyacente, y tratarlas en consecuencia como datos funcionales, es decir, en lugar de un vector $\mathbf{X}_t \in \mathbb{R}^p$ correspondiente al día t, se dispone de una curva $X_t(\tau)$, $\tau \in [0, 1]$, que resume la totalidad del registro intradía del período t. La Figura 1.1 ilustra esta idea: el panel superior muestra la serie completa a resolución de media hora durante 88 días, mientras que el panel inferior segmenta los primeros cinco días en las curvas diarias $X_1(\tau), \ldots, X_5(\tau)$. Este corte funcional no constituye una abstracción, sino una simple reorganización de la información ya registrada, la cual en lugar de una sucesión de valores indexados en el tiempo, ahora dispone de una sucesión de curvas.

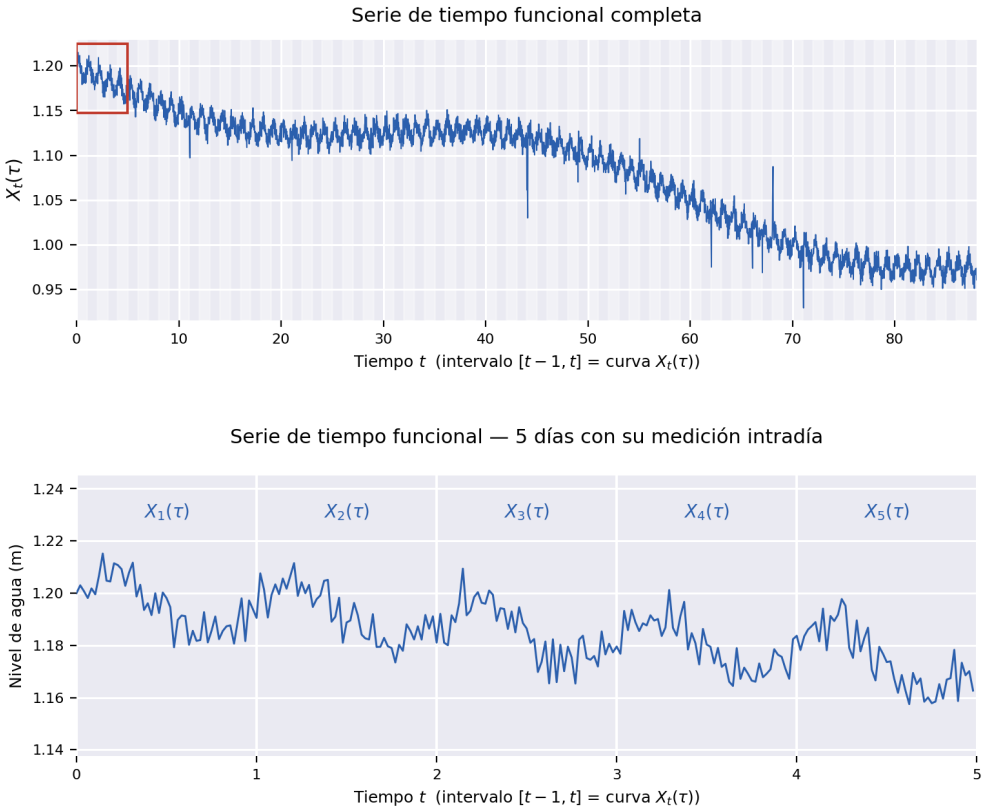


Figura 1.1: Ejemplo de serie de tiempo funcional. Panel superior: Serie de tiempo funcional completa durante 88 días. Panel inferior: Los primeros cinco días segmentados en curvas diarias con 48 mediciones diarias.

El registro de la Figura 1.1 es solo un ejemplo de una situación mucho más general, fenómenos tan diversos como la demanda y el precio de electricidad estudiados en Shah y Lisi, 2020; H. L. Shang, 2013, los retornos y la volatilidad intradía de activos financieros H. L. Shang, 2017; D. Wang et al., 2025, los caudales de un río Beyaztas, H. L. Shang y Yaseen, 2021 o el volumen de tráfico vehicular Wagner-Muns et al., 2018 que se registran de manera prácticamente continua y admiten esta misma lectura: las observaciones de cada período natural conforman una curva completa antes que una colección de valores aislados. Más aún, en todos estos casos la magnitud relevante para

la toma de decisiones no es un resumen escalar, sino la forma de la trayectoria. Así, el horario en que se alcanza el caudal máximo condiciona las acciones de prevención ante un eventual desbordamiento; el perfil intradía de volatilidad determina las estrategias de cobertura y la medición del riesgo a lo largo de la jornada bursátil; y la hora punta de demanda gobierna el despacho de generación eléctrica, así como la identificación de los horarios de menor consumo para mitigar costos.

Pese a lo anterior, una estrategia ampliamente utilizada en la práctica consiste en resumir cada período mediante estadísticos agregados, tales como promedios, máximos o mínimos diarios o semanales. Si bien este procedimiento reduce la dimensionalidad del problema, conlleva una pérdida en la forma completa de las trayectorias, la variabilidad intradía, los patrones locales y la posible presencia de comportamientos atípicos quedan descartados. En consecuencia, cuando se emplea un estadístico agregado como la media para resumir la información, la predicción se concentra exclusivamente en dicho valor e ignora la estructura de la curva, precisamente aquella sobre la que descansan muchas de las decisiones operativas señaladas.

El enfoque de series de tiempo funcionales evita esta pérdida, al conservar la información estructural de cada período y modelar la sucesión de curvas como un proceso estocástico con valores en un espacio de funciones.

1.2. Objetivo General

Desarrollar un modelo bayesiano no paramétrico basado en Mezclas de Procesos de Dirichlet Dependientes para series de tiempo funcionales, que describa la distribución condicional completa de la curva dado su pasado y permita predecirla.

1.2.1. Objetivos Específicos

- Representar las trayectorias funcionales observadas en una base de funciones de dimensión finita.
- Aplicar análisis de componentes principales funcional sobre las curvas representadas para obtener vectores de scores de dimensión reducida.
- Formular un modelo bayesiano no paramétrico para los scores mediante Mezclas de Procesos de Dirichlet Dependientes, en el que los pesos de la mezcla dependan del estado rezagado del proceso.
- Adaptar un esquema de inferencia bayesiana basado en métodos MCMC que entregue extracciones de la distribución a posteriori y, a partir de ellas, la distribución predictiva de los scores y de la curva.
- Incorporar metodologías de análisis de la forma de la distribución predictiva, mediante agrupamiento de sus extracciones, que identifiquen los comportamientos que la mezcla distingue y la probabilidad de cada uno.

- Estimar la curva futura y su incertidumbre a partir de la distribución predictiva mediante predictores puntuales e intervalos de credibilidad consistentes con la forma de dicha distribución.
- Evaluar el desempeño predictivo del modelo frente a modelos de referencia mediante estudios de simulación y aplicaciones a datos reales de series de tiempo funcionales.

Capítulo 2

Marco Teórico

El presente capítulo desarrolla los fundamentos teóricos que sustentan la metodología propuesta en este trabajo. El primer bloque, la Sección 2.1, introduce la noción de dato funcional y su representación mediante sistemas de funciones base, junto con los criterios para seleccionar la dimensión de dicha representación. Se discuten las propiedades que debe satisfacer el sistema de base, en particular la ortogonalidad y ortonormalidad, y se presentan las B-splines como familia de funciones base predeterminada. El bloque cierra con el Análisis de Componentes Principales Funcional (FPCA), que mediante la descomposición espectral del operador de covarianza y la representación de Karhunen–Loève provee el sistema ortonormal óptimo derivado de los propios datos.

El segundo bloque, la Sección 2.2, extiende la noción de serie de tiempo al caso funcional. Se presentan los modelos FAR, FMA y FARMA como generalizaciones de los modelos clásicos al espacio $L^2(\mathcal{T})$, y se identifican sus limitaciones estructurales: homogeneidad temporal, linealidad de la forma y supuestos distribucionales rígidos sobre las innovaciones, las cuales motivan la búsqueda de enfoques no paramétricos para modelar la dinámica del proceso. El bloque incorpora, además, los criterios de evaluación del desempeño predictivo, que comprenden el esquema de evaluación temporal, las métricas de error sobre la curva reconstruida, y la evaluación de la distribución predictiva mediante criterios.

El tercer bloque, la Sección 2.3, presenta los fundamentos de la inferencia bayesiana que sostienen el resto del trabajo. Se introducen el Teorema de Bayes, la modelación jerárquica y los métodos MCMC empleados en la estimación, en particular los algoritmos de Metropolis–Hastings, el muestreador de Gibbs y el Slice Sampling.

El cuarto bloque, las Secciones 2.4 y 2.5, desarrolla el Proceso de Dirichlet y sus modelos de mezcla. Se presentan su definición y propiedades, la construcción stick-breaking y el carácter discreto que de ella se desprende, la distribución posterior, y la inferencia en modelos DPM a partir de la partición en clusters inducida por dicho carácter discreto, incluyendo la aleatorización de hiperparámetros. Este bloque establece el prior no paramétrico sobre el cual se construye la extensión dependiente.

El quinto bloque, la Sección 2.6, introduce los Procesos de Dirichlet Dependientes como extensión del DPM al caso en que la distribución mezcladora varía con las covariables.

Se presentan las variantes según el componente sobre el cual recae la dependencia y los procesos de stick-breaking dependientes, que generalizan la construcción stick-breaking del DP para introducir dependencia en los pesos de la mezcla. El bloque desarrolla, a partir de ello, el modelo jerárquico de mezclas DDP, análogo al del DPM pero condicionado en la covariable, y discute su aplicación natural al modelamiento de series de tiempo mediante el uso de rezagos como predictores.

2.1. Datos Funcionales

Un dato funcional corresponde a una observación cuya unidad elemental no es un valor escalar o vectorial, sino una función definida sobre un dominio continuo, como el tiempo o el espacio. En consecuencia, cada observación puede interpretarse como una curva o realización funcional que varía de forma continua a lo largo de dicho dominio.

Formalmente, un dato funcional se define como una función:

$$\chi(\tau), \qquad \chi : \mathcal{T} \to \mathbb{R}, \tag{2.1}$$

donde $\mathcal{T}$ representa un dominio continuo, usualmente un intervalo compacto de $\mathbb{R}$. Por simplicidad, se considera frecuentemente $\mathcal{T} = [0, 1]$, aunque el dominio puede corresponder a cualquier intervalo adecuado para el problema de estudio.

En la práctica, las observaciones funcionales no se registran de manera continua, sino en un conjunto finito de puntos discretos, debido a limitaciones de medición y almacenamiento. No obstante, el enfoque funcional asume que dichas observaciones discretas provienen de una función subyacente suave, lo que permite representar y comparar curvas completas en lugar de valores puntuales.

Adicionalmente, una característica distintiva de los datos funcionales es que las observaciones no necesariamente comparten los mismos puntos de medición. Esta propiedad, junto con la capacidad de capturar comportamientos suaves subyacentes, permite que el enfoque de datos funcionales facilite la introducción y análisis del comportamiento de las derivadas, enriqueciendo así el análisis estadístico.

2.1.1. Representación Funcional de Dimensión Finita

Para llevar a cabo cualquier procedimiento inferencial es necesario tratar las funciones observadas como elementos de un espacio dotado de estructura adecuada, del mismo modo que en estadística clásica los datos escalares se interpretan como elementos de la recta real $\mathbb{R}$ y los datos multivariados como elementos del espacio euclídeo $\mathbb{R}^d$.

Definición 2.1.1 (Variable funcional aleatoria). Una variable aleatoria X se denomina variable funcional aleatoria si toma valores en un espacio de dimensión infinita, o espacio funcional, Ferraty y Vieu, 2006.

Una realización χ de X corresponde a lo que se presentó anteriormente como un dato u observación funcional. La definición de variable funcional aleatoria introduce, por tanto, un objeto de dimensión infinita, lo que motiva la búsqueda de un espacio que admita

una representación de dimensión finita capaz de conservar la información esencial de la curva.

Por esta razón se trabaja en el espacio $L^2(\mathcal{T})$, conformado por las funciones de cuadrado integrable sobre $\mathcal{T}$, esto es, aquellas que satisfacen:

$$\int_{\mathcal{T}} f^2(\tau)\, d\tau < \infty. \tag{2.2}$$

Este espacio aporta la estructura necesaria para la representación funcional ya que está dotado del producto interno

$$\langle f, g\rangle = \int_{\mathcal{T}} f(\tau)\, g(\tau)\, d\tau, \tag{2.3}$$

que induce una noción de norma $\|f\| = \langle f, f\rangle^{1/2}$ y de distancia $d(f, g) = \|f - g\|$.

Esta geometría, análoga a la del espacio euclídeo finito-dimensional, confiere sentido a la noción de proyección y a la representación de una función mediante sus coeficientes en un sistema de base, Kokoszka y Reimherr, 2017. Más aún, $L^2(\mathcal{T})$ es separable, propiedad que garantiza la existencia de una base numerable, es decir, un sistema $\{\phi_j\}_{j=1}^{\infty}$ indexado por los números naturales cuyos elementos generan todo el espacio.

Los sistemas de funciones empleados para representar curvas pueden clasificarse en dos categorías según su origen. Los sistemas predeterminados se definen con independencia de los datos, mediante construcciones analíticas fijadas de antemano, como las bases de Fourier, las wavelets y las B-splines, Ramsay y Silverman, 2006. Los sistemas derivados de los datos, en cambio, se construyen a partir del propio proceso observado, como el sistema de funciones propias que produce el Análisis de Componentes Principales Funcional (Sección 2.1.4). Esta clasificación es relevante porque determina tanto el mecanismo mediante el cual la representación finita aproxima a la curva como el criterio con que se elige su dimensión.

La forma en que una curva se representa mediante un número finito de coeficientes depende, además, de las propiedades geométricas del sistema. El caso más favorable corresponde a un sistema ortonormal completo, es decir, una base ortonormal de $L^2(\mathcal{T})$, propiedad que se define formalmente en la Sección 2.1.2.1. Si $\{\phi_j\}_{j=1}^{\infty}$ es una base ortonormal, toda función $X_i \in L^2(\mathcal{T})$ admite la expansión

$$X_i(\tau) = \sum_{j=1}^{\infty} \alpha_{ij}\, \phi_j(\tau), \qquad \alpha_{ij} = \langle X_i, \phi_j\rangle, \tag{2.4}$$

cuya serie converge a X_i en la norma de $L^2(\mathcal{T})$, y la suma parcial de K términos coincide con la proyección ortogonal de X_i sobre el subespacio generado por $\{\phi_1, \ldots, \phi_K\}$, que constituye la mejor aproximación posible dentro de dicho subespacio, Kokoszka y Reimherr, 2017. En este régimen, el truncamiento

$$X_i(\tau) \approx \sum_{j=1}^{K} \alpha_{ij}\, \phi_j(\tau) \tag{2.5}$$

está plenamente justificado, con un error igual a la cola de la serie, $\left\|X_i - \sum_{j=1}^{K} \alpha_{ij}\,\phi_j\right\|^2 = \sum_{j>K} \alpha_{ij}^2$, que decrece monótonamente conforme aumenta K.

Cabe precisar que esta garantía no se extiende de manera automática a cualquier sistema de funciones. Cuando el sistema no es ortonormal, la existencia de una expansión única y convergente con coeficientes estables requiere condiciones adicionales, y en el caso de los sistemas predeterminados de dimensión finita, el sistema no constituye una base del espacio, sino que genera un subespacio de dimensión finita. En ese régimen la representación finita no proviene de truncar una serie, sino de proyectar la curva sobre el subespacio generado, y la calidad de la aproximación mejora no al agregar términos de una serie fija, sino al enriquecer el propio subespacio, por ejemplo refinando la malla de nodos. La convergencia queda entonces garantizada por la densidad de estos subespacios en $L^2(\mathcal{T})$ conforme crece su dimensión, Boor, 2001.

En cualquiera de los dos regímenes, el problema original de dimensión infinita se reduce a un vector de coeficientes $\boldsymbol{\alpha}_i = (\alpha_{i1}, \ldots, \alpha_{iK})^\top \in \mathbb{R}^K$ que caracteriza la curva en el sistema elegido, de modo que las propiedades de dicho sistema determinan la relación entre la geometría del vector y la de la curva original. Los criterios para elegir la dimensión de la representación en sistemas predeterminados se abordan a continuación, mientras que el criterio correspondiente a los sistemas derivados de los datos se presenta en la Sección 2.1.4.3.

2.1.1.1. Criterios para el truncamiento

La elección de la dimensión de la representación responde a un compromiso entre fidelidad y regularidad. Una dimensión insuficiente produce un sesgo de aproximación, pues la representación no captura rasgos genuinos de la curva, mientras que una dimensión excesiva traslada a los coeficientes el ruido de medición de las observaciones discretas, degradando la regularidad que motiva el enfoque funcional. Los criterios que se presentan en este apartado corresponden a los sistemas predeterminados, como las B-splines, las bases de Fourier o las wavelets, en los cuales el sistema carece de una descomposición de la variabilidad del proceso asociada a sus elementos, de modo que la dimensión debe seleccionarse evaluando directamente la calidad de la reconstrucción.

Sea $\{(\tau_{il},\, \mathsf{x}_{il})\}_{l=1}^{L_i}$ el conjunto de observaciones discretas de la curva i-ésima, donde x_{il} denota el valor medido en el punto τ_{il} y L_i el número de puntos de medición, que puede diferir entre curvas conforme a lo señalado al inicio de la Sección 2.1. Denótese por $\hat{X}_i^{(K)}$ la curva obtenida con K funciones base y por $\bar{\mathsf{x}}_i = \frac{1}{L_i}\sum_{l=1}^{L_i} \mathsf{x}_{il}$ el promedio de las observaciones de la curva. La calidad de la reconstrucción se cuantifica a partir del error de cada curva:

$$\mathrm{SSE}_i(K) = \sum_{l=1}^{L_i} \big(\mathsf{x}_{il} - \hat{X}_i^{(K)}(\tau_{il})\big)^2. \tag{2.6}$$

Sobre esta cantidad se construyen tres criterios descriptivos complementarios. El primero corresponde a la proporción de variabilidad explicada por la reconstrucción,

$$\mathrm{VE}(K) = 1 - \frac{\sum_{i=1}^{N} \mathrm{SSE}_i(K)}{\sum_{i=1}^{N} \sum_{l=1}^{L_i} \big(\mathsf{x}_{il} - \bar{\mathsf{x}}_i\big)^2}, \tag{2.7}$$

que mide la fracción de la variabilidad total de las observaciones discretas capturada por el ajuste. Cabe precisar que esta medida evalúa la bondad de ajuste global de la reconstrucción y no constituye una descomposición de la varianza componente a componente, la cual no existe para sistemas predeterminados y es precisamente lo que distingue a este criterio del que se presenta en la Sección 2.1.4.3. El segundo criterio corresponde al error cuadrático medio de reconstrucción,

$$\mathrm{RMSE}(K) = \left(\frac{\sum_{i=1}^{N} \mathrm{SSE}_i(K)}{\sum_{i=1}^{N} L_i} \right)^{1/2}, \tag{2.8}$$

que resume el desajuste promedio en las unidades de la variable observada. El tercero corresponde al error máximo por curva. Para la curva i-ésima se define su error cuadrático medio de reconstrucción, $e_i(K) = \big(\mathrm{SSE}_i(K)/L_i\big)^{1/2}$, y el criterio reporta el peor caso sobre el conjunto:

$$\mathrm{E}_{\mathrm{máx}}(K) = \max_i \left(\frac{\mathrm{SSE}_i(K)}{L_i} \right)^{1/2}, \tag{2.9}$$

que identifica la curva peor reconstruida bajo la misma métrica del criterio anterior. Mientras que (2.8) resume el desajuste promedio del conjunto, (2.9) controla su cola, dado que un promedio favorable puede coexistir con curvas individuales mal representadas, cuyos rasgos la base no logra capturar y que este criterio detecta de forma directa.

Los tres criterios comparten una limitación estructural, puesto que mejoran de forma monótona conforme aumenta K, de modo que su minimización directa conduce siempre a la dimensión máxima disponible y al consecuente sobreajuste. Su uso requiere, por tanto, fijar umbrales de suficiencia, por ejemplo la menor dimensión que alcanza una proporción de variabilidad explicada predeterminada, o identificar el punto a partir del cual las mejoras marginales se vuelven despreciables. La validación cruzada generalizada (GCV) resuelve esta limitación penalizando la complejidad efectiva del ajuste. Para la curva i-ésima, el criterio se define como

$$\mathrm{GCV}_i(K) = \frac{L_i \, \mathrm{SSE}_i(K)}{\big(L_i - \mathrm{df}(K)\big)^2}, \tag{2.10}$$

donde $\mathrm{df}(K)$ denota los grados de libertad efectivos de la representación, y la dimensión común se elige minimizando el promedio de (2.10) sobre las N curvas, Ramsay y Silverman, 2006. La penalización del denominador confiere al criterio un mínimo interior, lo que permite seleccionar la dimensión sin recurrir a umbrales exógenos. En conjunto, el procedimiento selecciona la dimensión mediante GCV y verifica su adecuación mediante los criterios descriptivos, favoreciendo la dimensión más pequeña compatible con una reconstrucción fiel, lo que materializa el compromiso entre fidelidad y regularidad.

2.1.2. Propiedades de las Funciones Base

La elección de un sistema de funciones base adecuado constituye una de las decisiones fundamentales en el análisis de datos funcionales. El vector de coeficientes obtenido

en la sección anterior no es un descriptor neutro, es decir, según el sistema empleado, sea este predeterminado o derivado de los datos, los coeficientes pueden representar la curva de forma directa o requerir un tratamiento adicional para recuperar fielmente su información. Por esta razón, en este apartado se examinan las propiedades del sistema que determinan en qué sentido los coeficientes representan a la curva, así como el coste que conlleva obtener dicha representación cuando esta no es directa.

2.1.2.1. Ortogonalidad y Ortonormalidad

Un sistema de funciones base $\{\phi_j\} \subset L^2(\mathcal{T})$ se denomina ortogonal si sus elementos son mutuamente ortogonales bajo el producto interno de $L^2(\mathcal{T})$, y ortonormal si, además, cada elemento tiene norma unitaria:

$$\langle \phi_j, \phi_{j'} \rangle = \delta_{jj'} = \begin{cases} 1, & j = j', \\ 0, & j \neq j'. \end{cases} \tag{2.11}$$

Esta distinción es transversal a la clasificación de la Sección 2.1.1, puesto que un sistema de cualquiera de las dos categorías puede ser o no ortonormal, y condiciona tanto la obtención de los coeficientes como su interpretación.

En un sistema ortonormal, los coeficientes de la representación se obtienen directamente por proyección sobre cada elemento del sistema,

$$\alpha_{ij} = \langle X_i, \phi_j \rangle, \tag{2.12}$$

sin necesidad de resolver ningún sistema lineal.

En un sistema no ortonormal, en cambio, los coeficientes no se reducen a la proyección directa, sino que se obtienen resolviendo el sistema lineal

$$\mathbf{G}\,\boldsymbol{\alpha}_i = \mathbf{b}_i, \qquad \mathbf{G}_{jj'} = \langle \phi_j, \phi_{j'} \rangle, \quad (\mathbf{b}_i)_j = \langle X_i, \phi_j \rangle, \tag{2.13}$$

donde $\mathbf{G}$ es la matriz de Gram del sistema.

La ortonormalidad corresponde, precisamente, al caso $\mathbf{G} = \mathbf{I}$, en que el sistema se desacopla y cada coeficiente se reduce a su proyección.

La ortonormalidad incide, además, sobre la interpretación de los coeficientes. Cuando el sistema es ortonormal se verifica la identidad de Parseval, Kokoszka y Reimherr, 2017,

$$\|X_i\|^2 = \sum_j \alpha_{ij}^2, \tag{2.14}$$

de modo que la aplicación que asocia a cada curva sus coeficientes preserva normas y productos internos. Distancias y ángulos entre curvas coinciden, por tanto, con sus análogos euclídeos en el espacio de coeficientes, lo que permite trasladar el análisis de las funciones al de sus coeficientes sin distorsión geométrica. En un sistema no ortonormal, en cambio, la norma y el producto interno quedan mediados por la matriz de Gram,

$$\|X_i\|^2 = \boldsymbol{\alpha}_i^\top \mathbf{G}\,\boldsymbol{\alpha}_i, \qquad \langle X_i, X_{i'} \rangle = \boldsymbol{\alpha}_i^\top \mathbf{G}\,\boldsymbol{\alpha}_{i'}, \tag{2.15}$$

por lo que la distancia euclídea entre vectores de coeficientes ya no reproduce la distancia L^2 entre las curvas correspondientes.

2.1.2.2. Condiciones sobre el sistema de base

Las categorías examinadas hasta aquí, sistemas predeterminados o derivados de los datos según su origen, y sistemas ortonormales o no ortonormales según su geometría, no constituyen objetos de naturaleza distinta, sino que describen al mismo objeto matemático, un sistema de funciones base sobre el cual se representa la curva mediante un vector de coeficientes. Lo que distingue a un sistema idóneo no es, por tanto, su categoría, sino el cumplimiento de dos condiciones de distinta jerarquía.

La primera condición, de carácter indispensable, es la capacidad de aproximación arbitraria en $L^2(\mathcal{T})$, la cual puede alcanzarse por dos vías conforme a lo establecido en la Sección 2.1.1, sea porque el sistema constituye una base ortonormal del espacio, en cuyo caso el truncamiento de la expansión converge conforme crece K, o bien porque se genera subespacios densos a medida que aumenta su dimensión. Sin esta condición la representación finita no puede aproximar la curva con precisión arbitraria y el procedimiento completo carece de sustento.

La segunda condición, deseable pero no excluyente, es la ortonormalidad. Un sistema no ortonormal sigue siendo plenamente válido para representar curvas, con el coste operativo descrito en la Sección 2.1.2.1, pues la obtención de los coeficientes exige resolver el sistema de Gram y la geometría de las curvas queda mediada por la matriz $\mathbf{G}$. La ortonormalidad, cuando está disponible, elimina ambos costes, dado que los coeficientes se reducen a proyecciones directas, lo que abarata su cómputo, y la geometría de la curva se traslada sin distorsión al espacio de coeficientes, lo que permite operar sobre los vectores de coeficientes con métricas euclídeas ordinarias, ejemplos de esto se encuentran en las funciones base B-splines, utilizadas por su flexibilidad y localidad, las cuales generan subespacios densos de $L^2(\mathcal{T})$ al refinar la malla de nodos, pero no son ortonormales (Sección 2.1.3); por otra parte, el Análisis de Componentes Principales Funcional, representante de los sistemas derivados de los datos, construye un sistema ortonormal, al precio de derivarlo del propio proceso observado (Sección 2.1.4).

2.1.3. Función Base: B-splines

Las funciones base B-splines constituyen una familia de funciones polinomiales por tramos utilizada para suavizar observaciones discretas y obtener representaciones continuas de las curvas subyacentes , Ramsay y Silverman, 2006. Su principal ventaja es la localidad, es decir, cada B-spline es no nula únicamente sobre un intervalo compacto del dominio, lo que confiere al sistema flexibilidad local y estabilidad numérica.

Sea $\mathcal{T} = [0, 1]$ el dominio funcional y sea $\boldsymbol{\kappa} = (\kappa_0, \kappa_1, \ldots, \kappa_{K-m+1})$ un vector de $K-m+2$ nodos ordenados con $\kappa_0 = 0$ y $\kappa_{K-m+1} = 1$. Las B-splines de orden m se definen recursivamente a partir de las funciones indicadoras de orden cero:

$$B^{\boldsymbol{\kappa}}_{j,0}(\tau) = \mathbf{1}_{(\kappa_j,\, \kappa_{j+1}]}(\tau), \qquad j = 0, \ldots, K-1, \tag{2.16}$$

y para orden $m \geq 1$, la recurrencia de de Boor–Cox establece:

$$B^{\boldsymbol{\kappa}}_{j,m}(\tau) = \frac{\tau - \kappa_j}{\kappa_{j+m} - \kappa_j}\, B^{\boldsymbol{\kappa}}_{j,\,m-1}(\tau) + \frac{\kappa_{j+m+1} - \tau}{\kappa_{j+m+1} - \kappa_{j+1}}\, B^{\boldsymbol{\kappa}}_{j+1,\,m-1}(\tau), \tag{2.17}$$

donde, por convención, cualquier término cuyo denominador sea cero se considera nulo y con esta convención, una B-spline de orden m es un polinomio por tramos de grado $m-1$.

El soporte de $B_{j,m}^{\boldsymbol{\kappa}}$ es el intervalo compacto $[\kappa_j, \kappa_{j+m+1}]$, de modo que cada B-spline de orden m se solapa únicamente con sus m predecesoras y m sucesoras inmediatas. Bajo la convención de nodos extendidos, en la que los nodos de frontera se repiten con multiplicidad m, el sistema completo consta de K B-splines linealmente independientes y forma una partición de la unidad sobre $\mathcal{T}$:

$$\sum_{j=0}^{K-1} B_{j,m}^{\boldsymbol{\kappa}}(\tau) = 1, \qquad \tau \in \mathcal{T}. \tag{2.18}$$

En consecuencia, las B-splines no forman un sistema ortogonal, por lo que el producto interno $\langle B_{j,m}, B_{j',m} \rangle$ es no nulo para índices cuyos soportes se solapan, de modo que la matriz de Gram del sistema, $\mathbf{G}_{jj'} = \langle B_{j,m}, B_{j',m} \rangle$, no es diagonal.

2.1.4. Análisis de Componentes Principales Funcional

El Análisis de Componentes Principales Funcional (FPCA) constituye la extensión natural del análisis de componentes principales clásico al contexto de variables funcionales. Su objetivo es identificar las direcciones de máxima variabilidad en el espacio funcional $L^2(\mathcal{T})$, produciendo un sistema ortonormal óptimo en el sentido de que, para cada número de componentes, ningún otro sistema ortonormal explica mayor proporción de la varianza del proceso.

2.1.4.1. Operador de covarianza y descomposición espectral

Sea X una variable funcional aleatoria en $L^2(\mathcal{T})$ de segundo orden ($\mathbb{E}\|X\|^2 < \infty$), con función media $\mu(\tau) = \mathbb{E}[X(\tau)]$ y función de covarianza:

$$C(\tau, s) = \mathrm{Cov}\big(X(\tau),\, X(s)\big) = \mathbb{E}\big[(X(\tau) - \mu(\tau))(X(s) - \mu(s))\big]. \tag{2.19}$$

El operador de covarianza $\mathcal{C} : L^2(\mathcal{T}) \to L^2(\mathcal{T})$ se define mediante:

$$(\mathcal{C}f)(\tau) = \int_{\mathcal{T}} C(\tau, s)\, f(s)\, ds, \qquad f \in L^2(\mathcal{T}). \tag{2.20}$$

El operador $\mathcal{C}$ reúne un conjunto de propiedades que garantizan la existencia y las cualidades de su descomposición espectral, Hsing y Eubank, 2015. En primer lugar, es lineal, acotado y autoadjunto, pues su núcleo es simétrico, $C(\tau, s) = C(s, \tau)$, y es semidefinido positivo, ya que su forma cuadrática corresponde a una varianza, $\langle \mathcal{C}f, f \rangle = \mathrm{Var}\big(\langle X - \mu, f \rangle\big) \geq 0$ para toda $f \in L^2(\mathcal{T})$.

En segundo lugar, la condición de segundo orden implica que $C \in L^2(\mathcal{T} \times \mathcal{T})$, de modo que $\mathcal{C}$ es un operador de Hilbert–Schmidt y, en particular, compacto. Estas propiedades activan el teorema espectral para operadores compactos y autoadjuntos, el cual garantiza la existencia de una sucesión numerable de valores propios reales, con funciones

propias asociadas que forman un sistema ortonormal de $L^2(\mathcal{T})$, mientras que la positividad asegura que dichos valores propios son no negativos y pueden ordenarse de forma decreciente. Finalmente, $\mathcal{C}$ es un operador nuclear, es decir, de clase traza, propiedad que se expresa en la identidad

$$\sum_{k=1}^{\infty} \lambda_k = \int_{\mathcal{T}} C(\tau,\tau)\, d\tau = \mathbb{E}\|X-\mu\|^2 < \infty, \tag{2.21}$$

la cual establece que la variabilidad total del proceso se descompone exactamente en la suma de los valores propios y que dicha suma es finita, resultado que fundamenta el criterio de selección de componentes de la Sección 2.1.4.3.

Bajo la condición adicional de que $C(\tau, s)$ sea continua, el Teorema de Mercer Mercer, 1909 refina la descomposición espectral y establece que el núcleo admite la representación

$$C(\tau,s) = \sum_{k=1}^{\infty} \lambda_k\, v_k(\tau)\, v_k(s), \tag{2.22}$$

con convergencia absoluta y uniforme sobre $\mathcal{T}\times\mathcal{T}$, donde $\lambda_1 \geq \lambda_2 \geq \cdots \geq 0$ son los valores propios ordenados de manera decreciente y $\{v_k\}_{k=1}^{\infty}$ las correspondientes funciones propias ortonormales, que satisfacen:

$$\mathcal{C}v_k = \lambda_k\, v_k, \qquad \langle v_k, v_{k'}\rangle = \delta_{kk'}. \tag{2.23}$$

2.1.4.2. Representación de Karhunen–Loève y scores FPCA

La separabilidad de $L^2(\mathcal{T})$ garantiza, según se vio en la Sección 2.1.1, que toda curva admite una expansión en una base numerable. El Teorema de Karhunen–Loève, Kokoszka y Reimherr, 2017, precisa esta idea para procesos aleatorios funcionales y establece que toda variable funcional aleatoria de segundo orden puede representarse como una combinación lineal de funciones deterministas ortonormales, tomadas como las funciones propias del operador de covarianza del proceso. Estas funciones propias y su ortonormalidad provienen de la descomposición espectral establecida en la Sección 2.1.4.1, de modo que el teorema establece la descomposición correspondiente de la variable funcional aleatoria en esa misma base. Concretamente, para una colección $\{X_i(\tau)\}$ de variables funcionales idénticamente distribuidas según el proceso, dicha expansión adopta la forma

$$X_i(\tau) = \mu(\tau) + \sum_{k=1}^{\infty} \xi_{ik}\, v_k(\tau), \tag{2.24}$$

donde los coeficientes ξ_{ik}, denominados scores, se obtienen mediante proyección ortogonal de la curva centrada sobre cada función propia,

$$\xi_{ik} = \langle X_i - \mu, v_k\rangle = \int_{\mathcal{T}} \big(X_i(\tau)-\mu(\tau)\big)\, v_k(\tau)\, d\tau, \tag{2.25}$$

y la serie converge en media cuadrática, uniformemente en $\tau\in\mathcal{T}$ Kokoszka y Reimherr, 2017, esto es,

$$\mathbb{E}\left\| X_i - \mu - \sum_{k=1}^{K'} \xi_{ik}\, v_k \right\|^2 = \sum_{k=K'+1}^{\infty} \lambda_k \xrightarrow[K'\to\infty]{} 0, \tag{2.26}$$

donde la cola de valores propios es finita y decreciente en virtud de la propiedad de clase traza (2.21). El contenido esencial del teorema es doble. Por una parte, la expansión (2.24) reproduce exactamente la estructura de covarianza del proceso, pues al sustituir (2.25) en la covarianza se recupera la descomposición de Mercer (2.22). Por otra, los scores heredan de la ortonormalidad de $\{v_k\}$ las propiedades Kokoszka y Reimherr, 2017

$$\mathbb{E}[\xi_{ik}] = 0, \qquad \mathbb{E}[\xi_{ik}^2] = \lambda_k, \qquad \mathbb{E}[\xi_{ik}\,\xi_{ik'}] = 0 \quad \text{para } k \neq k', \tag{2.27}$$

de modo que cada score tiene varianza igual al valor propio asociado y los scores son no correlacionados.

No obstante, la no correlación no equivale a independencia. Ambas coinciden únicamente cuando el proceso es gaussiano, caso en que los scores son conjuntamente gaussianos. Fuera de ese supuesto, los scores pueden exhibir dependencia en momentos de orden superior pese a estar no correlacionados.

2.1.4.3. Selección de componentes

En la práctica, la expansión (2.24) se trunca a K' componentes:

$$X_i(\tau) \approx \mu(\tau) + \sum_{k=1}^{K'} \xi_{ik}\, v_k(\tau), \tag{2.28}$$

de modo que cada curva queda representada por el vector de scores:

$$\boldsymbol{\xi}_i = (\xi_{i1}, \xi_{i2}, \ldots, \xi_{iK'})^\top. \tag{2.29}$$

El número de componentes K' se selecciona de modo que la proporción de varianza explicada acumulada supere un umbral predeterminado:

$$\frac{\sum_{k=1}^{K'} \lambda_k}{\sum_{k=1}^{\infty} \lambda_k} \geq 1 - \nu, \tag{2.30}$$

donde $\nu > 0$ es un nivel de error admisible. El criterio está bien definido gracias a la propiedad de clase traza (2.21), la cual garantiza que el denominador es finito e igual a la variabilidad total del proceso, de manera que el cociente admite una interpretación directa como la proporción de dicha variabilidad capturada por las primeras K' componentes. En la práctica, la suma infinita se aproxima por la suma sobre los valores propios estimados.

En la implementación, las funciones propias $\{v_k\}$ y los valores propios $\{\lambda_k\}$ se estiman a partir de la función de covarianza empírica calculada sobre las curvas suavizadas mediante B-splines. Cuando las curvas se representan en el sistema B-spline, $X_i(\tau) \approx \sum_{j=0}^{K-1} \alpha_{ij}\, B_{j,m}(\tau)$, la descomposición espectral del operador $\mathcal{C}$ no se reduce a un problema de autovalores ordinario sobre los coeficientes, sino a un problema de autovalores generalizado

$$\mathbf{C}\,\mathbf{u} = \lambda\,\mathbf{G}\,\mathbf{u}, \tag{2.31}$$

donde $\mathbf{C}$ es la matriz de covarianza de los coeficientes B-spline y $\mathbf{G}$ la matriz de Gram del sistema (Sección 2.1.3). La presencia de $\mathbf{G}$ constituye la corrección por la no ortonormalidad del sistema, pues garantiza que las funciones propias estimadas sean ortonormales en la métrica de $L^2(\mathcal{T})$ y no en la métrica euclídea de los coeficientes.

El flujo completo de representación funcional mediante 2.28 es:

1. Suavizado de las observaciones discretas mediante una función base predeterminado, obteniendo las curvas continuas $\hat{X}_i(\tau)$, con la dimensión del sistema seleccionada conforme a los criterios de la Sección 2.1.1.1.

2. Estimación de la función de covarianza empírica y resolución del problema de autovalores generalizado (2.31) para obtener las funciones propias estimadas $\hat{v}_k$.

3. Proyección de las curvas suavizadas sobre las funciones propias estimadas para obtener los scores $\hat{\xi}_{ik} = \langle \hat{X}_i - \hat{\mu}, \hat{v}_k \rangle$.

4. Selección del número de componentes K' según el criterio de varianza explicada (2.30).

El resultado es un conjunto de vectores $\{\boldsymbol{\xi}_i\}_{i=1}^N$ cuyas componentes son contemporáneamente no correlacionadas, de varianza decreciente $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_{K'}$, y que capturan los principales modos de variación del proceso funcional.

2.2. Series de Tiempo Funcionales

Una serie de tiempo es una secuencia de observaciones $\{x_t\}_{t=1}^T$ registradas de manera ordenada en el tiempo, cuyo análisis se centra en caracterizar la estructura de dependencia temporal del proceso subyacente con el fin de describir su dinámica y obtener predicciones. Su extensión natural al caso funcional surge al reemplazar cada observación escalar por una observación funcional, esto es una secuencia de curvas $\{\chi_t\}_{t=1}^T$, con $\chi_t \in L^2(\mathcal{T})$, registradas de manera ordenada en el tiempo.

Esta extensión hereda la doble naturaleza del problema. Por un lado, cada observación es un objeto de dimensión infinita que, según la representación desarrollada en la Sección 2.1, admite una descripción mediante un vector de coeficientes en un sistema de base; por otro, la secuencia de tales objetos posee una estructura de dependencia temporal que debe modelarse.

2.2.1. Proceso Estocástico Funcional

El tratamiento estadístico de una serie de tiempo funcional requiere modelar la secuencia de observaciones como la realización de un proceso estocástico cuyos estados son funciones. Un proceso estocástico funcional es, en este sentido, una familia de variables funcionales aleatorias $\{X_t,\ t \in \mathbb{Z}\}$, donde cada X_t toma valores en $L^2(\mathcal{T})$.

La ley de un proceso de esta naturaleza es un objeto sobre un espacio de dimensión infinita y no resulta manejable de forma directa. No obstante, bajo condiciones de regularidad sobre el espacio de estados, en particular, que sea un espacio métrico completo y

separable (satisfecha por $L^2(\mathcal{T})$), el proceso queda completamente caracterizado por sus distribuciones finito-dimensionales, es decir, por las distribuciones conjuntas de cualquier número finito de observaciones $(X_{t_1}, \ldots, X_{t_k})$ Bosq, 2000. Esta propiedad, común a todo proceso estocástico, es la que permite trabajar con colecciones finitas de curvas en lugar de con la ley completa del proceso.

Para que la inferencia sobre la dinámica del proceso sea factible a partir de una única trayectoria observada, se requiere además que su estructura probabilística permanezca estable en el tiempo, propiedad formalizada mediante la estacionariedad.

Definición 2.2.1 (**Estacionariedad débil**)**.** Un proceso $\{X_t,\ t \in \mathbb{Z}\}$ es débilmente estacionario (o estacionario de segundo orden) si su esperanza $\mathbb{E}[X_t]$ y sus covarianzas $\mathrm{Cov}(X_t, X_{t+h})$ no dependen de t Bosq, 2000.

La definición establece que las dos primeras estructuras de momentos del proceso son invariantes en el tiempo, en otras palabras, la función media es constante respecto a t y la dependencia entre dos observaciones depende únicamente del desfase h que las separa, no del instante en que se midan. En el caso funcional, $\mathbb{E}[X_t]$ es una función media $\mu \in L^2(\mathcal{T})$, y $\mathrm{Cov}(X_t, X_{t+h})$ corresponde a la función de covarianza cruzada a desfase h,

$$C_h(\tau, s) = \mathrm{Cov}\big(X_t(\tau),\ X_{t+h}(s)\big), \tag{2.32}$$

que induce el operador de covarianza a desfase h asociado. Este objeto posee una estructura doble, ya que describe la dependencia entre observaciones separadas por el desfase temporal h y, simultáneamente, la covariación entre los valores de las curvas en pares de puntos (τ, s) del dominio. La estacionariedad exige que tanto μ como C_h sean independientes de t, de modo que esta estructura de dependencia temporal y funcional se mantenga constante a lo largo del tiempo.

Esta invariancia es la que habilita la estimación de la estructura de dependencia a partir de una sola realización del proceso, fundamento sobre el cual se construyen los modelos que se presentan a continuación.

2.2.2. Modelos Funcionales Clásicos

Los modelos de series de tiempo funcionales clásicos extienden los procesos AR, MA y ARMA al contexto de datos funcionales Bosq, 2000. La diferencia fundamental respecto al caso escalar es que los coeficientes reales ψ_i y ϑ_j son reemplazados por operadores lineales que actúan sobre funciones en $L^2(\mathcal{T})$.

Definición 2.2.2 (**Operador Integral**)**.** Sea $\psi \in L^2(\mathcal{T}\times\mathcal{T})$. El operador $\Psi : L^2(\mathcal{T}) \to L^2(\mathcal{T})$ definido por

$$(\Psi f)(\tau) = \int_{\mathcal{T}} \psi(\tau, u)\, f(u)\, du, \qquad f \in L^2(\mathcal{T}), \tag{2.33}$$

es lineal y acotado, y se denomina operador integral con núcleo ψ Bosq, 2000; Hsing y Eubank, 2015. En el contexto de series de tiempo funcionales, estos operadores generalizan los coeficientes escalares de los modelos clásicos.

Definición 2.2.3 (**Proceso Autorregresivo Funcional FAR(p)**)**.** Un proceso estocástico funcional $\{X_t(\tau)\}$ sigue un modelo autorregresivo funcional de orden p, denotado FAR(p), si satisface Aue, Norinho y Hörmann, 2015; Bosq, 2000:

$$X_t(\tau) = \sum_{i=1}^{p} \int_{\mathcal{T}} \psi_i(\tau, u)\, X_{t-i}(u)\, du + \varepsilon_t(\tau), \tag{2.34}$$

donde $\psi_i(\tau, u)$ es el núcleo del operador autorregresivo Ψ_i, para $i = 1, \ldots, p$, y $\{\varepsilon_t(\tau)\}$ es un proceso de ruido blanco funcional. Este modelo generaliza el proceso AR(p) escalar al permitir que cada función observada en el instante t dependa funcionalmente de las observaciones pasadas.

Definición 2.2.4 (**Proceso de Medias Móviles Funcional FMA(q)**)**.** Un proceso estocástico funcional $\{X_t(\tau)\}$ sigue un modelo de medias móviles funcional de orden q, denotado FMA(q), si satisface Klepsch y Klüppelberg, 2017:

$$X_t(\tau) = \varepsilon_t(\tau) + \sum_{j=1}^{q} \int_{\mathcal{T}} \vartheta_j(\tau, u)\, \varepsilon_{t-j}(u)\, du, \tag{2.35}$$

donde $\vartheta_j(\tau, u)$ es el núcleo del operador $\boldsymbol{\vartheta}_j$, para $j = 1, \ldots, q$, y $\{\varepsilon_t(\tau)\}$ es un proceso de ruido blanco funcional. Este modelo expresa cada función observada como una combinación lineal de innovaciones funcionales contemporáneas y pasadas, generalizando el proceso MA(q) al contexto funcional.

Definición 2.2.5 (**Proceso Autorregresivo de Medias Móviles Funcional FARMA(p, q)**)**.** Un proceso estocástico funcional $\{X_t(\tau)\}$ sigue un modelo FARMA(p, q) si combina componentes autorregresivas y de medias móviles Klepsch, Klüppelberg y Wei, 2017:

$$X_t(\tau) = \sum_{i=1}^{p} \int_{\mathcal{T}} \psi_i(\tau, u)\, X_{t-i}(u)\, du + \varepsilon_t(\tau) + \sum_{j=1}^{q} \int_{\mathcal{T}} \vartheta_j(\tau, u)\, \varepsilon_{t-j}(u)\, du, \tag{2.36}$$

donde $\{\varepsilon_t(\tau)\}$ es un proceso de ruido blanco funcional. Este modelo generaliza tanto el FAR(p) (caso $q = 0$) como el FMA(q) (caso $p = 0$), permitiendo capturar estructuras de dependencia temporal más complejas en el contexto funcional.

2.2.2.1. Limitaciones Estructurales

Los modelos FAR, FMA y FARMA constituyen extensiones naturales y bien fundamentadas de los modelos clásicos de series de tiempo al contexto funcional. Sin embargo, comparten con sus contrapartes escalares tres supuestos estructurales que acotan la clase de fenómenos que pueden representar. Los dos primeros operan sobre ejes independientes, la forma de la relación entre presente y pasado y su estabilidad en el tiempo, cuyo cruce se resume en el Cuadro 2.1; el tercero concierne a la estructura distribucional del proceso.

En primer lugar, estos modelos son temporalmente homogéneos: los operadores Ψ_i y $\boldsymbol{\vartheta}_j$ son fijos, de modo que una misma dinámica rige el comportamiento del sistema en todos los períodos. Este supuesto resulta restrictivo cuando el proceso exhibe regímenes

	Estable en el tiempo	**Cambia en el tiempo**
Lineal	Representable por la clase lineal	Falla por homogeneidad
No lineal	Falla por forma	Falla por ambos ejes

Cuadro 2.1: Combinaciones de forma de la relación (filas) y estabilidad temporal (columnas). Los modelos FAR, FMA y FARMA cubren únicamente la celda lineal y estable.

diferenciados o cambios estructurales, es decir, cuando la relación entre el presente y el pasado se altera a lo largo del tiempo (columna derecha del Cuadro 2.1).

En segundo lugar, y con independencia de su homogeneidad temporal, estos modelos son lineales, es decir, la dependencia entre el presente y el pasado se restringe a combinaciones lineales de un número finito de operadores integrales. Aun cuando la dinámica fuese perfectamente estable en el tiempo, si la relación verdadera entre las observaciones es no lineal, no pertenece a esta familia y ningún valor de los núcleos permite representarla (fila inferior del Cuadro 2.1). El modelo incurre entonces en un error de especificación irreducible, que no se corrige con más datos, sino solo ampliando la clase de relaciones admisibles.

En tercer lugar, la especificación se limita a la estructura de segundo orden del proceso. En un modelo lineal con innovaciones de distribución fija, la distribución condicional de X_t dado el pasado hereda la forma de la distribución de las innovaciones y solo se desplaza según la predicción lineal, por tanto, su asimetría, su dispersión y su número de modas son idénticos en todo estado del sistema. Características como heterocedasticidad condicional, asimetría cambiante o multimodalidad dependiente del estado quedan, por construcción, fuera de la clase. A ello se suma que la inferencia descansa habitualmente en supuestos fuertes sobre las innovaciones funcionales $\{\varepsilon_t(\tau)\}$, como su normalidad, que refuerzan esta rigidez distribucional.

En conjunto, estas limitaciones son de carácter estructural: no obedecen a deficiencias de estimación ni se atenúan con el tamaño muestral, sino que delimitan la clase de dinámicas y de distribuciones condicionales que la familia lineal homogénea puede describir.

2.2.3. Criterios de Evaluación

La evaluación del desempeño predictivo de un modelo de series de tiempo funcionales se realiza, en esencia, a través de la curva, tal como en un modelo escalar se evalúa contrastando su predicción con la observación bajo distintos criterios, aquí ese contraste se extiende a la curva completa que se busca predecir.

2.2.3.1. Esquema de evaluación temporal con ventana móvil

La evaluación de modelos de series de tiempo debe considerar la dependencia temporal de las observaciones. En este contexto, una partición aleatoria de los datos en conjuntos de entrenamiento y prueba no resulta adecuada, ya que puede incorporar observaciones futuras en el conjunto utilizado para ajustar el modelo. Por esta razón, la estrategia de

evaluación debe preservar el orden temporal de la serie Bergmeir y Benítez, 2012.

Para evaluar el desempeño predictivo del modelo se emplea un esquema de ventana móvil, que consiste en calcular las métricas de error a lo largo de la serie en bloques de observaciones consecutivos. Una vez separados los datos en un conjunto de entrenamiento y un conjunto de prueba, se define una ventana de evaluación de longitud fija, por ejemplo 40. La ventana se sitúa inicialmente sobre las primeras observaciones del conjunto de prueba y se calcula la métrica de desempeño correspondiente; luego se desplaza un período hacia adelante y se recalcula la métrica, repitiendo el procedimiento hasta recorrer todo el conjunto de prueba. De esta manera se obtiene una secuencia de métricas que permite monitorear el desempeño del modelo a lo largo de la serie, en lugar de un único valor global, además de evaluar el deterioro en pasos futuros.

2.2.3.2. Métricas de error

Sea $\hat{X}_t$ la predicción de la curva en el instante t a horizonte h, esto es, generada desde el origen $t-h$, el error de predicción queda expresado como:

$$e_t(\tau) = X_t(\tau) - \hat{X}_t(\tau). \tag{2.37}$$

Se define el MAE funcional como:

$$\mathrm{MAE}(h) = \frac{1}{N}\sum_{t=t_0}^{T_V}\int_{\mathcal{T}}\big|e_t(\tau)\big|\,\frac{d\tau}{|\mathcal{T}|}, \tag{2.38}$$

donde $N = T_V - t_0 + 1$ es el número de curvas evaluadas, esto es, los instantes $t = t_0, \ldots, T_V$ comprendidos entre el inicio de al ventana t_0 y el instante final de esta T_V. Naturalmente, esta definición se extiende al RMSE funcional como:

$$\mathrm{RMSE}(h) = \left(\frac{1}{N}\sum_{t=t_0}^{T_V}\int_{\mathcal{T}}\big(e_t(\tau)\big)^2\,\frac{d\tau}{|\mathcal{T}|}\right)^{1/2}. \tag{2.39}$$

Por último, al evaluar la curva completa interesa conocer el peor error cometido a lo largo de su predicción. Para el instante t se define el error máximo de la curva como:

$$\mathrm{E}_{\mathrm{máx}}(t) = \sup_{\tau\in\mathcal{T}}\big|e_t(\tau)\big|, \tag{2.40}$$

esto es, el peor desajuste puntual dentro de la curva predicha en t. A partir de esta cantidad se derivan dos agregaciones sobre la ventana $\{t_0, \ldots, T_V\}$. La primera es el promedio de los errores máximos por curva,

$$\overline{\mathrm{E}}_{\mathrm{máx}}(h) = \frac{1}{N}\sum_{t=t_0}^{T_V}\mathrm{E}_{\mathrm{máx}}(t), \tag{2.41}$$

que indica, en promedio (en la ventana), cuál es la peor predicción a lo largo del recorrido de τ en cada curva. La segunda es el máximo de los errores máximos por curva,

$$\mathrm{E}^{\mathrm{glob}}_{\mathrm{máx}}(h) = \max_{t\in\{t_0,\ldots,T_V\}}\mathrm{E}_{\mathrm{máx}}(t), \tag{2.42}$$

que corresponde al peor error puntual observado en toda la ventana.

2.2.3.3. Evaluación de la intervalos de credibilidad

Los intervalos de credibilidad $\mathrm{IC}_t(\tau) = [L_t(\tau),\, U_t(\tau)]$ al nivel $1-\zeta$ se construyen a partir de los cuantiles empíricos de las extracciones de la predictiva. Su calidad también debe ser medida.

En primera se define el ancho medio del intervalo alrededor de la curva, que se integra sobre el dominio para cada curva y se promedia sobre la ventana:

$$\mathrm{MPIW}(h) = \frac{1}{N}\sum_{t=t_0}^{T_V}\int_{\mathcal{T}}\big(U_t(\tau) - L_t(\tau)\big)\,\frac{d\tau}{|\mathcal{T}|}. \tag{2.43}$$

En segunda se tiene el porcentaje de cobertura alrededor de la curva. Para cada curva t se calcula la fracción del dominio τ en que la observación queda dentro del intervalo,

$$\mathrm{PICP}_t = \int_{\mathcal{T}}\mathbf{1}\big(X_t(\tau) \in \mathrm{IC}_t(\tau)\big)\,\frac{d\tau}{|\mathcal{T}|}, \tag{2.44}$$

y el PICP de la ventana es el promedio de estos porcentajes,

$$\mathrm{PICP}(h) = \frac{1}{N}\sum_{t=t_0}^{T_V}\mathrm{PICP}_t. \tag{2.45}$$

La tercera indica si la curva quedó cubierta en su totalidad o no. Por curva, es un indicador binario,

$$\mathrm{PICPB}_t = \mathbf{1}\Big(X_t(\tau) \in \mathrm{IC}_t(\tau) \;\; \forall\,\tau \in \mathcal{T}\Big), \tag{2.46}$$

y su promedio en la ventana es el porcentaje de curvas completamente cubiertas:

$$\mathrm{PICPB}(h) = \frac{1}{N}\sum_{t=t_0}^{T_V}\mathrm{PICPB}_t. \tag{2.47}$$

La cuarta y última es el puntaje de Winkler Gneiting y Raftery, 2007; Winkler, 1972, que combina cobertura y ancho en una única cifra, penalizando el ancho del intervalo linealmente y agregando una penalización proporcional a la distancia cuando la observación queda fuera:

$$\mathrm{W}_t(\tau) = \big(U_t(\tau) - L_t(\tau)\big) + \frac{2}{\zeta}\big(L_t(\tau) - X_t(\tau)\big)^{+} + \frac{2}{\zeta}\big(X_t(\tau) - U_t(\tau)\big)^{+}, \tag{2.48}$$

con $(\cdot)^{+} = \mathrm{máx}(\cdot, 0)$. Esta expresión evalúa el puntaje en un punto τ lo que implica que el valor de Winkler para la curva completa se obtiene integrando sobre el dominio,

$$\mathrm{W}_t = \int_{\mathcal{T}}\mathrm{W}_t(\tau)\,\frac{d\tau}{|\mathcal{T}|}, \tag{2.49}$$

y su promedio en la ventana es, por tanto, sobre las N curvas, del promedio de $\mathrm{W}_t(\tau)$ a lo largo de cada una,

$$\mathrm{W}(h) = \frac{1}{N}\sum_{t=t_0}^{T_V}\mathrm{W}_t. \tag{2.50}$$

De forma análoga al error máximo, también puede reportarse el peor Winkler cometido dentro de cada curva, $\mathrm{W}_t^{\text{máx}} = \sup_{\tau \in \mathcal{T}} \mathrm{W}_t(\tau)$, y de ahí derivar dos agregaciones sobre la ventana.

El promedio del peor, $\overline{\mathrm{W}}_{\text{máx}}(h) = \frac{1}{N} \sum_{t=t_0}^{T_V} \mathrm{W}_t^{\text{máx}}$, que describe cuán mal se penaliza, en promedio, el punto más comprometido de cada curva, y el peor de los peores, $\mathrm{W}_{\text{máx}}^{\text{glob}}(h) = \text{máx}_{t \in \{t_0, \ldots, T_V\}} \mathrm{W}_t^{\text{máx}}$, que corresponde al peor punto observado en toda la ventana.

2.3. Fundamentos de Inferencia Bayesiana

La inferencia estadística tiene como objetivo estimar cantidades desconocidas θ, denominadas parámetros, a partir de datos observados x. El enfoque frecuentista trata θ como una cantidad fija desconocida y basa la inferencia exclusivamente en la verosimilitud de los datos. El enfoque bayesiano, en cambio, trata θ como una variable aleatoria y combina la información aportada por los datos con el conocimiento previo disponible sobre θ, expresado en términos probabilísticos mediante una distribución a priori Bayes, 1763.

Formalmente, sea $p(\theta)$ la distribución a priori que codifica el conocimiento sobre θ antes de observar los datos, y sea $p(x \mid \theta)$ la función de verosimilitud que describe la probabilidad de los datos dado el parámetro. La actualización del conocimiento sobre θ tras observar x se realiza mediante el Teorema de Bayes:

$$p(\theta \mid x) = \frac{p(x \mid \theta)\, p(\theta)}{p(x)}, \tag{2.51}$$

donde $p(x) = \int_\Theta p(x \mid \theta)\, p(\theta)\, d\theta$ es la distribución marginal de los datos, que actúa como constante de normalización. La distribución $p(\theta \mid x)$ se denomina distribución a posteriori y constituye el objeto central de la inferencia bayesiana, ya que concentra toda la información disponible sobre θ una vez observados los datos. Esta relación se resume en la proporcionalidad:

$$p(\theta \mid x) \propto p(x \mid \theta)\, p(\theta). \tag{2.52}$$

2.3.1. Modelación Jerárquica Bayesiana

En muchas aplicaciones, la estructura del modelo admite múltiples niveles de parámetros, donde algunos parámetros dependen a su vez de otros, denominados hiperparámetros. Esta organización da lugar a los modelos jerárquicos bayesianos, en los que la distribución a priori sobre θ depende de hiperparámetros η que también poseen una distribución a priori propia, Gelman et al., 2013. Formalmente, el modelo se especifica mediante tres niveles:

$$X \mid \theta \sim p(X \mid \theta), \qquad \text{(datos)} \tag{2.53}$$

$$\theta \mid \eta \sim p(\theta \mid \eta), \qquad \text{(parámetros)} \tag{2.54}$$

$$\eta \sim p(\eta), \qquad \text{(hiperparámetros)} \tag{2.55}$$

donde X denota la variable aleatoria observable y θ, η son cantidades latentes no observadas. La distribución a posteriori conjunta sobre todos los parámetros del modelo es:

$$p(\theta, \eta \mid x) \propto p(x \mid \theta)\, p(\theta \mid \eta)\, p(\eta). \tag{2.56}$$

La estructura jerárquica permite que los parámetros compartan información a través de los niveles del modelo, lo que resulta especialmente ventajoso cuando los datos son escasos o cuando se desea incorporar conocimiento estructural sobre la relación entre parámetros. En el contexto del presente trabajo, esta estructura es fundamental para especificar priors sobre objetos de dimensión infinita, como distribuciones o funciones, mediante la introducción de procesos estocásticos como priors de nivel superior.

2.3.2. Inferencia Probabilística y Métodos MCMC

En modelos bayesianos de complejidad moderada o alta, la distribución a posteriori $p(\theta \mid x)$ raramente admite una forma analítica cerrada, en particular cuando las distribuciones a priori no son conjugadas con la verosimilitud. En estos casos, la inferencia se realiza mediante métodos de simulación basados en cadenas de Markov Monte Carlo (MCMC), los cuales construyen una cadena de Markov $\{\theta^{(1)}, \theta^{(2)}, \ldots, \theta^{(S)}\}$ cuya distribución estacionaria coincide con la distribución a posteriori de interés Rizzo, 2007.

Una vez que la cadena ha alcanzado su distribución estacionaria, las muestras obtenidas pueden utilizarse para aproximar cualquier cantidad de interés posterior, como la media, la varianza o los cuantiles de $p(\theta \mid x)$. En la práctica, las primeras b iteraciones de la cadena se descartan (período de burn-in) para eliminar la influencia de los valores iniciales. Adicionalmente, dado que muestras consecutivas de la cadena están correlacionadas, es habitual retener solo una de cada k iteraciones (thinning) con el fin de obtener un conjunto de muestras aproximadamente independientes.

A continuación se describen los tres algoritmos MCMC empleados en el posterior algoritmo.

2.3.2.1. Algoritmo de Metropolis–Hastings

El algoritmo de Metropolis–Hastings genera muestras de una distribución objetivo $f(\theta)$ construyendo una cadena de Markov mediante un mecanismo de propuesta y aceptación Rizzo, 2007. En cada iteración, se propone un candidato $\theta^* \sim q(\cdot \mid \theta^{(s)})$ a partir de una distribución de propuesta q, y se acepta con probabilidad:

$$\alpha(\theta^{(s)}, \theta^*) = \min\left(1,\ \frac{f(\theta^*)\, q(\theta^{(s)} \mid \theta^*)}{f(\theta^{(s)})\, q(\theta^* \mid \theta^{(s)})}\right). \tag{2.57}$$

Si el candidato es rechazado, la cadena permanece en $\theta^{(s)}$. Nótese que el algoritmo requiere únicamente evaluar f hasta una constante de proporcionalidad, lo que lo hace directamente aplicable en el contexto bayesiano donde $p(\theta \mid x) \propto p(x \mid \theta)\, p(\theta)$.

2.3.2.2. Muestreador de Gibbs

El muestreador de Gibbs es un caso particular del algoritmo de Metropolis–Hastings aplicable cuando el vector de parámetros $\boldsymbol{\theta} = (\theta_1, \ldots, \theta_d)$ puede particionarse en bloques cuyas distribuciones condicionales completas son conocidas y tratables Rizzo, 2007. El algoritmo actualiza cada componente θ_j muestreando de su distribución condicional completa:

$$\theta_j^{(s+1)} \sim p\Big(\theta_j \mid \theta_1^{(s+1)}, \ldots, \theta_{j-1}^{(s+1)}, \theta_{j+1}^{(s)}, \ldots, \theta_d^{(s)}, x\Big), \qquad j = 1, \ldots, d. \tag{2.58}$$

Dado que cada muestra se genera directamente de la condicional exacta, toda propuesta es aceptada automáticamente. Este algoritmo resulta especialmente eficiente en modelos jerárquicos con estructura condicional tratable, como los que se derivan de priors conjugados por bloques.

2.3.2.3. Slice Sampling

El Slice Sampling es un método MCMC que evita la necesidad de especificar una distribución de propuesta explícita Neal, 2003. La idea central consiste en introducir una variable auxiliar u y muestrear uniformemente de la región bajo la curva de la densidad objetivo. Formalmente, dado el valor actual $\theta^{(s)}$, el algoritmo procede en dos pasos: primero genera $u \sim \text{Uniform}(0, f(\theta^{(s)}))$, definiendo el *slice* $\mathcal{Q} = \{\theta : f(\theta) \geq u\}$; luego muestrea $\theta^{(s+1)} \sim \text{Uniform}(\mathcal{Q})$. Al adaptarse automáticamente a la forma local de la densidad, el método evita el problema de los paseos aleatorios y reduce la autocorrelación entre muestras, lo que lo hace particularmente útil para distribuciones con geometrías complejas o mal condicionadas.

2.4. Procesos de Dirichlet

El marco bayesiano presentado en la Sección 2.3.1 requiere especificar una distribución a priori sobre los parámetros del modelo. Cuando la distribución generadora de los datos es desconocida o de forma compleja, los priors paramétricos convencionales (como una distribución Normal o Gamma) resultan insuficientes, pues restringen la inferencia a una familia distribucional de forma fija. La inferencia bayesiana no paramétrica supera esta limitación definiendo priors directamente sobre espacios de medidas de probabilidad, de modo que la complejidad del modelo pueda adaptarse automáticamente a los datos, Müller et al., 2015.

El Proceso de Dirichlet (DP) constituye el prior no paramétrico bayesiano más ampliamente utilizado. Introducido por Ferguson, 1973, define una distribución aleatoria sobre el espacio de medidas de probabilidad, de modo que sus realizaciones son distribuciones de probabilidad. Esto lo convierte en un prior natural para modelos en los que la distribución generadora de los datos es desconocida y se desea estimarla de manera flexible.

2.4.1. Definición y propiedades

Definición 2.4.1 (**Proceso de Dirichlet, Müller et al., 2015**). Sea $M > 0$ un parámetro de concentración y G_0 una medida de probabilidad definida sobre un espacio medible $(\mathcal{S}, \mathcal{B})$. Se dice que una medida de probabilidad aleatoria G sigue un Proceso de Dirichlet con parámetros M y G_0, denotado $G \sim \mathrm{DP}(M, G_0)$, si para toda partición finita medible $\{B_1, \ldots, B_k\}$ de $\mathcal{S}$ se cumple:

$$\big(G(B_1), \ldots, G(B_k)\big) \sim \mathrm{Dirichlet}\big(MG_0(B_1), \ldots, MG_0(B_k)\big). \tag{2.59}$$

La definición caracteriza al DP a través del comportamiento de G sobre particiones del espacio. Dada cualquier partición finita $\{B_1, \ldots, B_k\}$, las masas que G asigna a cada bloque, $\big(G(B_1), \ldots, G(B_k)\big)$, forman un vector aleatorio de componentes no negativas que suman uno, con distribución de Dirichlet finita. Esta condición debe cumplirse simultáneamente para toda partición posible, lo que determina por completo la ley de G como medida de probabilidad aleatoria. En otras palabras, el DP no especifica directamente una densidad sobre el espacio de medidas, sino que prescribe cómo se distribuye la masa de probabilidad de manera consistente sobre cualquier agrupamiento finito de regiones.

Los dos parámetros admiten una lectura directa a partir de las propiedades de la distribución de Dirichlet: G_0 actúa como centro del prior y M como su parámetro de concentración en torno a ese centro. Esta lectura se precisa a través de los momentos de G sobre cualquier conjunto medible B:

$$\mathbb{E}[G(B)] = G_0(B), \qquad \mathrm{Var}[G(B)] = \frac{G_0(B)\,(1 - G_0(B))}{1 + M}. \tag{2.60}$$

La esperanza sitúa a G_0 como la localización esperada de los átomos de G, mientras que la varianza decrece conforme M aumenta, de modo que valores grandes de M producen realizaciones cercanas a G_0 y valores pequeños generan mayor variabilidad. Además, G concentra su masa en el soporte de G_0: si $G_0(B) > 0$ entonces $G(B) > 0$ casi seguramente, y viceversa.

Una propiedad adicional, útil para la construcción de modelos jerárquicos, es que el DP se descompone en subprocesos independientes al restringirse a un subconjunto del espacio. Si A es un conjunto medible con $G_0(A) > 0$, la restricción de G al conjunto A, denotada $G \mid A$, sigue un $\mathrm{DP}(MG_0(A),\, G_0(\cdot \mid A))$ y es independiente de $G(A)$.

2.4.2. Construcción Stick-Breaking

La representación stick-breaking, introducida por Sethuraman, 1994, proporciona una construcción explícita de las realizaciones del DP como sumas ponderadas infinitas de masas puntuales. Si $G \sim \mathrm{DP}(M, G_0)$, entonces:

$$G(\cdot) = \sum_{h=1}^{\infty} w_h\, \delta_{\theta_h}(\cdot), \tag{2.61}$$

donde los átomos $\theta_h \overset{\text{iid}}{\sim} G_0$ y los pesos w_h se construyen mediante la regla:

$$w_h = v_h \prod_{l=1}^{h-1}(1 - v_l), \qquad v_h \overset{\text{iid}}{\sim} \text{Beta}(1, M). \tag{2.62}$$

La construcción toma su nombre de la analogía con el quiebre sucesivo de un segmento de longitud unitaria: en cada paso h se extrae una fracción v_h del segmento restante, asignando ese fragmento como peso w_h al átomo θ_h. La suma resultante satisface $\sum_{h=1}^{\infty} w_h = 1$ casi seguramente.

Esta representación evidencia una propiedad estructural central del Proceso de Dirichlet, correspondiente al carácter discreto de G. Aun cuando G_0 sea una medida no atómica (por ejemplo, una distribución Normal), la suma (2.61) concentra toda la masa de G en el conjunto numerable de átomos $\{\theta_h\}_{h=1}^{\infty}$, de modo que G es una medida discreta con probabilidad uno, independientemente de la continuidad de G_0.

Esta discreción tiene una consecuencia directa sobre cualquier muestra generada a partir de G. Si $X_1, \ldots, X_n \mid G \overset{\text{iid}}{\sim} G$, cada observación X_i toma necesariamente el valor de alguno de los átomos θ_h, y dado que el soporte de G es numerable, dos o más observaciones pueden coincidir en el mismo átomo con probabilidad positiva. Estos empates entre observaciones no son una degeneración del modelo, sino el mecanismo mediante el cual el DP induce una partición aleatoria de las observaciones en grupos. Cuantas más observaciones comparten un átomo, mayor es la masa que dicho átomo concentra bajo la construcción stick-breaking, lo que a su vez refuerza su probabilidad de ser reutilizado por observaciones futuras.

2.4.3. Distribución Posterior

Una propiedad central del DP es su conjugación respecto al muestreo independiente e idénticamente distribuido. Sea $X_1, \ldots, X_n \mid G \overset{\text{iid}}{\sim} G$ con $G \sim \text{DP}(M, G_0)$. Entonces la distribución posterior de G dado el conjunto de observaciones es nuevamente un Proceso de Dirichlet, Müller et al., 2015:

$$G \mid X_1, \ldots, X_n \;\sim\; \text{DP}\left(M + n,\; \frac{M}{M+n}\, G_0 + \frac{n}{M+n}\, \hat{F}_n\right), \tag{2.63}$$

donde $\hat{F}_n = \frac{1}{n}\sum_{i=1}^{n} \delta_{X_i}$ es la medida empírica de las observaciones. La medida base posterior es por tanto un promedio ponderado entre el prior G_0 y la evidencia empírica $\hat{F}_n$, con pesos proporcionales a M y n respectivamente. El parámetro de concentración se actualiza de M a $M + n$, reflejando el incremento en la precisión posterior conforme aumenta el tamaño muestral.

La propiedad de conjugación garantiza que la inferencia sobre G sea analíticamente tratable en el caso independiente e idénticamente distribuido, y constituye la base de los algoritmos de muestreo para modelos de mezcla basados en DP que se describen en la sección siguiente. Una representación alternativa de la distribución marginal, conocida como urna de Pólya de Blackwell y MacQueen, 1973, conduce a la misma posterior y es la base de los muestreadores de Gibbs colapsados para estos modelos.

2.5. Mezcla de Procesos de Dirichlet

En la modelación jerárquica bayesiana (Sección 2.3.1) se asigna a los parámetros del modelo una distribución a priori. Sobre esa idea, la Sección 2.4 presentó el Proceso de Dirichlet como un prior flexible sobre el espacio de medidas de probabilidad, dotado de propiedades como su carácter discreto y su conjugación. Como se estableció a partir de su construcción stick-breaking (Sección 2.4.2), esa misma discreción impide emplear el DP de forma directa como modelo para datos continuos, pues sus realizaciones concentran toda la masa en un conjunto numerable de átomos.

Para conservar la flexibilidad del prior no paramétrico sin renunciar a una densidad continua sobre los datos, surgen los modelos de Mezcla de Procesos de Dirichlet (DPM), que emplean el DP como prior sobre los parámetros de un núcleo de densidad continua, Müller et al., 2015.

2.5.1. Modelo Jerárquico con DP

Sea $f(X \mid \theta)$ un núcleo de densidad continua parametrizado por $\theta \in \Theta$, y sea G una medida de probabilidad aleatoria sobre Θ. La densidad marginal inducida por la mezcla de f respecto a G es:

$$f_G(X) = \int_\Theta f(X \mid \theta)\, dG(\theta). \tag{2.64}$$

Al colocar un DP como prior sobre G, el modelo jerárquico completo se especifica como, Müller et al., 2015:

$$\begin{aligned} X_i \mid \theta_i &\overset{\text{ind}}{\sim} f(\cdot \mid \theta_i), \qquad i = 1, \ldots, n, \\ \theta_i \mid G &\overset{\text{iid}}{\sim} G, \\ G &\sim \text{DP}(M, G_0). \end{aligned} \tag{2.65}$$

Utilizando la representación stick-breaking de la Sección 2.4.2, el modelo DPM puede escribirse equivalentemente como una mezcla infinita:

$$f_G(X) = \sum_{h=1}^{\infty} w_h\, f(X \mid \theta_h), \tag{2.66}$$

donde los átomos $\theta_h \overset{\text{iid}}{\sim} G_0$ y los pesos w_h se construyen mediante la regla stick-breaking con $v_h \overset{\text{iid}}{\sim} \text{Beta}(1, M)$.

2.5.2. Clusters y Asignación

El carácter discreto de las realizaciones del DP implica que los parámetros $\theta_1, \ldots, \theta_n$ toman valores repetidos con probabilidad positiva, induciendo de manera natural una partición aleatoria de las observaciones en grupos o clusters.

Sean $\theta_1^*, \ldots, \theta_k^*$ los valores únicos adoptados por los θ_i. Cada observación X_i queda asignada al cluster j mediante el indicador $s_i \in \{1, \ldots, k\}$, donde $s_i = j$ si y solo si $\theta_i = \theta_j^*$; se denota $S_j = \{i : s_i = j\}$ el conjunto de índices asignados al j-ésimo cluster

y $n_j = |S_j|$ su tamaño.

La distribución condicional de asignación de una observación X_i dado el resto satisface, Escobar y West, 1995:

$$p(s_i = j \mid s_{-i}, X) \propto \begin{cases} n_{-i,j}\, f(X_i \mid \theta_j^*), & j = 1, \ldots, k, \\ M\, h_0(X_i), & j = k+1, \end{cases} \tag{2.67}$$

donde $n_{-i,j}$ es el tamaño del cluster j excluyendo X_i, y $h_0(X_i) = \int f(X_i \mid \theta)\, G_0(d\theta)$ es la verosimilitud marginal bajo la medida base. El primer caso refleja que los clusters más poblados atraen nuevas observaciones con mayor probabilidad, mientras que el segundo controla la propensión a generar un nuevo cluster mediante el parámetro M.

2.5.3. Inferencia Posterior

La inferencia en el DPM se realiza mediante algoritmos MCMC que alternan entre la actualización de las asignaciones $\{s_i\}$ y la de los parámetros de cluster $\{\theta_j^*\}$. Los parámetros de cada cluster se actualizan desde su distribución condicional completa:

$$p(\theta_j^* \mid s, X) \propto G_0(\theta_j^*) \prod_{i \in S_j} f(X_i \mid \theta_j^*). \tag{2.68}$$

En el caso conjugado, ambas distribuciones condicionales son analíticamente tratables y pueden muestrearse directamente mediante un muestreador de Gibbs Escobar y West, 1995. Para modelos no conjugados, Neal, 2000 propone el Algoritmo 8, que introduce clusters candidatos muestreados de G_0 para aproximar la integral $h_0(X_i)$, evitando el requisito de conjugación.

2.5.4. Aleatorización de Hiperparámetros

Una especificación completamente bayesiana asigna distribuciones a priori tanto al parámetro de concentración M como a los hiperparámetros η de la medida base $G_0(\cdot \mid \eta)$, incorporando una capa jerárquica adicional que refleja la incertidumbre sobre dichos valores. El modelo extendido se especifica como:

$$\begin{aligned} X_i \mid \theta_i &\overset{\text{ind}}{\sim} f(\cdot \mid \theta_i), \\ \theta_i \mid G &\overset{\text{iid}}{\sim} G, \\ G \mid \eta, M &\sim \mathrm{DP}\big(M,\, G_0(\cdot \mid \eta)\big), \\ (\eta, M) &\sim \pi(\eta, M). \end{aligned} \tag{2.69}$$

La inferencia sobre η y M se realiza de forma conjunta con el resto de los parámetros del modelo. Para el parámetro de concentración, asumiendo $M \sim \mathrm{Gamma}(a, b)$, Escobar y West, 1995 proponen un esquema eficiente basado en una variable auxiliar que permite muestrear M desde una mezcla de distribuciones Gamma, cuya composición depende del número de clusters activos k y del tamaño muestral n. Para los hiperparámetros η, la actualización se incorpora como un paso adicional en el muestreador de Gibbs, muestreando desde:

$$p(\eta \mid \theta_1^*, \ldots, \theta_k^*) \propto \pi(\eta) \prod_{j=1}^{k} G_0(\theta_j^* \mid \eta). \tag{2.70}$$

2.6. Mezcla de Procesos Dirichlet Dependientes

Los modelos de Mezcla de Procesos de Dirichlet desarrollados en la Sección 2.5 proporcionan un prior no paramétrico flexible sobre una densidad, pero modelan una única distribución común a todas las observaciones. En numerosos problemas el interés recae en la densidad condicional $f(y \mid x)$ de una respuesta dado un conjunto de covariables, cuya forma puede variar a lo largo del espacio de predictores. Los Modelos de Mezcla de Procesos de Dirichlet Dependientes extienden el DPM precisamente en esa dirección, ya que permiten que la distribución mezcladora dependa de las covariables, de modo que no solo la media, sino la forma completa de la distribución condicional pueda cambiar con x.

La idea central es sustituir la medida aleatoria única del DPM por una familia de medidas aleatorias indexada por las covariables, conservando para cada valor de x la estructura de mezcla infinita que caracteriza al DPM.

2.6.1. Procesos de Dirichlet Dependientes

La extensión del DPM al caso condicional se formaliza mediante los Procesos de Dirichlet Dependientes (DDP), introducidos por MacEachern, 1999. La idea consiste en reemplazar la medida de probabilidad aleatoria única $G \sim \mathrm{DP}(M, G_0)$ por una familia de medidas aleatorias indexada por las covariables,

$$\{G_x : x \in \mathcal{X}\}, \tag{2.71}$$

donde $\mathcal{X}$ denota el espacio de covariables. La construcción de MacEachern, 1999 impone que cada G_x sea marginalmente un Proceso de Dirichlet, de modo que, fijado un valor x, se recupera exactamente la estructura del DPM. El conjunto completo de la familia, en cambio, posee una estructura de dependencia que hace que G_x y $G_{x'}$ sean tanto más similares cuanto más próximos estén x y x' en $\mathcal{X}$. De este modo, el DDP define un prior no paramétrico sobre la aplicación $x \mapsto G_x$, permitiendo que la distribución condicional de los datos varíe de manera flexible y coherente a lo largo del espacio de predictores MacEachern, 1999.

Mediante la representación stick-breaking de la Sección 2.4.2, la familia $\{G_x\}$ admite la forma general

$$G_x = \sum_{h=1}^{\infty} w_h(x)\, \delta_{\theta_h(x)}, \tag{2.72}$$

donde tanto los pesos $w_h(x)$ como los átomos $\theta_h(x)$ pueden depender de x.

Las distintas variantes del DDP se diferencian según el componente sobre el cual recae la dependencia. En la variante de átomos dependientes y pesos fijos, la heterogeneidad entre distribuciones se introduce a través de los átomos $\theta_h(x)$, mientras que la estructura de pesos permanece invariante. En la variante de pesos dependientes y átomos fijos, los átomos $\theta_h \overset{\text{iid}}{\sim} G_0$ son compartidos por todas las distribuciones de la familia y la dependencia se introduce exclusivamente a través de los pesos $w_h(x)$; esta última resulta de especial relevancia para el presente trabajo, pues permite que la estructura

de mezcla varíe con las covariables sin alterar la localización de los componentes.

La variante de pesos dependientes resulta especialmente atractiva porque hereda de forma directa la construcción stick-breaking presentada en la Sección 2.4.2: basta con permitir que las variables de quiebre v_h dejen de ser constantes iid y pasen a depender del predictor x, dando lugar a los Procesos Stick-Breaking Dependientes.

2.6.2. Procesos Stick-Breaking Dependientes

La construcción stick-breaking presentada en la Sección 2.4.2 proporciona un mecanismo constructivo natural para introducir dependencia en los pesos de la mezcla. Recuérdese que en el DP estándar los pesos se construyen como:

$$w_h = v_h \prod_{l=1}^{h-1}(1 - v_l), \qquad v_h \overset{\text{iid}}{\sim} \text{Beta}(1, M). \tag{2.73}$$

La generalización dependiente reemplaza las variables de stick-breaking iid por procesos estocásticos indexados por el predictor:

$$w_h(x) = v_h(x) \prod_{l=1}^{h-1}\big\{1 - v_l(x)\big\}, \qquad v_h : \mathcal{X} \to [0, 1]. \tag{2.74}$$

Esta estructura garantiza que, para cada valor fijo $x \in \mathcal{X}$, los pesos $\{w_h(x)\}_{h=1}^{\infty}$ forman una distribución de probabilidad válida: $\sum_{h=1}^{\infty} w_h(x) = 1$ casi seguramente para todo x, siempre que las variables de quiebre satisfagan

$$\sum_{h=1}^{\infty} \mathbb{E}\big[\log\{1 - v_h(x)\}\big] = -\infty \qquad \text{para cada } x \in \mathcal{X}, \tag{2.75}$$

condición análoga a la establecida para procesos stick-breaking generales Chung y Dunson, 2009.

La elección del proceso $v_h(\cdot)$ determina las propiedades del DDP resultante y ha dado lugar a diversas formulaciones en la literatura, que se diferencian en el mecanismo mediante el cual se induce dependencia entre las variables de quiebre.

Griffin y Steel (2006) propusieron procesos que preservan el orden estocástico entre distribuciones con índices distintos, de modo que la relación de orden entre G_x y $G_{x'}$ se mantiene consistente a lo largo de $\mathcal{X}$. Reich y Fuentes (2007) desarrollaron aplicaciones espaciales en las que la dependencia entre $v_h(x)$ y $v_h(x')$ se modela mediante kernels de correlación definidos sobre la distancia entre ubicaciones espaciales. Dunson y Park (2008) introdujeron el Kernel Stick-Breaking Process (KSBP), en el que cada variable de quiebre se pondera mediante una función kernel del predictor, permitiendo que la influencia de cada componente decaiga suavemente con la distancia en $\mathcal{X}$. Estas formulaciones comparten la flexibilidad de admitir prácticamente cualquier estructura de dependencia deseada, pero a costa de una estructura a posteriori compleja que dificulta la inferencia eficiente, en particular cuando el espacio de covariables es de dimensión moderada o alta Chung y Dunson, 2009. Esta limitación motiva la búsqueda

de especificaciones alternativas que introduzcan dependencia en los pesos mediante una estructura que admita conjugacidad y permita el desarrollo de algoritmos de muestreo eficientes.

2.6.3. Modelos de Mezclas DDP

De manera análoga a como el Proceso de Dirichlet se emplea como prior sobre los parámetros de un núcleo de densidad continua en el DPM (Sección 2.5.1), el DDP puede emplearse como prior sobre los parámetros de un núcleo de densidad continua indexado por covariables, dando lugar a un modelo para la densidad condicional $f(y \mid x)$. Sea $f(y \mid \theta)$ un núcleo de densidad continua parametrizado por $\theta \in \Theta$, y sea $\{G_x : x \in \mathcal{X}\}$ una familia de medidas de probabilidad aleatorias sobre Θ. La densidad condicional inducida por la mezcla de f respecto a G_x es:

$$f(y \mid x) = \int_{\Theta} f(y \mid \theta)\, dG_x(\theta). \tag{2.76}$$

Al colocar un DDP como prior sobre la familia $\{G_x\}$, siguiendo la estructura jerárquica bayesiana introducida en la Sección 2.3.1, el modelo completo se especifica en tres niveles:

$$\begin{aligned} Y_i \mid \theta_i, x_i &\overset{\text{ind}}{\sim} f(\cdot \mid \theta_i), \qquad i = 1, \ldots, n, \\ \theta_i \mid G_{x_i} &\overset{\text{ind}}{\sim} G_{x_i}, \\ \{G_x : x \in \mathcal{X}\} &\sim \text{DDP}. \end{aligned} \tag{2.77}$$

La diferencia esencial respecto al modelo jerárquico del DPM reside en el segundo nivel: mientras que en el DPM los parámetros θ_i son idénticamente distribuidos, en el DDP cada θ_i se extrae de la medida G_{x_i} asociada a su propia covariable x_i, por lo que los parámetros dejan de ser idénticamente distribuidos entre observaciones con covariables distintas. Utilizando la representación stick-breaking dependiente de la Sección 2.6.2, el modelo puede escribirse equivalentemente como una mezcla infinita indexada por x:

$$f(y \mid x) = \sum_{h=1}^{\infty} w_h(x)\, f(y \mid \theta_h(x)), \tag{2.78}$$

donde la dependencia de $\theta_h(x)$ respecto a x desaparece en la variante de pesos dependientes y átomos fijos, de modo que (2.78) se reduce a $f(y \mid x) = \sum_{h=1}^{\infty} w_h(x)\, f(y \mid \theta_h)$, con átomos $\theta_h \overset{\text{iid}}{\sim} G_0$ comunes a toda la familia y solo los pesos variando con x. Bajo esta especificación, fijado un valor x, el modelo recupera exactamente la estructura del DPM (Sección 2.5.1), mientras que la variación de x a x' modula gradualmente la composición de la mezcla, permitiendo que la forma completa de la distribución condicional, y no solo su media, cambie a lo largo del espacio de covariables.

2.6.3.1. Modelos con Dependencia Temporal

Una aplicación natural del modelo de mezclas de DDP presentado en la Sección 2.6.3 en el contexto de series de tiempo consiste en tomar como covariable x los rezagos de la propia variable observada. Bajo este enfoque, la distribución condicional de y_t dado el pasado del proceso se modela mediante la familia de distribuciones dependientes $\{G_x\}$,

donde el predictor $x = (y_{t-1}, y_{t-2}, \ldots, y_{t-P})$ recoge la historia reciente del proceso hasta el rezago P, y el modelo jerárquico de la ecuación (2.77) se aplica directamente sustituyendo x_i por dicho vector de rezagos.

El interés de esta formulación reside en la naturaleza de la dependencia que admite. Los modelos clásicos (Sección 2.2.2.1) asumen que la media o la varianza condicional son funciones lineales del pasado; el DDP, en cambio, no impone ninguna forma paramétrica fija a la relación temporal, sino que permite que la distribución completa de y_t (incluyendo su forma, asimetría y colas) varíe de manera no paramétrica en función del estado previo del sistema. De este modo, el enfoque cubre precisamente las situaciones que los modelos lineales no pueden representar, correspondientes a la fila no lineal del Cuadro 2.1.

Esta estrategia ha sido ilustrada por Quintana et al., 2022 en el contexto del modelo LDDP aplicado a la serie del géiser Old Faithful, donde el predictor $x = y_{t-1}$ determina distribuciones condicionales que exhiben bimodalidad cambiante según el valor rezagado, un comportamiento que un modelo lineal no podría capturar.

Capítulo 3

Mezclas DDP para Series de Tiempo Funcionales

3.1. Motivación

Al igual que en el contexto escalar y multivariado, donde la dependencia temporal se captura mediante la distribución condicional de X_t dado su historia $\{X_{t-1}, X_{t-2}, \ldots\}$, en las series de tiempo funcionales el objetivo es análogo, es decir, caracterizar la ley condicional de la curva $X_t(\tau)$ dado el conjunto de curvas pasadas $\{X_{t-1}(\tau), X_{t-2}(\tau), \ldots\}$. Así como en el caso clásico existen múltiples metodologías para modelar dicha dependencia, en el contexto funcional el abanico de estrategias se amplía aún más, precisamente porque cada observación ya no es un escalar o un vector de dimensión finita sino una curva que vive en un espacio funcional de dimensión infinita.

La estrategia más común consiste en extender los modelos clásicos de series de tiempo al contexto funcional, es decir, utilizar los modelos funcionales FAR, FMA y FARMA, los cuales postulan una dinámica lineal gobernada por un operador acotado sobre el espacio de funciones, Bosq, 2000. Otra estrategia recurre a esquemas de reducción de dimensión, en los cuales se proyectan las curvas sobre una base de componentes principales funcionales y se modelan por separado las series de scores resultantes mediante técnicas clásicas univariadas, Hyndman y H. L. Shang, 2009; Hyndman y Ullah, 2007, o bien mediante un modelo vectorial autorregresivo sobre el vector de scores, Aue, Norinho y Hörmann, 2015. Ambos enfoques incorporan explícitamente la dependencia temporal entre observaciones funcionales y permiten cuantificar la incertidumbre predictiva; sin embargo, heredan limitaciones estructurales. En primer lugar, la dinámica se restringe a un operador lineal actuando sobre la curva (o el vector de scores) rezagado, de modo que la distribución condicional de X_t dado su pasado queda completamente determinada por una única ley de innovación homogénea en el tiempo, es decir, el modelo podria no admitir multimodalidad condicional, asimetrías dependientes del estado ni regímenes dinámicos cambiantes. En segundo lugar, la teoría de estimación y predicción descansa en supuestos de estacionariedad, Aue, Norinho y Hörmann, 2015; Hörmann y Kokoszka, 2010 cuya violación ha sido documentada empíricamente en aplicaciones prácticas como las curvas de precios intradiarios, Horváth, Kokoszka y Rice (2014), y las curvas de temperatura, Aue, Rice y Sönmez (2018), donde la hipótesis de estacionariedad resulta rechazada y motiva por tanto el estudio de otras metodologías.

Paralelamente, los avances en aprendizaje automático han dado lugar a modelos altamente flexibles, como redes neuronales, Random Forest y máquinas de soporte vectorial, con aplicaciones directas al pronóstico de series de tiempo funcionales, típicamente operando sobre los scores de una descomposición en componentes principales funcionales, Beyaztas y H. Shang, 2022. Estos métodos relajan la restricción de linealidad en la media condicional y exhiben, en general, un elevado poder predictivo puntual.No obstante, sus limitaciones para el problema que aquí interesa son de naturaleza distribucional. En primer lugar, estos métodos producen pronósticos puntuales sin medida de incertidumbre asociada, de modo que su cuantificación debe añadirse externamente al modelo, como ocurre con los intervalos de predicción construidos mediante remuestreo bootstrap de residuos, Beyaztas y H. Shang, 2022. Ese remuestreo no impone una forma a la distribución del error, pero suma a cada predicción la misma población de residuos con independencia del estado del proceso, de manera que la forma y la amplitud del intervalo no pueden cambiar con la historia reciente, que es precisamente lo que una ley condicional heterogénea exige. En segundo lugar, los intentos de dotar a estas arquitecturas de un marco probabilístico, como las redes neuronales bayesianas, los deep ensembles y los procesos neuronales, enfrentan dificultades como inferencia exacta intratable, especificación problemática de distribuciones a priori sobre los pesos, subestimación sistemática de la incertidumbre y costos computacionales elevados, Kamarthi et al., 2021. El esfuerzo más reciente en esta dirección, específico para series de tiempo funcionales, es la red neuronal probabilística de H. Wang y Cao (2025), que confirma el diagnóstico anterior pero lo resuelve dentro de una verosimilitud gaussiana paramétrica, la cual produce nuevamente una distribución predictiva unimodal y de forma fija, incapaz de representar heterogeneidad distribucional en la ley condicional de la curva.

Se configura así una disyuntiva entre dos familias de métodos que excede la simple oposición entre rigor y flexibilidad. Los enfoques funcionales de base estadística ofrecen un marco probabilístico coherente al precio de supuestos estructurales que la evidencia empírica contradice en los dominios de alta frecuencia que motivan esta tesis; los enfoques de aprendizaje automático flexibilizan la media condicional, pero su cuantificación de incertidumbre es ad hoc, en el sentido de ser externa al modelo, paramétrica de forma fija bajo verosimilitudes gaussianas, o mal calibrada por efecto de la inferencia variacional sobre pesos de redes. En ninguna de las dos familias el objeto de modelamiento es la distribución condicional completa de la observación funcional dada su historia, ambas la reducen a una media condicional más una ley de error rígida.

3.2. Estado del Arte

La aplicación de métodos bayesianos no paramétricos al modelamiento de series de tiempo cuenta con una literatura consolidada para el caso univariado, organizada en torno al proceso de Dirichlet dependiente y sistematizada en la revisión de Quintana et al. (2022).

Una primera línea introduce la dependencia temporal en los átomos de la mezcla, manteniendo los pesos fijos. Rodríguez y Horst (2008) definen la distribución en cada instante

como una mezcla de gaussianas cuyos átomos evolucionan según un modelo dinámico lineal, lo que permite capturar colas pesadas, multimodalidad y clusters de volatilidad en fenómenos financieros con la maquinaria computacional de un DPM estándar, precisamente porque los pesos no requieren actualización. Di Lucca et al. (2013) dan un paso conceptual decisivo al indexar el DDP no por el tiempo sino por la covariable rezagada y_{t-1}, con átomos afines de la forma $\theta_h(y) = \beta_h + \gamma_h y$, demostrando que un DDP puede operar directamente como motor de un modelo autorregresivo de regresión de densidad. Estos trabajos aportan la plantilla de "mezcla condicionada al estado del proceso", pero con dos restricciones compartidas. Primero la covariable es escalar y la segunda es que la dependencia recae únicamente en los átomos, de modo que los pesos de mezcla permanecen constantes y no responden al estado rezagado.

Una segunda línea introduce la dependencia temporal en los pesos, de modo que lo que cambia en el tiempo no es la ubicación de los componentes sino cuánta probabilidad recibe cada uno. Griffin y Steel (2011) lo consiguen mediante una recursión estocástica sobre las fracciones stick-breaking que preserva, en cada instante. En la representación de particiones, donde los pesos quedan integrados y solo se modela la regla de asignación a grupos, se han propuesto urnas de Pólya variantes en el tiempo Caron, Davy y Doucet, 2007 y, en el caso multivariado, Saad y Mansinghka (2018) reponderan la asignación de un proceso de restaurante chino según la recencia de las observaciones de cada grupo, logrando pronosticar, imputar y agrupar simultáneamente cientos de series heterogéneas y no estacionarias. Frente al problema de esta tesis, estos mecanismos presentan dos limitaciones. Ninguno ha sido aplicado a datos funcionales y la recursión sobre fracciones no admite generalización natural a covariables en $\mathbb{R}^M$. Son de hecho notablemente escasos los trabajos que transitan del caso escalar al vectorial dentro de la familia DDP.

En el frente de los datos funcionales, la literatura bayesiana no paramétrica ha producido construcciones dependientes genuinas, pero con la dependencia orientada a ejes distintos del temporal. Petrone, Guindani y Gelfand (2009) formalizan los priors Dirichlet híbridos, en los que cada curva se recombina localmente a partir de unas pocas curvas mediante un proceso de etiquetas oculto gobernado por una cópula gaussiana sobre el propio dominio funcional; el aporte es un mecanismo de heterogeneidad local dentro de la curva, pero no existe estructura temporal entre curvas sucesivas. Rodríguez, Dunson y Gelfand (2009) estiman colecciones de curvas compartiendo información mediante mezclas DDP de gaussianas; la dependencia, sin embargo, es entre curvas de una muestra y no una estructura autorregresiva sobre la ley de mezcla. Scarpa y Dunson (2014) enriquecen el stick-breaking funcional con una jerarquía de dos niveles que agrupa las curvas primero por atributos globales conocidos y luego por características finas, mecanismo valioso para incorporar información previa sobre regímenes pero atemporal por construcción. Más cerca del objetivo de esta tesis, Gamasaee y Fazel Zarandi (2017) combinan un DDP con mezclas de regresión por tramos para clustering dinámico, segmentación y pronóstico de funciones, con clusters que nacen, persisten y transitan en el tiempo; no obstante, su representación por tramos no se articula con expansiones FPCA ni con una covariable de scores rezagados. El balance de esta literatura funcional es claro: existen mezclas dependientes para curvas, pero en ninguna de ellas la distribución de la curva presente está indexada por el estado funcional rezagado de la serie.

Finalmente, dentro de la familia stick-breaking dependiente, Rodríguez y Dunson (2011) proponen el proceso probit stick-breaking, que sustituye las fracciones Beta de la representación de Sethuraman por transformaciones probit de procesos gaussianos; con ello, la dependencia de los pesos respecto de una covariable (escalar, vectorial, temporal o espacial) se obtiene especificando la estructura de covarianza del proceso subyacente, y la inferencia se reduce, vía la representación de razón de continuación, a una secuencia de regresiones probit resolubles con el aumento de datos de Albert y Chib, preservando esquemas de Gibbs estándar. En esta misma familia, Chung y Dunson (2009) habían empleado mezclas probit stick-breaking con pesos indexados por un vector de predictores para la estimación de distribuciones condicionales con selección de variables, demostrando la viabilidad del mecanismo con covariables escalares; su contexto, sin embargo, es el de regresión con observaciones intercambiables, donde los predictores son exógenos y no existe estructura temporal alguna. Las aplicaciones de Rodríguez y Dunson (2011), por su parte, se limitan a ilustraciones en finanzas y ecología con átomos euclidianos, y los desarrollos posteriores de la familia han avanzado hacia índices espacio-temporales conjuntos, incluyendo un test de separabilidad entre ambas fuentes de dependencia Grazian, 2025, sin abordar hasta ahora observaciones funcionales ni covariables construidas a partir de la propia historia del proceso.

3.2.1. Discusión y brecha de investigación

La revisión anterior muestra que un modelo para el problema de esta tesis necesita que la ley de mezcla dependa del estado rezagado del proceso y que las observaciones sean funcionales.

La mezcla probit stick-breaking permite construir un modelo cuyos pesos dependen de covariables construidas con los rezagos del proceso, mientras que la parte funcional se puede ajustar con M modelos univariados para los scores obtenidos de un análisis de componentes principales funcionales.

Por tanto, la brecha de investigación que este trabajo busca cubrir consiste en desarrollar un modelo bayesiano no paramétrico que combine modelos univariados para los scores con pesos de stick-breaking dependientes del estado funcional rezagado, y que permita predecir los scores para, a partir de ellos, reconstruir la curva $X_t(\tau)$.

3.3. Probit Stick-Breaking Process Mixture

Esta sección presenta el Probit Stick-Breaking Process (PSBP) y el modelo de mezcla construido sobre él, el PSBP Mixture (PSBPM), desarrollado por Chung y Dunson (2009). Salvo indicación en contrario, las definiciones, resultados y el esquema de inferencia expuestos en esta secciónprovienen de dicho trabajo.

El PSBP define una colección de distribuciones dependientes del predictor $\mathcal{P}_{\mathcal{X}} = \{P_x : x \in \mathcal{X}\}$ mediante una modificación del proceso stick-breaking estándar en la que las variables de quiebre se construyen a través de un modelo probit. La motivación de esta

construcción parte de la representación estándar del DP:

$$P = \sum_{h=1}^{\infty} \pi_h \delta_{\theta_h}, \qquad \pi_h = V_h \prod_{l<h}(1 - V_l), \qquad V_h \overset{\text{iid}}{\sim} \text{Beta}(1, c), \tag{3.1}$$

y propone reemplazar las variables Beta por variables latentes normales transformadas mediante la función de distribución acumulada $\Phi(\cdot)$ de la normal estándar:

$$\pi_h = \Phi(\eta_h) \prod_{l<h} \big\{1 - \Phi(\eta_l)\big\}, \qquad \eta_h \overset{\text{iid}}{\sim} \mathcal{N}(\mu, 1). \tag{3.2}$$

En el caso particular $c = 1$ y $\mu = 0$, ambas formulaciones producen variables de quiebre con distribución Uniform$(0, 1)$, de modo que los dos priors son idénticos. En general, μ desempeña un rol análogo al del parámetro de concentración c del DP, es decir, valores grandes de μ concentran la masa en los primeros componentes de la mezcla, mientras que valores pequeños producen una distribución más difusa sobre el espacio de componentes.

Para construir una colección de distribuciones dependientes del predictor, la ecuación (3.2) se generaliza permitiendo que el predictor lineal η_h dependa de x:

$$P_x = \sum_{h=1}^{\infty} \pi_h(x) \delta_{\theta_h}, \qquad \pi_h(x) = \Phi\big(\eta_h(x)\big) \prod_{l<h} \big\{1 - \Phi\big(\eta_l(x)\big)\big\}, \tag{3.3}$$

donde los átomos $\theta_h \sim P_0$ son independientes del predictor y compartidos entre todas las distribuciones de la colección. El predictor lineal se especifica como $\eta_h(x) = \alpha_h + f_h(x)$, con $\alpha_h \sim \mathcal{N}(\mu, 1)$ y $f_h : \mathbb{R}^p \to \mathbb{R}$ una función de regresión desconocida de los predictores. La notación compacta $\mathcal{P}_{\mathcal{X}} \sim \text{PSBP}(\mu, H, P_0)$ designa que la colección sigue esta distribución con hiperparámetros μ, H y medida base P_0, donde H caracteriza la distribución de los parámetros que definen $f_h(\cdot)$. El Lema 1 de Chung y Dunson (2009) establece que los pesos definidos en (3.3) satisfacen $\sum_{h=1}^{\infty} \pi_h(x) = 1$ casi seguramente para todo $x \in \mathcal{X}$, garantizando la coherencia del prior.

Para la función de regresión $f_h(\cdot)$, los autores proponen la forma basada en distancias absolutas ponderadas:

$$f_h(x) = -\sum_{j=1}^{p} \rho_{hj} |x_j - \Gamma_{hj}|, \tag{3.4}$$

donde $\rho_{hj} \geq 0$ controla la tasa de decaimiento de la dependencia para el j-ésimo predictor en el h-ésimo componente, y Γ_{hj} es una localización de referencia en el espacio del predictor. Las distribuciones a priori sobre los parámetros $\boldsymbol{\phi}_h = \{\rho_{hj}, \Gamma_{hj}\}_{j=1}^{p}$ se especifican como:

$$H \equiv \prod_{j=1}^{p} \left\{ \mathcal{N}^{+}\left(\rho_{hj}; \mu_{\rho_j}, \nu_{\rho_j}^{-1}\right) \times \sum_{l=1}^{L_j} \frac{1}{L_j} \delta_{\Gamma^*_{jl}}(\Gamma_{hj}) \right\}, \tag{3.5}$$

donde $\mathcal{N}^{+}$ denota una distribución normal truncada en cero por abajo, garantizando $\rho_{hj} \geq 0$, y $\{\Gamma^*_{jl}\}_{l=1}^{L_j}$ es una grilla discreta de puntos de referencia para el j-ésimo

predictor. La interpretación geométrica es directa, si x se encuentra lejos del centro $\mathbf{\Gamma}_h = \{\Gamma_{hj}\}_{j=1}^p$, entonces $f_h(x)$ toma valores negativos de gran magnitud, $\Phi(\eta_h(x)) \approx 0$, y el h-ésimo componente contribuye con peso reducido en x, favoreciendo a los componentes cuyos centros son más próximos al punto de evaluación.

3.3.1. Especificación del modelo de mezclas

Para el modelamiento de la densidad condicional $f(y \mid x)$, el PSBP se emplea como prior sobre la distribución mezcladora en un modelo de mezcla infinita de regresiones normales lineales, denominado PSBP Mixture (PSBPM):

$$f(y \mid x) = \int \mathcal{N}(y; \mathbf{x}_0^\top \boldsymbol{\beta}, \nu^{-1}) dP_x(\boldsymbol{\beta}, \nu), \qquad \mathcal{P}_\mathcal{X} \sim \text{PSBP}(\mu, H, P_0), \tag{3.6}$$

donde $\mathbf{x}_0 = (1, x^\top)^\top$ es el vector predictor incluyendo un intercepto y $\boldsymbol{\beta} = (\beta_0, \ldots, \beta_p)^\top$ es el vector de coeficientes de regresión. Aplicando la forma stick-breaking de la ecuación (2.66), y considerando además $\theta_h = (\boldsymbol{\beta}_h^*, \nu_h^*)$, se obtiene la representación equivalente como mezcla infinita:

$$f(y \mid x) = \sum_{h=1}^{\infty} \pi_h(x) \mathcal{N}\left(y; \mathbf{x}_0^\top \boldsymbol{\beta}_h^*, \nu_h^{*-1}\right), \tag{3.7}$$

que corresponde a una mezcla infinita de regresiones lineales normales con pesos dependientes de los predictores.

De forma análoga al modelo de Mezcla de Procesos de Dirichlet (Sección 2.5.1), el PSBPM admite una representación jerárquica en tres niveles. La diferencia esencial reside en que la distribución de la cual se extraen los parámetros de cada observación depende ahora de su covariable, por lo que los parámetros dejan de ser idénticamente distribuidos:

$$\begin{aligned} y_i \mid \theta_i, x_i &\overset{\text{ind}}{\sim} \mathcal{N}\left(y_i; \mathbf{x}_{i0}^\top \boldsymbol{\beta}_i, \nu_i^{-1}\right), \qquad i = 1, \ldots, n, \\ \theta_i = (\boldsymbol{\beta}_i, \nu_i) \mid P_{x_i} &\overset{\text{ind}}{\sim} P_{x_i}, \\ \mathcal{P}_\mathcal{X} = \{P_x : x \in \mathcal{X}\} &\sim \text{PSBP}(\mu, H, P_0), \end{aligned} \tag{3.8}$$

donde, fijada la covariable x_i, cada P_{x_i} es una medida stick-breaking con variables de quiebre $\Phi(\eta_h(x_i))$ independientes entre componentes, que no es un Proceso de Dirichlet salvo en el caso $\mu = 0$ sin dependencia del predictor señalado tras (3.2). El esquema conserva así la estructura del DPM, con la medida mezcladora seleccionada por la covariable de cada observación.

Para incorporar selección de variables, se introduce un indicador $\gamma_{hj} \in \{0, 1\}$ que controla la inclusión del j-ésimo predictor en el h-ésimo componente. Cuando $\gamma_{hj} = 0$, se tiene simultáneamente $\rho_{hj} = 0$ y $\beta_{hj}^* = 0$, de modo que el j-ésimo predictor queda excluido tanto de los pesos $\pi_h(x)$ como de la media condicional del componente. Si $\gamma_{hj} = 0$ para todo h, el j-ésimo predictor queda globalmente excluido del modelo. Para

modelar la incertidumbre sobre la inclusión se especifica:

$$\gamma_{hj} \sim \text{Bernoulli}(\kappa_j), \tag{3.9}$$
$$\kappa_j \sim (1 - w_j)\delta_0 + w_j \text{Beta}(a_{\kappa_j}, b_{\kappa_j}), \tag{3.10}$$
$$w_j \sim \text{Bernoulli}(0{,}5), \tag{3.11}$$

donde w_j es un indicador global de inclusión del j-ésimo predictor en el modelo completo. Los priors sobre los parámetros de los átomos se especifican mediante:

$$\boldsymbol{\beta}^*_{\gamma_h,h} \mid \nu^*_h \sim \mathcal{N}\left(\boldsymbol{\beta}^*_{\gamma_h,h}; \mathbf{0}, \boldsymbol{\Sigma}_{\gamma_h,h}\right), \qquad \nu^*_h \sim \text{Gamma}(\nu^*_h; a_\nu, b_\nu), \tag{3.12}$$

$$\boldsymbol{\Sigma}_{\gamma_h,h} = ng^{-1}\left(\mathbf{X}^\top_{\gamma_h,h}\mathbf{X}_{\gamma_h,h}\right)^{-1}/\nu^*_h, \qquad g \sim \text{Gamma}(g; a_g, b_g), \tag{3.13}$$

donde la especificación de $\boldsymbol{\Sigma}_{\gamma_h,h}$ corresponde al g-prior de Zellner (1986), que ajusta la escala de los coeficientes en función de los predictores y la precisión residual del componente.

3.3.2. Esquema de inferencia bayesiana

La inferencia en el PSBPM se realiza mediante un muestreador de Gibbs que combina aumento de datos con condicionales completas conjugadas. Para obtener una aproximación tratable, el proceso infinito se trunca al nivel N, fijando $\Phi(\eta_N(x)) = 1$ de modo que $\sum_{h=1}^N \pi_h(x) = 1$ para todo x.

El aumento de datos introduce variables latentes Z^*_{il} que transforman el problema de actualización de los parámetros del predictor lineal en una regresión normal conjugada. Para cada observación i con asignación $S_i = h$, se define:

$$Z_{il} = \mathbf{1}(Z^*_{il} > 0), \qquad Z^*_{il} \sim \mathcal{N}\left(Z^*_{il}; \alpha_h - \sum_{j=1}^p \rho_{hj}|x_{ij} - \Gamma_{hj}|, 1\right), \tag{3.14}$$

con $Z_{il} = 0$ para $l = 1, \ldots, S_i - 1$ y $Z_{il} = 1$ para $l = S_i$. Dado Z^*_{il}, todos los parámetros de los pesos y de los átomos admiten distribuciones condicionales completas de forma cerrada. Los pasos de actualización del muestreador son los siguientes.

1. **Actualización de asignaciones S_i:** Para cada $i = 1, \ldots, n$,

$$\Pr(S_i = h) = \frac{\pi_h(x_i)\mathcal{N}(y_i; \mathbf{x}^\top_{i0}\boldsymbol{\beta}^*_h, \nu^{*-1}_h)}{\sum_{h=1}^N \pi_h(x_i)\mathcal{N}(y_i; \mathbf{x}^\top_{i0}\boldsymbol{\beta}^*_h, \nu^{*-1}_h)}. \tag{3.15}$$

2. **Actualización de variables latentes Z^*_{il}:** Para cada i con $S_i = h$, se muestrean variables normales truncadas:

$$Z^*_{il} \sim \mathcal{N}(\eta_l(x_i), 1)\,\mathbf{1}_{(-\infty,0)}, \quad l = 1, \ldots, h-1,$$
$$Z^*_{ih} \sim \mathcal{N}(\eta_h(x_i), 1)\,\mathbf{1}_{(0,\infty)}.$$

3. **Actualización de interceptos probit α_h:** Para $h = 1, \ldots, N-1$, con $n_h = \sum_{i=1}^{n} \mathbf{1}(S_i \geq h)$,

$$\alpha_h \sim \mathcal{N}\left(\alpha_h; [n_h+1]^{-1}\left[\sum_{i:S_i \geq h} W_{ih}^* + \mu\right], [n_h+1]^{-1}\right), \tag{3.16}$$

donde $W_{ih}^* = Z_{ih}^* + \sum_{j=1}^{p} \rho_{hj}|x_{ij} - \Gamma_{hj}|$.

4. **Actualización de coeficientes de decaimiento ρ_{hj}:** Para $j = 1, \ldots, p$ y $h = 1, \ldots, N-1$: si $\gamma_{hj} = 0$, entonces $\rho_{hj} = 0$; si $\gamma_{hj} = 1$, definiendo $U_{ih}^* = \alpha_h - Z_{ih}^* - \sum_{k \neq j} \rho_{hk}|x_{ik} - \Gamma_{hk}|$ y $D_{ihj} = |x_{ij} - \Gamma_{hj}|$,

$$\begin{aligned}
\rho_{hj} &\sim \mathcal{N}^{+}\left(m_{\rho_{hj}}, v_{\rho_{hj}}\right), \\
v_{\rho_{hj}} &= \left[\nu_{\rho_j} + \sum_{i:S_i \geq h} D_{ihj}^2\right]^{-1}, \\
m_{\rho_{hj}} &= v_{\rho_{hj}}\left[\nu_{\rho_j}\mu_{\rho_j} + \sum_{i:S_i \geq h} D_{ihj}U_{ih}^*\right].
\end{aligned} \tag{3.17}$$

5. **Actualización de centros de referencia Γ_{hj}:** Para $j = 1, \ldots, p$ y $h = 1, \ldots, N-1$: si $\gamma_{hj} = 0$, no se actualiza; si $\gamma_{hj} = 1$, definiendo $R_{ih}^{(j)} = \alpha_h - \sum_{k \neq j} \rho_{hk}|x_{ik} - \Gamma_{hk}|$,

$$\Pr(\Gamma_{hj} = \Gamma_{jl}^*) \propto \frac{1}{L_j} \prod_{i:S_i \geq h} \mathcal{N}\Big(Z_{ih}^*; R_{ih}^{(j)} - \rho_{hj}|x_{ij} - \Gamma_{jl}^*|, 1\Big). \tag{3.18}$$

6. **Actualización de coeficientes de regresión $\boldsymbol{\beta}_h^*$:** Para $h = 1, \ldots, N$, con $\boldsymbol{\beta}_{\bar{\gamma}_h,h}^* = \mathbf{0}$,

$$\begin{aligned}
\boldsymbol{\beta}_{\gamma_h,h}^* &\sim \mathcal{N}(\mathbf{m}_{\beta_h}, \mathbf{V}_{\beta_h}), \\
\mathbf{V}_{\beta_h} &= \left[\nu_h^* \mathbf{X}_{\gamma_h,h}^\top \mathbf{X}_{\gamma_h,h} + \boldsymbol{\Sigma}_{\gamma_h,h}^{-1}\right]^{-1}, \\
\mathbf{m}_{\beta_h} &= \mathbf{V}_{\beta_h} \nu_h^* \mathbf{X}_{\gamma_h,h}^\top \mathbf{y}_h.
\end{aligned} \tag{3.19}$$

7. **Actualización de precisiones ν_h^*:** Para $h = 1, \ldots, N$, con $k_h = \sum_{i=1}^{n} \mathbf{1}(S_i = h)$, $p_{\gamma_h} = \sum_{j=1}^{p} \gamma_{hj}$, $\mathbf{r}_h = \mathbf{y}_h - \mathbf{X}_{\gamma_h,h}\boldsymbol{\beta}_{\gamma_h,h}^*$ y $Q_h = \boldsymbol{\beta}_{\gamma_h,h}^{*\top}(\mathbf{X}_{\gamma_h,h}^\top \mathbf{X}_{\gamma_h,h})\boldsymbol{\beta}_{\gamma_h,h}^*$,

$$\begin{aligned}
\nu_h^* &\sim \text{Gamma}(a_\nu^*, b_\nu^*), \\
a_\nu^* &= a_\nu + \frac{k_h}{2} + \frac{p_{\gamma_h}+1}{2}, \\
b_\nu^* &= b_\nu + \frac{1}{2}\mathbf{r}_h^\top \mathbf{r}_h + \frac{g}{2n} Q_h.
\end{aligned} \tag{3.20}$$

8. **Actualización de g, κ_j, w_j y μ:** Estos hiperparámetros se actualizan desde sus distribuciones condicionales completas conjugadas. En particular, μ se actualiza como:

$$\mu \sim \mathcal{N}\left(\mu; [N-1+\nu_\mu]^{-1}\left[\sum_{h=1}^{N-1} \alpha_h + \nu_\mu \mu_\mu\right], [N-1+\nu_\mu]^{-1}\right). \tag{3.21}$$

9. **Actualización de indicadores de inclusión γ_{hj}:** Para $j = 1, \ldots, p$ y $h = 1, \ldots, N$,

$$\Pr(\gamma_{hj} = 1) = \frac{a_{hj}}{a_{hj} + b_{hj}}, \tag{3.22}$$

donde a_{hj} y b_{hj} se calculan marginalizando ρ_{hj} y β^*_{hj} de la verosimilitud conjunta de (y, S). Esta marginalización es posible gracias a la conjugación obtenida por la estructura probit de los pesos, y generaliza el paso de búsqueda estocástica para selección de variables (SSVS, por sus siglas en inglés) propio de la regresión lineal.

3.3.3. Propiedades

El PSBP y el modelo de mezcla construido sobre él presentan un conjunto de propiedades que los distinguen de otras formulaciones de procesos stick-breaking dependientes y que justifican su adopción en problemas de modelamiento de distribuciones condicionales.

La primera propiedad es la conjugación del PSBPM. La estructura probit de las variables de quiebre, combinada con el aumento de datos mediante las variables latentes Z^*_{il}, produce condicionales completas de forma cerrada para todos los parámetros del modelo. Esto contrasta con formulaciones alternativas como el KSBP Dunson y Park, 2008, cuya inferencia requiere pasos de Metropolis–Hastings, de modo que el PSBPM admite un muestreador de Gibbs más eficiente.

La segunda propiedad es la adaptación local del PSBP al espacio de predictores. Los pesos $\pi_h(x)$ concentran su masa en torno al centro $\mathbf{\Gamma}_h$, de modo que cada componente de la mezcla domina en una región distinta del espacio $\mathcal{X}$. La tasa de decaimiento ρ_{hj} controla cuán rápidamente decrece la influencia del h-ésimo componente al alejarse de su centro, permitiendo que la estructura de mezcla se adapte a la heterogeneidad local de los datos sin imponer una forma global paramétrica.

La tercera propiedad es la selección de variables en dos niveles del PSBPM. El indicador γ_{hj} actúa simultáneamente sobre los pesos $\pi_h(x)$ —a través de ρ_{hj}— y sobre la media condicional del componente a través de β^*_{hj}. Esto permite distinguir entre predictores que afectan la forma de la distribución condicional de manera local (en ciertas regiones de $\mathcal{X}$) y predictores con efectos globales sobre toda la distribución, mediante el indicador de inclusión global w_j.

La cuarta y ultima propiedad de interes es la coherencia del prior. El Lema 1 de Chung y Dunson (2009) garantiza que $\sum_{h=1}^{\infty} \pi_h(x) = 1$ casi seguramente para todo $x \in \mathcal{X}$, condición necesaria para que P_x sea una distribución de probabilidad válida para cada valor del predictor. Esta propiedad no es automática en procesos stick-breaking dependientes y requiere verificación explícita para cada elección del proceso de quiebre en la ecuación (2.74).

3.4. Modelo PSBPM-FD

El modelo PSBPM-FD traslada la construcción de la Sección 3.3 al espacio de los scores funcionales obtenidos mediante la descomposición de FPCA descrita en el Capítulo 2.

Sea $\{X_t\}$ una serie de tiempo funcional con valores en $L^2(\mathcal{T})$ y sea

$$X_t^{(M)}(\tau) = \mu(\tau) + \sum_{m=1}^{M} \xi_{tm}\psi_m(\tau), \qquad \tau \in \mathcal{T}, \tag{3.23}$$

su expansión truncada en M términos, donde $\mu(\tau)$ denota la función media, $\{\psi_m\}_{m=1}^{K}$ las autofunciones del operador de covarianza ordenadas según sus autovalores $\lambda_1 \geq \cdots \geq \lambda_K$, de las que se retienen las $M \leq K$ primeras, y $\xi_{tm} = \langle X_t - \mu, \psi_m \rangle$ el m-ésimo score de la curva observada en el instante t. Las cantidades $\mu(\tau)$ y $\{\psi_m\}$ se obtienen del bloque de entrenamiento y se tratan como conocidas en lo sucesivo, de modo que la totalidad de la aleatoriedad del proceso reside en la sucesión de vectores de scores $\{\boldsymbol{\xi}_t\}$, con $\boldsymbol{\xi}_t = (\xi_{t1}, \ldots, \xi_{tM})^\top \in \mathbb{R}^M$.

Se adopta un supuesto markoviano de orden q, de modo que la historia relevante queda resumida en el vector $\mathbf{z}_t = (\boldsymbol{\xi}_{t-1}^\top, \ldots, \boldsymbol{\xi}_{t-q}^\top)^\top$, de dimensión $p = qM$, y se postula sobre él la independencia condicional entre componentes,

$$f\big(\boldsymbol{\xi}_t \mid \mathbf{z}_t\big) = \prod_{m=1}^{M} f\big(\xi_{tm} \mid \mathbf{z}_t\big). \tag{3.24}$$

La factorización no restringe el condicionante sino solo la dependencia contemporánea entre componentes. Cada factor admite la historia completa del proceso, de manera que el rezago de cualquier componente puede influir sobre la ley de cualquier otra, e incluso permite incorporar covariables exógenas a $\mathbf{z}_t$ sin alterar la estructura de (3.24).

Bajo este supuesto cada factor de (3.24) puede especificarse por separado. Se emplea para ello un proceso de Dirichlet dependiente indexado por $\mathbf{z}_t$, esto es, una colección de medidas de probabilidad aleatorias $\{P_{\mathbf{z}}\}$ con representación stick-breaking

$$P_{\mathbf{z}} = \sum_{h=1}^{\infty} \pi_h(\mathbf{z})\delta_{\theta_h}, \qquad \theta_h \overset{\text{iid}}{\sim} P_0, \tag{3.25}$$

cuyos pesos se construyen según el mecanismo probit de la ecuación (3.3) y cuyos átomos son independientes del índice y compartidos por toda la colección. El carácter autorregresivo de orden q reside en que dicho índice no es una covariable exógena sino el estado rezagado del propio proceso, de manera que la medida que gobierna la distribución de $\boldsymbol{\xi}_t$ queda seleccionada por la historia reciente de la serie. Esta es la diferencia esencial respecto del uso original del PSBP en Chung y Dunson (2009), donde las observaciones son intercambiables y los predictores externos, y la que permite que no solo la ubicación de cada régimen sino su probabilidad de ocurrencia responda al estado del sistema.

La construcción anterior se instancia por separado para cada componente, con átomos $\theta_{hm} = (\beta_{0,hm}^*, \boldsymbol{\beta}_{hm}^*, \nu_{hm}^*)$ y núcleo de regresión lineal normal, de donde cada factor de

(3.24) resulta una mezcla de regresiones normales con pesos dependientes del estado rezagado,

$$f(\xi_{tm} \mid \mathbf{z}_t) = \sum_{h=1}^{N} \pi_{hm}(\mathbf{z}_t)\mathcal{N}\big(\xi_{tm}; \beta^*_{0,hm} + \mathbf{z}_t^\top \boldsymbol{\beta}^*_{hm}, \nu^{*-1}_{hm}\big)\,, \qquad m = 1, \ldots, M, \tag{3.26}$$

donde el score presente juega el rol de la variable respuesta y de la Sección 3.3.1 y el vector $\mathbf{z}_t$ el del predictor x, y los pesos se obtienen del predictor lineal

$$\eta_{hm}(\mathbf{z}_t) = \alpha_{hm} - \sum_{j=1}^{p} \rho_{hmj}\big|z_{tj} - \Gamma_{hmj}\big|, \tag{3.27}$$

donde α_{hm} denota el intercepto probit del h-ésimo componente de la m-ésima mezcla, en la notación de la Sección 3.3. El nivel de truncamiento N reemplaza a la suma infinita de (3.25), en los mismos términos descritos en la Sección 3.3.2.

La variabilidad del proceso queda así contenida en la propia mezcla, tanto en la precisión ν^*_{hm} de cada componente como en la dispersión de sus medias, sin que la especificación requiera un término de error aditivo externo como el de una formulación autorregresiva lineal. Como los pesos varían con $\mathbf{z}_t$, la densidad condicional puede alterar su número de modos, su asimetría y su dispersión al desplazarse el estado del proceso, sin que ninguno de esos rasgos deba fijarse de antemano. El mecanismo de selección de variables de la ecuación (3.9) determina además, mediante las probabilidades posteriores de inclusión, cuáles de los p rezagos resultan relevantes para cada componente, lo que permite identificar qué modos de variación anteceden a cuáles.

3.4.1. Esquema de inferencia

La implementación opera directamente sobre los scores tal como los entrega la descomposición, sin transformarlos. La grilla de referencia $\{\Gamma^*_{jl}\}$ de la Sección 3.3.2 se construye por predictor, sobre el rango que cada uno toma en el bloque de entrenamiento ampliado en los extremos, de modo que no presupone una escala común. El prior sobre los coeficientes de decaimiento ρ_{hj} y el prior sobre la precisión de los átomos sí dependen de la escala, ya que $\mathrm{Var}(\xi_{tm}) = \lambda_m$ decrece con el orden de la componente. Esa dependencia no se elimina reescalando los datos, sino expresando los hiperparámetros de escala relativos a la dispersión de cada serie, si s_m es la desviación estándar de ξ_{tm} en el bloque de entrenamiento y s_j la del predictor j, el hiperparámetro de escala del prior de los átomos se fija proporcional a s_m^2 y el de los coeficientes de decaimiento proporcional a s_j^2, con las constantes de proporcionalidad de Chung y Dunson (2009). Así el prior conserva el significado que esa calibración le asigna sobre variables de escala unitaria, sin modificar los datos. Las desviaciones s_m y s_j se calculan únicamente con el bloque de entrenamiento, de modo que la evaluación fuera de muestra no incorpora información del período evaluado.

Por lo tanto el modelo se ajusta sobre ξ_{tm} y sobre el predictor $\mathbf{z}_t = (\boldsymbol{\xi}_{t-1}^\top, \ldots, \boldsymbol{\xi}_{t-q}^\top)^\top$, común a las M mezclas, según ilustra la Figura 3.1. La curva se reconstruye directamente a partir de los scores.

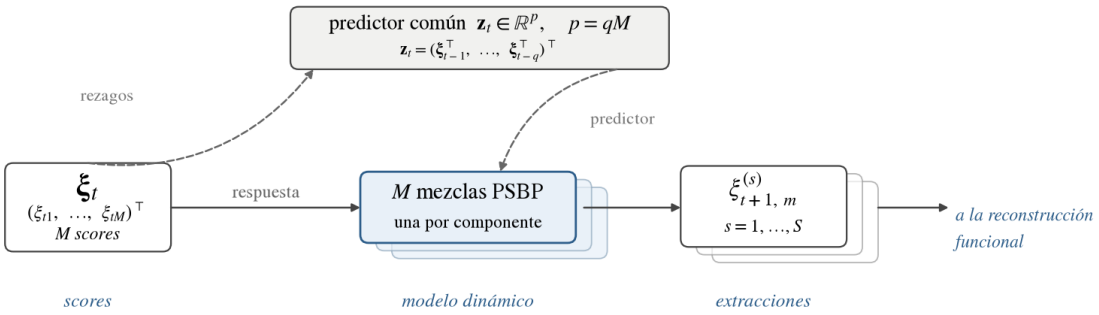


Figura 3.1: Esquema de inferencia del PSBPM-FD. Cada mezcla toma como respuesta el score ξ_{tm} de su componente y como predictor el vector común $\mathbf{z}_t$, de modo que el rezago de cualquier componente puede influir sobre la ley de cualquier otra. Su salida son S extracciones de la predictiva a posteriori.

Sobre estos datos se aplica sin modificación el muestreador de Gibbs descrito en la Sección 3.3.2, sustituyendo y_i por ξ_{tm} y x_i por $\mathbf{z}_t$, sobre los $T_0 - q$ pares disponibles en un bloque de entrenamiento de longitud T_0. La factorización (3.24) descompone la verosimilitud en el producto de las M verosimilitudes individuales, de manera que los muestreadores son mutuamente independientes.

Cada uno entrega una colección de extracciones $\boldsymbol{\vartheta}_m^{(s)}$, con $s = 1, \ldots, S$, provenientes de la distribución a posteriori $p(\boldsymbol{\vartheta}_m \mid \mathcal{D})$ tras descartar el período de calentamiento, donde $\boldsymbol{\vartheta}_m$ agrupa los parámetros de pesos y átomos de la m-ésima mezcla y $\mathcal{D}$ denota el bloque de entrenamiento. Las extracciones de varias cadenas se agrupan por concatenación. Estas colecciones constituyen la única representación disponible del posterior y son, en consecuencia, el insumo del que se derivan todas las cantidades desconocidas del análisis, que quedan así definidas como funcionales de las extracciones y no como estimaciones puntuales.

La primera de dichas cantidades es la distribución predictiva del score, obtenida marginalizando la incertidumbre sobre los parámetros,

$$f\big(\xi_{tm} \mid \mathbf{z}_t, \mathcal{D}\big) = \int f\big(\xi_{tm} \mid \mathbf{z}_t, \boldsymbol{\vartheta}_m\big) p\big(\boldsymbol{\vartheta}_m \mid \mathcal{D}\big) d\boldsymbol{\vartheta}_m \;\approx\; \frac{1}{S} \sum_{s=1}^{S} f\big(\xi_{tm} \mid \mathbf{z}_t, \boldsymbol{\vartheta}_m^{(s)}\big), \tag{3.28}$$

donde el integrando es la mezcla (3.26) evaluada en cada extracción. La predictiva es una mezcla de mezclas y no la evaluación de (3.26) en una estimación puntual de $\boldsymbol{\vartheta}_m$, distinción que resulta determinante para la incertidumbre reportada.

La aproximación (3.28) entrega la densidad predictiva en forma cerrada sobre una grilla, ademas su versión muestral se obtiene simulando en cada iteración el índice de componente desde la ley de pesos y a continuación la respuesta desde el átomo seleccionado, procedimiento cuya marginal es precisamente (3.28) y que basta ejecutar una vez por iteración.

3.5. Reconstrucción Funcional

El objeto de interés del estudio no es el score sino la curva, de modo que la predictiva de $\boldsymbol{\xi}_t$ dado $\mathbf{z}_t$, obtenida en $\mathbb{R}^M$, debe transportarse al espacio funcional. La descomposición que dio origen a los scores provee esa transformacion, ya que la expansión (3.23) es un mapa lineal que asigna a cada vector de $\mathbb{R}^M$ una curva del subespacio generado por las autofunciones retenidas, y basta recorrerla en sentido inverso al empleado para construir la representación. Proyectando el vector de scores sobre dichas autofunciones, la curva queda escrita como

$$X_t^{(M)}(\tau_g) = \mu(\tau_g) + \sum_{m=1}^{M} \xi_{tm}\psi_m(\tau_g), \qquad g = 1, \ldots, G, \tag{3.29}$$

donde $\mu(\tau_g)$ y $\psi_m(\tau_g)$ denotan la función media y las autofunciones evaluadas en la grilla del dominio.

La expresión (3.29) es una identidad entre el vector de scores y la curva que representa, y adquiere carácter predictivo al evaluarla en el vector aleatorio cuya ley es la predictiva del modelo. Sustituyendo en ella $\boldsymbol{\xi}_t \mid \mathbf{z}_t, \mathcal{D}$ se induce la distribución predictiva de $X_t^{(M)}$ dado el estado rezagado, que es el objeto de interés del pronóstico. Como $\mu(\tau_g)$ y $\{\psi_m\}$ se tratan como conocidas, el mapa es determinista y afín, propiedad de la que se sigue que los momentos condicionales de la curva se obtengan en forma cerrada a partir de los momentos condicionales de los scores y que cada extracción predictiva de los scores, transportada por el mapa, sea una extracción exacta de la predictiva funcional condicional.

La predictiva funcional por tanto es una mezcla que hereda de (3.28) tantos modos como regímenes distingan los pesos de mezcla $\pi_h(\mathbf{z}_t)$.

3.5.1. Esperanza predictiva

Aplicando el operador esperanza condicional a (3.29), y observando que $\mu(\tau_g)$ y $\psi_m(\tau_g)$ son constantes que salen del operador, su linealidad entrega

$$\mathbb{E}\big[X_t^{(M)}(\tau_g) \mid \mathbf{z}_t, \mathcal{D}\big] = \mu(\tau_g) + \sum_{m=1}^{M} \mathbb{E}\big[\xi_{tm} \mid \mathbf{z}_t, \mathcal{D}\big]\psi_m(\tau_g). \tag{3.30}$$

La esperanza predictiva de la curva queda determinada por las M esperanzas predictivas de los scores, sin aproximación adicional.

La esperanza de cada score se obtiene de (3.28). Para una extracción $\boldsymbol{\vartheta}_m^{(s)}$, la media de la mezcla es la suma de las medias de sus átomos ponderada por los pesos,

$$m_{ms} = \sum_{h=1}^{N} \pi_{hm}^{(s)}\mu_{hm}^{(s)}, \qquad \pi_{hm}^{(s)} = \pi_{hm}\big(\mathbf{z}_t; \boldsymbol{\vartheta}_m^{(s)}\big), \quad \mu_{hm}^{(s)} = \beta_{0,hm}^{*(s)} + \mathbf{z}_t^{\top}\boldsymbol{\beta}_{hm}^{*(s)}, \tag{3.31}$$

y la esperanza predictiva es el promedio de dichas medias sobre las S extracciones,

$$\widehat{\mathbb{E}}\big[\xi_{tm} \mid \mathbf{z}_t, \mathcal{D}\big] = \frac{1}{S}\sum_{s=1}^{S} m_{ms}. \tag{3.32}$$

El orden de las operaciones no es intercambiable, ya que m_{ms} es un funcional de la mezcla completa e invariante a permutaciones de las etiquetas h, mientras que los parámetros individuales de cada átomo no lo son.

3.5.2. Varianza predictiva

Conviene partir de la desviación respecto de la media, donde la función media se cancela,

$$X_t^{(M)}(\tau_g) - \mathbb{E}\big[X_t^{(M)}(\tau_g)\big] = \sum_{m=1}^{M} \psi_m(\tau_g)\Big(\xi_{tm} - \mathbb{E}\big[\xi_{tm}\big]\Big). \tag{3.33}$$

Elevando al cuadrado se obtiene una suma doble sobre pares de componentes, y al tomar esperanza los términos diagonales entregan varianzas y los restantes covarianzas, cada par de índices distintos contado dos veces,

$$\mathrm{Var}\big[X_t^{(M)}(\tau_g) \mid \mathbf{z}_t, \mathcal{D}\big] = \sum_{m=1}^{M} \psi_m(\tau_g)^2 \mathrm{Var}\big[\xi_{tm}\big] + 2\sum_{m<m'} \psi_m(\tau_g)\psi_{m'}(\tau_g)\mathrm{Cov}\big[\xi_{tm}, \xi_{tm'}\big], \tag{3.34}$$

donde todos los momentos se entienden condicionales a $\mathbf{z}_t$ y $\mathcal{D}$. Aplicando ahora la ley de covarianza total sobre la distribución a posteriori de los parámetros,

$$\mathrm{Cov}\big[\xi_{tm}, \xi_{tm'}\big] = \mathbb{E}_{\boldsymbol{\vartheta}}\Big[\mathrm{Cov}\big(\xi_{tm}, \xi_{tm'} \mid \boldsymbol{\vartheta}\big)\Big] + \mathrm{Cov}_{\boldsymbol{\vartheta}}\Big[\mathbb{E}\big(\xi_{tm} \mid \boldsymbol{\vartheta}_m\big), \mathbb{E}\big(\xi_{tm'} \mid \boldsymbol{\vartheta}_{m'}\big)\Big], \tag{3.35}$$

el término cruzado se anula por dos razones de naturaleza distinta. El primer sumando es nulo por el supuesto de factorización (3.24) y el segundo lo es porque la distribución a posteriori factoriza entre componentes, consecuencia de que la verosimilitud se descomponga en el producto de las verosimilitudes individuales y las distribuciones a priori sean independientes entre mezclas. Solo el primer sumando constituye un supuesto sustantivo; el segundo se deriva de la especificación y justifica formalmente ejecutar los muestreadores por separado.

La varianza predictiva de la curva resulta entonces aditiva sobre las componentes,

$$\mathrm{Var}\big[X_t^{(M)}(\tau_g) \mid \mathbf{z}_t, \mathcal{D}\big] = \sum_{m=1}^{M} \psi_m(\tau_g)^2 \mathrm{Var}\big[\xi_{tm} \mid \mathbf{z}_t, \mathcal{D}\big]. \tag{3.36}$$

El factor $\psi_m(\tau_g)^2$ implica que la incertidumbre no se distribuya de manera uniforme sobre el dominio, sino que se concentre en las regiones donde la autofunción correspondiente presenta mayor amplitud, lo que permite atribuir la amplitud del intervalo en cada zona de la curva a componentes específicas.

Resta la varianza predictiva de cada score, que a su vez se descompone por la ley de varianza total en

$$\mathrm{Var}\big[\xi_{tm} \mid \mathbf{z}_t, \mathcal{D}\big] = \underbrace{\mathbb{E}_{\boldsymbol{\vartheta}_m}\big[\mathrm{Var}\big(\xi_{tm} \mid \mathbf{z}_t, \boldsymbol{\vartheta}_m\big)\big]}_{\text{dispersión de la mezcla}} + \underbrace{\mathrm{Var}_{\boldsymbol{\vartheta}_m}\big[\mathbb{E}\big(\xi_{tm} \mid \mathbf{z}_t, \boldsymbol{\vartheta}_m\big)\big]}_{\text{incertidumbre sobre el centro}}, \tag{3.37}$$

donde el primer término recoge la variabilidad irreducible del proceso y el segundo la incertidumbre a posteriori sobre los parámetros, que se reduce al aumentar la información disponible. Ambos son cantidades agregadas y no componentes separadamente identificables de la mezcla, razón por la cual la descomposición se obtiene por la ley de varianza total y no atribuyendo dispersión a los átomos por un lado y a los pesos por otro. Emplear una estimación puntual de $\boldsymbol{\vartheta}_m$ anula el segundo término por construcción y produce intervalos sistemáticamente demasiado angostos.

Para la estimación se evalúa en cada iteración la varianza de la mezcla en forma cerrada,

$$v_{ms} = \sum_{h=1}^{N} \pi_{hm}^{(s)} \Big[\big(\mu_{hm}^{(s)}\big)^2 + \big(\nu_{hm}^{*(s)}\big)^{-1} \Big] - m_{ms}^2, \tag{3.38}$$

y se agregan ambos términos de (3.37) sobre las S extracciones,

$$\widehat{\mathrm{Var}}\big[\xi_{tm} \mid \mathbf{z}_t, \mathcal{D}\big] = \frac{1}{S}\sum_{s=1}^{S} v_{ms} + \frac{1}{S-1}\sum_{s=1}^{S} \big(m_{ms} - \bar{m}_m\big)^2, \tag{3.39}$$

donde el primer sumando es un promedio de varianzas y el segundo la varianza de las medias, en correspondencia con los dos términos de la descomposición. La varianza funcional se obtiene finalmente sustituyendo (3.39) en (3.36), operación que solo recombina M escalares por punto de la grilla.

La varianza así definida existe solo si el segundo momento de cada átomo es finito a posteriori, lo que exige que el hiperparámetro de forma de la distribución a priori de las precisiones supere la unidad.

3.5.3. Extracciones de la predictiva funcional

Los momentos no determinan la predictiva, ya que una mezcla no queda caracterizada por sus dos primeros momentos. Todo resumen que vaya más allá de ellos, sean cuantiles, medianas, regiones de máxima densidad o modos, se construye sobre extracciones de la predictiva.

Para cada extracción s de los parámetros y cada componente m se obtiene una extracción del score en dos pasos: primero el índice del átomo, con los pesos evaluados en $\mathbf{z}_t$, y a continuación la respuesta desde el átomo seleccionado,

$$h_m^{(s)} \sim \text{Categórica}\Big(\pi_{1m}^{(s)}, \ldots, \pi_{Nm}^{(s)}\Big), \qquad \xi_{tm}^{(s)} \sim \mathcal{N}\Big(\mu_{h_m^{(s)} m}^{(s)}, \big(\nu_{h_m^{(s)} m}^{*(s)}\big)^{-1}\Big). \tag{3.40}$$

Las M extracciones de una misma iteración s se apilan en un vector, lo que es legítimo bajo la factorización (3.24), y se transportan a la curva mediante (3.29),

$$\widehat{X}_t^{(s)}(\tau_g) = \mu(\tau_g) + \sum_{m=1}^{M} \xi_{tm}^{(s)} \psi_m(\tau_g), \qquad s = 1, \ldots, S. \tag{3.41}$$

Al ser (3.29) un mapa determinista, las curvas así construidas son extracciones exactas de la predictiva funcional y la muestra $\{\widehat{X}_t^{(s)}\}_{s=1}^{S}$ es la representación de esa ley.

Al muestrear de este modo, cada extracción elige primero un átomo y luego extrae de él, de manera que la muestra mezcla las extracciones de todos los átomos con peso en $\mathbf{z}_t$ sin registrar de cuál proviene cada una. Si dos o más átomos reciben peso apreciable y sus medias condicionales están separadas, la muestra resulta multimodal y por tanto las extracciones se agrupan en torno a la media de cada átomo. Esa multimodalidad es una propiedad de la mezcla en $\mathbf{z}_t$, no del muestreo, y existiría aunque los parámetros fuesen conocidos.

3.5.4. Predictores puntuales de la curva

La esperanza de la Sección 3.5.1 es el predictor puntual óptimo bajo pérdida cuadrática cualquiera sea la forma de la predictiva, y describe bien lo que el modelo espera cuando esta es unimodal y simétrica, por ejemplo cuando los pesos $\pi_{hm}(\mathbf{z}_t)$ concentran la masa en un solo átomo. Cuando la predictiva resulta multimodal o asimétrica, lo que suele indicar que el estado rezagado $\mathbf{z}_t$ no separa por completo los regímenes de la mezcla, la esperanza pasa a ser un promedio de comportamientos posibles que no coincide con ninguno de ellos. Por eso se presentan dos predictores menos sensibles a esos efectos, calculados sobre las extracciones de la Sección 3.5.3.

3.5.4.1. Mediana puntual

Denotando por $\widehat{F}_{t,g}$ la función de distribución empírica de la muestra en el punto τ_g,

$$\widehat{F}_{t,g}(u) = \frac{1}{S}\sum_{s=1}^{S} \mathbf{1}\big\{\widehat{X}_t^{(s)}(\tau_g) \le u\big\}, \tag{3.42}$$

la mediana puntual es la curva $\tau_g \mapsto \widehat{F}_{t,g}^{-1}(1/2)$. Como el error absoluto funcional es una integral de errores absolutos en cada punto, la mediana puntual lo minimiza punto a punto y es el predictor consistente con esa métrica. Su limitación es que no es necesariamente una curva que el modelo genere, ya que en cada punto del dominio toma la mediana de las extracciones, y si en una parte del dominio domina un grupo de extracciones y en otra parte domina otro, el resultado junta tramos de curvas distintas. El control empírico es la distancia L^1 entre la mediana puntual y la extracción más cercana, que debe ser comparable a la distancia típica entre extracciones.

3.5.4.2. Átomo más probable

En cada iteración s y componente m se toma el átomo de mayor peso en $\mathbf{z}_t$ y su media condicional,

$$h_m^{\star(s)} = \operatorname*{argmax}_h \pi_{hm}^{(s)}, \qquad \xi_{tm}^{\mathrm{mod}} = \mathrm{mediana}_s\, \mu_{h_m^{\star(s)} m}^{(s)}, \tag{3.43}$$

y la curva modal se obtiene transportando el vector $\boldsymbol{\xi}_t^{\mathrm{mod}}$ por (3.29). Se trata del predictor óptimo bajo pérdida cero-uno sobre la asignación de régimen de cada componente, y su cálculo es exacto, ya que la ley conjunta de los M scores es una mezcla sobre configuraciones $(h_1, \ldots, h_M)$ con pesos $\prod_m \pi_{h_m m}^{(s)}$, de modo que, al maximizarse un producto de factores independientes factor a factor, la configuración más probable es la que toma el átomo más probable de cada componente. La agregación sobre s se realiza

mediante la mediana y no mediante el promedio, con el fin de evitar que las iteraciones en que los pesos $\pi_{hm}^{(s)}$ se reparten casi por igual entre dos átomos desplacen el predictor hacia la región entre ambos. Este predictor responde a cómo sería la curva si se realizara el régimen más probable y acompaña de modo natural a la probabilidad de ese régimen.

Los tres predictores coinciden aproximadamente cuando la predictiva es unimodal y simétrica, y se separan en la medida en que no lo es.

3.5.5. Intervalos de credibilidad predictivos

Los intervalos se construyen a partir de los cuantiles empíricos de las extracciones y no como intervalos simétricos en torno a la esperanza, que impondrían por construcción la simetría y unimodalidad que el modelo existe para no suponer.

3.5.5.1. Intervalo puntual equi-colas

Con la distribución empírica (3.42), el intervalo de credibilidad de nivel $1-\zeta$ en cada punto del dominio es

$$\Big[\widehat{F}_{t,g}^{-1}(\zeta/2),\ \widehat{F}_{t,g}^{-1}(1-\zeta/2)\Big], \qquad g=1,\dots,G. \tag{3.44}$$

El intervalo así construido es puntual y no simultáneo.

3.5.5.2. Banda simultánea

Cuando el objeto de interés es la curva completa, la banda debe calibrarse para que contenga la curva entera con probabilidad $1-\zeta$. Con un centro $\widehat{c}_t(\tau_g)$ y una escala $\widehat{s}_t(\tau_g)$ obtenidos de la muestra, se define la desviación máxima normalizada de cada extracción,

$$D^{(s)} = \max_{g}\ \frac{\big|\widehat{X}_t^{(s)}(\tau_g)-\widehat{c}_t(\tau_g)\big|}{\widehat{s}_t(\tau_g)}, \tag{3.45}$$

y la banda $\widehat{c}_t(\tau_g)\pm q_{1-\zeta}(D)\widehat{s}_t(\tau_g)$, con $q_{1-\zeta}(D)$ el cuantil empírico de $\{D^{(s)}\}$, contiene por construcción a una fracción $1-\zeta$ de las extracciones en toda su extensión. Es la banda de tipo supremo de Degras (2011) evaluada sobre la predictiva. Este intervalo contiene una limitación cuando la predictiva es multimodal, porque al ser regiones conexas, cubren también el valle entre los cumbres.

3.5.5.3. Región de máxima densidad

La región de máxima densidad de nivel $1-\zeta$ (Hyndman, 1996) es el conjunto de menor medida que acumula probabilidad $1-\zeta$,

$$R_{1-\zeta} = \big\{u : f(u) \geq f_\zeta\big\}, \qquad \Pr\big(U \in R_{1-\zeta}\big) = 1-\zeta, \tag{3.46}$$

con f la densidad predictiva. Con una predictiva unimodal coincide con el intervalo equi-colas, mientras que con dos modos es la unión de dos intervalos, uno por modo, cuya longitud total es menor que la del intervalo central al mismo nivel porque excluye

el valle. Es la contraparte, para intervalos, de la observación de la Sección 3.5.4 sobre la esperanza.

En el caso funcional la región se construye punto a punto sobre el dominio, del mismo modo que el intervalo (3.44). En cada τ_g se estima la densidad de la muestra $\{\widehat{X}_t^{(s)}(\tau_g)\}_{s=1}^{S}$ y se toma el conjunto (3.46), que en los puntos donde la predictiva es unimodal se reduce al intervalo equi-colas y en los puntos donde es multimodal se descompone en tantos tramos como modos.

El puntaje de Winkler se extiende a una región de este tipo sumando las longitudes de sus tramos y penalizando por la distancia de la observación al tramo más cercano, y del mismo modo el MPIW suma las longitudes de los tramos y el PICP cuenta si la observación cae en alguno de ellos, de manera que las tres construcciones se comparan con las métricas de la Sección 3.7. Cabe tener presente que el funcional que el puntaje de Winkler elicita es el intervalo central, de modo que la región de máxima densidad no tiene por qué mejorarlo aun cuando sea más angosta.

3.6. Comportamientos predictivos

Cada vez que se predice la curva de un origen t, la Sección 3.5.3 produce S extracciones del vector de scores $\boldsymbol{\xi}_t^{(s)}$ a partir del estado rezagado $\mathbf{z}_t$, las mismas con las que se construyen la banda y los predictores puntuales. El análisis de esta sección se aplica a esa muestra, origen por origen, y forma parte de la predicción de cada curva y no de un análisis posterior sobre el conjunto de los datos. Su objeto es que la predictiva conjunta del vector de scores es, en cada iteración, una mezcla sobre configuraciones de átomos $(h_1, \ldots, h_M)$ con pesos $\prod_m \pi_{h_m m}^{(s)}$, y sus modos son los comportamientos que el modelo considera posibles para la curva siguiente. Describir la predictiva de cada origen por esos comportamientos, con la probabilidad de cada uno, su curva típica y su dispersión condicional, es la lectura natural de un modelo de mezcla y una que los modelos de referencia, de ley unimodal, no pueden ofrecer.

Los comportamientos no pueden leerse de los parámetros, ya que los átomos de componentes distintas no se corresponden entre sí, un mismo régimen puede repartirse en varios átomos equivalentes y el peso de una configuración completa, al ser un producto de M pesos, no se interpreta como la probabilidad de un comportamiento. Lo único que vincula a las M mezclas es $\mathbf{z}_t$, de modo que los comportamientos se identifican sobre las extracciones, que son extracciones de la predictiva conjunta en ese $\mathbf{z}_t$.

3.6.1. Agrupamiento de las extracciones

Como las autofunciones son ortonormales en L^2, la distancia euclídea entre dos vectores de scores coincide con la distancia L^2 entre las curvas que representan, de modo que basta agrupar las extracciones en $\mathbb{R}^M$ con los scores. Para cada origen t se agrupan las S extracciones $\{\boldsymbol{\xi}_t^{(s)}\}$ mediante k-medias, esto es, se busca la partición en K grupos

$C_1, \ldots, C_K$ que minimiza la suma de cuadrados dentro de los grupos,

$$\min_{C_1,\ldots,C_K} \sum_{c=1}^{K} \sum_{s \in C_c} \left\| \boldsymbol{\xi}_t^{(s)} - \mathbf{c}_{t,c} \right\|^2, \qquad \mathbf{c}_{t,c} = \frac{1}{|C_c|} \sum_{s \in C_c} \boldsymbol{\xi}_t^{(s)}, \tag{3.47}$$

resuelta alternando la asignación de cada extracción al centroide más cercano con el recálculo de los centroides como medias de sus grupos, desde varios inicios aleatorios.

La fracción de varianza explicada por la partición, $R^2_K = 1 - W_K/W_1$ con W_K el mínimo de (3.47), crece con K aunque no exista estructura, de manera que el número de comportamientos no puede fijarse por un umbral sobre ella y se decide con las tres reglas de la Sección 3.6.2. Cuando la distribución a priori de las precisiones admite átomos de varianza no acotada, las extracciones se recortan a los cuantiles extremos de cada score antes del agrupamiento.

3.6.2. Número de comportamientos

La primera regla decide si existe más de un comportamiento. Con $K = 2$, las extracciones se proyectan sobre el eje que une los dos centroides, $u = (\mathbf{c}_{t,2} - \mathbf{c}_{t,1})/\|\mathbf{c}_{t,2} - \mathbf{c}_{t,1}\|$, y sobre la proyección se estima por núcleo la densidad $\widehat{f}$. Se declara que hay dos modos si la densidad entre los centroides desciende por debajo de la mitad de la menor de las densidades evaluadas en ellos,

$$\frac{\min_{a \le v \le b} \widehat{f}(v)}{\min\{\widehat{f}(a), \widehat{f}(b)\}} < \tfrac{1}{2}, \qquad a = \mathbf{c}_{t,1}^{\top} u, \quad b = \mathbf{c}_{t,2}^{\top} u, \tag{3.48}$$

y en caso contrario se declara un único comportamiento. Esta regla es una versión operativa del contraste de unimodalidad de J. A. Hartigan y P. M. Hartigan (1985), y es la que distingue una predictiva con dos modos de una unimodal alargada o asimétrica, que k-medias también parte en dos pero sin que la densidad presente un valle.

La segunda regla acota el número de comportamientos. A partir de $K = 2$ se acepta la partición en $K + 1$ grupos solo si el grupo adicional explica al menos tanto como explica en promedio cada uno de los existentes,

$$R^2_{K+1} \;\ge\; R^2_K + \frac{R^2_K}{K}, \tag{3.49}$$

condición equivalente a que la varianza explicada por comportamiento no disminuya, y el barrido se detiene en el primer K que la incumple.

La tercera regla exige que cada comportamiento reúna una masa de al menos ζ, el nivel de la banda de credibilidad, de manera que un comportamiento sea un grupo de extracciones que la banda al nivel $1-\zeta$ tendría que cubrir; un grupo de masa menor es una cola y no un comportamiento, y la partición que lo produce se descarta. Las tres reglas dependen de dos constantes, el cociente de valle y ζ.

3.6.3. Comportamientos como opciones de estimación

El resultado por origen es un conjunto de K_t comportamientos. Cada uno tiene probabilidad $p_{t,c} = |C_c|/S$, igual a la fracción de extracciones del grupo, curva típica $\widehat{X}_{t,c}$ igual al centroide $\mathbf{c}_{t,c}$ transportado por (3.29), que por linealidad del mapa es la esperanza predictiva condicional a ese comportamiento, e intervalo condicional dado por los cuantiles equi-colas (3.44) calculados solo sobre las extracciones del grupo. La mezcla de las curvas típicas ponderada por sus probabilidades es la media de las extracciones recortadas, que aproxima a la esperanza predictiva de la Sección 3.5.1,

$$\widehat{\mathbb{E}}\big[X_t^{(M)}(\tau_g) \mid \mathbf{z}_t, \mathcal{D}\big] \approx \sum_{c=1}^{K_t} p_{t,c}\widehat{X}_{t,c}(\tau_g), \tag{3.50}$$

relación que muestra por qué, con más de un comportamiento, la esperanza se sitúa entre ellos. El contraste entre dos comportamientos es la diferencia de sus curvas típicas, $\Delta_{t,ab}(\tau_g) = \widehat{X}_{t,a}(\tau_g) - \widehat{X}_{t,b}(\tau_g)$, que localiza en qué parte del dominio difieren y en cuánto.

Los comportamientos permiten un predictor puntual distinto de los de la Sección 3.5.4. Aquellos resumen la predictiva completa, y por (3.50) la esperanza queda entre los comportamientos cuando hay más de uno, mientras que la mediana puntual elige entre modos de forma indirecta y el átomo más probable lo hace componente a componente en el espacio de los scores. El pronóstico por comportamiento elige de forma explícita un modo de la predictiva conjunta, ya que se toma se toma el comportamiento de mayor probabilidad y se predice con su curva típica,

$$\widehat{X}_t^{\mathrm{mp}}(\tau_g) = \widehat{X}_{t,c_t^*}(\tau_g), \qquad c_t^* = \arg\max_{c=1,\dots,K_t} p_{t,c}. \tag{3.51}$$

Con $K_t = 1$ se toma la esperanza predictiva de la Sección 3.5.1, de modo que el predictor solo se aparta de ella en los orígenes en que la predictiva tiene más de un modo, y ahí lo hace comprometiéndose con uno de ellos en lugar de promediarlos. La curva típica puede reemplazarse por la mediana puntual calculada solo sobre las extracciones del comportamiento elegido (y, con $K_t = 1$, por la marginal), que es la variante del mismo predictor para una condicional asimétrica.

3.7. Diseño del Estudio de Simulación

El estudio aborda tres preguntas de evaluación para cada uno de los tres escenarios: ¿en cuáles la predicción puntual del PSBPM-FD supera a la de los modelos de referencia?, ¿en cuáles sus intervalos de credibilidad ofrecen un mejor desempeño? y ¿en qué medida su distribución predictiva reproduce los comportamientos característicos de cada escenario y permite generar pronósticos a partir de ellos? La evaluación se realiza mediante las métricas definidas en la Sección 2.2.3.

En los tres escenarios el procedimiento es el mismo, las curvas se generan con el esquema común del Anexo A.1 y se parten en orden cronológico en un bloque de entrenamiento (70 %) y uno de prueba. Las predicciones a un paso sobre el segundo usan los rezagos observados, sin reestimar.

Las métricas de la Sección 2.2.3 se calculan sobre la ventana móvil de ancho $w_{\text{ref}} = 30$, contra la curva ajustada por la representación (Sección 3.5), para cada M del barrido. El PSBPM-FD se ajusta con los hiperparámetros de Chung y Dunson (2009) llevados a la escala de cada score y, como $a_\nu = 0{,}5$, todo lo que se reporta se deriva de las S extracciones de la predictiva.

Las referencias son el FAR, con orden fijo igual al número de rezagos del escenario e intervalo gaussiano, y el Random Forest con la misma especificación que el PSBPM-FD. Se reportan el MAE y el RMSE de los tres predictores puntuales, del pronóstico por comportamiento (Sección 3.6.3) y de su cota, el mejor comportamiento, que usa la curva observada, cada uno contra el FAR y el Random Forest; y el Winkler, el MPIW y el PICP de las tres construcciones de intervalo contra el FAR.

Los comportamientos se resumen por la distribución de K_t en el bloque de prueba y, origen a origen, en una ventana de detalle de $N_{\text{det}} = 10$ orígenes elegida con lo que el generador registra y nunca con lo predicho. Hay una realización por escenario, de modo que las cifras son descriptivas. La configuración completa está en el Anexo A.3 y las métricas restantes y los otros anchos de ventana, en el Anexo B.

3.7.1. Escenarios

Cada escenario introduce un rasgo de la ley condicional del score que un modelo de media lineal no representa; los algoritmos y sus valores están en el Anexo A. En los tres la dinámica vive en los $J_a = 4$ primeros scores y los restantes son autorregresivos de primer orden, de modo que $M = 4$ es la primera dimensión que observa toda la dinámica.

El régimen o mecanismo que sortea el generador se registra pero no se entrega a ningún método. El Cuadro 3.1 resume la configuración de cada escenario.

Cuadro 3.1: Escenarios del estudio y configuración de los métodos en cada uno.

	Rasgo	Algoritmo	p	Covariables	M
C-1	heterocedasticidad condicional	Anexo A.2.1	4	rezagos propios	$1, \ldots, 10$
C-2	cambio de régimen por umbral	Anexo A.2.2	4	rezagos propios	$1, \ldots, 10$
C-3	multimodalidad en la ley condicional	Anexo A.2.3	2	rezagos de todas las componentes	$3, \ldots, 6$

- **C-1.** Los scores activos son autorregresivos con innovaciones GARCH$(1, 1)$. La media condicional es lineal y la no linealidad está únicamente en la varianza, con una memoria de unas siete curvas. Como la señal de volatilidad depende de los dos rezagos propios más próximos, el modelo puede aprenderla, por lo que la ventaja esperable del PSBPM-FD está en los intervalos de credibilidad y no en la predicción puntual.
- **C-2.** Cada score activo alterna, mediante una transición probit dependiente de su

propio rezago, entre un régimen persistente de escala pequeña y otro más volátil y con reversión. La media condicional es no lineal y la varianza depende del estado. La calibración favorece deliberadamente la separación entre regímenes, por lo que las conclusiones se limitan a esta configuración.

- **C-3.** Un softmax sobre los dos rezagos de los dos primeros scores selecciona entre tres mecanismos lineales, uno central y dos con niveles distintos, cuyas localizaciones difieren en más que la escala de la innovación. Esto genera una distribución condicional multimodal, aunque la media condicional sea casi lineal. Como el mecanismo depende de los rezagos de ξ_1 y ξ_2, las covariables incluyen los rezagos de todas las componentes y el muestreador se ejecuta para cada valor de M.

3.8. Resultados

Los resultados se presentan en el orden del diseño: el error puntual, los intervalos, los comportamientos y el pronóstico por comportamiento. En cada bloque hay un cuadro en M_{ref} y w_{ref} del Cuadro A.7 sobre el bloque de prueba, un cuadro con la misma cifra para todos los M del barrido, y las figuras con la trayectoria sobre la ventana móvil del bloque de prueba; $M_{\text{ref}} = 10$ en C-1 y C-2 y $M_{\text{ref}} = 6$ en C-3. Hay una realización por escenario, de modo que las cifras son descriptivas y una diferencia de pocos puntos porcentuales no se lee como superioridad.

3.8.1. Error puntual

Cuadro 3.2: Bloque A en el bloque de prueba (w_{ref}): MAE promedio sobre las ventanas, contra la curva ajustada, de los tres predictores del PSBPM-FD y del Random Forest para cada M, por escenario; la última fila es el FAR, que usa los coeficientes completos y no depende de M. En negrita el menor de cada escenario en M_{ref}. El RMSE está en el Anexo B.1.

	C-1				C-2				C-3			
M	esp.	med.	modal	RF	esp.	med.	modal	RF	esp.	med.	modal	RF
1	0.754	0.755	0.755	0.764	0.714	0.720	0.725	0.710	—	—	—	—
2	0.739	0.739	0.739	0.753	0.673	0.675	0.691	0.658	—	—	—	—
3	0.724	0.724	0.726	0.740	0.635	0.633	0.653	0.617	0.694	0.695	0.703	0.699
4	0.717	0.717	0.722	0.734	0.612	0.605	0.635	0.591	0.690	0.691	0.700	0.699
5	0.714	0.714	0.719	0.733	0.610	0.603	0.633	0.591	0.684	0.686	0.693	0.693
6	0.713	0.713	0.718	0.733	0.609	0.602	0.632	0.592	**0.689**	0.689	0.698	0.700
7	0.712	0.713	0.718	0.733	0.609	0.601	0.631	0.592	—	—	—	—
8	0.712	0.712	0.717	0.733	0.609	0.601	0.631	0.592	—	—	—	—
9	0.711	0.712	0.717	0.734	0.609	0.601	0.631	0.591	—	—	—	—
10	**0.711**	0.712	0.717	0.734	0.609	0.601	0.631	**0.591**	—	—	—	—
FAR	0.723				0.770				0.700			

En M_{ref}, el mejor predictor del PSBPM-FD bajo MAE en C-2 es la mediana puntual, con un 1,3 % menos que la esperanza, mientras que bajo RMSE la esperanza es la mejor en los tres escenarios (Anexo B.1), como corresponde al funcional que cada métrica elicita.

El átomo más probable es el peor en los tres (+3,6 % de MAE respecto de la esperanza en C-2, +0,7 % en C-1 y +1,4 % en C-3): una sola extracción arrastra el ruido de los scores pasivos. En C-1 y C-3 la esperanza y la mediana quedan a menos de 0,1 % entre sí: la predictiva es unimodal y simétrica y la elección del predictor no cambia la lectura. En C-2 la diferencia entre ambas aparece desde $M = 3$, cuando el modelo ya observa los scores que cambian de régimen.

Frente a los modelos de referencia, el PSBPM-FD con su mejor predictor supera al FAR en MAE en C-2 (22 % menos; el FAR no gana ninguna de las 271 ventanas de prueba), en C-1 (1,7 % menos; el FAR es el mejor en 11 % de las ventanas y alguno de los predictores del PSBPM-FD en 83 %) y en C-3 (1,5 % menos; el FAR gana 13 % de las ventanas y la esperanza 28 %). En C-1 la media condicional es lineal y en C-3 es casi lineal, de modo que la ganancia sobre el FAR es la que cabía esperar: pequeña y sostenida. El Random Forest, que comparte la especificación del PSBPM-FD, es el mejor modelo en C-2 (MAE 0,591, 1,5 % bajo la mediana del PSBPM-FD, y gana 64 % de las ventanas), y el peor en C-1 (3 % sobre la esperanza) y queda a la par del FAR en C-3. La diferencia entre ambos aísla el mecanismo que liga covariables y respuesta: ante un umbral sobre el rezago propio, los cortes del árbol lo reproducen de forma directa, mientras que la mezcla lo aproxima con átomos cuyo peso varía de forma suave con la covariable; ante una media lineal con ruido heterocedástico el árbol sobreajusta y la mezcla no.

El error del PSBPM-FD baja con M y se estabiliza desde $M = 4$, que es la primera dimensión que observa toda la dinámica activa: en C-2 pasa de 0,714 con $M = 1$ a 0,612 con $M = 4$ y luego se mueve en la tercera cifra. Supera al FAR desde $M = 1$ en C-2, desde $M = 4$ en C-1 (con $M = 3$ empatan en 0,724 contra 0,723) y en todo el barrido de C-3, donde el mínimo está en $M = 5$ y $M = 6$ agrega un score pasivo que sólo suma ruido. Con $M \leq 2$ en C-1 el truncamiento domina y el FAR, que usa los coeficientes completos, gana.

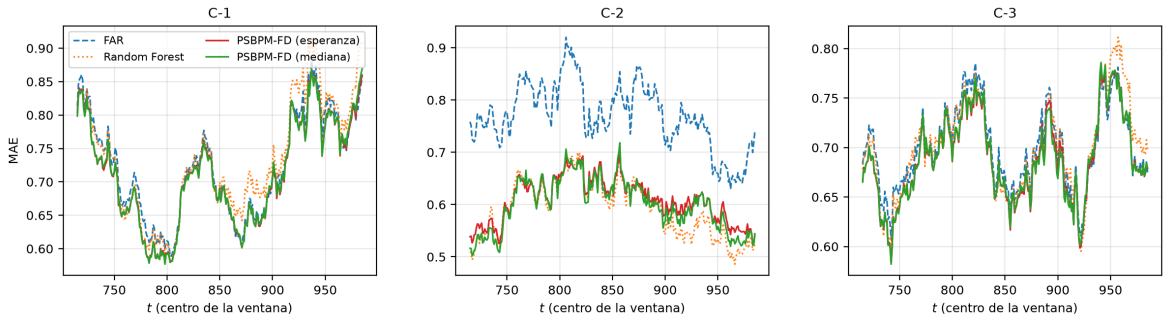


Figura 3.2: MAE sobre la ventana móvil del bloque de prueba (w_{ref}, M_{ref}) de la esperanza y la mediana puntual del PSBPM-FD, el FAR y el Random Forest; un panel por escenario.

La Figura 3.2 muestra que en C-2 la ventaja del PSBPM-FD sobre el FAR es uniforme a lo largo del bloque de prueba, con una brecha de entre 0,15 y 0,25 en todas las ventanas, y que el PSBPM-FD y el Random Forest se superponen salvo en el tramo final ($t > 900$), donde el bosque queda por debajo. En C-1 los cuatro modelos siguen la misma trayectoria, gobernada por los episodios de volatilidad del generador: el PSBPM-FD queda apenas bajo el FAR en los tramos tranquilos (t entre 750 y 800 y alrededor

de 900) y el Random Forest por encima de todos en el tramo final. En C-3 las curvas se superponen y el FAR sólo se despega hacia arriba en los máximos locales del error.

3.8.2. Intervalos de predicción

Cuadro 3.3: Bloque B en el bloque de prueba, M_{ref} y w_{ref}: Winkler, MPIW, PICP y PICPB de cada banda contra la curva ajustada, y fracción de ventanas en que la construcción tiene menor Winkler que el FAR.

Escenario	Banda	Winkler	MPIW	PICP	PICPB	gana al FAR
C-1	FAR, gaussiano	4.35	3.42	0.940	0.62	—
	PSBPM-FD, equi-colas	4.23	3.49	0.947	0.65	81 %
	PSBPM-FD, simultánea	5.33	5.26	0.995	0.97	5 %
	PSBPM-FD, máxima densidad	4.23	3.49	0.948	0.66	88 %
C-2	FAR, gaussiano	4.86	3.98	0.952	0.70	—
	PSBPM-FD, equi-colas	3.91	3.58	0.969	0.69	100 %
	PSBPM-FD, simultánea	6.36	6.35	0.999	0.99	0 %
	PSBPM-FD, máxima densidad	3.79	3.49	0.975	0.77	100 %
C-3	FAR, gaussiano	4.23	3.28	0.937	0.56	—
	PSBPM-FD, equi-colas	4.11	3.33	0.944	0.58	81 %
	PSBPM-FD, simultánea	4.99	4.93	0.995	0.93	1 %
	PSBPM-FD, máxima densidad	4.11	3.33	0.945	0.59	73 %

El intervalo equi-colas del PSBPM-FD tiene menor Winkler que el del FAR en los tres escenarios. En C-2 la diferencia es grande (3,91 contra 4,86, un 20 % menos; gana el 100 % de las ventanas) y viene de las dos componentes a la vez: la banda es más angosta (MPIW 3,58 contra 3,98) y cubre más (PICP 0,969 contra 0,952), porque su ancho sigue el régimen en que está cada score mientras que el del FAR es el mismo en todos los orígenes. En C-1 y C-3 la diferencia es pequeña (2,7 % y 3,0 % menos; gana el 81 % de las ventanas en ambos) y tiene otra composición: la banda del PSBPM-FD es apenas más ancha (+2 % y +1 % de MPIW) y su PICP está más cerca del nominal (0,947 y 0,944 contra 0,940 y 0,937), de modo que gana por calibración y no por ancho; en C-1 la banda gaussiana del FAR queda corta donde la varianza condicional sube.

Las tres construcciones salen de las mismas extracciones y difieren en lo que prometen. La región de máxima densidad coincide con la equi-colas cuando la predictiva es unimodal: en C-1 y C-3 tiene un solo tramo en más del 99,9 % de los puntos (t, τ) del bloque de prueba y las dos filas del Cuadro 3.3 son iguales a la segunda cifra. Sólo se separa en C-2, donde se parte en el 9,5 % de los puntos (en el 53 % de los orígenes hay algún τ con más de un tramo) y baja el Winkler en 2,9 % respecto de la equi-colas, ganándole en el 91 % de las ventanas: la masa que la equi-colas gasta en el valle entre modos se reasigna a los modos. La banda simultánea es 1,5 veces más ancha en C-1 y C-3 y 1,8 veces en C-2 y pierde el Winkler, que elicita el intervalo central de cada τ, pero es la única calibrada para la curva completa: su PICPB es 0,97, 0,99 y 0,93 contra 0,65, 0,69 y 0,58 de la equi-colas y 0,62, 0,70 y 0,56 del FAR, y reduce el peor Winkler de la ventana ($W^{\text{glob}}_{\text{máx}}$) a menos de la mitad del de las otras dos construcciones.

Cuadro 3.4: Winkler en el bloque de prueba (w_{ref}) contra M para las tres construcciones del PSBPM-FD, por escenario. La última fila es el FAR, que no depende de M.

	C-1			C-2			C-3		
M	equi-colas	HDR	simult.	equi-colas	HDR	simult.	equi-colas	HDR	simult.
1	9.94	9.93	9.92	11.95	12.09	10.74	—	—	—
2	4.98	4.94	4.44	5.69	5.29	6.54	—	—	—
3	4.49	4.46	4.68	4.61	4.31	7.91	4.31	4.31	4.42
4	4.32	4.30	4.92	3.97	3.75	6.73	4.15	4.16	4.71
5	4.27	4.26	5.11	3.91	3.75	6.57	4.08	4.09	4.89
6	4.24	4.24	5.19	3.90	3.76	6.32	4.11	4.11	4.99
7	4.23	4.23	5.26	3.90	3.77	6.41	—	—	—
8	4.23	4.23	5.30	3.91	3.78	6.36	—	—	—
9	4.23	4.23	5.32	3.91	3.79	6.37	—	—	—
10	4.23	4.23	5.33	3.91	3.79	6.36	—	—	—
FAR		4.35			4.86			4.23	

Las bandas puntuales del PSBPM-FD superan al FAR en Winkler desde $M = 3$ en C-2 (la máxima densidad gana ahí el 84 % de las ventanas y desde $M = 4$ las dos ganan el 100 %) y desde $M = 4$ en C-1 y C-3. Con $M = 1$ el truncamiento deja la banda demasiado angosta (MPIW 1,95 y 1,76 en C-1 y C-2, PICP 0,64 y 0,54) y el Winkler es más del doble del FAR; el PICP de la equi-colas se acerca al nominal desde $M = 4$ (0,93 en C-1 y C-3, 0,94 en C-2) y se estabiliza desde $M = 6$. La banda simultánea es la mejor de las tres sólo con $M = 2$ en C-1 y $M = 1$ en C-2, donde las otras dos quedan cortas; con $M \geq 4$ su Winkler es siempre el mayor. El MPIW y el PICP por M van en el Anexo B.1.

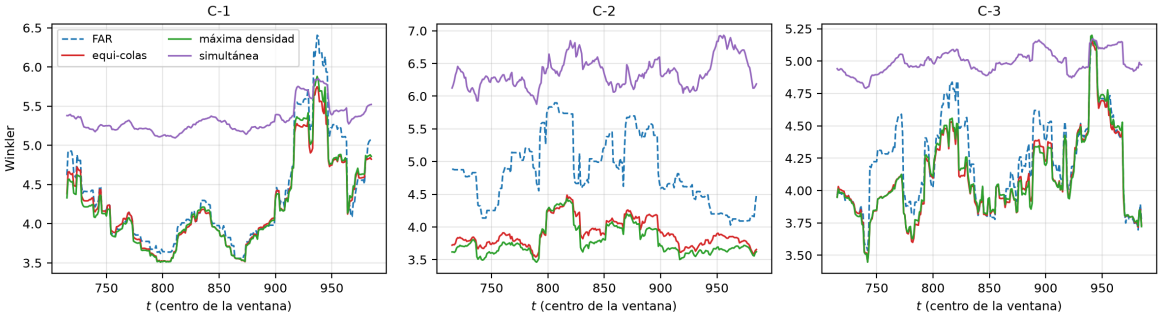


Figura 3.3: Winkler sobre la ventana móvil del bloque de prueba (w_{ref}, M_{ref}) del FAR y de las tres construcciones del PSBPM-FD; un panel por escenario.

El ancho de la banda del FAR es el mismo en todos los orígenes, porque hereda una varianza residual fija, de modo que su Winkler sólo se mueve por la penalización de los puntos no cubiertos: en C-2 oscila entre 4,1 y 5,9 según la ventana contenga o no episodios del régimen volátil, mientras que el del PSBPM-FD se mantiene entre 3,5 y 4,5 y queda debajo en todas las ventanas (Figura 3.3). En C-1 las tres curvas suben juntas en el episodio de volatilidad del tramo final (alrededor de $t = 930$, donde la varianza condicional del generador alcanza su máximo de prueba): ahí la banda del PSBPM-FD se ensancha y acompaña al proceso, y su ventaja sobre el FAR está en los tramos tranquilos, donde la banda gaussiana es más ancha de lo necesario. En C-3 las

curvas se superponen y el FAR se despega hacia arriba en las ventanas de t entre 760 y 830, con los peores errores.

3.8.3. Comportamientos predictivos

Cuadro 3.5: Número de comportamientos en el bloque de prueba. Izquierda: distribución de K_t en M_{ref}. Derecha: fracción de orígenes con $K_t \geq 2$ para cada M.

	$K_t = 1$	$K_t = 2$	$K_t \geq 3$
C-1	99.7 %	0.3 %	0.0 %
C-2	70.0 %	16.7 %	13.3 %
C-3	100.0 %	0.0 %	0.0 %

M	C-1	C-2	C-3
1	0.0 %	31.3 %	—
2	0.3 %	30.0 %	—
3	0.3 %	30.3 %	0.0 %
4	0.3 %	30.7 %	0.0 %
5	0.3 %	30.3 %	0.0 %
6	0.3 %	29.7 %	0.0 %
7	0.3 %	30.3 %	—
8	0.3 %	30.3 %	—
9	0.3 %	30.0 %	—
10	0.3 %	30.0 %	—

El modelo declara más de un comportamiento en el 30 % de los orígenes de prueba de C-2, desde $M = 1$ y sin cambio con M: con $M = 1$ sólo hay $K_t = 2$ y desde $M = 2$ aparece $K_t = 3$, porque los comportamientos los fijan los dos primeros scores, que son los de mayor varianza y los que más cambian de régimen. La ley condicional verdadera de C-2 tiene más de un modo en un 9 % de los orígenes: el modelo declara tres veces más, porque el *gating* deja cerca de un 10 % de masa en un átomo del régimen volátil en orígenes en que la probabilidad verdadera de ese régimen es casi nula. Donde la ley sí es bimodal, el modelo lo detecta. En C-1 hay un único origen con $K_t = 2$ ($t = 933$, el máximo de la varianza condicional en el bloque de prueba, con masas 0,60 y 0,40 para una curva de reversión y una persistente más ancha) y en C-3 ninguno, en ningún M. En C-3 la ley condicional verdadera tiene más de un modo en el 3 % de los orígenes y únicamente en la ley conjunta de los scores: la multimodalidad del escenario no llega a la marginal de cada punto de la curva, y el $K_t = 1$ del modelo es correcto, no una omisión.

Cuadro 3.6: Ventana de detalle de cada escenario ($N_{\text{det}} = 10$ orígenes de prueba, M_{ref}): orígenes de la ventana, orígenes con $K_t \geq 2$ en el modelo y en la ley condicional verdadera, en cuántos la curva observada cae en el comportamiento más probable y en cuántos K_t coincide con el de la ley verdadera. En C-1 el criterio de la ventana es la varianza condicional y no hay régimen que contrastar.

Escenario	orígenes t	$K_t \geq 2$ (modelo)	$K_t \geq 2$ (verdad)	cae en el más probable	K_t coincide
C-1	931–940	1 de 10	—	10 de 10	—
C-2	807–816	6 de 10	2 de 10	7 de 10	6 de 10
C-3	776–785	0 de 10	3 de 10	10 de 10	7 de 10

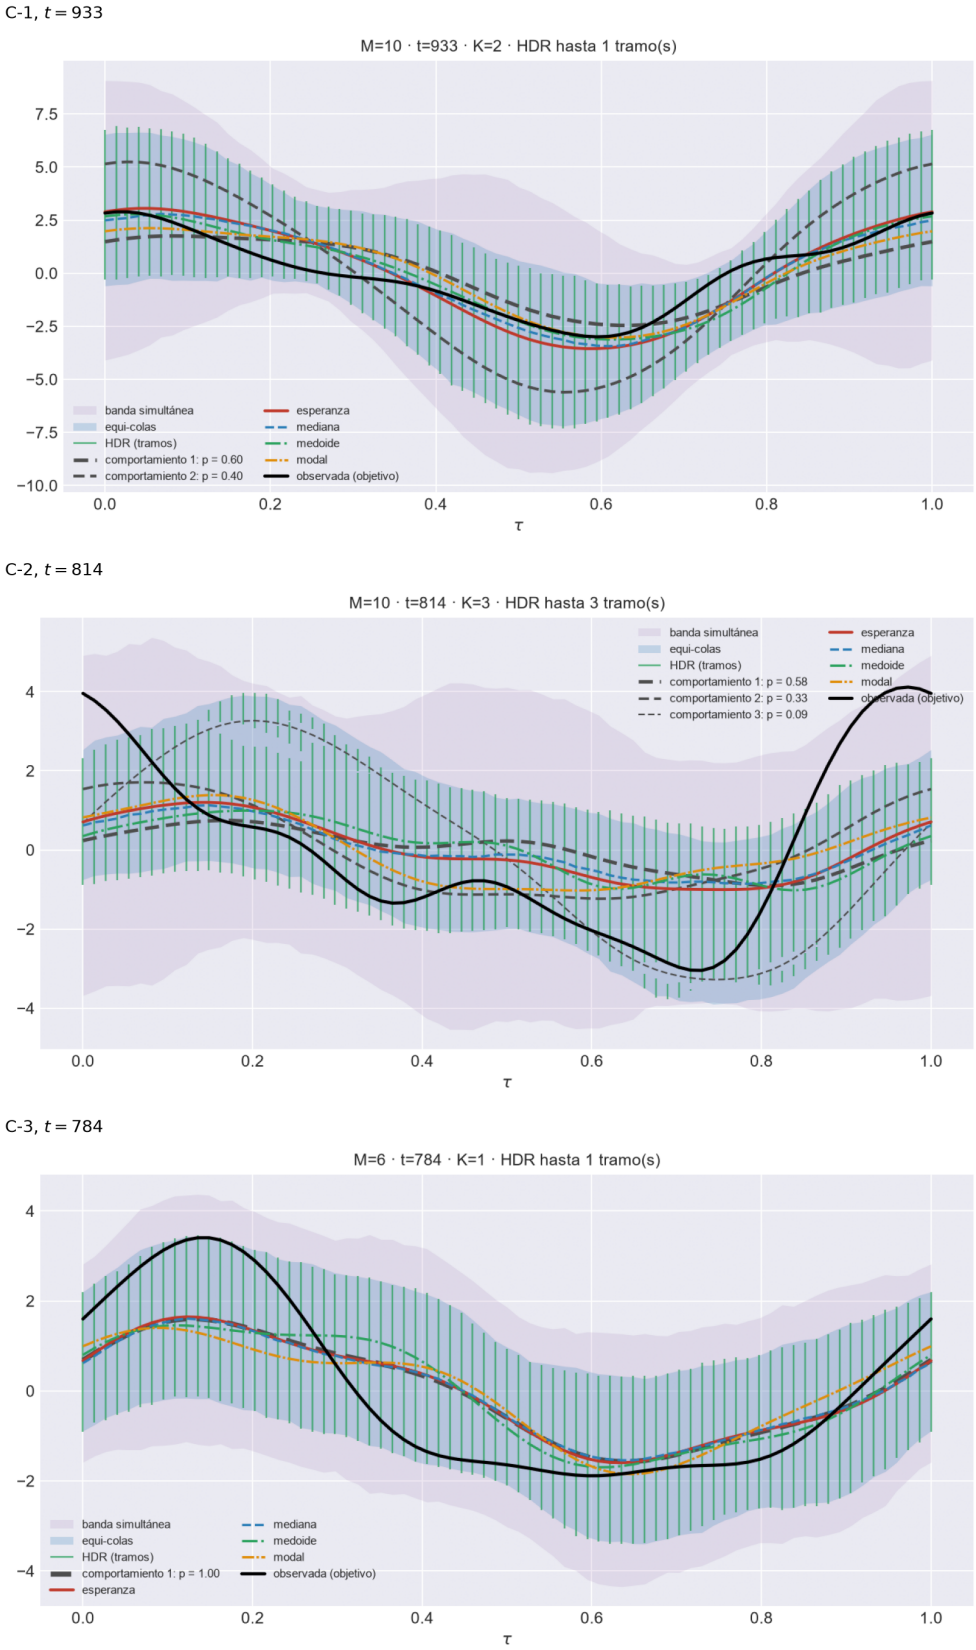


Figura 3.4: Un origen de la ventana de detalle de cada escenario (M_{ref}): curva observada, los cuatro predictores puntuales, las tres bandas (la región de máxima densidad como tramos verticales) y las curvas típicas de los comportamientos con su probabilidad. Arriba C-1, $t = 933$ (máximo de la varianza condicional, $K_t = 2$); al centro C-2, $t = 814$ (tres scores activos en el régimen volátil, $K_t = 3$); abajo C-3, $t = 784$ (origen con más de un modo en la ley conjunta verdadera, $K_t = 1$).

En la ventana de C-2 (orígenes $t = 807$ a 816, la de más cambios de régimen verdadero en los scores activos: 14 en diez pasos) el modelo declara $K_t \geq 2$ en seis orígenes y la ley verdadera en dos; en los tres orígenes con $K_t = 3$ (807, 814 y 816) la región de máxima densidad se parte en hasta tres tramos. En $t = 814$, con tres de los cuatro scores activos en el régimen volátil, la curva observada tiene amplitud cuatro y sale de la equi-colas (cobertura puntual 0,79) pero queda dentro de la simultánea (Figura 3.4); el comportamiento más probable ($p = 0{,}58$) tiene la forma de la curva observada y la esperanza, que promedia los tres, no. Sobre los diez orígenes la simultánea cubre la curva entera en los diez, la equi-colas y la máxima densidad en ocho y el FAR en cuatro, y la banda condicional al comportamiento realizado tiene un MPIW de 3,17 contra 3,99 de la marginal: cuando se conoce el comportamiento, el intervalo se angosta un 21 % sin perder cobertura. En la ventana de C-1 (orígenes 931 a 940, con el máximo de la varianza condicional del generador en $t = 933$, de 2,34 contra una mediana de 0,70 en el bloque de prueba) el ancho de la equi-colas sigue a la varianza verdadera, de 3,8 en $t = 931$ a 5,8 en $t = 933$ y de vuelta a 3,4 al final de la ventana, con una correlación de Spearman de 0,83 entre ambas sobre los diez orígenes; el peor origen es $t = 932$, el anterior al pico, donde la volatilidad todavía no se ha manifestado en los rezagos y la curva sale de todas las bandas (cobertura 0,49 de la equi-colas, 0,40 del FAR, 0,75 de la simultánea). En la ventana de C-3 (orígenes 776 a 785, la de más orígenes con más de un modo en la ley conjunta verdadera: 782, 784 y 785) el modelo da $K_t = 1$ en los diez y su región de máxima densidad no se parte en ningún (t, τ), mientras que la de la ley verdadera lo hace en el 4 % de ellos; la banda unimodal del modelo cubre el 0,956 de la masa verdadera, contra 0,951 de la banda verdadera al mismo nivel, siendo un 10 % más ancha. La ventaja del PSBPM-FD en el Bloque B de C-3 no viene de la multimodalidad, que no alcanza a verse en la marginal, sino de una banda bien calibrada.

3.8.4. Pronóstico por comportamiento

Cuadro 3.7: Pronóstico por comportamiento en el bloque de prueba, M_{ref}: MAE medio por origen del pronóstico (comportamiento más probable), de la cota (mejor comportamiento), de la esperanza, el FAR y el Random Forest; fracción de orígenes en que el pronóstico tiene menor error que el FAR y que el Random Forest; y acierto, la fracción en que el mejor comportamiento es el más probable. Fila "$K_t \geq 2$": solo los orígenes con más de un comportamiento, donde pronóstico y cota se apartan de la esperanza.

				MAE				pronóstico gana a		
Escenario	orígenes	n	pronóstico	cota	esperanza	FAR	RF	FAR	RF	acierto
C-1	todos	300	0.728	0.728	0.727	0.738	0.749	56 %	56 %	100 %
	$K_t \geq 2$	1	0.885	0.885	0.704	0.624	0.746	0 %	0 %	100 %
C-2	todos	300	0.607	0.565	0.602	0.769	0.584	84 %	44 %	93 %
	$K_t \geq 2$	90	0.619	0.478	0.602	0.749	0.559	83 %	44 %	78 %
C-3	todos	300	0.687	0.687	0.687	0.697	0.696	58 %	53 %	100 %
	$K_t \geq 2$	0	—	—	—	—	—	—	—	—

En los 90 orígenes de C-2 con más de un comportamiento, el pronóstico por comportamiento tiene un MAE de 0,619, un 17 % menor que el FAR, al que le gana en el 83 % de esos orígenes, pero un 3 % mayor que la esperanza y un 11 % mayor que el Random

Forest, al que le gana en el 44 %. Comprometerse con el comportamiento más probable no mejora la esperanza en promedio: en el 78 % de los orígenes el elegido es el mejor y el error baja, y en el 22 % restante el error sube más de lo que se ganó. La cota baja a 0,478, un 21 % bajo la esperanza, un 14 % bajo el Random Forest y un 36 % bajo el FAR, y le gana al FAR en el 96 % de esos orígenes y al Random Forest en el 61 %: alguna de las opciones describe la curva observada mejor que cualquier referencia, y la distancia entre cota y pronóstico, 0,14, es lo que se pierde por elegir con la probabilidad. Sobre todo el bloque de prueba la cota es, en C-2, el mejor predictor puntual del estudio (0,565 contra 0,584 del Random Forest). En C-1 el único origen con $K_t \geq 2$ es $t = 933$, donde el comportamiento elegido es el de reversión y la curva observada persiste, y en C-3 no hay ninguno: en ambos las cifras coinciden con las de la esperanza.

Cuadro 3.8: MAE en el bloque de prueba (w_{ref}) contra M del pronóstico por comportamiento y de la cota, por escenario; el FAR y el Random Forest son los del Cuadro 3.2.

	C-1		C-2		C-3	
M	pronóstico	cota	pronóstico	cota	pronóstico	cota
1	0.754	0.754	0.713	0.693	—	—
2	0.740	0.740	0.676	0.641	—	—
3	0.725	0.725	0.637	0.601	0.694	0.694
4	0.717	0.717	0.617	0.574	0.690	0.690
5	0.714	0.714	0.615	0.572	0.684	0.684
6	0.714	0.714	0.613	0.572	0.689	0.689
7	0.713	0.713	0.613	0.570	—	—
8	0.712	0.712	0.613	0.570	—	—
9	0.712	0.712	0.613	0.570	—	—
10	0.712	0.712	0.612	0.570	—	—

Sobre la ventana móvil la cota de C-2 queda un 6 % bajo la esperanza y un 4 % bajo el Random Forest en M_{ref}, y la brecha con el pronóstico se abre ya con $M = 1$ y crece hasta $M = 4$, como el resto del Bloque A. La Figura 3.5 muestra que en C-2 la cota se separa del pronóstico a lo largo de todo el bloque de prueba, porque los orígenes con $K_t \geq 2$ están repartidos en él, y que la separación es mayor en el tramo de t entre 800 y 880, el de más cambios de régimen (la ventana de detalle está en él), donde además el pronóstico queda por encima de la esperanza. En C-1 y C-3 las curvas del pronóstico, la cota y la esperanza se superponen en todo el bloque de prueba.

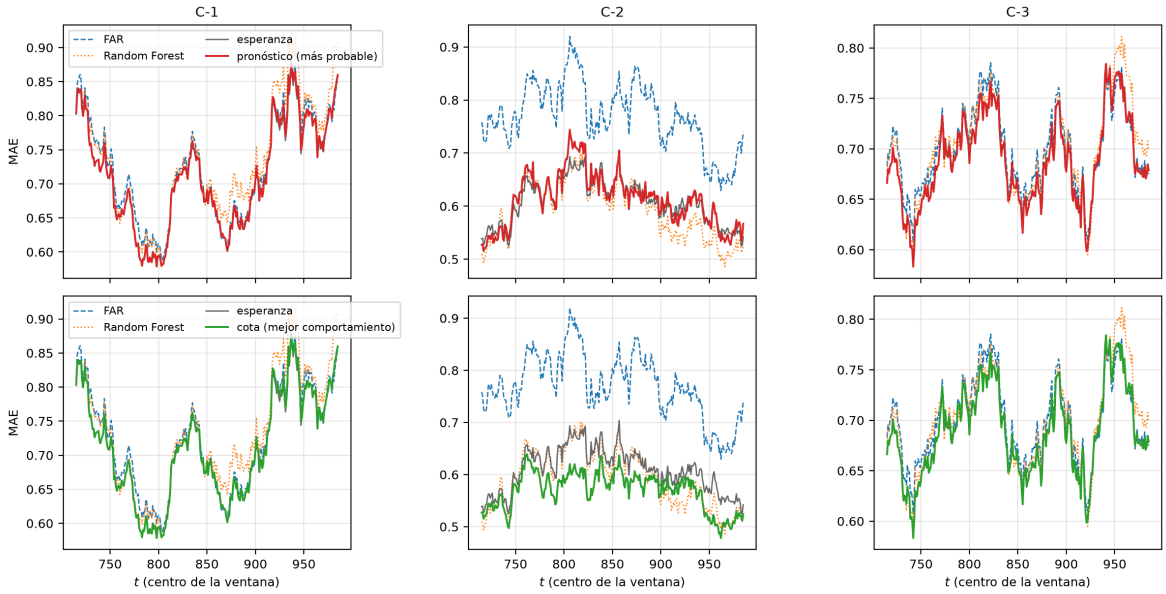


Figura 3.5: MAE sobre la ventana móvil del bloque de prueba (w_{ref}, M_{ref}). Arriba, el pronóstico por comportamiento contra el FAR y el Random Forest; abajo, la cota del mejor comportamiento contra los mismos; la esperanza como referencia. Un panel por escenario.

Cuadro 3.9: Acierto de la elección por probabilidad en C-2 (bloque de prueba, $K_t \geq 2$, M_{ref}): por tramo de la probabilidad p_{t,c^*} del comportamiento elegido, número de orígenes, fracción en que el mejor comportamiento es el más probable y MAE perdido respecto de la cota. Los 7 orígenes con $p_{t,c^*} < 0{,}5$ (tres comportamientos sin ninguno dominante) no se tabulan.

p_{t,c^*}	orígenes	acierto	MAE perdido
[0,5, 0,6)	5	20 %	0.61
[0,6, 0,7)	11	36 %	0.28
[0,7, 0,8)	31	87 %	0.11
[0,8, 0,9)	28	93 %	0.06
[0,9, 1]	8	100 %	0.00

Con $p_{t,c^*} \geq 0{,}8$ el comportamiento más probable es el mejor en el 94 % de los orígenes y el pronóstico queda a 0,05 de la cota; con $p_{t,c^*} \geq 0{,}7$ el acierto es del 90 %. Con masas por debajo de 0,7 el acierto cae al 31 %, que es lo esperable de dos o tres opciones casi equiprobables, y ahí se concentra la pérdida: entre 0,28 y 0,61 de MAE por origen. El 74 % de los orígenes con $K_t \geq 2$ están en el primer caso; el 22 % de desaciertos del Cuadro 3.7 viene casi por completo de los 16 orígenes con p_{t,c^*} entre 0,5 y 0,7. La probabilidad del comportamiento elegido es, por tanto, un indicador de cuándo conviene comprometerse con él y cuándo conviene reportar las opciones.

3.8.5. Síntesis

El PSBPM-FD supera a la referencia lineal en el error puntual en los tres escenarios desde $M = 4$ (desde $M = 1$ en C-2, con una brecha del 22 %; del orden del 2 % en

C-1 y C-3, donde la media condicional es lineal o casi lineal), y el Random Forest con la misma especificación le gana en C-2 y pierde en C-1. En los intervalos supera al FAR en los tres escenarios desde $M = 3$ o 4: en C-2 con una banda un 10 % más angosta y mejor cubierta, y en C-1 y C-3 por calibración, con un ancho que sigue el estado del proceso. Elegir el predictor cambia el resultado sólo donde la predictiva es multimodal (C-2), donde la mediana puntual mejora el MAE en 1,3 % y la región de máxima densidad el Winkler en 2,9 %; en C-1 y C-3 las tres construcciones puntuales y los tres predictores coinciden, y la banda simultánea es en todos la única calibrada para la curva completa. Los comportamientos aparecen en el 30 % de los orígenes de C-2 y no en C-1 ni en C-3, en acuerdo con la ley verdadera de cada escenario aunque con exceso en C-2. Donde aparecen, el pronóstico por comportamiento reduce el MAE frente al FAR en 17 % pero no frente a la esperanza, y la cota muestra que acertar el comportamiento lo reduciría en 21 % frente a la esperanza y en 14 % frente al Random Forest: el modelo produce opciones de las que alguna es la buena, y elige bien cuando la probabilidad del comportamiento elegido supera 0,7.

Capítulo 4

Aplicacion

Apéndice A

Algoritmos de Simulación

Este anexo presenta los algoritmos empleados para generar los datos del estudio de simulación del Capítulo 3. Cada algoritmo especifica su mecanismo generador, el rol de sus parámetros y los valores numéricos con que se emplea, los cuales se recogen en un cuadro al cierre de cada uno.

Todos los algoritmos especifican la dinámica directamente sobre los scores de la representación funcional. Se consideran tres algoritmos, C-1 a C-3, uno por escenario del estudio; el rasgo que cada uno introduce en la ley condicional del score, su propósito y la configuración con que se ajustan los métodos se describen en la Sección 3.7.1.

A.1. Esquema común

Esta sección presenta los elementos comunes a los tres algoritmos, la representación de las curvas en una base ortonormal, la grilla de observación, el espectro de varianzas de los scores y la generación de los scores pasivos. Los algoritmos se distinguen únicamente por el mecanismo que gobierna la dinámica de los scores activos presentados posteriormente.

Sea $\{\varphi_j\}_{j=1}^{J}$ un sistema ortonormal en $L^2([0,1])$ y sea $\mu(\tau)$ la función media. Cada curva se representa como

$$X_t(\tau) = \mu(\tau) + \sum_{j=1}^{J} \xi_{tj}\, \varphi_j(\tau), \tag{A.1}$$

donde ξ_{tj} es el score de la j-ésima componente en el período t. Se emplea la base de Fourier sin término constante,

$$\varphi_{2k-1}(\tau) = \sqrt{2}\,\sin(2\pi k\tau), \qquad \varphi_{2k}(\tau) = \sqrt{2}\,\cos(2\pi k\tau), \tag{A.2}$$

con $k = 1, \ldots, J/2$, $J = 10$, y $\mu(\tau) = \sin(2\pi\tau)$, que pertenece al espacio generado por la base.

La estructura temporal se especifica en el espacio de los scores y las curvas se obtienen luego mediante (A.1). Las curvas se evalúan sobre la grilla regular $\tau_l = (l-1)/(L-1)$, $l = 1, \ldots, L$, común a todos los períodos. Como la base es ortonormal y μ está en su

espacio, la representación es exacta.

Cada algoritmo genera además un período de calentamiento de B curvas que se descartan antes de retener las T curvas del estudio, de modo que las condiciones iniciales no influyan en los datos.

La escala de los scores sigue un espectro decreciente, $\mathrm{Var}(\xi_{tj}) = \lambda_j = \lambda_1 \rho^{j-1}$ con $\lambda_1 > 0$ y $\rho \in (0, 1)$, de modo que

$$\xi_{tj} = \sqrt{\lambda_j}\, z_{tj}, \tag{A.3}$$

donde z_{tj} es una serie de varianza marginal unitaria cuyo mecanismo generador define cada algoritmo. Los primeros $J_a = 4$ scores son los activos, por lo que llevan la dinámica distintiva del escenario. Los $J - J_a$ restantes siguen un proceso autorregresivo de primer orden común, $z_{tj} = \phi_p\, z_{t-1,j} + \sqrt{1 - \phi_p^2}\, e_{tj}$ con $e_{tj} \overset{\text{iid}}{\sim} \mathcal{N}(0, 1)$, y completan el espectro sin contribuir a la estructura que el escenario busca evaluar. Las componentes se generan de forma independiente entre sí, de modo que la correlación contemporánea de los scores es nula y la descomposición de las curvas puede alinearse con $\{\varphi_j\}$.

Cuadro A.1: Parámetros del esquema común.

Símbolo	Descripción	Valor
L	número de puntos de la grilla	75
T	número de curvas retenidas	1000
B	curvas de calentamiento	300
J	número de scores	10
J_a	número de scores activos	4
λ_1	varianza del primer score	0,5
ρ	razón de decaimiento del espectro	0,55
ϕ_p	coeficiente autorregresivo de los scores pasivos	0,3

A.2. Algoritmos basados en Scores de la Representación Funcional

Esta sección presenta los tres algoritmos de simulación. Cada uno describe su mecanismo generador, el rol de sus parámetros, el procedimiento de generación y los valores numéricos empleados.

A.2.1. Algoritmo C-1: Heterocedasticidad condicional en los scores

Cada score activo $j \leq J_a$ sigue un proceso autorregresivo con innovaciones GARCH$(1, 1)$ Bollerslev, 1986,

$$u_{tj} = \phi\, u_{t-1,j} + a_{tj}, \qquad a_{tj} = \sqrt{h_{tj}}\, \varepsilon_{tj}, \qquad \varepsilon_{tj} \overset{\text{iid}}{\sim} \mathcal{N}(0, 1), \tag{A.4}$$

con varianza condicional

$$h_{tj} = \alpha_0 + \alpha_1 \, a_{t-1,j}^2 + \beta_1 \, h_{t-1,j}, \tag{A.5}$$

donde α_1 gobierna la sensibilidad de la varianza futura a la innovación más reciente y β_1 la persistencia de la varianza condicional pasada. La estacionariedad de segundo orden requiere $\alpha_1 + \beta_1 < 1$, y esta persistencia total fija la memoria de la volatilidad, del orden de $1/(1-\alpha_1-\beta_1)$ períodos. El nivel base se despeja de la varianza incondicional de la innovación como $\alpha_0 = \sigma_a^2(1-\alpha_1-\beta_1)$, y ϕ, con $|\phi| < 1$, determina la persistencia del nivel del score.

El proceso u_{tj} tiene varianza marginal $\sigma_a^2/(1-\phi^2)$, de modo que

$$z_{tj} = u_{tj} \, \frac{\sqrt{1-\phi^2}}{\sigma_a}, \qquad \xi_{tj} = \sqrt{\lambda_j} \, z_{tj}, \tag{A.6}$$

tiene varianza λ_j para todo j, conforme a (A.3).

La generación procede en los pasos que siguen.

1. Se fijan ϕ, α_1, β_1 y σ_a^2, y se calcula α_0.
2. Para cada score activo se inicializan $h_{1j} = \sigma_a^2$ y $u_{0j} = 0$, y se itera (A.4)–(A.5) durante $B + T$ períodos.
3. Los scores pasivos se generan como se indica en el esquema común.
4. Se descartan los B primeros períodos, se obtienen los scores mediante (A.6) y se reconstruyen las curvas mediante (A.1).

Cuadro A.2: Parámetros del Algoritmo C-1.

Símbolo	Descripción	Valor
ϕ	coeficiente autorregresivo	0,5
α_1	sensibilidad a la innovación reciente	0,25
β_1	persistencia de la varianza condicional pasada	0,60
σ_a^2	varianza incondicional de la innovación	1,0

A.2.2. Algoritmo C-2: Cambio de régimen por umbral en los scores

Cada score activo $j \le J_a$ evoluciona en una coordenada cruda u_{tj} con dos regímenes, A y B, asignados mediante un umbral c_j sobre $u_{t-1,j}$. Condicionalmente al régimen $R_{tj} = k \in \{A, B\}$,

$$u_{tj} = \mu_{kj} + \phi_{kj} \, u_{t-1,j} + s_{kj} \, e_{tj}, \qquad e_{tj} \overset{\text{iid}}{\sim} \mathcal{N}(0,1), \tag{A.7}$$

de modo que los regímenes difieren en nivel μ_{kj}, persistencia ϕ_{kj} y escala s_{kj}: el régimen A es persistente y de escala pequeña, y el B revierte y es más volátil.

La asignación es un probit sobre el rezago propio. Con Φ la función de distribución normal estándar y $h_j > 0$ el ancho de la transición,

$$P(R_{tj} = B \mid u_{t-1,j}) = \Phi\left(\frac{u_{t-1,j} - c_j}{h_j}\right), \qquad (A.8)$$
$$P(R_{tj} = A \mid u_{t-1,j}) = 1 - P(R_{tj} = B \mid u_{t-1,j}).$$

Con $h_j \to 0$ la asignación se vuelve determinista y el escenario es un SETAR clásico, mientras que un h_j positivo hace la transición suave.

La media condicional es exacta,

$$\mathbb{E}\big[u_{tj} \mid u_{t-1,j}\big] = \big(1 - p_{tj}\big)\big(\mu_{Aj} + \phi_{Aj}\, u_{t-1,j}\big) + p_{tj}\big(\mu_{Bj} + \phi_{Bj}\, u_{t-1,j}\big), \qquad (A.9)$$
$$p_{tj} = P(R_{tj} = B \mid u_{t-1,j}),$$

y se registra en cada período junto con el régimen sorteado. La dinámica usa un único rezago.

El score se obtiene estandarizando u_{tj} con sus momentos poblacionales (m_j, d_j), estimados una sola vez mediante una simulación larga, y escalando por (A.3),

$$z_{tj} = \frac{u_{tj} - m_j}{d_j}, \qquad \xi_{tj} = \sqrt{\lambda_j}\, z_{tj}. \qquad (A.10)$$

La estandarización pertenece al generador, que fija la escala del escenario, y no se aplica a los datos que recibe un método.

La generación procede en los pasos que siguen.

1. Se fijan, para cada score activo, el umbral c_j, el ancho h_j y los parámetros $(\mu_{kj}, \phi_{kj}, s_{kj})$ de los dos regímenes.
2. Para cada período se calcula la probabilidad (A.8) a partir de $u_{t-1,j}$ y se sortea R_{tj}. La secuencia de regímenes no se entrega a los métodos.
3. Se genera u_{tj} mediante (A.7), con el régimen sorteado.
4. Los scores pasivos se generan como se indica en el esquema común.
5. Se descartan los B primeros períodos, se obtienen los scores mediante (A.10) y se reconstruyen las curvas mediante (A.1).

Cuadro A.3: Parámetros del Algoritmo C-2.

Símbolo	Descripción	Valor
K	número de regímenes	2
c_j	umbral sobre el rezago propio	0
h_j	ancho de la transición probit	Cuadro A.4
$\mu_{kj},\ \phi_{kj},\ s_{kj}$	nivel, coeficiente autorregresivo y escala del régimen k	Cuadro A.4
(m_j, d_j)	media y desviación poblacionales de u_{tj}	simulación larga

Cuadro A.4: Parámetros del Algoritmo C-2 por score activo.

j	h_j	μ_{Aj}	ϕ_{Aj}	s_{Aj}	μ_{Bj}	ϕ_{Bj}	s_{Bj}	c_j
1	0,10	0	0,8	0,25	2,5	−0,9	1,0	0
2	0,10	0	0,6	0,25	2,0	−0,9	1,0	0
3	0,25	0	0,8	0,40	2,0	−0,9	1,0	0
4	0,25	0	0,6	0,40	2,5	−0,9	1,0	0

A.2.3. Algoritmo C-3: Multimodalidad en los scores

Este algoritmo genera el vector de scores con una mezcla de K mecanismos lineales, cuya selección depende de la historia reciente del proceso.

Sea $Z_t \in \{1, \ldots, K\}$ la variable latente que identifica el mecanismo utilizado en el período t. Condicionalmente a $Z_t = k$, el vector de scores se genera mediante

$$\boldsymbol{\xi}_t = \boldsymbol{\mu}_{Z_t} + \sum_{\ell=1}^{L} A_{Z_t,\ell}\, \boldsymbol{\xi}_{t-\ell} + \boldsymbol{\varepsilon}_t, \tag{A.11}$$

donde $\boldsymbol{\xi}_t = (\xi_{t1}, \ldots, \xi_{tJ})^\top$ es el vector de scores, $\boldsymbol{\mu}_{Z_t}$ es la localización del mecanismo seleccionado, $A_{Z_t,\ell}$ es la matriz de dependencia asociada al ℓ-ésimo rezago y $\boldsymbol{\varepsilon}_t$ es un vector de innovaciones gaussianas independientes de Z_t. Los mecanismos comparten el patrón de dependencia de las matrices $A_{k,\ell}$ y difieren en sus valores.

La selección del mecanismo depende de los scores correspondientes a múltiples rezagos mediante

$$P\left(Z_t = k \mid \boldsymbol{\xi}_{t-1}, \ldots, \boldsymbol{\xi}_{t-L}\right) = \frac{\exp\left\{q_k\left(\boldsymbol{\xi}_{t-1}, \ldots, \boldsymbol{\xi}_{t-L}\right)\right\}}{\displaystyle\sum_{h=1}^{K} \exp\left\{q_h\left(\boldsymbol{\xi}_{t-1}, \ldots, \boldsymbol{\xi}_{t-L}\right)\right\}}, \tag{A.12}$$

donde $q_k(\cdot)$ es afín en los scores considerados y el mecanismo 1 es la referencia del softmax, $q_1 \equiv 0$.

Para incorporar dependencia temporal de más de un período se emplean $L = 2$ rezagos, de modo que tanto la selección del mecanismo como la generación de los scores utilizan $\boldsymbol{\xi}_{t-1}$ y $\boldsymbol{\xi}_{t-2}$. La dinámica distintiva se concentra en los J_a scores activos; los scores restantes siguen el proceso autorregresivo del esquema común, de modo que el espectro de varianzas sea el de (A.3).

Los valores se especifican en la coordenada estandarizada $z_{tj} = \xi_{tj}/\sqrt{\lambda_j}$ de (A.3), de modo que un coeficiente cruzado se lee igual cualquiera sea la varianza de las componentes que conecta. En la escala de los scores, con $D = \mathrm{diag}(\sqrt{\lambda_1}, \ldots, \sqrt{\lambda_J})$, $\boldsymbol{\mu}_k = D\tilde{\boldsymbol{\mu}}_k$, $A_{k,\ell} = D\tilde{A}_{k,\ell}D^{-1}$, $q_k(\boldsymbol{\xi}) = \tilde{q}_k(D^{-1}\boldsymbol{\xi})$ y $\mathrm{Var}(\varepsilon_{tj}) = \lambda_j\tilde{\sigma}_j^2$. Los tres mecanismos son un centro ($k = 1$) y dos niveles, alto ($k = 2$) y bajo ($k = 3$), que se separan solo en la localización del primer score, $\tilde{\mu}_{k1} = 0, +1, -1$, con $\tilde{\mu}_{kj} = 0$ para $j \geq 2$. La asignación

es

$$\begin{aligned} \tilde{q}_1 &= 0, \\ \tilde{q}_2 &= -2{,}1 + 1{,}75\, z_{1,t-1} + 0{,}7\, z_{1,t-2} + 0{,}5\, z_{2,t-1}, \\ \tilde{q}_3 &= -2{,}1 - 1{,}75\, z_{1,t-1} - 0{,}7\, z_{1,t-2} + 0{,}5\, z_{2,t-1}. \end{aligned} \tag{A.13}$$

Las matrices $\tilde{A}_{k,\ell}$ comparten el patrón del Cuadro A.6, la diagonal del bloque activo en el primer rezago y cuatro entradas cruzadas, y difieren en los valores; las entradas no listadas son cero. La entrada (j, m) de $\tilde{A}_{k,\ell}$ es el coeficiente con que el score m rezagado ℓ períodos entra en el score j. Los scores pasivos conservan su coeficiente ϕ_p en el primer rezago, igual en los tres mecanismos. La innovación tiene desviación $\tilde{\sigma}_j$ en el bloque activo y $\sqrt{1-\phi_p^2}$ en el pasivo.

La generación procede en los pasos que siguen.

1. Se fijan el número de mecanismos K, los vectores $\boldsymbol{\mu}_k$, las matrices $A_{k,\ell}$ y las funciones de asignación $q_k(\cdot)$.

2. Se calculan las probabilidades condicionales de los mecanismos mediante (A.12), utilizando los scores de los dos rezagos anteriores.

3. Se sortea Z_t a partir de dichas probabilidades. La secuencia de mecanismos no se entrega a los métodos.

4. Se genera $\boldsymbol{\xi}_t$ mediante (A.11), con los parámetros del mecanismo seleccionado.

5. Se descartan los B primeros períodos y se reconstruyen las curvas mediante (A.1).

Cuadro A.5: Parámetros del Algoritmo C-3 (coordenada estandarizada z).

Símbolo	Descripción	Valor
K	número de mecanismos	3
L	número de rezagos utilizados	2
$\tilde{\mu}_{k1}$	localización del primer score, $k = 1, 2, 3$	$0,\ +1,\ -1$
$\tilde{q}_k$	funciones de asignación	(A.13)
$\tilde{A}_{k,\ell}$	matrices de dependencia	Cuadro A.6
$\tilde{\sigma}_j$	desviación de la innovación, $j = 1, \ldots, 4$	0,45, 0,75, 0,80, 0,80

Cuadro A.6: Entradas no nulas de $\tilde{A}_{k,\ell}$ en el bloque activo, por mecanismo.

		$\ell = 1$						$\ell = 2$	
k	mecanismo	$(1,1)$	$(2,2)$	$(3,3)$	$(4,4)$	$(2,1)$	$(3,2)$	$(1,1)$	$(4,3)$
1	centro	0,2	0,3	0,3	0,3	0,2	0,8	−0,1	−0,6
2	nivel alto	0,2	0,4	0,2	0,2	0,5	−0,3	0,1	0,3
3	nivel bajo	0,2	0,4	0,2	0,2	−0,5	−0,3	0,1	0,3

A.3. Configuración del estudio de simulación

Esta sección recoge la configuración con que se corrió el estudio de simulación de la Sección 3.7: partición y ventana móvil, muestreador y predictiva, modelos de referencia, métricas por resumen y constantes de los comportamientos.

Partiendo por Cuadro A.7 el cual presenta la partición temporal, la ventana móvil y las referencias de los cuadros del capítulo; las ventanas que cruzan T_0 se excluyen de todo agregado.

Cuadro A.7: Partición temporal, ventana móvil y referencias de los cuadros.

Símbolo	Descripción	Valor
T_0	corte entrenamiento / prueba (70 % de las $T = 1000$ curvas del Cuadro A.1)	700
h	horizonte de predicción	1
w	anchos de la ventana móvil	$\{20, 30, 40\}$
w_{ref}	ancho reportado en el capítulo	30
paso	desplazamiento entre ventanas	1
M_{ref}	dimensión del estado en los cuadros, la mayor del barrido de cada escenario (Cuadro 3.1)	10 (6 en C-3)
$1 - \zeta$	nivel de los intervalos de credibilidad	0,95

El Cuadro A.8 recoge la configuración del muestreador (Sección 3.4) y de la predictiva; con $a_\nu = 0{,}5$ la varianza predictiva de la Sección 3.5.2 no existe y no se reporta.

Cuadro A.8: Configuración del muestreador y de la predictiva.

Símbolo	Descripción	Valor
N	truncamiento del stick-breaking	30
L_j	puntos de la grilla de localización por predictor	50
iteraciones	por cadena / descartadas	2500 / 500
cadenas	cadenas independientes por score	3
a_ν, a_g, b_g	forma de las precisiones y de la contracción	0,5
b_ν	escala de la precisión del átomo	$0{,}5\,\mathrm{sd}^2(\xi_m)$
ν_{ρ_j}	precisión a priori de los coeficientes de decaimiento ρ_{hj}	$10\,\mathrm{sd}^2(z_j)$
$(a_{\kappa_j}, b_{\kappa_j})$	inclusión, rezago propio de orden uno / resto	$(0{,}5, 0{,}5)$ / $(0{,}5, 5)$
S	extracciones de la predictiva por origen	1000

Los modelos de referencia siguen el Cuadro A.9. El FAR se estima sobre los coeficientes completos de la representación, en la métrica L^2, con orden fijo igual al número de rezagos del escenario, para no darle una ventaja de especificación que el PSBPM-FD no tiene; su intervalo es gaussiano con los residuos de entrenamiento. El Random Forest comparte la especificación del PSBPM-FD, un modelo por score con las mismas covariables, de modo que la diferencia entre ambos es solo el mecanismo que liga covariables y respuesta.

Cuadro A.9: Ajuste de los modelos de referencia.

Modelo	Elemento	Valor
FAR(p)	orden p	número de rezagos del escenario, fijo
	dimensión del subespacio k_n	por predicción a un paso, tope K
	tramo de selección	último 20 % del entrenamiento
	intervalo	gaussiano, residuos de entrenamiento, $\sigma(\tau)$
Random Forest	árboles / hojas mínimas / covariables por corte	500 / 5 / $\sqrt{p}$
	orden de rezago	por error absoluto en ventanas de entrenamiento

El Cuadro A.10 indica, para cada métrica, sobre qué resumen de la predictiva del PSBPM-FD se calcula y contra qué modelos se compara; el Random Forest no entrega intervalos.

Cuadro A.10: Métricas reportadas, resumen del PSBPM-FD sobre el que se calculan y modelos comparados.

Métrica (Sección 2.2.3)	Resumen del PSBPM-FD	Modelos comparados
RMSE, MAE	esperanza, mediana puntual, átomo más probable	FAR, Random Forest
RMSE, MAE	pronóstico por comportamiento (Sección 3.6.3) y mejor comportamiento (cota)	FAR, Random Forest, por separado
$\overline{\mathrm{E}}_{\mathrm{máx}}$, $\mathrm{E}^{\mathrm{glob}}_{\mathrm{máx}}$ (anexo)	los mismos predictores	FAR, Random Forest
Winkler, MPIW, PICP	intervalo equi-colas, banda simultánea, región de máxima densidad	FAR
$\overline{W}_{\mathrm{máx}}$, $W^{\mathrm{glob}}_{\mathrm{máx}}$, PICPB (anexo)	los mismos intervalos	FAR

El Cuadro A.11 fija las constantes del análisis de comportamientos. La ventana de detalle de N_{det} orígenes consecutivos de prueba se elige con un criterio propio de cada escenario, calculado sobre lo que el generador registra y nunca sobre lo predicho: la que contiene el máximo de la varianza condicional verdadera en C-1, la de más cambios de régimen en C-2 y la de más orígenes con ley condicional multimodal en C-3. El pronóstico por comportamiento y su cota se comparan con el FAR y el Random Forest en figuras separadas, sobre todos los orígenes de prueba y sobre los de $K_t \geq 2$, y el acierto de la elección se lee por tramos de p_{t,c^*}.

Cuadro A.11: Constantes del análisis de comportamientos.

Elemento	Descripción	Valor
S	extracciones del vector de scores por origen	1000
inicios	inicios aleatorios de k-medias	10
cociente de valle	umbral de (3.48) para declarar dos modos	0,5
núcleo	estimador de densidad sobre la proyección	gaussiano, ancho de Scott
ζ	masa mínima de un comportamiento	0,05
recorte	cuantiles de recorte cuando $a_\nu \leq 1$	0,5 % y 99,5 %
N_{det}	orígenes de la ventana de detalle	10

Apéndice B

Resultados Complementarios del Estudio de Simulación

B.1. Métricas completas por número de componentes

B.1.1. Escenario TAR

B.1.2. Escenario GARCH

B.1.3. Escenario de multimodalidad

B.2. Sensibilidad al ancho de la ventana

B.3. Desempeño a lo largo del período de prueba

B.3.1. Error de predicción

B.3.2. Intervalos de predicción

B.4. Calibración respecto de la representación truncada

B.5. Intervalos por componente

B.6. Predicciones curva a curva

B.6.1. Escenario TAR

B.6.2. Escenario GARCH

B.6.3. Escenario de multimodalidad

Bibliografía

Aue, Alexander, Diogo Dubart Norinho y Siegfried Hörmann (2015). "On the Prediction of Stationary Functional Time Series". En: *Journal of the American Statistical Association* 110.509, págs. 378-392. DOI: 10.1080/01621459.2014.909317.

Aue, Alexander, Gregory Rice y Ozan Sönmez (2018). "Detecting and Dating Structural Breaks in Functional Data Without Dimension Reduction". En: *Journal of the Royal Statistical Society: Series B (Statistical Methodology)* 80.3. Verificar DOI. Preprint: arXiv:1511.04020, págs. 509-529. DOI: 10.1111/rssb.12257.

Bayes, Thomas (1763). "An Essay Towards Solving a Problem in the Doctrine of Chances". En: *Philosophical Transactions of the Royal Society of London* 53. Publicado póstumamente por Richard Price, págs. 370-418. URL: https://royalsocietypublishing.org/doi/10.1098/rstl.1763.0053.

Bergmeir, Christoph y José M. Benítez (2012). "On the use of cross-validation for time series predictor evaluation". En: *Information Sciences* 191, págs. 192-213.

Beyaztas, Ufuk, Han Lin Shang y Zaher Mundher Yaseen (2021). "A Functional Autoregressive Model Based on Exogenous Hydrometeorological Variables for River Flow Prediction". En: *Journal of Hydrology* 598, pág. 126380. DOI: 10.1016/j.jhydrol.2021.126380.

Beyaztas, Ufuk y Hanlin Shang (2022). "Machine-Learning-Based Functional Time Series Forecasting: Application to Age-Specific Mortality Rates". En: *Forecasting* 4.1, págs. 394-408. DOI: 10.3390/forecast4010022.

Blackwell, David y James B. MacQueen (1973). "Ferguson Distributions via Pólya Urn Schemes". En: *The Annals of Statistics* 1.2, págs. 353-355. DOI: 10.1214/aos/1176342372.

Bollerslev, Tim (1986). "Generalized autoregressive conditional heteroskedasticity". En: *Journal of Econometrics* 31.3, págs. 307-327.

Boor, Carl de (2001). *A Practical Guide to Splines*. Revised. Vol. 27. Applied Mathematical Sciences. New York: Springer-Verlag. ISBN: 978-0-387-95366-3.

Bosq, Denis (2000). *Linear Processes in Function Spaces: Theory and Applications*. Vol. 149. Lecture Notes in Statistics. New York: Springer-Verlag. ISBN: 978-0-387-95052-7. DOI: 10.1007/978-1-4612-1154-9.

Caron, François, Manuel Davy y Arnaud Doucet (2007). "Generalized Polya Urn for Time-Varying Dirichlet Process Mixtures". En: *Proceedings of the 23rd Conference on Uncertainty in Artificial Intelligence (UAI 2007)*. AUAI Press, págs. 33-40.

Chung, Yeonseung y David B. Dunson (2009). "Nonparametric Bayes Conditional Distribution Modeling with Variable Selection". En: *Journal of the American Statistical Association* 104.488, págs. 1646-1660. DOI: 10.1198/jasa.2009.tm08302.

Degras, David A. (2011). "Simultaneous confidence bands for nonparametric regression with functional data". En: *Statistica Sinica* 21.4, págs. 1735-1765.

Di Lucca, Maria Anna et al. (mar. de 2013). "A Simple Class of Bayesian Nonparametric Autoregression Models". En: *Bayesian Analysis* 8.1, págs. 63-88. DOI: 10.1214/13-BA803.

Dunson, David B. y Ju-Hyun Park (2008). "Kernel Stick-Breaking Processes". En: *Biometrika* 95.2, págs. 307-323. DOI: 10.1093/biomet/asn012.

Escobar, Michael D. y Mike West (1995). "Bayesian Density Estimation and Inference Using Mixtures". En: *Journal of the American Statistical Association* 90.430, págs. 577-588.

Ferguson, Thomas S. (1973). "A Bayesian Analysis of Some Nonparametric Problems". En: *The Annals of Statistics* 1.2, págs. 209-230. DOI: 10.1214/aos/1176342360.

Ferraty, Frédéric y Philippe Vieu (2006). *Nonparametric Functional Data Analysis: Theory and Practice*. Springer Series in Statistics. New York: Springer. ISBN: 9780387303697.

Gamasaee, R. y M. H. Fazel Zarandi (sep. de 2017). "A New Dirichlet Process for Mining Dynamic Patterns in Functional Data". En: *Information Sciences* 405, págs. 55-80.

Gelman, Andrew et al. (2013). *Bayesian Data Analysis*. 3.ª ed. Boca Raton, FL: Chapman & Hall/CRC. ISBN: 978-1-4398-4095-5.

Gneiting, Tilmann y Adrian E. Raftery (2007). "Strictly proper scoring rules, prediction, and estimation". En: *Journal of the American Statistical Association* 102.477, págs. 359-378.

Grazian, Clara (sep. de 2025). "Spatio-Temporal Stick-Breaking Process". En: *Bayesian Analysis* 20.3. Preprint: arXiv:2303.17177 (2023), págs. 763-794. DOI: 10.1214/24-BA1419.

Griffin, Jim E. y Mark F. J. Steel (2006). "Order-Based Dependent Dirichlet Processes". En: *Journal of the American Statistical Association* 101.473, págs. 179-194. DOI: 10.1198/016214505000000727.

— (2011). "Stick-Breaking Autoregressive Processes". En: *Journal of Econometrics* 162.2, págs. 383-396. DOI: 10.1016/j.jeconom.2011.03.001.

Hartigan, J. A. y P. M. Hartigan (1985). "The dip test of unimodality". En: *The Annals of Statistics* 13.1, págs. 70-84.

Hörmann, Siegfried y Piotr Kokoszka (2010). "Weakly Dependent Functional Data". En: *The Annals of Statistics* 38.3, págs. 1845-1884. DOI: 10.1214/09-AOS768.

Horváth, Lajos, Piotr Kokoszka y Gregory Rice (2014). "Testing Stationarity of Functional Time Series". En: *Journal of Econometrics* 179.1. Verificar DOI, págs. 66-82. DOI: 10.1016/j.jeconom.2013.11.002.

Hsing, Tailen y Randall Eubank (2015). *Theoretical Foundations of Functional Data Analysis, with an Introduction to Linear Operators*. Wiley Series in Probability and Statistics. Chichester, UK: Wiley. ISBN: 978-0-470-01691-6. DOI: 10.1002/9781118762547.

Hyndman, Rob J. (1996). "Computing and graphing highest density regions". En: *The American Statistician* 50.2, págs. 120-126.

Hyndman, Rob J. y Han Lin Shang (2009). "Forecasting functional time series". En: *Journal of the Korean Statistical Society* 38.3, págs. 199-221.

Hyndman, Rob J. y Md. Shahid Ullah (2007). "Robust forecasting of mortality and fertility rates: A functional data approach". En: *Computational Statistics & Data Analysis* 51.10, págs. 4942-4956.

Kamarthi, Harshavardhan et al. (2021). "When in Doubt: Neural Non-Parametric Uncertainty Quantification for Epidemic Forecasting". En: *Advances in Neural Information Processing Systems*. Vol. 34. arXiv:2106.03904. URL: https://arxiv.org/abs/2106.03904.

Klepsch, Johannes y Claudia Klüppelberg (2017). "An Innovations Algorithm for the Prediction of Functional Linear Processes". En: *Journal of Multivariate Analysis* 155, págs. 252-271. DOI: 10.1016/j.jmva.2017.01.005.

Klepsch, Johannes, Claudia Klüppelberg y Taojun Wei (2017). "Prediction of Functional ARMA Processes with an Application to Traffic Data". En: *Econometrics and Statistics* 1, págs. 128-149. DOI: 10.1016/j.ecosta.2016.10.009.

Kokoszka, Piotr y Matthew Reimherr (2017). *Introduction to Functional Data Analysis*. Chapman & Hall/CRC Texts in Statistical Science. CRC Press. ISBN: 9781498746694.

MacEachern, Steven N. (1999). "Dependent Nonparametric Processes". En: *Proceedings of the Section on Bayesian Statistical Science*. American Statistical Association, págs. 50-55.

Mercer, James (1909). "Functions of Positive and Negative Type and Their Connection With the Theory of Integral Equations". En: *Philosophical Transactions of the Royal Society of London. Series A* 209.441-458, págs. 415-446.

Müller, Peter et al. (2015). *Bayesian Nonparametric Data Analysis*. Springer Series in Statistics. Springer. ISBN: 978-3-319-18967-1. DOI: 10.1007/978-3-319-18968-8.

Neal, Radford M. (2000). "Markov Chain Sampling Methods for Dirichlet Process Mixture Models". En: *Journal of Computational and Graphical Statistics* 9.2, págs. 249-265. DOI: 10.1080/10618600.2000.10474879.

— (2003). *Slice Sampling*. Technical Report TR-2003-010. Version publicada con discusion en Annals of Statistics 31(3):705–767. Verificar cual citar. Department of Statistics y Department of Computer Science, University of Toronto.

Petrone, Sonia, Michele Guindani y Alan E. Gelfand (sep. de 2009). "Hybrid Dirichlet Mixture Models for Functional Data". En: *Journal of the Royal Statistical Society Series B (Statistical Methodology)* 71.4, págs. 755-782. DOI: 10.1111/j.1467-9868.2009.00708.x.

Quintana, Fernando A. et al. (2022). "The Dependent Dirichlet Process and Related Models". En: *Statistical Science* 37.1, págs. 24-41. DOI: 10.1214/20-STS819.

Ramsay, James O. y Bernard W. Silverman (2006). *Functional Data Analysis*. Springer Series in Statistics. New York: Springer. ISBN: 9780387227511.

Reich, Brian J. y Montserrat Fuentes (2007). "A Multivariate Semiparametric Bayesian Spatial Modeling Framework for Hurricane Surface Wind Fields". En: *The Annals of Applied Statistics* 1.1, págs. 249-264. DOI: 10.1214/07-AOAS108.

Rizzo, Maria L. (2007). *Statistical Computing with R*. Chapman & Hall/CRC The R Series. Chapman & Hall/CRC. ISBN: 9781584885450.

Rodríguez, Abel y David B. Dunson (mar. de 2011). "Nonparametric Bayesian Models Through Probit Stick-Breaking Processes". En: *Bayesian Analysis* 6.1, págs. 145-177. DOI: 10.1214/11-BA605.

Rodríguez, Abel, David B. Dunson y Alan E. Gelfand (mar. de 2009). "Bayesian Nonparametric Functional Data Analysis Through Density Estimation". En: *Biometrika* 96.1, págs. 149-162. DOI: 10.1093/biomet/asn054.

Rodríguez, Abel y Enrique ter Horst (2008). "Bayesian Dynamic Density Estimation". En: *Bayesian Analysis* 3.2, págs. 339-365. DOI: 10.1214/08-BA313.

Saad, Feras A. y Vikash K. Mansinghka (2018). "Temporally-Reweighted Chinese Restaurant Process Mixtures for Clustering, Imputing, and Forecasting Multivariate Time Series". En: *Proceedings of the 21st International Conference on Artificial Intelligence and Statistics (AISTATS)*. Vol. 84. Proceedings of Machine Learning Research. PMLR, págs. 755-764.

Scarpa, Bruna y David B. Dunson (2014). "Enriched Stick-Breaking Processes for Functional Data". En: *Journal of the American Statistical Association* 109.506, págs. 647-660. DOI: 10.1080/01621459.2013.866564.

Sethuraman, Jayaram (1994). "A Constructive Definition of Dirichlet Priors". En: *Statistica Sinica* 4.2, págs. 639-650.

Shah, Ismail y Francesco Lisi (2020). "Forecasting of Electricity Price Through a Functional Prediction of Sale and Purchase Curves". En: *Journal of Forecasting* 39.2, págs. 242-259. DOI: 10.1002/for.2624.

Shang, Han Lin (2013). "Functional Time Series Approach for Forecasting Very Short-Term Electricity Demand". En: *Journal of Applied Statistics* 40.1, págs. 152-168. DOI: 10.1080/02664763.2012.740619.

— (2017). "Forecasting Intraday S&P 500 Index Returns: A Functional Time Series Approach". En: *Journal of Forecasting* 36.7, págs. 741-755. DOI: 10.1002/for.2467.

Wagner-Muns, Ian M. et al. (2018). "A Functional Data Analysis Approach to Traffic Volume Forecasting". En: *IEEE Transactions on Intelligent Transportation Systems* 19.3, págs. 878-888. DOI: 10.1109/TITS.2017.2706143.

Wang, Deqing et al. (2025). "A Functional Mixture Prediction Model for Dynamically Forecasting Cumulative Intraday Returns of Crude Oil Futures". En: *International Journal of Forecasting*. En prensa. Verificar volumen, número, páginas y DOI.

Wang, Haixu y Jiguo Cao (2025). *Probabilistic Functional Neural Networks*. arXiv preprint arXiv:2503.21585. Verificar si ya fue publicado en revista al momento de cerrar la bibliografía. URL: https://arxiv.org/abs/2503.21585.

Winkler, Robert L. (1972). "A Decision-Theoretic Approach to Interval Estimation". En: *Journal of the American Statistical Association* 67.337, págs. 187-191. DOI: 10.1080/01621459.1972.10481224.

Zellner, Arnold (1986). "On Assessing Prior Distributions and Bayesian Regression Analysis with g-Prior Distributions". En: *Bayesian Inference and Decision Techniques: Essays in Honor of Bruno de Finetti*. Ed. por Prem K. Goel y Arnold Zellner. Amsterdam: North-Holland, págs. 233-243.