



UNIVERSIDAD DE SANTIAGO DE CHILE
FACULTAD DE CIENCIA

Departamento de Matemática y Ciencia de la Computación

Predicción de series temporales funcionales
mediante modelos de espacio de estados y filtro de Kalman
unscented

Autor(a):

Katerin Carla Queralto Araya

Profesor(a) Guía:

Andrés Iturriaga Jofré

Profesores informantes:

Dr. Miguel Carrasco Briones

Dr. Julio López Luis

Trabajo para optar al título de Ingeniería en matemáticas

Santiago - Chile

2026

Resumen

En esta tesis se estudia el problema de la modelación y predicción de series temporales funcionales mediante una formulación de espacio de estados en dimensión reducida. El enfoque propuesto combina una etapa de suavizamiento funcional y reducción de dimensión vía análisis de componentes principales funcionales (FPCA) con un modelo dinámico sobre las puntuaciones retenidas, cuya estimación se realiza mediante el filtro de Kalman *unscented* (UKF). Esta formulación permite representar trayectorias funcionales de manera parsimoniosa, trasladar el problema desde un espacio de Hilbert infinito-dimensional a un contexto multivariado de baja dimensión y realizar inferencia recursiva sobre la dinámica latente del sistema. Desde el punto de vista teórico, se desarrollan resultados sobre representación funcional, truncamiento, reducción de dimensión y predicción funcional; desde el punto de vista empírico, se evalúa el desempeño del modelo en distintos escenarios simulados y en cinco conjuntos de datos reales provenientes de dominios heterogéneos.

Los resultados muestran que la utilidad del enfoque propuesto depende de la estructura dinámica del proceso observado y de la métrica de evaluación considerada. En algunos escenarios, particularmente cuando la dinámica reducida exhibe patrones no lineales o cambios abruptos, el UKF mejora el desempeño predictivo respecto de modelos lineales y funcionales clásicos. Sin embargo, en otros casos, modelos más parsimoniosos como FAR(1), f-GARCH o el filtro de Kalman lineal resultan competitivos o superiores. Por tanto, el UKF debe entenderse como una herramienta flexible, no como una mejora automática.

Palabras clave: series temporales funcionales, análisis de componentes principales funcionales, modelos de espacio de estados, filtro de Kalman *unscented*, predicción funcional.

Índice general

Resumen	I
Tabla de Contenido	IV
Índice de cuadros	IV
Índice de figuras	VI
1 Introducción	1
2 Marco teórico	5
2.1 Datos funcionales y representación en bases	5
2.1.1 Espacio funcional	5
2.1.2 Procesos funcionales	6
2.1.3 Expansión en bases funcionales	6
2.1.4 Representación finita en base ortonormal	7
2.1.5 Caso general: bases no ortonormales	8
2.1.6 Notación matricial global	9
2.1.7 Elección de bases funcionales	10
2.2 Análisis de componentes principales funcionales	13
2.2.1 Operador de covarianza	13
2.2.2 Propiedades de autoadjunción y positividad	15
2.2.3 Teorema espectral y FPCA	15
2.2.4 Teorema espectral y FPCA	15
2.2.5 Truncamiento y error de aproximación	17
2.2.6 Descomposición del error total	19
2.2.7 FPCA como paso de reducción de dimensión para modelación di- námica	20

2.3	Series Temporales Funcionales	22
2.3.1	Modelo FAR(1)	22
2.3.2	Representación finito-dimensional del FAR(1)	23
2.3.3	Estabilidad y estacionariedad del sistema truncado	25
2.3.4	Extensiones del modelo FAR y modelos dinámicos relacionados . . .	27
2.3.5	Alcance y limitaciones de los modelos funcionales clásicos	30
2.4	Modelos de Espacio de Estados Funcionales	31
2.4.1	Formulación lineal-gaussiana del modelo funcional	31
2.4.2	Inferencia en el caso lineal: filtro de Kalman	33
2.4.3	Extensión no lineal: filtro de Kalman unscented	35
2.4.4	Innovaciones, residuos y diagnóstico del modelo	39
2.4.5	Comentario sobre otros enfoques	40
2.4.6	Cierre de la sección	41
2.5	Predicción Funcional	41
2.5.1	Predicción del estado reducido	42
2.5.2	Reconstrucción funcional	43
2.5.3	Error de predicción en norma funcional	44
2.5.4	Comentario final sobre el alcance predictivo	46
3	Metodología propuesta	47
3.1	Introducción	47
3.2	Estado del Arte	49
3.2.1	Predicción de series temporales funcionales	49
3.2.2	Brecha metodológica	51
3.3	Metodología	52
3.3.1	Formulación del problema	52
3.3.2	Esquema general del procedimiento	53
3.3.3	Construcción de la representación funcional reducida	53
3.3.4	Modelo dinámico propuesto en el espacio de scores	55
3.3.5	Consideraciones de regularidad y estabilidad	58
3.3.6	Consideraciones de regularidad y estabilidad	58
3.3.7	Procedimiento de estimación mediante UKF	60
3.3.8	Reconstrucción funcional y evaluación	64

3.3.9	Consideraciones computacionales	64
4	Experimentos y resultados	66
4.1	Descripción de los conjuntos de datos	66
4.2	Protocolo de entrenamiento y testeo	67
4.3	Resultados predictivos	69
4.3.1	Conjunto de las criptomonedas	72
4.3.2	Conjunto de electricidad	75
4.3.3	Conjunto de flujo vehicular	79
4.3.4	Conjunto de polución	82
4.3.5	Conjunto de temperatura OT	85
4.4	Experimento 1: Detección de cambio estructural bajo distintas intensidades	89
4.5	Experimento 2: Sensibilidad a la Dimensionalidad y a la Representación Funcional	91
4.6	Experimento 3: Robustez del UKF ante violaciones de gaussianidad	94
4.7	Conclusiones	96
5	Conclusiones	98
	Bibliografía	101
A	Código computacional	105
A.1	Código base para los dataset	105

Índice de cuadros

4.1	Resultados de MAE y MSE para distintos modelos en cinco datasets	70
-----	--	----

Índice de figuras

4.1	Comparación de las predicciones obtenidas mediante los 6 modelos frente a la curva observada del precio ASH/USD.	74
4.2	Evolución temporal de los coeficientes dinámicos asociados a los componentes principales del modelo para el dataset de criptomonedas.	74
4.3	Diagnóstico de innovaciones del modelo para el dataset de criptomonedas. Se muestran el ACF, el histograma y el gráfico Q-Q de los residuos.	75
4.4	Dinámica temporal del sistema para el dataset de criptomonedas: radio espectral y volatilidad condicional.	75
4.5	Comparación de las predicciones obtenidas mediante los 6 modelos propuestos frente a la curva observada del consumo en KW.	77
4.6	Evolución temporal de los coeficientes dinámicos asociados a los componentes principales del modelo para el dataset de criptomonedas.	78
4.7	Diagnóstico de innovaciones del modelo para el dataset de criptomonedas. Se muestran el ACF, el histograma y el gráfico Q-Q de los residuos.	78
4.8	Dinámica temporal del sistema para el dataset de consumo eléctrico: radio espectral y volatilidad condicional.	79
4.9	Comparación de las predicciones obtenidas mediante los 6 modelos propuestos frente a la curva observada de volumen de vehículos.	81
4.10	Evolución temporal de los coeficientes dinámicos asociados a los componentes principales del modelo para el dataset de flujo vehicular.	81
4.11	Diagnóstico de innovaciones del modelo para el dataset de flujo vehicular. Se muestran el ACF, el histograma y el gráfico Q-Q de los residuos.	82
4.12	Dinámica temporal del sistema para el dataset de flujo vehicular: radio espectral y volatilidad condicional.	82

4.13	Comparación de las predicciones obtenidas mediante el modelo VAR dinámico, el filtro de Kalman lineal y el UKF frente a la curva observada de concentración de $PM_{2,5}$	84
4.14	Evolución temporal de los coeficientes dinámicos asociados a los componentes principales del modelo para el dataset de polución.	84
4.15	Diagnóstico de innovaciones del modelo para el dataset de polución. Se muestran el ACF, el histograma y el gráfico Q-Q de los residuos.	85
4.16	Dinámica temporal del sistema para el dataset de material particulado 2.5 : radio espectral y volatilidad condicional.	85
4.17	Comparación de las predicciones obtenidas mediante los 6 modelos frente a la curva observada de temperatura de aceite	88
4.18	Evolución temporal de los coeficientes dinámicos asociados a los componentes principales del modelo para el dataset de temperatura del aceite OT.	88
4.19	Diagnóstico de innovaciones del modelo para el dataset de polución. Se muestran el ACF, el histograma y el gráfico Q-Q de los residuos.	89
4.20	Dinámica temporal del sistema para el dataset de temperatura: radio espectral y volatilidad condicional.	89
4.21	Gráficos del experimento 2 respecto de la dimensionalidad	94

Capítulo 1

Introducción

El análisis de series temporales funcionales constituye una extensión natural de la teoría clásica de series temporales al caso en que cada observación temporal es una función definida sobre un dominio continuo. En este contexto, el objeto de estudio ya no es una sucesión de variables aleatorias escalares o vectoriales, sino una familia de elementos de un espacio de Hilbert, típicamente $L^2(\mathcal{S})$. Esta generalización permite modelar de manera más adecuada fenómenos en los cuales la estructura básica de observación es una trayectoria completa, como ocurre en aplicaciones provenientes de energía, finanzas, transporte, monitoreo ambiental y procesos industriales.

Desde el punto de vista metodológico, el tratamiento de series temporales funcionales exige resolver dos problemas al mismo tiempo. El primero consiste en representar de manera parsimoniosa objetos de naturaleza infinito-dimensional. El segundo corresponde a modelar la dependencia temporal entre tales objetos, preservando en la medida de lo posible la estructura funcional subyacente. Una estrategia ampliamente utilizada para abordar esta dificultad consiste en proyectar las trayectorias sobre una base funcional y trabajar con los coeficientes resultantes. En particular, el análisis de componentes principales funcionales (FPCA) permite construir una base empírica ortonormal adaptada a la estructura de covarianza del proceso, reduciendo el problema a la evolución temporal de un vector de puntuaciones funcionales.

Sin embargo, los enfoques clásicos para series temporales funcionales presentan limitacio-

nes importantes. Por una parte, muchos modelos autorregresivos funcionales se formulan mediante operadores lineales fijos, lo que restringe su capacidad para representar dinámicas más complejas. Por otra, en numerosos métodos la reducción de dimensión y la modelación temporal se realizan en etapas separadas, sin una formulación explícita que distinga entre estado latente y observación. Esta dificultad se vuelve especialmente relevante en presencia de ruido de medición, cambios estructurales, errores de especificación o relaciones no lineales entre las componentes.

En este trabajo se estudia un modelo de espacio de estados para series temporales funcionales construido sobre una representación reducida obtenida mediante FPCA. La idea central consiste en describir la evolución temporal del proceso a través de las puntuaciones funcionales asociadas a las primeras componentes principales, formulando su dinámica en un espacio de dimensión finita y realizando inferencia secuencial mediante el filtro de Kalman *unscented* (UKF). Esta formulación permite integrar reducción de dimensión, modelación dinámica e inferencia recursiva en un mismo espacio probabilístico.

El interés del enfoque propuesto no está únicamente en la formulación de un modelo alternativo, sino también en el análisis de su comportamiento bajo distintos escenarios de experimentación. En particular, en esta tesis se estudia el efecto de la elección de la base funcional, de la dimensión truncada, de la presencia de no linealidades y de desviaciones respecto a los supuestos distribucionales usuales. Asimismo, se compara el desempeño del modelo propuesto con métodos funcionales y lineales clásicos, con el fin de determinar en qué contextos la incorporación de una dinámica latente no lineal resulta ventajosa.

El objetivo general de esta tesis es formular y evaluar un modelo de predicción para series temporales funcionales basado en una representación finito-dimensional vía FPCA y en una formulación de espacio de estados estimada secuencialmente mediante un filtro de Kalman *unscented*. De manera más específica, los objetivos del trabajo son los siguientes:

1. Establecer el marco teórico necesario para la representación de trayectorias funcionales en espacios de Hilbert;
2. Justificar el uso de FPCA como mecanismo de reducción de dimensión y como base para la construcción del estado reducido;

3. Formular modelos dinámicos funcionales y describir su relación con modelos autorregresivos y modelos de espacio de estados;
4. Desarrollar un procedimiento de estimación secuencial en el espacio reducido mediante el filtro de Kalman *unscented*;
5. Evaluar experimentalmente el comportamiento del enfoque propuesto en datos simulados y reales, analizando su estabilidad, robustez y desempeño predictivo.

Las contribuciones principales del trabajo son las siguientes:

- Se sistematiza un marco teórico que conecta representación funcional en espacios de Hilbert, FPCA, modelos autorregresivos funcionales y formulaciones en espacio de estados.
- Se formula una estrategia de predicción funcional basada en una representación reducida de las curvas mediante FPCA y en la evolución temporal de las puntuaciones funcionales retenidas.
- Se implementa un esquema de estimación secuencial mediante el filtro de Kalman *unscented* para modelar dinámicas potencialmente no lineales en el espacio reducido.
- Se evalúa empíricamente el desempeño del enfoque propuesto frente a modelos funcionales y multivariados de referencia en cinco conjuntos de datos reales.
- Se analiza la sensibilidad del procedimiento frente a la dimensión funcional retenida, cambios estructurales y desviaciones respecto de supuestos gaussianos.

La evaluación experimental se realiza sobre cinco conjuntos de datos reales provenientes de dominios heterogéneos, a saber: criptomonedas, consumo eléctrico, flujo vehicular, población atmosférica y temperatura de aceite de transformadores. Esta diversidad permite estudiar el comportamiento del modelo propuesto bajo estructuras dinámicas de naturaleza distinta y proporciona una base empírica para comparar su desempeño con el de modelos funcionales clásicos y lineales. Los resultados muestran que el UKF puede ofrecer ventajas predictivas en ciertos escenarios, particularmente cuando la dinámica del estado reducido parece presentar relaciones no lineales relevantes. No obstante, su desempeño

no domina uniformemente al de modelos más parsimoniosos. En consecuencia, la elección entre UKF, Kalman lineal, FAR(1), TV-FAR o f-GARCH debe realizarse considerando la estructura dinámica del proceso, la escala de los errores y la métrica predictiva utilizada.

La tesis se organiza de la siguiente manera. En el Capítulo 2 se desarrolla el marco teórico, incluyendo representación funcional en bases, análisis de componentes principales funcionales, modelos FAR, modelos de espacio de estados funcionales y predicción funcional. En el Capítulo 3 se presenta la metodología propuesta y se reportan los resultados experimentales obtenidos sobre datos simulados y reales. Finalmente, en el Capítulo 4 se exponen las conclusiones del trabajo, junto con sus principales limitaciones y posibles líneas de investigación futura.

Capítulo 2

Marco teórico

2.1. Datos funcionales y representación en bases

2.1.1. Espacio funcional

Sea $\mathcal{S} \subset \mathbb{R}$ un dominio compacto. Se denota por

$$L^2(\mathcal{S}) = \left\{ f : \mathcal{S} \rightarrow \mathbb{R} : \int_{\mathcal{S}} |f(s)|^2 ds < \infty \right\} \quad (2.1)$$

el espacio de funciones cuadrado integrables sobre $\mathcal{S}$. Este espacio se considera provisto del producto interno

$$\langle f, g \rangle_{L^2} = \int_{\mathcal{S}} f(s) g(s) ds, \quad \|f\|_{L^2(\mathcal{S})} = \sqrt{\langle f, f \rangle_{L^2}}. \quad (2.2)$$

Con esta estructura, $L^2(\mathcal{S})$ es un espacio de Hilbert separable. Formalmente, sus elementos corresponden a clases de equivalencia de funciones que son iguales casi en todas partes respecto de la medida de Lebesgue. No obstante, en esta tesis se empleará la notación funcional usual, identificando cada clase de equivalencia con un representante siempre que no exista ambigüedad.

En este trabajo, las observaciones funcionales se modelan como variables aleatorias con va-

lores en $L^2(\mathcal{S})$, y se denotan por $\{X_t\}_{t \in \mathbb{Z}}$. En aplicaciones, estas trayectorias no suelen observarse de manera continua, sino mediante mediciones discretas de la forma $Y_{t,j} \approx X_t(s_j)$, donde $\{s_j\}$ representa una malla finita de puntos en $\mathcal{S}$. Por esta razón, la representación funcional utilizada en esta tesis se obtiene a partir de una etapa previa de suavizamiento o reconstrucción.

2.1.2. Procesos funcionales

Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad. Una variable aleatoria funcional se define como una aplicación medible $X_t : \Omega \rightarrow L^2(\mathcal{S})$, donde $L^2(\mathcal{S})$ está provisto de su σ -álgebra boreliana inducida por la norma.

La colección $\{X_t\}_{t \in \mathbb{Z}}$ de variables aleatorias funcionales se denomina proceso funcional. En este contexto, el índice t se interpreta como un índice temporal externo, mientras que $s \in \mathcal{S}$ corresponde al índice funcional interno. En particular, para cada realización $\omega \in \Omega$, la trayectoria $X_t(\cdot, \omega)$ define una función cuadrado integrable sobre $\mathcal{S}$.

Aquí por conveniencia, se considerarán procesos funcionales de segundo orden, es decir, tales que $\mathbb{E}\|X_t\|_{L^2(\mathcal{S})}^2 < \infty$, lo que garantiza la existencia de operadores de covarianza bien definidos y permite el uso de representaciones espectrales.

A diferencia del análisis funcional estático, en este trabajo interesa modelar la dependencia serial de la sucesión $\{X_t\}$, de modo que la información contenida en $X_{t-1}, X_{t-2}, \dots$ contribuya a la predicción de X_t .

2.1.3. Expansión en bases funcionales

Sea $\{\phi_i\}_{i=1}^{\infty}$ una base ortonormal completa de $L^2(\mathcal{S})$. Entonces, para cada $t \in \mathbb{Z}$, el proceso funcional X_t admite la representación

$$X_t(s) = \sum_{i=1}^{\infty} c_{t,i} \phi_i(s), \quad c_{t,i} = \langle X_t, \phi_i \rangle_{L^2(\mathcal{S})} \quad (2.3)$$

donde la serie converge en norma $L^2(\mathcal{S})$.

Dado que en aplicaciones se trabaja con representaciones finitas, esta expansión infinita se aproxima mediante una truncación a un número finito p de términos, dando lugar a la representación

$$X_t^{(p)}(s) = \sum_{i=1}^p c_{t,i} \phi_i(s) \quad (2.4)$$

Proposición 2.1.1 (Error de truncación). *Sea $X_t \in L^2(\mathcal{S})$ y $\{\phi_i\}_{i \geq 1}$ una base ortonormal. Entonces, el error de aproximación en norma $L^2(\mathcal{S})$ al truncar la expansión en p términos está dado por*

$$\|X_t - X_t^{(p)}\|_{L^2(\mathcal{S})}^2 = \sum_{i>p} c_{t,i}^2 \quad (2.5)$$

Demostración. El resultado se sigue directamente de la identidad de Parseval:

$$\|X_t\|_{L^2(\mathcal{S})}^2 = \sum_{i=1}^{\infty} c_{t,i}^2,$$

de donde

$$\|X_t - X_t^{(p)}\|_{L^2(\mathcal{S})}^2 = \sum_{i=1}^{\infty} c_{t,i}^2 - \sum_{i=1}^p c_{t,i}^2 = \sum_{i>p} c_{t,i}^2.$$

□

2.1.4. Representación finita en base ortonormal

Sea $\{\phi_i\}_{i=1}^p$ un sistema ortonormal en $L^2(\mathcal{S})$ y consideremos el subespacio

$$\mathcal{H}_p = \text{span}\{\phi_1, \dots, \phi_p\}.$$

Definimos

$$\phi(s) = \begin{pmatrix} \phi_1(s) \\ \vdots \\ \phi_p(s) \end{pmatrix}, \quad \mathbf{c}_t = \begin{pmatrix} c_{t,1} \\ \vdots \\ c_{t,p} \end{pmatrix}, \quad c_{t,i} = \langle X_t, \phi_i \rangle.$$

La proyección de X_t sobre $\mathcal{H}_p$ está dada por

$$X_t^{(p)}(s) = \sum_{i=1}^p c_{t,i} \phi_i(s)$$

$$X_t^{(p)}(s) = \mathbf{c}_t^\top \boldsymbol{\phi}(s) \quad (2.6)$$

Tenemos que en una base ortonormal, la norma funcional de la curva truncada coincide con la norma euclidiana del vector de coeficientes.

Proposición 2.1.2 (Norma inducida por la representación finita). *Si $\{\phi_i\}_{i=1}^p$ es un sistema ortonormal, entonces*

$$\|X_t^{(p)}\|_{L^2(S)}^2 = \sum_{i=1}^p c_{t,i}^2 \quad (2.7)$$

Demostración. Usando la ortonormalidad del sistema,

$$\|X_t^{(p)}\|_{L^2(S)}^2 = \left\langle \sum_{i=1}^p c_{t,i} \phi_i, \sum_{j=1}^p c_{t,j} \phi_j \right\rangle = \sum_{i,j=1}^p c_{t,i} c_{t,j} \langle \phi_i, \phi_j \rangle = \sum_{i=1}^p c_{t,i}^2.$$

□

Esta identidad muestra que, en una base ortonormal, el problema de estimación funcional puede tratarse como un problema de estimación sobre los coeficientes, preservando la estructura cuadrática del error.

2.1.5. Caso general: bases no ortonormales

Sea $\{\phi_i\}_{i=1}^p$ una familia linealmente independiente en $L^2(\mathcal{S})$ y sea

$$\mathcal{H}_p = \text{span}\{\phi_1, \dots, \phi_p\}.$$

Definimos la matriz de Gram asociada por

$$G_{ij} = \langle \phi_i, \phi_j \rangle_{L^2(S)}, \quad i, j = 1, \dots, p.$$

Para la proyección de X_t sobre $\mathcal{H}_p$,

$$X_t^{(p)}(s) = \sum_{i=1}^p c_{t,i} \phi_i(s),$$

se tiene que la norma inducida satisface

$$\|X_t^{(p)}\|_{L^2(S)}^2 = \mathbf{c}_t^\top \mathbf{G} \mathbf{c}_t,$$

donde $\mathbf{c}_t = (c_{t,1}, \dots, c_{t,p})^\top$.

En ausencia de ortonormalidad, la geometría del problema queda codificada por la matriz de Gram, por lo que el análisis en coeficientes debe ajustarse en consecuencia.

2.1.6. Notación matricial global

Sea $T \in \mathbb{N}$ y consideremos la representación finita de orden p de la serie temporal funcional $\{X_t\}_{t=1}^T$. Definimos la matriz de coeficientes

$$\mathbf{C} = \begin{pmatrix} c_{1,1} & \cdots & c_{1,p} \\ \vdots & & \vdots \\ c_{T,1} & \cdots & c_{T,p} \end{pmatrix},$$

donde la fila t corresponde al vector de coeficientes $\mathbf{c}_t^\top$ asociado a la curva $X_t^{(p)}$.

Definiendo

$$\boldsymbol{\phi}(s) = \begin{pmatrix} \phi_1(s) \\ \vdots \\ \phi_p(s) \end{pmatrix},$$

la colección de curvas proyectadas puede escribirse de forma compacta como

$$\mathbf{X}^{(p)}(s) = \begin{pmatrix} X_1^{(p)}(s) \\ \vdots \\ X_T^{(p)}(s) \end{pmatrix} = \mathbf{C} \boldsymbol{\phi}(s).$$

Esta representación permite abordar el análisis de la serie temporal funcional mediante modelos multivariados definidos sobre la secuencia de vectores de coeficientes $\{\mathbf{c}_t\}_{t=1}^T$, tales como modelos autorregresivos vectoriales o formulaciones en espacio de estados.

2.1.7. Elección de bases funcionales

Sea $S \subset \mathbb{R}$ un dominio compacto y $L^2(S)$ el espacio de Hilbert de funciones cuadrado integrables. Una representación funcional de una trayectoria $X_t \in L^2(S)$ se obtiene mediante una expansión en una familia de funciones base $\{\phi_k\}_{k \geq 1}$:

$$X_t(s) = \sum_{k=1}^{\infty} c_{t,k} \phi_k(s), \quad c_{t,k} = \langle X_t, \phi_k \rangle.$$

La elección de la base $\{\phi_k\}$ determina las propiedades de aproximación, regularidad y parsimonia de la representación. A continuación se describen tres familias fundamentales de bases funcionales.

Base de Fourier

Sea $S = [0, 1]$. La base de Fourier ortonormal en $L^2([0, 1])$ está dada por

$$\phi_1(s) = 1, \quad \phi_{2k}(s) = \sqrt{2} \cos(2\pi ks), \quad \phi_{2k+1}(s) = \sqrt{2} \sin(2\pi ks), \quad k \geq 1.$$

Esta familia satisface la propiedad de ortonormalidad:

$$\langle \phi_i, \phi_j \rangle = \delta_{ij}.$$

La expansión de Fourier de X_t viene dada por

$$X_t(s) = a_{t,0} + \sum_{k=1}^{\infty} (a_{t,k} \cos(2\pi ks) + b_{t,k} \sin(2\pi ks)),$$

donde los coeficientes se obtienen mediante proyecciones en L^2 .

Base de Fourier

Sea $\mathcal{S} = [0, 1]$. La base de Fourier ortonormal en $L^2([0, 1])$ está dada por

$$\phi_1(s) = 1, \quad \phi_{2k}(s) = \sqrt{2} \cos(2\pi ks), \quad \phi_{2k+1}(s) = \sqrt{2} \sin(2\pi ks), \quad k \geq 1.$$

Esta familia satisface la propiedad de ortonormalidad

$$\langle \phi_i, \phi_j \rangle = \delta_{ij},$$

donde δ_{ij} corresponde al delta de Kronecker.

Por lo tanto, si $X_t \in L^2([0, 1])$, su expansión en esta base puede escribirse como

$$X_t(s) = c_{t,1}\phi_1(s) + \sum_{k=1}^{\infty} \{c_{t,2k}\phi_{2k}(s) + c_{t,2k+1}\phi_{2k+1}(s)\}.$$

Debido a la ortonormalidad de la base, los coeficientes se obtienen directamente mediante proyecciones en $L^2([0, 1])$:

$$c_{t,j} = \langle X_t, \phi_j \rangle = \int_0^1 X_t(s) \phi_j(s) ds.$$

En particular,

$$c_{t,1} = \int_0^1 X_t(s) ds,$$

mientras que, para $k \geq 1$,

$$c_{t,2k} = \sqrt{2} \int_0^1 X_t(s) \cos(2\pi ks) ds, \quad c_{t,2k+1} = \sqrt{2} \int_0^1 X_t(s) \sin(2\pi ks) ds.$$

De manera equivalente, la expansión también puede expresarse en la forma clásica

$$X_t(s) = a_{t,0} + \sum_{k=1}^{\infty} (a_{t,k} \cos(2\pi ks) + b_{t,k} \sin(2\pi ks)),$$

Esta base es adecuada para funciones suaves y periódicas, debido a su soporte global.

Base B-spline

Sea $\{\tau_i\}_{i=0}^m$ una partición creciente del dominio S (nudos). Para un grado $p \geq 0$, las funciones B-spline se definen recursivamente mediante:

$$B_{i,0}(s) = \begin{cases} 1, & \tau_i \leq s < \tau_{i+1}, \\ 0, & \text{en otro caso,} \end{cases}$$

y para $p \geq 1$,

$$B_{i,p}(s) = \frac{s - \tau_i}{\tau_{i+p} - \tau_i} B_{i,p-1}(s) + \frac{\tau_{i+p+1} - s}{\tau_{i+p+1} - \tau_{i+1}} B_{i+1,p-1}(s).$$

Una función X_t se representa como

$$X_t(s) = \sum_{k=1}^K c_{t,k} B_{k,p}(s).$$

Las bases B-spline poseen soporte local, es decir, cada $B_{i,p}$ es distinta de cero sólo en un subconjunto del dominio, lo que permite capturar heterogeneidades locales y controlar la suavidad mediante el grado p y la elección de los nudos.

Base wavelet

Sea $\psi \in L^2(\mathbb{R})$ una función madre (wavelet) y ϕ la función de escala asociada. Las bases wavelet se generan mediante dilataciones y traslaciones:

$$\psi_{j,k}(s) = 2^{j/2} \psi(2^j s - k), \quad j, k \in \mathbb{Z}.$$

Asimismo, las funciones de escala se definen como

$$\phi_{j,k}(s) = 2^{j/2} \phi(2^j s - k).$$

La expansión wavelet de una función toma la forma

$$X_t(s) = \sum_k \alpha_{J,k} \phi_{J,k}(s) + \sum_{j=J}^{\infty} \sum_k \beta_{j,k} \psi_{j,k}(s),$$

donde $\alpha_{J,k}$ y $\beta_{j,k}$ son coeficientes de aproximación y detalle, respectivamente.

Las bases wavelet permiten una representación multirresolución, capturando simultáneamente estructuras globales y locales, siendo especialmente útiles para funciones con irregularidades o cambios abruptos.

2.2. Análisis de componentes principales funcionales

En esta sección se presenta el análisis de componentes principales funcionales (FPCA) como una forma de obtener bases empíricas ortonormales adaptadas a la variabilidad del proceso funcional.

2.2.1. Operador de covarianza

Sea $\{X_t\}_{t \in \mathbb{Z}}$ un proceso funcional de segundo orden con valores en $L^2(\mathcal{S})$, es decir,

$$\mathbb{E} \left(\|X_t\|_{L^2(\mathcal{S})}^2 \right) < \infty,$$

y supóngase que es estacionario en segundo orden. Bajo esta condición, la media funcional está bien definida como un elemento de $L^2(\mathcal{S})$ y se define por

$$\mu(s) = \mathbb{E}[X_t(s)]. \quad (2.8)$$

El núcleo de covarianza asociado se define como

$$C(s, u) = \mathbb{E}[(X_t(s) - \mu(s))(X_t(u) - \mu(u))], \quad s, u \in \mathcal{S}. \quad (2.9)$$

La condición de segundo orden garantiza que el núcleo de covarianza pertenece a $L^2(\mathcal{S} \times \mathcal{S})$ bajo los supuestos usuales de integrabilidad. Además, los intercambios entre esperanza e integración se justifican mediante el teorema de Fubini–Tonelli.

A partir del núcleo C , se define el operador de covarianza $\mathcal{C} : L^2(\mathcal{S}) \rightarrow L^2(\mathcal{S})$ como el operador integral

$$(\mathcal{C}f)(s) = \int_{\mathcal{S}} C(s, u)f(u) du, \quad f \in L^2(\mathcal{S}). \quad (2.10)$$

Proposición 2.2.1. *Si $C(s, u) \in L^2(\mathcal{S} \times \mathcal{S})$, entonces el operador de covarianza $\mathcal{C}$ es un operador Hilbert–Schmidt y, en particular, compacto.*

Demostración. Un operador integral con núcleo $C(s, u) \in L^2(\mathcal{S} \times \mathcal{S})$ es Hilbert–Schmidt, ya que

$$\|\mathcal{C}\|_{HS}^2 = \int_{\mathcal{S}} \int_{\mathcal{S}} |C(s, u)|^2 du ds < \infty.$$

Dado que todo operador Hilbert–Schmidt en un espacio de Hilbert es compacto, se concluye que $\mathcal{C}$ es compacto. $\square$

Además, el operador $\mathcal{C}$ es autoadjunto y positivo, lo que permite aplicar el teorema espectral para operadores compactos.

2.2.2. Propiedades de autoadjunción y positividad

Proposición 2.2.2. *El operador de covarianza $\mathcal{C}$ es autoadjunto y positivo semidefinido, es decir, para todo $f, g \in L^2(\mathcal{S})$ se cumple*

$$\langle \mathcal{C}f, g \rangle_{L^2(\mathcal{S})} = \langle f, \mathcal{C}g \rangle_{L^2(\mathcal{S})}, \quad \langle f, \mathcal{C}f \rangle_{L^2(\mathcal{S})} \geq 0.$$

Demostración. Dado que el núcleo de covarianza satisface $C(s, u) = C(u, s)$, el operador integral $\mathcal{C}$ es autoadjunto. En efecto,

$$\langle \mathcal{C}f, g \rangle = \int_{\mathcal{S}} \int_{\mathcal{S}} C(s, u) f(u) g(s) du ds = \int_{\mathcal{S}} \int_{\mathcal{S}} C(u, s) g(s) f(u) ds du = \langle f, \mathcal{C}g \rangle.$$

Para la positividad, se tiene

$$\langle f, \mathcal{C}f \rangle = \int_{\mathcal{S}} \int_{\mathcal{S}} f(s) C(s, u) f(u) du ds = \mathbb{E} \left[\left(\int_{\mathcal{S}} f(s) (X_t(s) - \mu(s)) ds \right)^2 \right] \geq 0,$$

lo que concluye la demostración. □

2.2.3. Teorema espectral y FPCA

2.2.4. Teorema espectral y FPCA

Teorema 2.2.1 (Descomposición espectral). *Sea $\mathcal{C} : L^2(\mathcal{S}) \rightarrow L^2(\mathcal{S})$ un operador compacto, autoadjunto y positivo. Entonces existe una familia ortonormal de autofunciones $\{\psi_i\}_{i=1}^{\infty}$ y una sucesión de autovalores $\{\lambda_i\}_{i=1}^{\infty}$, con $\lambda_i \geq 0$, tales que*

$$\mathcal{C}\psi_i = \lambda_i \psi_i. \tag{2.11}$$

Las autofunciones asociadas a autovalores no nulos generan el cierre del rango de $\mathcal{C}$. Si dicho subespacio no coincide con todo $L^2(\mathcal{S})$, la familia se completa con una base ortonormal de $\ker(\mathcal{C})$, cuyos elementos están asociados al autovalor cero. De este modo se obtiene una base ortonormal de $L^2(\mathcal{S})$ formada por autofunciones de $\mathcal{C}$.

Además, para cada t , se tiene la expansión

$$X_t(s) = \mu(s) + \sum_{i=1}^{\infty} \xi_{t,i} \psi_i(s), \quad (2.12)$$

con convergencia en norma $L^2(\mathcal{S})$, donde las puntuaciones funcionales están dadas por

$$\xi_{t,i} = \langle X_t - \mu, \psi_i \rangle. \quad (2.13)$$

Estas puntuaciones satisfacen

$$\mathbb{E}[\xi_{t,i}] = 0, \quad \text{Var}(\xi_{t,i}) = \lambda_i. \quad (2.14)$$

Demostración. Por la proposición anterior, el operador de covarianza $\mathcal{C}$ es compacto, autoadjunto y positivo en el espacio de Hilbert separable $L^2(\mathcal{S})$.

Por el teorema espectral para operadores compactos autoadjuntos, las autofunciones asociadas a los autovalores no nulos de $\mathcal{C}$ forman una familia ortonormal que genera el cierre del rango de $\mathcal{C}$. Los autovalores correspondientes son reales, no negativos y pueden ordenarse como una sucesión no creciente que converge a cero.

Si el cierre del rango de $\mathcal{C}$ no coincide con todo $L^2(\mathcal{S})$, esta familia se completa con una base ortonormal de $\ker(\mathcal{C})$. Los elementos añadidos corresponden al autovalor cero. De este modo se obtiene una base ortonormal completa de $L^2(\mathcal{S})$ formada por autofunciones de $\mathcal{C}$.

Sea ahora $X_t - \mu \in L^2(\mathcal{S})$. Al ser $\{\psi_i\}_{i=1}^{\infty}$ una base ortonormal completa, se tiene la expansión

$$X_t(s) - \mu(s) = \sum_{i=1}^{\infty} \langle X_t - \mu, \psi_i \rangle \psi_i(s),$$

con convergencia en norma $L^2(\mathcal{S})$. Definimos las puntuaciones funcionales como

$$\xi_{t,i} := \langle X_t - \mu, \psi_i \rangle.$$

Por lo tanto,

$$X_t(s) = \mu(s) + \sum_{i=1}^{\infty} \xi_{t,i} \psi_i(s).$$

Por linealidad de la esperanza y por la definición de μ , se obtiene

$$\mathbb{E}[\xi_{t,i}] = \mathbb{E}[\langle X_t - \mu, \psi_i \rangle] = \langle \mathbb{E}[X_t - \mu], \psi_i \rangle = 0.$$

Para la varianza, usando la definición del operador de covarianza,

$$\text{Var}(\xi_{t,i}) = \mathbb{E}[\langle X_t - \mu, \psi_i \rangle^2] = \langle \mathcal{C}\psi_i, \psi_i \rangle.$$

Como $\mathcal{C}\psi_i = \lambda_i\psi_i$, se sigue que

$$\text{Var}(\xi_{t,i}) = \lambda_i \langle \psi_i, \psi_i \rangle = \lambda_i,$$

ya que $\|\psi_i\|_{L^2} = 1$.

Finalmente, para $i \neq j$,

$$\text{Cov}(\xi_{t,i}, \xi_{t,j}) = \mathbb{E}[\xi_{t,i}\xi_{t,j}] = \langle \mathcal{C}\psi_i, \psi_j \rangle = \lambda_i \langle \psi_i, \psi_j \rangle = 0.$$

Esta propiedad implica que las puntuaciones funcionales correspondientes a distintas componentes principales no presentan correlación entre sí. En este sentido, cada puntuación $\xi_{t,i}$ captura un modo de variación distinto del proceso funcional. En consecuencia, la variabilidad total del proceso se descompone aditivamente a lo largo de las componentes principales funcionales.

En la práctica, las componentes principales funcionales corresponden a las autofunciones asociadas a los autovalores positivos, ya que las direcciones pertenecientes a $\ker(\mathcal{C})$ tienen varianza nula y no aportan a la variabilidad del proceso. $\square$

2.2.5. Truncamiento y error de aproximación

Sea $\{X_t\}_{t \in \mathbb{Z}}$ un proceso funcional de segundo orden con expansión de Karhunen–Loève

$$X_t(s) = \mu(s) + \sum_{i=1}^{\infty} \xi_{t,i} \psi_i(s),$$

donde $\{\psi_i\}_{i \geq 1}$ es una base ortonormal de autofunciones del operador de covarianza $\mathcal{C}$, asociadas a autovalores $\{\lambda_i\}_{i \geq 1}$ tales que $\lambda_1 \geq \lambda_2 \geq \dots \geq 0$.

Dado que en la práctica se trabaja con representaciones finitas, se considera la aproximación truncada de orden K :

$$X_t^{(K)}(s) = \mu(s) + \sum_{i=1}^K \xi_{t,i} \psi_i(s) \quad (2.15)$$

Error de aproximación

El error cuadrático medio en norma $L^2(\mathcal{S})$ asociado a la aproximación truncada satisface :

$$\mathbb{E} \|X_t - X_t^{(K)}\|_{L^2(\mathcal{S})}^2 = \sum_{i > K} \lambda_i \quad (2.16)$$

Este resultado muestra que la calidad de la aproximación depende exclusivamente de la energía contenida en las componentes descartadas, cuantificada por los autovalores del operador de covarianza.

En particular, la varianza total del proceso funcional se descompone como:

$$\mathbb{E} \|X_t - \mu\|_{L^2(\mathcal{S})}^2 = \sum_{i \geq 1} \lambda_i,$$

por lo que la proporción de varianza explicada por las primeras K componentes principales está dada por:

$$\frac{\sum_{i=1}^K \lambda_i}{\sum_{i \geq 1} \lambda_i} \quad (2.17)$$

Optimalidad de la aproximación

La aproximación truncada basada en las primeras K autofunciones es óptima en el sentido de mínimos cuadrados entre todas las aproximaciones de rango K . Más precisamente, se

cumple que:

$$\inf_{\{\varphi_1, \dots, \varphi_K\}} \mathbb{E} \left\| X_t - \mu - \sum_{i=1}^K \langle X_t - \mu, \varphi_i \rangle \varphi_i \right\|_{L^2(\mathcal{S})}^2 = \sum_{i>K} \lambda_i,$$

donde el ínfimo se toma sobre todos los sistemas ortonormales $\{\varphi_1, \dots, \varphi_K\}$ en $L^2(\mathcal{S})$, y se alcanza cuando $\varphi_i = \psi_i$ para $i = 1, \dots, K$.

Este resultado justifica el uso del Análisis de Componentes Principales Funcionales como un procedimiento de reducción de dimensión óptimo en media cuadrática, ya que permite representar el proceso funcional mediante un número reducido de coeficientes preservando la mayor parte de su variabilidad.

2.2.6. Descomposición del error total

La aproximación truncada mediante FPCA introduce dos fuentes distintas de error. Por una parte, aparece un error de truncación asociado a las componentes no retenidas en la expansión. Por otra, al modelar o predecir las primeras componentes principales, surge un error de estimación sobre los coeficientes retenidos. El siguiente resultado permite separar ambas contribuciones de manera exacta.

Proposición 2.2.3 (Descomposición del error total). *Sea*

$$X_t(s) = \mu(s) + \sum_{i=1}^{\infty} \xi_{t,i} \psi_i(s)$$

la expansión de Karhunen–Loève de un proceso funcional en una base ortonormal de autofunciones $\{\psi_i\}_{i \geq 1}$. Sea además

$$\widehat{X}_t^{(K)}(s) = \mu(s) + \sum_{i=1}^K \widehat{\xi}_{t,i} \psi_i(s)$$

una estimación o predicción basada en las primeras K componentes principales. Entonces,

$$\|X_t - \widehat{X}_t^{(K)}\|_{L^2(\mathcal{S})}^2 = \sum_{i=1}^K (\xi_{t,i} - \widehat{\xi}_{t,i})^2 + \sum_{i>K} \xi_{t,i}^2 \quad (2.18)$$

Demostración. Por definición de X_t y de $\widehat{X}_t^{(K)}$, se tiene

$$X_t(s) - \widehat{X}_t^{(K)}(s) = \sum_{i=1}^K (\xi_{t,i} - \widehat{\xi}_{t,i}) \psi_i(s) + \sum_{i>K} \xi_{t,i} \psi_i(s).$$

Dado que $\{\psi_i\}_{i \geq 1}$ es una base ortonormal de $L^2(\mathcal{S})$, la identidad de Parseval implica que

$$\|X_t - \widehat{X}_t^{(K)}\|_{L^2(\mathcal{S})}^2 = \sum_{i=1}^K (\xi_{t,i} - \widehat{\xi}_{t,i})^2 + \sum_{i>K} \xi_{t,i}^2.$$

Esto concluye la demostración. □

La proposición anterior muestra que el error total de reconstrucción o predicción funcional puede interpretarse como la suma de dos términos complementarios: el primero corresponde al error cometido al estimar o predecir las puntuaciones funcionales retenidas, mientras que el segundo representa la pérdida de información inducida por truncar la expansión en solo K componentes. En consecuencia, la elección de K determina un compromiso natural entre parsimonia y fidelidad de representación.

2.2.7. FPCA como paso de reducción de dimensión para modelación dinámica

La expansión truncada mediante componentes principales funcionales no solo proporciona una aproximación eficiente de las trayectorias en $L^2(\mathcal{S})$, sino que además induce una representación finito-dimensional natural del proceso funcional. En efecto, al retener las primeras K componentes principales, cada observación funcional puede escribirse como:

$$X_t^{(K)}(s) = \mu(s) + \sum_{i=1}^K \xi_{t,i} \psi_i(s),$$

de modo que la información relevante contenida en la curva X_t queda resumida en el vector de puntuaciones funcionales:

$$\boldsymbol{\xi}_t = (\xi_{t,1}, \dots, \xi_{t,K})^\top \in \mathbb{R}^K \tag{2.19}$$

Desde esta perspectiva, el proceso funcional infinito-dimensional $\{X_t\}_{t \in \mathbb{Z}}$ se reemplaza por una sucesión de vectores $\{\boldsymbol{\xi}_t\}_{t \in \mathbb{Z}}$ en dimensión finita, lo que permite formular modelos dinámicos sobre un espacio euclidiano de dimensión reducida. En particular, la dependencia temporal del proceso puede modelarse a través de la evolución de las puntuaciones funcionales, ya sea mediante modelos autorregresivos multivariados o mediante formulaciones en espacio de estados.

Más precisamente, si se interpreta $\boldsymbol{\xi}_t$ como una representación reducida del estado del sistema en el instante t , entonces la dinámica temporal puede describirse mediante una ecuación de transición del tipo:

$$\boldsymbol{\xi}_t = f(\boldsymbol{\xi}_{t-1}) + \mathbf{w}_t \quad (2.20)$$

acompañada, si es necesario, de una ecuación de observación que vincule el estado latente con las cantidades observadas. En el caso lineal, esta formulación conduce naturalmente a modelos VAR o a sistemas lineales de espacio de estados; en contextos no lineales, permite utilizar extensiones tales como el filtro de Kalman *unscented*.

La reconstrucción funcional de una estimación o predicción del estado reducido se obtiene de manera inmediata a través de la base de autofunciones:

$$\widehat{X}_t^{(K)}(s) = \mu(s) + \sum_{i=1}^K \widehat{\xi}_{t,i} \psi_i(s) \quad (2.21)$$

De este modo, la etapa de reducción de dimensión vía FPCA constituye el puente entre la estructura funcional del problema y la modelación dinámica posterior, permitiendo trasladar el análisis desde un espacio de Hilbert infinito-dimensional a un marco multivariado finito-dimensional sin perder los principales modos de variación del proceso.

En consecuencia, el FPCA desempeña un doble papel en esta tesis. Por una parte, actúa como una herramienta de compresión óptima en media cuadrática. Por otra, proporciona las variables de estado reducidas sobre las cuales se construyen los modelos dinámicos considerados en los capítulos posteriores.

2.3. Series Temporales Funcionales

El proceso completo puede verse como una función de dos dominios:

$$X : \mathbb{Z} \times \mathcal{S} \rightarrow \mathbb{R}, \quad (t, s) \mapsto X_t(s),$$

donde, para cada instante temporal t , la realización $X_t(\cdot)$ es un elemento del espacio de Hilbert $L^2(\mathcal{S})$.

Decimos que $\{X_t\}_{t \in \mathbb{Z}}$ es una serie temporal funcional si:

1. $X_t \in L^2(\mathcal{S})$ casi seguramente para todo t ,
2. Existe dependencia temporal entre las observaciones funcionales X_t .

Desde este punto de vista, $\{X_t\}$ es un proceso estocástico con valores en el espacio de Hilbert $L^2(\mathcal{S})$. En lo que sigue, tras la reducción de dimensión inducida por FPCA, el análisis temporal de $\{X_t\}$ podrá formularse en términos de la evolución de sus puntuaciones funcionales principales

2.3.1. Modelo FAR(1)

Un modelo autorregresivo funcional de orden uno (FAR(1)) se define como:

$$X_t = \mathcal{A}X_{t-1} + \varepsilon_t \tag{2.22}$$

donde:

- $\mathcal{A} : L^2(\mathcal{S}) \rightarrow L^2(\mathcal{S})$ es un operador lineal y compacto,
- $\{\varepsilon_t\}_{t \in \mathbb{Z}}$ es un proceso de ruido funcional centrado, con $\mathbb{E}[\varepsilon_t] = 0$ y $\varepsilon_t \in L^2(\mathcal{S})$ casi seguramente,
- $\{\varepsilon_t\}$ es no correlado en el tiempo y no correlado con X_{t-1} .

Bajo condiciones adecuadas sobre el operador $\mathcal{A}$ (por ejemplo, $\|\mathcal{A}\|_{\mathcal{L}} < 1$), el proceso FAR(1) admite una solución estacionaria única en $L^2(\mathcal{S})$.

2.3.2. Representación finito-dimensional del FAR(1)

El modelo FAR(1) constituye una formulación infinita-dimensional de la dependencia autorregresiva. Sin embargo, para fines de inferencia y predicción resulta natural trabajar con una representación truncada en dimensión finita, obtenida al proyectar el proceso funcional sobre un subespacio de dimensión K .

Sea $\{\phi_i\}_{i=1}^K$ un sistema ortonormal en $L^2(\mathcal{S})$ y consideremos la aproximación truncada

$$X_t^{(K)}(s) = \sum_{i=1}^K c_{t,i} \phi_i(s), \quad \varepsilon_t^{(K)}(s) = \sum_{i=1}^K \eta_{t,i} \phi_i(s),$$

donde

$$c_{t,i} = \langle X_t, \phi_i \rangle, \quad \eta_{t,i} = \langle \varepsilon_t, \phi_i \rangle.$$

Si el proceso funcional satisface el modelo FAR(1)

$$X_t = \mathcal{A}X_{t-1} + \varepsilon_t,$$

entonces, al proyectar sobre la base $\{\phi_i\}_{i=1}^K$, se obtiene

$$c_{t,i} = \langle \mathcal{A}X_{t-1}, \phi_i \rangle + \eta_{t,i}.$$

Usando la expansión de $X_{t-1}^{(K)}$, se deduce que

$$c_{t,i} = \sum_{j=1}^K \langle \mathcal{A}\phi_j, \phi_i \rangle c_{t-1,j} + \eta_{t,i}.$$

Definiendo la matriz $A \in \mathbb{R}^{K \times K}$ por

$$A_{ij} = \langle \mathcal{A}\phi_j, \phi_i \rangle \quad (2.23)$$

y los vectores

$$\mathbf{c}_t = (c_{t,1}, \dots, c_{t,K})^\top, \quad \boldsymbol{\eta}_t = (\eta_{t,1}, \dots, \eta_{t,K})^\top,$$

la dinámica truncada adopta la forma matricial

$$\mathbf{c}_t = A\mathbf{c}_{t-1} + \boldsymbol{\eta}_t \quad (2.24)$$

En consecuencia, la proyección finito-dimensional de un modelo FAR(1) corresponde a un sistema autorregresivo multivariado de orden uno para los coeficientes funcionales.

En el contexto de esta tesis, una elección particularmente relevante de base está dada por las primeras K autofunciones del operador de covarianza, obtenidas mediante FPCA. En ese caso,

$$\phi_i = \psi_i, \quad c_{t,i} = \xi_{t,i},$$

donde $\xi_{t,i}$ corresponde a la i -ésima puntuación funcional principal. Por tanto, el vector reducido,

$$\boldsymbol{\xi}_t = (\xi_{t,1}, \dots, \xi_{t,K})^\top$$

puede interpretarse como una representación finito-dimensional del estado del proceso funcional, y su dinámica lineal truncada queda dada por:

$$\boldsymbol{\xi}_t = A\boldsymbol{\xi}_{t-1} + \mathbf{u}_t \quad (2.25)$$

donde $\mathbf{u}_t$ representa el término de innovación proyectado sobre el subespacio generado por las primeras K componentes principales.

Esta representación establece el vínculo entre el modelo funcional infinito-dimensional y los modelos dinámicos multivariados de dimensión reducida, los cuales servirán como base para las formulaciones en espacio de estados desarrolladas más adelante.

2.3.3. Estabilidad y estacionariedad del sistema truncado

La representación finito-dimensional del modelo FAR(1) conduce al sistema

$$\mathbf{c}_t = A\mathbf{c}_{t-1} + \boldsymbol{\eta}_t,$$

donde $A \in \mathbb{R}^{K \times K}$ y $\{\boldsymbol{\eta}_t\}$ es un proceso de innovaciones centrado con segundo momento finito.

La estabilidad de este sistema depende de las propiedades espectrales de la matriz A . El siguiente resultado establece una condición suficiente para la existencia de una solución causal y estacionaria en segundo orden.

Teorema 2.3.1 (Estabilidad del sistema truncado). *Supóngase que el radio espectral de A satisface*

$$\rho(A) < 1 \tag{2.26}$$

y que $\{\boldsymbol{\eta}_t\}$ es un proceso de ruido blanco con

$$\mathbb{E}[\boldsymbol{\eta}_t] = \mathbf{0}, \quad \mathbb{E}\|\boldsymbol{\eta}_t\|^2 < \infty.$$

Entonces, el sistema

$$\mathbf{c}_t = A\mathbf{c}_{t-1} + \boldsymbol{\eta}_t$$

admite una solución causal dada por

$$\mathbf{c}_t = \sum_{j=0}^{\infty} A^j \boldsymbol{\eta}_{t-j} \tag{2.27}$$

donde la serie converge en norma cuadrática. En particular, el proceso $\{\mathbf{c}_t\}$ es estacionario en segundo orden.

Demostración. Como $\rho(A) < 1$, existe una norma matricial submultiplicativa $\|\cdot\|$, constantes $M > 0$ y $0 < \gamma < 1$ tales que

$$\|A^j\| \leq M\gamma^j, \quad \forall j \geq 0.$$

Consideremos la serie

$$\sum_{j=0}^{\infty} A^j \boldsymbol{\eta}_{t-j}.$$

Entonces,

$$\mathbb{E}\|A^j \boldsymbol{\eta}_{t-j}\|^2 \leq \|A^j\|^2 \mathbb{E}\|\boldsymbol{\eta}_{t-j}\|^2 \leq M^2 \gamma^{2j} \mathbb{E}\|\boldsymbol{\eta}_0\|^2.$$

Puesto que la serie geométrica

$$\sum_{j=0}^{\infty} \gamma^{2j}$$

es convergente, se concluye que

$$\sum_{j=0}^{\infty} A^j \boldsymbol{\eta}_{t-j}$$

converge en L^2 y, por tanto, define un proceso bien determinado.

Definiendo

$$\mathbf{c}_t := \sum_{j=0}^{\infty} A^j \boldsymbol{\eta}_{t-j},$$

se verifica que

$$A\mathbf{c}_{t-1} = \sum_{j=1}^{\infty} A^j \boldsymbol{\eta}_{t-j},$$

por lo que

$$\mathbf{c}_t - A\mathbf{c}_{t-1} = \boldsymbol{\eta}_t.$$

Esto demuestra que $\{\mathbf{c}_t\}$ satisface la ecuación del sistema.

Finalmente, dado que $\mathbf{c}_t$ se expresa como combinación lineal de innovaciones con coeficientes que no dependen de t , el proceso resultante es causal y estacionario en segundo orden. □

El Teorema 2.3.1 muestra que el radio espectral de la matriz dinámica A constituye una cantidad central para caracterizar la estabilidad del sistema truncado. En efecto, la condición $\rho(A) < 1$ garantiza que los efectos de las innovaciones se disipan en el tiempo y que el proceso admite una representación causal con segundo momento finito.

Desde un punto de vista dinámico, el valor de $\rho(A)$ también permite interpretar el grado de persistencia del sistema. Cuando $\rho(A)$ se encuentra claramente por debajo de uno,

los choques tienden a amortiguarse con rapidez. En cambio, si $\rho(A)$ es cercano a uno, el proceso opera en un régimen de alta persistencia, donde las perturbaciones pueden permanecer durante largos periodos antes de disiparse. Finalmente, valores de $\rho(A)$ superiores a uno se asocian a comportamientos inestables o explosivos, en los cuales los efectos de los choques pueden amplificarse en el tiempo.

En consecuencia, el radio espectral resume de manera natural la estabilidad del sistema dinámico reducido y proporciona una herramienta útil para interpretar la evolución temporal de los coeficientes funcionales.

2.3.4. Extensiones del modelo FAR y modelos dinámicos relacionados

El modelo FAR(1)

$$X_t = \mathcal{A}X_{t-1} + \varepsilon_t$$

constituye una formulación natural para describir dependencia temporal lineal en procesos funcionales. No obstante, en diversas aplicaciones esta estructura puede resultar restrictiva, ya sea porque la dinámica del sistema varía en el tiempo o porque la variabilidad condicional de las innovaciones no permanece constante. Asimismo, al trabajar con una representación truncada del proceso, surgen de manera natural formulaciones multivariadas sobre los coeficientes o puntuaciones funcionales. En esta sección se consideran tres extensiones o modelos relacionados: el modelo TV-FAR, el modelo VAR dinámico y el modelo f-GARCH.

Modelo TV-FAR

Una extensión inmediata del modelo FAR(1) se obtiene al permitir que el operador autorregresivo dependa explícitamente del tiempo. Esto conduce al modelo autorregresivo funcional con operador variante en el tiempo (*Time-Varying Functional Autoregressive Model*), dado por

$$X_t = \mathcal{A}_t X_{t-1} + \varepsilon_t \tag{2.28}$$

donde, para cada t , el operador

$$\mathcal{A}_t : L^2(\mathcal{S}) \rightarrow L^2(\mathcal{S})$$

es lineal.

A diferencia del FAR(1) estacionario, en esta formulación la dependencia temporal del proceso queda gobernada por una sucesión de operadores $\{\mathcal{A}_t\}_{t \in \mathbb{Z}}$, lo que permite representar cambios graduales o estructurales en la dinámica. En particular, el modelo TV-FAR resulta adecuado cuando la ley de evolución del sistema no puede considerarse constante en el tiempo.

Si $\{\phi_i\}_{i=1}^K$ es una base ortonormal y

$$X_t^{(K)}(s) = \sum_{i=1}^K c_{t,i} \phi_i(s),$$

entonces la proyección del modelo TV-FAR sobre el subespacio truncado induce un sistema de la forma

$$\mathbf{c}_t = A_t \mathbf{c}_{t-1} + \boldsymbol{\eta}_t \tag{2.29}$$

donde

$$(A_t)_{ij} = \langle \mathcal{A}_t \phi_j, \phi_i \rangle, \quad \boldsymbol{\eta}_t = (\eta_{t,1}, \dots, \eta_{t,K})^\top.$$

Por consiguiente, el modelo TV-FAR puede interpretarse como la contraparte funcional de un sistema autorregresivo multivariado con matriz dinámica dependiente del tiempo.

Modelo VAR dinámico

Una vez representado el proceso funcional en dimensión finita mediante una base truncada o mediante FPCA, es natural modelar directamente la dinámica del vector de coeficientes o puntuaciones. Si

$$\boldsymbol{\xi}_t = (\xi_{t,1}, \dots, \xi_{t,K})^\top$$

denota el vector de puntuaciones funcionales retenidas, una formulación multivariada lineal de primer orden está dada por

$$\boldsymbol{\xi}_t = A_t \boldsymbol{\xi}_{t-1} + \mathbf{u}_t \quad (2.30)$$

donde $A_t \in \mathbb{R}^{K \times K}$ es una matriz de coeficientes dependiente del tiempo y $\mathbf{u}_t$ es un vector de innovaciones centrado.

Esta formulación puede interpretarse como un modelo VAR dinámico (*Dynamic Vector Autoregressive Model*) sobre el estado reducido del proceso funcional. A diferencia del modelo TV-FAR, el cual se formula inicialmente en el espacio funcional y luego se proyecta sobre una base finita, el VAR dinámico se plantea directamente en el espacio de coeficientes. Por ello, constituye una herramienta natural cuando el interés se centra en la dinámica de las puntuaciones principales más que en la estructura del operador funcional subyacente.

Desde un punto de vista estructural, el VAR dinámico ofrece una formulación más simple que el TV-FAR, aunque pierde parte de la interpretación funcional asociada al operador $\mathcal{A}_t$. No obstante, resulta útil como modelo de referencia en problemas de predicción sobre el espacio reducido.

Modelo f-GARCH

Mientras que los modelos FAR, TV-FAR y VAR dinámico se enfocan principalmente en describir la dinámica condicional de la media del proceso funcional, en algunas aplicaciones también es relevante modelar la evolución temporal de su variabilidad. En particular, puede ocurrir que la magnitud de las fluctuaciones no sea constante en el tiempo, sino que presente períodos de mayor o menor volatilidad. Este fenómeno se conoce como heterocedasticidad condicional.

En esta tesis, el término f-GARCH se utilizará para referirse a un modelo de heterocedasticidad condicional aplicado a la representación funcional reducida del proceso. Es decir, en lugar de modelar directamente la volatilidad de la trayectoria completa X_t , se considera

la dinámica de la variabilidad asociada a los puntajes funcionales obtenidos mediante la reducción de dimensión.

De manera general, se parte de la descomposición

$$X_t = \mu + \varepsilon_t, \quad (2.31)$$

donde μ representa la media funcional y ε_t corresponde al término de innovación. A diferencia de un modelo con covarianza constante, en un esquema f-GARCH la incertidumbre asociada a ε_t se modela mediante una estructura de covarianza condicional que depende de la información disponible hasta el instante anterior.

En la representación reducida, sea $\boldsymbol{\xi}_t$ el vector de puntajes funcionales asociado a X_t . El interés se centra entonces en modelar la matriz de covarianza condicional

$$\text{Cov}(\boldsymbol{\xi}_t \mid \mathcal{F}_{t-1}), \quad (2.32)$$

la cual puede depender tanto de innovaciones pasadas como de su propia evolución histórica. De este modo, el modelo permite capturar patrones de agrupamiento temporal de la variabilidad, característicos de procesos heterocedásticos.

2.3.5. Alcance y limitaciones de los modelos funcionales clásicos

Los modelos FAR(1), TV-FAR, VAR dinámico y f-GARCH constituyen referencias naturales para la modelación de series temporales funcionales en distintos niveles de generalidad. El FAR(1) proporciona una formulación lineal y parsimoniosa en el espacio funcional; el TV-FAR extiende dicha estructura al caso de operadores dependientes del tiempo; el VAR dinámico modela de manera directa la evolución del estado reducido en dimensión finita; y el f-GARCH permite incorporar heterocedasticidad condicional.

No obstante, estas formulaciones presentan restricciones importantes. En particular, los modelos autorregresivos funcionales clásicos suelen imponer una estructura lineal sobre la dinámica de la media, mientras que los modelos de volatilidad suelen tratar por separado la evolución de la media y de la varianza. Asimismo, cuando el interés se desplaza al espacio

reducido, los modelos multivariados pueden perder parte de la interpretación funcional del problema original.

En contextos donde la dinámica latente es más compleja, o donde se requiere una descripción conjunta de evolución temporal, incertidumbre y observación, resulta natural considerar formulaciones de espacio de estados. Por esta razón, en la sección siguiente se introducen los modelos de espacio de estados funcionales, los cuales proporcionan un marco más flexible para representar la dinámica del estado reducido e incorporar procedimientos de inferencia recursiva.

2.4. Modelos de Espacio de Estados Funcionales

La reducción de dimensión inducida por el análisis de componentes principales funcionales permite representar cada trayectoria funcional mediante un vector de puntuaciones de dimensión finita. Esta representación hace posible formular la dinámica temporal del proceso funcional dentro del marco de los modelos de espacio de estados, en los cuales se distingue entre una ecuación de transición, que describe la evolución de un estado latente, y una ecuación de observación, que relaciona dicho estado con la información efectivamente disponible.

En esta tesis, los modelos de espacio de estados funcionales no se introducen únicamente como una reformulación algebraica del problema, sino como un marco que permite incorporar inferencia recursiva, estimación secuencial del estado latente y extensiones no lineales. Esta formulación resulta particularmente adecuada cuando la dinámica del proceso funcional es compleja o cuando se desea actualizar las predicciones a medida que se incorporan nuevas observaciones.

2.4.1. Formulación lineal-gaussiana del modelo funcional

Sea $X_t \in L^2(\mathcal{S})$ la trayectoria funcional observada en el instante t . Luego de la etapa de suavizamiento y reducción de dimensión mediante FPCA, cada curva funcional se

representa mediante un vector de puntuaciones funcionales estimadas

$$\mathbf{z}_t = \widehat{\boldsymbol{\xi}}_t = (\widehat{\xi}_{t,1}, \dots, \widehat{\xi}_{t,K})^\top \in \mathbb{R}^K. \quad (2.33)$$

Este vector resume la información funcional observada en una representación finito-dimensional asociada a las primeras K componentes principales funcionales.

El modelo de espacio de estados se formula sobre un estado latente $\mathbf{a}_t \in \mathbb{R}^d$, el cual describe la dinámica subyacente del sistema. En general, este estado no necesariamente coincide con el vector de puntuaciones observadas $\mathbf{z}_t$. La formulación general está dada por

$$\mathbf{a}_t = f(\mathbf{a}_{t-1}; \theta) + \mathbf{w}_t, \quad \mathbf{w}_t \sim \mathcal{N}(\mathbf{0}, Q), \quad (2.34)$$

$$\mathbf{z}_t = h(\mathbf{a}_t) + \mathbf{v}_t, \quad \mathbf{v}_t \sim \mathcal{N}(\mathbf{0}, R), \quad (2.35)$$

donde $f(\cdot)$ representa la dinámica del estado latente, $h(\cdot)$ es la función de observación que vincula el estado con las puntuaciones funcionales estimadas, y Q y R son las matrices de covarianza del ruido de estado y del ruido de observación, respectivamente.

En el caso lineal-gaussiano, las funciones f y h se especifican como transformaciones lineales. Así, el modelo toma la forma

$$\mathbf{a}_t = G\mathbf{a}_{t-1} + \mathbf{w}_t, \quad \mathbf{w}_t \sim \mathcal{N}(\mathbf{0}, Q), \quad (2.36)$$

$$\mathbf{z}_t = H\mathbf{a}_t + \mathbf{v}_t, \quad \mathbf{v}_t \sim \mathcal{N}(\mathbf{0}, R), \quad (2.37)$$

donde $G \in \mathbb{R}^{d \times d}$ es la matriz de transición del estado y $H \in \mathbb{R}^{K \times d}$ es la matriz de observación. En esta formulación, $\mathbf{z}_t \in \mathbb{R}^K$ corresponde al vector de puntuaciones funcionales estimadas a partir de la curva X_t , mientras que $\mathbf{a}_t \in \mathbb{R}^d$ representa el estado latente que gobierna su evolución temporal.

Un caso particular importante ocurre cuando el estado latente se identifica directamente con las puntuaciones funcionales, es decir, cuando $d = K$, $\mathbf{a}_t = \boldsymbol{\xi}_t$ y $H = I_K$. En tal caso, la ecuación de observación se reduce a

$$\mathbf{z}_t = \mathbf{a}_t + \mathbf{v}_t,$$

y el modelo describe directamente la dinámica temporal de las primeras componentes principales funcionales.

Finalmente, una vez estimado el vector de puntuaciones en el instante t , la trayectoria funcional puede reconstruirse mediante la aproximación truncada

$$\widehat{X}_t^{(K)}(s) = \mu(s) + \sum_{i=1}^K \widehat{\xi}_{t,i} \psi_i(s), \quad (2.38)$$

donde $\{\psi_i\}_{i=1}^K$ son las autofunciones retenidas en la etapa de FPCA y $\widehat{\boldsymbol{\xi}}_t = (\widehat{\xi}_{t,1}, \dots, \widehat{\xi}_{t,K})^\top$ corresponde al vector de puntuaciones estimadas.

La formulación lineal-gaussiana constituye el caso base dentro de los modelos de espacio de estados, ya que permite obtener recursiones exactas para la distribución condicional del estado latente a partir de las observaciones disponibles. En el contexto funcional, esta estructura permite modelar la dinámica temporal de una representación reducida de las curvas observadas, manteniendo una separación clara entre la trayectoria funcional original X_t , las puntuaciones funcionales estimadas $\mathbf{z}_t$ y el estado latente $\mathbf{a}_t$.

2.4.2. Inferencia en el caso lineal: filtro de Kalman

Bajo los supuestos de linealidad y gaussianidad, la inferencia óptima en sentido de error cuadrático medio para el estado latente se obtiene mediante el filtro de Kalman. Este algoritmo calcula recursivamente la distribución condicional

$$p(\mathbf{a}_t \mid \mathbf{c}_1, \dots, \mathbf{c}_t),$$

la cual es gaussiana con media $\widehat{\mathbf{a}}_{t|t}$ y covarianza $P_{t|t}$.

El filtro de Kalman se compone de una etapa de predicción y una etapa de actualización.

Predicción

Dadas la media y la covarianza filtradas en el tiempo anterior, $\hat{\mathbf{a}}_{t-1|t-1}$ y $P_{t-1|t-1}$, se obtiene

$$\hat{\mathbf{a}}_{t|t-1} = G\hat{\mathbf{a}}_{t-1|t-1} \quad (2.39)$$

$$P_{t|t-1} = GP_{t-1|t-1}G^\top + W \quad (2.40)$$

Innovación

La discrepancia entre la observación y la predicción viene dada por la innovación

$$\mathbf{v}_t = \mathbf{c}_t - H\hat{\mathbf{a}}_{t|t-1} \quad (2.41)$$

cuya matriz de covarianza es

$$S_t = HP_{t|t-1}H^\top + R \quad (2.42)$$

Actualización

La ganancia de Kalman se define por

$$K_t = P_{t|t-1}H^\top S_t^{-1} \quad (2.43)$$

y permite corregir la predicción a partir de la nueva observación:

$$\hat{\mathbf{a}}_{t|t} = \hat{\mathbf{a}}_{t|t-1} + K_t\mathbf{v}_t \quad (2.44)$$

$$P_{t|t} = P_{t|t-1} - K_tS_tK_t^\top \quad (2.45)$$

La reconstrucción funcional asociada al estado filtrado se obtiene mediante la proyección

sobre la base funcional elegida. Si $H = I_K$, entonces

$$\widehat{\mathbf{c}}_t = \widehat{\mathbf{a}}_{t|t},$$

y por tanto

$$\widehat{X}_t^{(K)}(s) = \mu(s) + \sum_{i=1}^K \widehat{a}_{t|t,i} \psi_i(s).$$

El filtro de Kalman proporciona así un mecanismo recursivo para estimar el estado latente del sistema y actualizar secuencialmente las predicciones a medida que se incorporan nuevas observaciones.

2.4.3. Extensión no lineal: filtro de Kalman unscented

En numerosas aplicaciones, la dinámica del sistema o la relación entre el estado latente y la observación no puede describirse adecuadamente mediante funciones lineales. En el contexto funcional considerado en esta tesis, la trayectoria observada $X_t \in L^2(\mathcal{S})$ se representa, luego de la etapa de suavizamiento y FPCA, mediante un vector de puntuaciones funcionales estimadas

$$\mathbf{z}_t = \widehat{\boldsymbol{\xi}}_t = (\widehat{\xi}_{t,1}, \dots, \widehat{\xi}_{t,K})^\top \in \mathbb{R}^K.$$

El modelo de espacio de estados no lineal se formula sobre un estado latente $\mathbf{a}_t \in \mathbb{R}^d$, el cual no necesariamente coincide con $\mathbf{z}_t$. La formulación general está dada por

$$\mathbf{a}_t = g(\mathbf{a}_{t-1}; \theta) + \mathbf{w}_t, \quad \mathbf{w}_t \sim \mathcal{N}(\mathbf{0}, Q), \quad (2.46)$$

$$\mathbf{z}_t = h(\mathbf{a}_t; \theta) + \mathbf{v}_t, \quad \mathbf{v}_t \sim \mathcal{N}(\mathbf{0}, R), \quad (2.47)$$

donde

$$g : \mathbb{R}^d \rightarrow \mathbb{R}^d, \quad h : \mathbb{R}^d \rightarrow \mathbb{R}^K$$

son funciones posiblemente no lineales. La función g describe la dinámica del estado latente, mientras que h relaciona dicho estado con el vector de puntuaciones funcionales estimadas. Las matrices Q y R representan, respectivamente, la covarianza del ruido de

estado y la covarianza del ruido de observación.

Una estrategia ampliamente utilizada para abordar este problema es el filtro de Kalman *unscented* (UKF). A diferencia del filtro de Kalman extendido, que linealiza las funciones no lineales mediante Jacobianos, el UKF aproxima la propagación de la media y la covarianza a través de un conjunto determinista de puntos sigma.

Puntos sigma

Sea $\hat{\mathbf{a}}_{t-1|t-1}$ la media filtrada del estado latente en el instante $t-1$ y sea $P_{t-1|t-1}$ su matriz de covarianza. El UKF construye un conjunto de $2d+1$ puntos sigma de la forma

$$\chi_{t-1}^{(0)} = \hat{\mathbf{a}}_{t-1|t-1}, \quad (2.48)$$

$$\chi_{t-1}^{(i)} = \hat{\mathbf{a}}_{t-1|t-1} + \left(\sqrt{(d+\lambda)P_{t-1|t-1}} \right)_i, \quad i = 1, \dots, d, \quad (2.49)$$

$$\chi_{t-1}^{(i+d)} = \hat{\mathbf{a}}_{t-1|t-1} - \left(\sqrt{(d+\lambda)P_{t-1|t-1}} \right)_i, \quad i = 1, \dots, d, \quad (2.50)$$

donde λ es un parámetro de escalamiento y $\left(\sqrt{(d+\lambda)P_{t-1|t-1}} \right)_i$ denota la i -ésima columna de una raíz matricial de $(d+\lambda)P_{t-1|t-1}$.

A cada punto sigma se le asignan pesos $w_i^{(m)}$ y $w_i^{(c)}$, utilizados para calcular la media y la covarianza, respectivamente.

Predicción del estado

Los puntos sigma se propagan a través de la dinámica no lineal:

$$\chi_{t|t-1}^{(i)} = g\left(\chi_{t-1}^{(i)}; \theta\right), \quad i = 0, \dots, 2d. \quad (2.51)$$

La media predicha del estado latente se obtiene como

$$\hat{\mathbf{a}}_{t|t-1} = \sum_{i=0}^{2d} w_i^{(m)} \chi_{t|t-1}^{(i)}, \quad (2.52)$$

mientras que la covarianza predicha está dada por

$$P_{t|t-1} = \sum_{i=0}^{2d} w_i^{(c)} \left(\chi_{t|t-1}^{(i)} - \hat{\mathbf{a}}_{t|t-1} \right) \left(\chi_{t|t-1}^{(i)} - \hat{\mathbf{a}}_{t|t-1} \right)^\top + Q. \quad (2.53)$$

Predicción de la observación

Los puntos sigma predichos se transforman mediante la función de observación:

$$\gamma_t^{(i)} = h\left(\chi_{t|t-1}^{(i)}; \theta\right), \quad i = 0, \dots, 2d. \quad (2.54)$$

La media predictiva de la observación es

$$\hat{\mathbf{z}}_{t|t-1} = \sum_{i=0}^{2d} w_i^{(m)} \gamma_t^{(i)}, \quad (2.55)$$

y la covarianza predictiva de la observación queda dada por

$$S_t = \sum_{i=0}^{2d} w_i^{(c)} \left(\gamma_t^{(i)} - \hat{\mathbf{z}}_{t|t-1} \right) \left(\gamma_t^{(i)} - \hat{\mathbf{z}}_{t|t-1} \right)^\top + R. \quad (2.56)$$

Asimismo, la covarianza cruzada entre el estado latente y la observación se calcula mediante

$$P_{az,t} = \sum_{i=0}^{2d} w_i^{(c)} \left(\chi_{t|t-1}^{(i)} - \hat{\mathbf{a}}_{t|t-1} \right) \left(\gamma_t^{(i)} - \hat{\mathbf{z}}_{t|t-1} \right)^\top. \quad (2.57)$$

Actualización

La ganancia de Kalman *unscented* está dada por

$$K_t = P_{az,t} S_t^{-1}. \quad (2.58)$$

Luego, la media filtrada del estado latente se actualiza según

$$\hat{\mathbf{a}}_{t|t} = \hat{\mathbf{a}}_{t|t-1} + K_t \left(\mathbf{z}_t - \hat{\mathbf{z}}_{t|t-1} \right), \quad (2.59)$$

mientras que la covarianza filtrada queda dada por

$$P_{t|t} = P_{t|t-1} - K_t S_t K_t^\top. \quad (2.60)$$

La principal ventaja del UKF es que evita la linealización explícita del modelo y permite capturar con mayor fidelidad el efecto de transformaciones no lineales sobre la media y la covarianza del estado. En particular, cuando las funciones g y h son lineales, el procedimiento recupera el caso clásico del filtro de Kalman.

Filtrado de estados y estimación de parámetros

Es importante distinguir entre el filtrado de estados y la estimación de parámetros. El UKF proporciona aproximaciones recursivas a la distribución condicional del estado latente,

$$p(\mathbf{a}_t \mid \mathbf{z}_{1:t}),$$

suponiendo conocidos los parámetros del sistema. Estos parámetros incluyen, por ejemplo, las matrices de covarianza Q y R , así como los parámetros que definen las funciones no lineales g y h .

Por lo tanto, el UKF no estima automáticamente los parámetros del modelo. Si estos deben ser estimados a partir de los datos, es necesario especificar un criterio adicional de estimación. Una alternativa consiste en maximizar una log-verosimilitud predictiva aproximada de la forma

$$\hat{\Theta} = \arg \max_{\Theta} \sum_{t=1}^T \log \mathcal{N}(\mathbf{z}_t; \hat{\mathbf{z}}_{t|t-1}(\Theta), S_t(\Theta)), \quad (2.61)$$

donde Θ denota el conjunto de parámetros del modelo, $\hat{\mathbf{z}}_{t|t-1}(\Theta)$ corresponde a la media predictiva de la observación entregada por el filtro, y $S_t(\Theta)$ es la matriz de covarianza predictiva asociada.

También pueden emplearse otros procedimientos, como algoritmos de tipo EM o métodos de optimización numérica, dependiendo de la estructura específica del modelo.

Finalmente, una vez obtenido el vector de puntuaciones estimadas o filtradas, la trayectoria funcional puede reconstruirse mediante la aproximación truncada

$$\widehat{X}_t^{(K)}(s) = \mu(s) + \sum_{i=1}^K \widehat{\xi}_{t,i} \psi_i(s), \quad (2.62)$$

donde $\{\psi_i\}_{i=1}^K$ son las autofunciones retenidas en la etapa de FPCA. Así, el UKF opera sobre una representación finito-dimensional del proceso funcional, manteniendo diferenciados la curva original X_t , las puntuaciones funcionales observadas o estimadas $\mathbf{z}_t$ y el estado latente $\mathbf{a}_t$.

2.4.4. Innovaciones, residuos y diagnóstico del modelo

Tanto en el caso lineal como en el no lineal, la secuencia de innovaciones o residuos de predicción constituye una herramienta fundamental para evaluar la adecuación del modelo.

En el contexto lineal, la innovación en el tiempo t está dada por

$$\mathbf{v}_t = \mathbf{c}_t - H\widehat{\mathbf{a}}_{t|t-1}.$$

De forma análoga, en el caso no lineal se considera el residuo

$$\mathbf{r}_t = \mathbf{c}_t - \widehat{\mathbf{c}}_{t|t-1} \quad (2.63)$$

donde $\widehat{\mathbf{c}}_{t|t-1}$ corresponde a la predicción de la observación obtenida mediante el filtro.

Bajo una especificación adecuada del modelo, se espera que las innovaciones no presenten estructura temporal remanente significativa y que su comportamiento sea aproximadamente compatible con el supuesto distribucional adoptado. En particular, la presencia de autocorrelación residual, asimetrías pronunciadas o colas pesadas puede indicar deficiencias en la dinámica del estado, en la ecuación de observación o en la especificación de las covarianzas de ruido.

El análisis de innovaciones permite además monitorear la estabilidad del sistema y detectar

posibles cambios estructurales. Incrementos persistentes en la magnitud de los residuos, variaciones abruptas en su energía o cambios en su distribución pueden interpretarse como evidencia de mala especificación del modelo o de modificaciones en la dinámica subyacente del proceso. Por esta razón, las innovaciones constituyen una base natural para procedimientos de diagnóstico, detección de anomalías y análisis de robustez.

2.4.5. Comentario sobre otros enfoques

Existen otras estrategias para realizar inferencia en modelos de espacio de estados no lineales o no gaussianos. Una de ellas es el filtro de Kalman extendido (EKF), que aproxima el modelo mediante una linealización local basada en Jacobianos. Si bien este enfoque puede ser computacionalmente eficiente, su desempeño depende de manera sensible de la calidad de la aproximación lineal y puede deteriorarse en presencia de no linealidades fuertes.

Otra alternativa está dada por los filtros de partículas, los cuales aproximan la distribución posterior del estado mediante una colección de partículas ponderadas. Estos métodos son altamente flexibles y permiten tratar modelos no lineales y no gaussianos de manera más general, pero su costo computacional crece rápidamente con la dimensión del estado y con la complejidad de la dinámica.

Finalmente, el problema puede abordarse desde una perspectiva bayesiana completa, especificando distribuciones a priori para los estados latentes y los parámetros del modelo. Este enfoque permite cuantificar de manera integral la incertidumbre, aunque suele requerir métodos de simulación más costosos, tales como algoritmos MCMC o procedimientos secuenciales avanzados.

Dado que el objetivo principal de esta tesis es estudiar la dinámica funcional a través de representaciones reducidas e inferencia recursiva, el énfasis se pondrá en el filtro de Kalman lineal y en el filtro de Kalman *unscented*, los cuales constituyen las herramientas centrales del análisis empírico posterior.

2.4.6. Cierre de la sección

Los modelos de espacio de estados funcionales proporcionan un marco natural para describir la evolución temporal de procesos funcionales a partir de una representación reducida del estado latente. En el caso lineal-gaussiano, esta formulación conduce al filtro de Kalman, que permite realizar inferencia recursiva óptima en sentido de error cuadrático medio. Cuando la dinámica del sistema o la relación entre estado y observación es no lineal, el filtro de Kalman *unscented* ofrece una extensión flexible basada en la propagación de puntos sigma.

Además, el análisis de innovaciones y residuos constituye una herramienta esencial para el diagnóstico del modelo, la detección de cambios estructurales y la evaluación de robustez frente a perturbaciones o mala especificación. En consecuencia, el marco de espacio de estados funcionales no solo permite representar la dinámica latente del proceso, sino también desarrollar procedimientos de inferencia y validación que resultan fundamentales para el análisis experimental considerado en esta tesis.

2.5. Predicción Funcional

Una vez obtenida una representación reducida del proceso funcional mediante FPCA, el problema de predicción de trayectorias puede formularse en términos de la evolución futura de un vector de dimensión finita. En este contexto, la predicción funcional se descompone naturalmente en dos etapas: primero se predicen las puntuaciones o coeficientes asociados a la representación truncada, y luego se reconstruye la curva funcional correspondiente a partir de la base elegida.

Esta formulación permite integrar de manera coherente la reducción de dimensión funcional con distintos modelos dinámicos, tales como el modelo FAR(1), los modelos de espacio de estados lineales o sus extensiones no lineales.

2.5.1. Predicción del estado reducido

Sea

$$\boldsymbol{\xi}_t = (\xi_{t,1}, \dots, \xi_{t,K})^\top$$

el vector de puntuaciones asociado a las primeras K componentes principales funcionales. La predicción h -pasos adelante del proceso funcional se basa, en primer lugar, en la predicción del vector reducido $\boldsymbol{\xi}_{t+h}$.

Predicción en el modelo FAR(1)

Si la dinámica truncada del proceso viene dada por

$$\boldsymbol{\xi}_t = A\boldsymbol{\xi}_{t-1} + \mathbf{u}_t,$$

donde $\mathbf{u}_t$ es un proceso de innovaciones centrado, entonces el predictor h -pasos adelante condicionado a la información disponible hasta el tiempo t está dado por

$$\widehat{\boldsymbol{\xi}}_{t+h|t} = A^h \boldsymbol{\xi}_t \tag{2.64}$$

Predicción en el modelo lineal de espacio de estados

En el caso lineal-gaussiano, si el estado reducido satisface

$$\mathbf{a}_t = G\mathbf{a}_{t-1} + \mathbf{w}_t, \quad \mathbf{c}_t = H\mathbf{a}_t + \boldsymbol{\epsilon}_t,$$

y se dispone de la estimación filtrada $\widehat{\mathbf{a}}_{t|t}$, entonces la predicción del estado h -pasos adelante viene dada por:

$$\widehat{\mathbf{a}}_{t+h|t} = G^h \widehat{\mathbf{a}}_{t|t} \tag{2.65}$$

La predicción correspondiente de los coeficientes observables es:

$$\widehat{\mathbf{c}}_{t+h|t} = H\widehat{\mathbf{a}}_{t+h|t} \tag{2.66}$$

Predicción en el caso no lineal

Cuando la dinámica del estado está gobernada por una ecuación no lineal

$$\mathbf{a}_t = g(\mathbf{a}_{t-1}) + \mathbf{w}_t,$$

la predicción h -pasos adelante se obtiene mediante la propagación recursiva del estado estimado a través de la función g . En el contexto del filtro de Kalman *unscented*, esta propagación se realiza utilizando puntos sigma, lo que permite aproximar la media y la covarianza de la distribución predictiva del estado sin recurrir a linealizaciones locales.

En consecuencia, la predicción funcional en modelos no lineales sigue la misma lógica conceptual que en el caso lineal: primero se obtiene una predicción del estado reducido y luego se reconstruye la trayectoria funcional a partir de la base seleccionada.

2.5.2. Reconstrucción funcional

Una vez obtenida la predicción h -pasos adelante del vector reducido, la curva funcional pronosticada se reconstruye proyectando dicho vector sobre la base de autofunciones retenidas. En particular, si

$$X_t^{(K)}(s) = \mu(s) + \sum_{i=1}^K \xi_{t,i} \psi_i(s),$$

entonces la predicción funcional viene dada por

$$\hat{X}_{t+h|t}^{(K)}(s) = \mu(s) + \sum_{i=1}^K \hat{\xi}_{t+h|t,i} \psi_i(s) \quad (2.67)$$

donde $\hat{\xi}_{t+h|t,i}$ denota la predicción de la i -ésima puntuación funcional en horizonte h .

De manera equivalente, si la predicción se formula en términos de un estado latente $\hat{\mathbf{a}}_{t+h|t}$ y una ecuación de observación lineal, entonces se obtiene primero

$$\hat{\mathbf{c}}_{t+h|t} = H \hat{\mathbf{a}}_{t+h|t},$$

y luego la reconstrucción funcional correspondiente:

$$\widehat{X}_{t+h|t}^{(K)}(s) = \mu(s) + \sum_{i=1}^K \widehat{c}_{t+h|t,i} \psi_i(s).$$

Así, la etapa de reconstrucción funcional transforma una predicción multivariada en dimensión reducida en una predicción de trayectorias completas en el espacio $L^2(\mathcal{S})$.

2.5.3. Error de predicción en norma funcional

La calidad de una predicción funcional puede evaluarse naturalmente mediante el error en norma $L^2(\mathcal{S})$. Supóngase que la trayectoria verdadera admite la expansión

$$X_{t+h}(s) = \mu(s) + \sum_{i=1}^{\infty} \xi_{t+h,i} \psi_i(s),$$

donde $\{\psi_i\}_{i=1}^{\infty}$ es un sistema ortonormal en $L^2(\mathcal{S})$. Si la predicción se construye a partir de las primeras K componentes,

$$\widehat{X}_{t+h|t}^{(K)}(s) = \mu(s) + \sum_{i=1}^K \widehat{\xi}_{t+h|t,i} \psi_i(s),$$

entonces, dado que la predicción truncada asigna coeficiente cero a las componentes $i > K$, se obtiene la descomposición

$$\|X_{t+h} - \widehat{X}_{t+h|t}^{(K)}\|_{L^2(\mathcal{S})}^2 = \sum_{i=1}^K (\xi_{t+h,i} - \widehat{\xi}_{t+h|t,i})^2 + \sum_{i>K} \xi_{t+h,i}^2. \quad (2.68)$$

La identidad anterior es válida debido a la ortonormalidad de la base $\{\psi_i\}_{i=1}^{\infty}$. El primer término corresponde al error de predicción sobre las componentes retenidas, mientras que el segundo representa el error de truncación asociado a la parte de la señal que no ha sido incorporada en la representación reducida. En consecuencia, el error funcional total depende tanto de la calidad del modelo dinámico como de la elección del número de componentes principales K .

Si la media funcional μ es desconocida y se estima a partir de los datos, la descomposición anterior debe interpretarse condicionalmente a dicha estimación. En particular, podría aparecer un término adicional asociado al error de estimación de μ , especialmente en muestras finitas.

En el caso lineal, si $\Sigma_{t+h|t}$ denota la matriz de covarianza del error de predicción de los coeficientes retenidos, entonces, bajo una base ortonormal, se cumple

$$\mathbb{E} \left[\|X_{t+h}^{(K)} - \widehat{X}_{t+h|t}^{(K)}\|_{L^2(S)}^2 \mid \mathcal{F}_t \right] = \text{tr}(\Sigma_{t+h|t}), \quad (2.69)$$

donde $\mathcal{F}_t$ representa la información disponible hasta el tiempo t .

Este resultado permite interpretar la traza de la covarianza predictiva como una medida natural de incertidumbre funcional en el subespacio truncado.

Por otro lado, si la reconstrucción funcional se realiza mediante una base no ortonormal $\{\varphi_j\}_{j=1}^K$, la norma del error no se reduce, en general, a una suma de cuadrados de coeficientes. En tal caso, si

$$e(s) = \sum_{j=1}^K d_j \varphi_j(s)$$

denota el error expresado en dicha base, entonces

$$\|e\|_{L^2(S)}^2 = \mathbf{d}^\top G \mathbf{d},$$

donde $\mathbf{d} = (d_1, \dots, d_K)^\top$ y G es la matriz de Gram asociada a la base, definida por

$$G_{ij} = \langle \varphi_i, \varphi_j \rangle_{L^2}.$$

Por lo tanto, la expresión como suma de cuadrados es un caso particular que se obtiene cuando la base es ortonormal y, en consecuencia, $G = I_K$.

2.5.4. Comentario final sobre el alcance predictivo

La predicción funcional de largo plazo descansa sobre la calidad de dos etapas complementarias: la reducción de dimensión, que determina qué parte de la variabilidad del proceso es retenida en la representación finita, y el modelo dinámico utilizado para describir la evolución temporal del estado reducido. En particular, una representación funcional poco eficiente puede introducir error de truncación significativo, mientras que una especificación dinámica inadecuada puede deteriorar la precisión de las predicciones sobre las componentes retenidas.

Por ello, la comparación entre distintos enfoques predictivos como modelos funcionales autorregresivos, formulaciones lineales en espacio de estados o extensiones no lineales basadas en el filtro de Kalman *unscented* debe entenderse dentro de un mismo marco de reconstrucción funcional. En todos los casos, la predicción final de la trayectoria observada se obtiene a partir de un estado reducido cuya calidad depende tanto de la representación elegida como de la dinámica impuesta por el modelo.

Capítulo 3

Metodología propuesta

3.1. Introducción

Los modelos de espacio estado han demostrado ser una herramienta fundamental para el análisis de series temporales, debido a su estructura flexible y su capacidad para modelar dinámicas latentes complejas mediante representaciones recursivas en el tiempo (Durbin and Koopman, 2012). En el contexto de las series temporales funcionales, donde cada observación corresponde a una función en un espacio de Hilbert, su extensión permite capturar simultáneamente dependencia temporal y estructura infinita-dimensional (Bosq, 2000; Hörmann and Kokoszka, 2012).

Una estrategia ampliamente utilizada en este contexto consiste en proyectar las funciones sobre una base funcional, por ejemplo, componentes principales funcionales y modelar la dinámica de los coeficientes resultantes (Hyndman and Ullah, 2007). Sin embargo, muchos de estos enfoques, incluyendo los modelos autorregresivos funcionales (FAR), describen la dependencia temporal mediante operadores lineales fijos, sin separar explícitamente la dinámica latente del proceso observacional.

Esta limitación resulta especialmente relevante en escenarios donde existe incertidumbre estructural, cambios en la dinámica o presencia de ruido de medición significativo. En tales casos, la falta de una representación latente explícita dificulta la interpretación del sistema, la actualización recursiva de la información y la cuantificación coherente de la

incertidumbre.

Para abordar este problema, en este capítulo se propone un modelo de espacio estado para series temporales funcionales en el cual los coeficientes de una expansión funcional evolucionan según una ecuación de transición latente, mientras que las observaciones se generan mediante una ecuación de medición separada. Esta formulación permite distinguir entre variabilidad observacional y dinámica subyacente, facilitando tanto la interpretación como la estimación mediante filtros tipo Kalman.

Más allá de su formulación, un aspecto central de este trabajo es evaluar empíricamente el comportamiento de este tipo de modelos bajo distintos escenarios de modelación. En particular, se estudia la sensibilidad del sistema ante (i) cambios estructurales en la dinámica, (ii) especificación incorrecta de la dimensión funcional, y (iii) desviaciones de los supuestos distribucionales, tales como la presencia de colas pesadas y valores atípicos.

Como se mostrará en las secciones posteriores, el modelo propuesto proporciona un marco unificado que integra reducción de dimensionalidad funcional y modelación dinámica latente, manteniendo un equilibrio entre flexibilidad estructural, interpretabilidad y eficiencia computacional.

Las principales contribuciones de este trabajo son las siguientes:

- Se formula un modelo de espacio de estados para series temporales funcionales en dimensión reducida, donde el proceso observado se representa mediante puntuaciones funcionales obtenidas por FPCA y la dinámica temporal se describe a través de un estado latente explícito.
- Se desarrolla un esquema de estimación secuencial basado en el filtro de Kalman *unscented*, el cual permite realizar inferencia recursiva sobre el estado reducido y cuantificar la incertidumbre predictiva dentro de un marco probabilístico coherente.
- Se realiza una evaluación experimental sistemática del modelo bajo distintos escenarios de especificación, incluyendo cambios estructurales, elección de la dimensión funcional y desviaciones respecto a los supuestos distribucionales, con el fin de analizar su estabilidad, robustez y desempeño predictivo.

3.2. Estado del Arte

3.2.1. Predicción de series temporales funcionales

La predicción de series temporales funcionales ha sido ampliamente estudiada desde la consolidación del análisis de datos funcionales como marco estadístico formal (Bosq, 2000; Hörmann and Kokoszka, 2012). En este contexto, cada observación temporal corresponde a una función con valores en un espacio de Hilbert, lo que introduce dificultades adicionales en comparación con las series temporales finito-dimensionales (Ramsay and Silverman, 2005). En particular, la modelación requiere abordar simultáneamente dos problemas: la reducción de dimensión de objetos infinito-dimensionales y la descripción de su dependencia temporal.

Una primera familia de métodos corresponde a los enfoques secuenciales basados en descomposición funcional. En este paradigma, el proceso funcional se representa mediante una expansión truncada, usualmente de Karhunen–Loève, y la dinámica temporal se modela posteriormente sobre los *scores*. El método de Hyndman and Ullah (2007), basado en modelos ARIMA univariados para cada componente, constituye uno de los ejemplos más influyentes. Extensiones posteriores han incorporado modelos multivariados, tales como VAR, con el fin de capturar dependencia entre componentes (Aue et al., 2015). La principal ventaja de estos enfoques radica en su simplicidad, interpretabilidad y bajo costo computacional. Sin embargo, presentan una limitación estructural importante: la reducción de dimensión y la modelación temporal se realizan en etapas separadas, y en general no se introduce una representación latente explícita que distinga entre la evolución del sistema y el error de observación.

Una segunda familia corresponde a los modelos autorregresivos funcionales (FAR), que extienden la estructura autorregresiva clásica al espacio infinito-dimensional (Bosq, 2000; Hörmann and Kokoszka, 2012). Estos modelos preservan una interpretación funcional directa del operador dinámico y cuentan con una teoría bien desarrollada bajo hipótesis de linealidad y estacionariedad. Además, admiten extensiones como los modelos TV-FAR, en los cuales el operador depende del tiempo, y los modelos formulados en dimensión reducida mediante representaciones VAR dinámicas sobre los scores. No obstante, tanto

en su versión funcional como truncada, estos enfoques suelen mantener una dinámica lineal en la media y no incorporan, en su formulación básica, una separación explícita entre estado latente y mecanismo de observación.

Una tercera línea de trabajo considera modelos que extienden la descripción de la media condicional hacia estructuras más complejas. Entre ellos destacan los modelos de volatilidad funcional, tales como los modelos f-GARCH (Aue and Horváth, 2013), que permiten modelar heterocedasticidad condicional y episodios de agrupamiento de volatilidad. Su principal fortaleza radica en la capacidad para describir la evolución temporal de la incertidumbre, aspecto que no es capturado por modelos autorregresivos funcionales estándar. Sin embargo, estos modelos se concentran primordialmente en la dinámica de la varianza condicional y no necesariamente introducen una representación de estado latente adecuada para inferencia recursiva sobre la trayectoria del sistema.

Otra familia relevante incluye modelos de factores dinámicos funcionales, en los cuales las trayectorias se representan como combinaciones de factores latentes con dinámica temporal (Hays et al., 2012). Estos modelos introducen explícitamente una estructura latente, lo que los aproxima conceptualmente a formulaciones de espacio de estados. Su principal ventaja es que permiten distinguir entre una estructura de baja dimensión subyacente y las observaciones funcionales. Sin embargo, en muchas implementaciones la dinámica de los factores permanece restringida a formas lineales o gaussianas, y la inferencia puede volverse considerablemente más compleja.

También se han desarrollado enfoques no paramétricos, tales como métodos basados en vecinos más cercanos funcionales y suavizamiento kernel (Ferraty and Vieu, 2006). Estos métodos no imponen una estructura paramétrica fija y pueden adaptarse a relaciones no lineales entre trayectorias. No obstante, su flexibilidad tiene como contrapartida una menor interpretabilidad estructural, ausencia de una representación explícita del estado latente y una cuantificación de incertidumbre menos natural desde un punto de vista probabilístico.

En el ámbito bayesiano, los modelos basados en procesos gaussianos funcionales ofrecen un marco probabilístico flexible para predicción y cuantificación de incertidumbre (Rasmussen and Williams, 2006). Su principal fortaleza es la coherencia probabilística global,

aunque ello suele ir acompañado de una mayor carga computacional y de dificultades de escalamiento en problemas con gran número de observaciones o estados de dimensión elevada.

Finalmente, una línea de creciente relevancia corresponde a métodos basados en aprendizaje automático y aprendizaje profundo, incluyendo redes recurrentes, modelos LSTM y arquitecturas tipo Transformer (Vaswani, 2017; Lim et al., 2021). Estos enfoques pueden capturar relaciones altamente no lineales y muestran, en muchos contextos, un elevado desempeño predictivo. Sin embargo, en el caso de series funcionales suelen operar sobre discretizaciones o *embeddings* de las curvas, por lo que la interpretación funcional del modelo se debilita. Además, usualmente no incorporan una representación explícita del estado latente ni una separación clara entre evolución del sistema y ruido de observación.

Desde esta perspectiva, el modelo considerado en esta tesis se sitúa en la intersección entre dos objetivos. Por una parte, preservar una representación funcional parsimoniosa mediante FPCA, de modo que el análisis siga anclado en la estructura del proceso funcional. Por otra, introducir una formulación de espacio de estados que permita separar dinámica latente y observación, realizando inferencia recursiva sobre el estado reducido. En comparación con los enfoques secuenciales clásicos, esta formulación proporciona una integración más explícita entre representación funcional y dinámica temporal. En comparación con los modelos FAR y VAR lineales, permite incorporar no linealidad en la evolución del estado. No obstante, a diferencia de modelos como f-GARCH, no está diseñada específicamente para modelar heterocedasticidad condicional, y frente a enfoques de aprendizaje profundo conserva mayor interpretabilidad a costa de una menor flexibilidad universal.

3.2.2. Brecha metodológica

La revisión anterior permite identificar tres limitaciones principales en la literatura. En primer lugar, una parte importante de los métodos funcionales clásicos se formula bajo dinámicas lineales o estacionarias, lo que restringe su capacidad para adaptarse a cambios estructurales o relaciones no lineales en el tiempo (Bosq, 2000; Hörmann and Kokoszka, 2012). En segundo lugar, muchos enfoques basados en FPCA y modelación de *scores* ope-

ran en dos etapas separadas, sin una formulación unificada que describa explícitamente el estado latente del sistema (Hyndman and Ullah, 2007). En tercer lugar, aunque existen metodologías que capturan volatilidad, no linealidad o gran flexibilidad predictiva, no todas combinan simultáneamente interpretabilidad funcional, representación latente explícita e inferencia recursiva probabilísticamente coherente.

En este contexto, resulta natural considerar un modelo que combine una representación funcional de baja dimensión con una formulación de espacio de estados en la que el estado reducido evolucione dinámicamente y pueda ser estimado de forma secuencial. Esta es precisamente la motivación del enfoque desarrollado en esta tesis: utilizar una representación funcional vía FPCA y modelar la dinámica de las puntuaciones retenidas mediante un sistema de espacio de estados no lineal, cuya estimación se realiza mediante el filtro de Kalman *unscented*. Esta formulación no pretende reemplazar de manera universal a los métodos existentes, sino proporcionar un marco alternativo en aquellos contextos donde la combinación de no linealidad moderada, estado latente explícito e inferencia recursiva resulte relevante para la predicción y el análisis del sistema.

3.3. Metodología

3.3.1. Formulación del problema

Sea $\{X_t\}_{t=1}^T$ una serie temporal funcional con trayectorias definidas sobre un dominio compacto $\mathcal{S} \subset \mathbb{R}$ y con valores en el espacio de Hilbert $L^2(\mathcal{S})$, definido en (2.1) y provisto del producto interno y la norma dados en (2.2). El objetivo de esta tesis es construir un modelo dinámico estadístico que permita describir la evolución temporal de dichas trayectorias mediante una representación funcional parsimoniosa y de dimensión finita.

La idea central consiste en transformar cada curva observada en un vector reducido de puntuaciones funcionales, modelar dinámicamente la evolución de dicho vector mediante una formulación no lineal e inferir secuencialmente su estado a través del filtro de Kalman *unscented* (UKF), cuya formulación general fue presentada en (2.46)–(2.60). A partir de esta representación reducida, se reconstruye la trayectoria funcional correspondiente

mediante (2.21).

Este enfoque permite trabajar en dimensión finita sin perder interpretabilidad funcional, trasladando el problema desde un espacio infinito-dimensional a un contexto multivariado reducido, en concordancia con la representación truncada (2.15) y con el estado reducido (2.19).

3.3.2. Esquema general del procedimiento

La metodología propuesta se organiza en las siguientes etapas:

1. **Construcción de curvas funcionales.** A partir de observaciones discretas $Y_{t,j} \approx X_t(s_j)$, se construyen trayectorias funcionales suaves sobre una malla finita del dominio $\mathcal{S}$.
2. **Reducción de dimensión mediante FPCA.** Las curvas suavizadas se representan mediante la expansión de Karhunen–Loève (2.12), reteniendo las primeras K componentes según la truncación (2.15).
3. **Modelación dinámica en el espacio reducido.** La dinámica temporal se formula sobre el vector de puntuaciones funcionales (2.19), utilizando un modelo no lineal del tipo (2.46).
4. **Estimación secuencial mediante UKF.** La inferencia del estado reducido se realiza mediante el filtro de Kalman *unscented*, utilizando las ecuaciones (2.49)–(2.60).
5. **Reconstrucción funcional y evaluación.** Finalmente, las estimaciones del estado reducido se proyectan sobre la base de autofunciones para obtener la reconstrucción funcional (2.21) y la predicción funcional (2.67).

3.3.3. Construcción de la representación funcional reducida

Los datos originales consisten en observaciones discretas registradas a frecuencia horaria. A partir de dichas mediciones, se construyen curvas diarias completas sobre una malla de

24 puntos, descartando aquellos días con observaciones incompletas.

Posteriormente, cada trayectoria diaria se suaviza mediante una base B-spline. Si $s \in \mathcal{S}$ denota la hora del día, la curva asociada al día t se representa aproximadamente como

$$X_t(s) \approx \sum_{\ell=1}^L b_{t,\ell} B_\ell(s),$$

donde $\{B_\ell\}_{\ell=1}^L$ es una base spline y los coeficientes $\{b_{t,\ell}\}$ se obtienen a partir del suavizado de los datos discretos.

Para evitar filtración de información, la media funcional, el operador de covarianza, las autofunciones FPCA y el número de componentes retenidas se estiman exclusivamente a partir del conjunto de entrenamiento. Sea $\mathcal{T}_{\text{train}}$ el conjunto de tiempos utilizados para entrenamiento. La media funcional de entrenamiento se estima como

$$\hat{\mu}_{\text{train}}(s) = \frac{1}{|\mathcal{T}_{\text{train}}|} \sum_{t \in \mathcal{T}_{\text{train}}} X_t(s). \quad (3.1)$$

A partir de las curvas centradas respecto de $\hat{\mu}_{\text{train}}$, se construye el operador de covarianza empírico de entrenamiento. Sus primeras autofunciones $\hat{\psi}_1, \dots, \hat{\psi}_K$ se obtienen únicamente usando las curvas del conjunto de entrenamiento. De este modo, para $t \in \mathcal{T}_{\text{train}} \cup \mathcal{T}_{\text{test}}$, las puntuaciones funcionales estimadas se calculan proyectando cada curva sobre la base FPCA aprendida durante el entrenamiento:

$$\hat{\xi}_{t,j} = \left\langle X_t - \hat{\mu}_{\text{train}}, \hat{\psi}_j \right\rangle, \quad j = 1, \dots, K. \quad (3.2)$$

En particular, las curvas del conjunto de prueba no se utilizan para estimar la media funcional, el operador de covarianza, las autofunciones ni el número de componentes principales retenidas. Estas curvas se incorporan únicamente mediante su proyección sobre la base FPCA previamente estimada con los datos de entrenamiento.

Una vez construidas las curvas suavizadas y estimada la base FPCA de entrenamiento,

cada trayectoria se representa mediante una aproximación truncada de Karhunen–Loève:

$$\widehat{X}_t^{(K)}(s) = \widehat{\mu}_{\text{train}}(s) + \sum_{j=1}^K \widehat{\xi}_{t,j} \widehat{\psi}_j(s), \quad (3.3)$$

donde $\widehat{\mu}_{\text{train}}(s)$ es la media funcional estimada usando solo el conjunto de entrenamiento, $\{\widehat{\psi}_j\}_{j=1}^K$ son las primeras autofunciones empíricas del operador de covarianza de entrenamiento, y $\widehat{\xi}_{t,j}$ son las puntuaciones funcionales estimadas mediante (3.2).

En consecuencia, cada trayectoria funcional queda representada por el vector reducido

$$\widehat{\boldsymbol{\xi}}_t = (\widehat{\xi}_{t,1}, \dots, \widehat{\xi}_{t,K})^\top \in \mathbb{R}^K. \quad (3.4)$$

La selección de K se realiza utilizando el criterio de varianza explicada acumulada, definido en (2.17), calculado exclusivamente sobre los autovalores empíricos obtenidos a partir del conjunto de entrenamiento. Este criterio se apoya en el hecho de que el error cuadrático medio de truncación viene dado por (2.16), por lo que retener las primeras K componentes equivale a controlar la energía contenida en la cola de la expansión. Además, la optimalidad de la truncación FPCA en media cuadrática, establecida en la subsección correspondiente del marco teórico, justifica el uso de esta representación como punto de partida para la modelación dinámica.

3.3.4. Modelo dinámico propuesto en el espacio de scores

Una vez construida la representación funcional reducida, es importante distinguir entre las puntuaciones funcionales estimadas y el estado latente del modelo dinámico. En lo que sigue,

$$\mathbf{z}_t = \widehat{\boldsymbol{\xi}}_t = (\widehat{\xi}_{t,1}, \dots, \widehat{\xi}_{t,K})^\top \in \mathbb{R}^K$$

denotará el vector de puntuaciones FPCA estimadas a partir de la curva funcional X_t , mientras que

$$\mathbf{a}_t \in \mathbb{R}^d$$

denotará el estado latente del modelo de espacio de estados. Esta distinción es necesaria porque las puntuaciones FPCA son cantidades estimadas a partir de datos discretos y suavizados, mientras que el estado latente representa la dinámica no observada que el filtro busca inferir.

Con esta notación, el modelo dinámico se formula sobre el estado latente $\mathbf{a}_t$. En una formulación general no lineal, se considera

$$\mathbf{a}_t = g(\mathbf{a}_{t-1}; \theta) + \mathbf{w}_t, \quad \mathbf{w}_t \sim \mathcal{N}(\mathbf{0}, Q), \quad (3.5)$$

donde $g : \mathbb{R}^d \rightarrow \mathbb{R}^d$ describe la dinámica del estado latente, θ representa los parámetros del modelo y Q es la matriz de covarianza del ruido de estado.

La ecuación de observación vincula el estado latente con las puntuaciones FPCA estimadas:

$$\mathbf{z}_t = h(\mathbf{a}_t; \theta) + \mathbf{v}_t, \quad \mathbf{v}_t \sim \mathcal{N}(\mathbf{0}, R), \quad (3.6)$$

donde $h : \mathbb{R}^d \rightarrow \mathbb{R}^K$ es la función de observación y R es la matriz de covarianza del ruido de observación. En este contexto, $\mathbf{z}_t$ corresponde a la cantidad observada en el espacio reducido, mientras que $\mathbf{a}_t$ es inferido recursivamente a partir de dichas observaciones.

Un caso particular importante ocurre cuando el estado latente se identifica directamente con las puntuaciones funcionales. En tal caso, se toma $d = K$, $\mathbf{a}_t = \boldsymbol{\xi}_t$ y $h(\mathbf{a}_t) = \mathbf{a}_t$, de modo que la ecuación de observación se reduce a

$$\mathbf{z}_t = \mathbf{a}_t + \mathbf{v}_t. \quad (3.7)$$

Esta formulación permite interpretar las puntuaciones FPCA estimadas como mediciones ruidosas del estado reducido del sistema.

Una forma particular de introducir no linealidad en la dinámica consiste en permitir que la matriz de transición dependa del estado previo y de un vector de parámetros dinámicos. En este caso, se considera el sistema

$$\mathbf{a}_t = A(\mathbf{a}_{t-1}, \boldsymbol{\theta}_t) \mathbf{a}_{t-1} + \mathbf{w}_t, \quad \mathbf{w}_t \sim \mathcal{N}(\mathbf{0}, Q), \quad (3.8)$$

donde

$$A(\mathbf{a}_{t-1}, \boldsymbol{\theta}_t) \in \mathbb{R}^{d \times d}$$

es una matriz de transición que puede variar en el tiempo y depender del estado anterior.

Por ejemplo, puede considerarse una parametrización lineal en $\boldsymbol{\theta}_t$ de la forma

$$A(\mathbf{a}_{t-1}, \boldsymbol{\theta}_t) = A_0 + \sum_{\ell=1}^m \theta_{t,\ell} A_\ell, \quad (3.9)$$

donde $A_0, A_1, \dots, A_m \in \mathbb{R}^{d \times d}$ son matrices fijas y $\boldsymbol{\theta}_t = (\theta_{t,1}, \dots, \theta_{t,m})^\top$ controla la variación temporal de la matriz de transición.

Si $\boldsymbol{\theta}_t$ también se considera latente, debe especificarse una ecuación de evolución adicional, por ejemplo

$$\boldsymbol{\theta}_t = q(\boldsymbol{\theta}_{t-1}, \mathbf{a}_{t-1}) + \mathbf{r}_t, \quad \mathbf{r}_t \sim \mathcal{N}(\mathbf{0}, Q_\theta), \quad (3.10)$$

donde $q(\cdot)$ describe la dinámica de los parámetros variables en el tiempo. En ese caso, el estado latente total puede ampliarse como

$$\tilde{\mathbf{a}}_t = \begin{pmatrix} \mathbf{a}_t \\ \boldsymbol{\theta}_t \end{pmatrix},$$

lo que permite aplicar el filtro de Kalman unscented al sistema aumentado.

Una vez estimado o filtrado el estado latente, se obtiene una predicción o estimación de las puntuaciones funcionales. En el caso en que $\mathbf{a}_t$ coincida con las puntuaciones, se puede reconstruir la curva funcional mediante

$$\widehat{X}_t^{(K)}(s) = \widehat{\mu}_{\text{train}}(s) + \sum_{j=1}^K \widehat{a}_{t,j} \widehat{\psi}_j(s). \quad (3.11)$$

Más generalmente, si las puntuaciones se obtienen a través de la función de observación h , la reconstrucción se realiza a partir de $\widehat{\mathbf{z}}_t = h(\widehat{\mathbf{a}}_t; \widehat{\theta})$.

3.3.5. Consideraciones de regularidad y estabilidad

3.3.6. Consideraciones de regularidad y estabilidad

La modelación dinámica en el espacio reducido se apoya en la hipótesis de que la mayor parte de la variabilidad relevante del proceso funcional queda contenida en las primeras K componentes principales. Esta hipótesis se justifica por el resultado de truncación (2.16) y por la descomposición del error total (2.18), la cual muestra que el error funcional puede separarse en una componente de truncación y una componente de estimación dinámica.

En el caso lineal con matriz de transición fija, la estabilidad del sistema reducido se caracteriza mediante la condición espectral (2.26), la cual garantiza la existencia de una solución causal del tipo (2.27). Sin embargo, cuando la matriz de transición depende del tiempo, del estado o de parámetros latentes, la condición $\rho(\mathbb{E}[A_t]) < 1$ no es, en general, suficiente para garantizar estabilidad en media cuadrática. Esto se debe a que la dinámica depende de productos sucesivos, potencialmente aleatorios, de matrices de transición.

En este contexto, una condición suficiente simple para obtener estabilidad uniforme consiste en suponer que existe una norma matricial submultiplicativa $\|\cdot\|$ y una constante $0 < r < 1$ tales que

$$\sup_t \|A_t\| \leq r. \quad (3.12)$$

Bajo esta condición, los efectos de las perturbaciones pasadas se amortiguan geométricamente. En efecto, para $j \geq 1$ se tiene

$$\|A_t A_{t-1} \cdots A_{t-j+1}\| \leq \prod_{\ell=0}^{j-1} \|A_{t-\ell}\| \leq r^j.$$

Por lo tanto, las contribuciones de estados e innovaciones pasadas decrecen de manera exponencial, evitando trayectorias explosivas en el sistema reducido.

En el contexto no lineal adoptado en esta tesis, estas condiciones deben interpretarse de manera local o aproximada. En particular, se asume que la función de transición

$$g : \mathbb{R}^d \rightarrow \mathbb{R}^d$$

es suficientemente regular en el rango de operación observado. Una forma usual de expresar esta regularidad es mediante una condición de tipo Lipschitz. Es decir, se supone que existe una constante $L > 0$ tal que

$$\|g(\mathbf{x}) - g(\mathbf{y})\| \leq L\|\mathbf{x} - \mathbf{y}\|, \quad \mathbf{x}, \mathbf{y} \in \mathcal{D}, \quad (3.13)$$

donde $\mathcal{D} \subset \mathbb{R}^d$ representa el dominio relevante para la dinámica observada.

La continuidad tipo Lipschitz garantiza regularidad local de la dinámica y controla la sensibilidad de la función de transición ante pequeñas perturbaciones del estado. Sin embargo, esta condición no excluye por sí sola comportamientos inestables o caóticos. Para controlar la estabilidad se requiere una condición más fuerte, como una propiedad de contracción. Por ejemplo, si la constante Lipschitz respecto de la variable de estado satisface

$$L < 1$$

en el dominio $\mathcal{D}$, entonces las diferencias entre trayectorias inducidas por condiciones iniciales cercanas se amortiguan geométricamente dentro de dicho dominio.

De forma equivalente, cuando la dinámica no lineal se aproxima localmente por una matriz de transición efectiva A_t , puede imponerse una condición suficiente de estabilidad uniforme de la forma

$$\sup_t \|A_t\| \leq r < 1,$$

para alguna norma matricial submultiplicativa. Bajo esta condición, los efectos de perturbaciones pasadas decrecen geométricamente, lo que evita trayectorias explosivas en el sistema reducido.

Estas consideraciones no se introducen aquí con ánimo exhaustivo, sino como condiciones estructurales que permiten interpretar la dinámica estimada y justificar la aplicación de procedimientos recursivos de inferencia, como el filtro de Kalman *unscented*, sobre el estado reducido.

3.3.7. Procedimiento de estimación mediante UKF

La estimación del modelo se realiza en varias etapas, apoyándose en la formulación del filtro de Kalman *unscented* desarrollada en la subsección correspondiente del marco teórico. En lo que sigue, $\mathbf{z}_t = \hat{\boldsymbol{\xi}}_t \in \mathbb{R}^K$ denota el vector de puntuaciones FPCA estimadas a partir de la curva funcional X_t , mientras que $\mathbf{a}_t \in \mathbb{R}^d$ representa el estado latente del modelo de espacio de estados.

Etapas 1: suavizamiento y FPCA

A partir de las observaciones discretas, se construyen curvas funcionales diarias y se obtiene una representación suave mediante bases B-spline. Posteriormente, se aplica FPCA para extraer las primeras K puntuaciones funcionales, de acuerdo con (3.2). Estas puntuaciones constituyen la representación reducida observada del proceso:

$$\mathbf{z}_t = \hat{\boldsymbol{\xi}}_t = (\hat{\xi}_{t,1}, \dots, \hat{\xi}_{t,K})^\top \in \mathbb{R}^K.$$

Para evitar filtración de información, la media funcional, el operador de covarianza, las autofunciones FPCA y el número de componentes retenidas se estiman exclusivamente usando el conjunto de entrenamiento. Las curvas del conjunto de prueba se proyectan posteriormente sobre la base FPCA aprendida en entrenamiento.

Etapas 2: inicialización del estado latente

El estado inicial del sistema se define a partir de las puntuaciones funcionales observadas en el conjunto de entrenamiento o mediante una inicialización compatible con la estructura reducida del proceso. En particular, se especifican una media inicial del estado $\hat{\mathbf{a}}_{0|0}$ y una matriz de covarianza inicial $P_{0|0}$ para comenzar el procedimiento recursivo.

Cuando el estado latente se identifica directamente con las puntuaciones funcionales, se

considera $d = K$ y puede tomarse, por ejemplo,

$$\hat{\mathbf{a}}_{0|0} = \mathbf{z}_1,$$

donde $\mathbf{z}_1$ corresponde al primer vector de puntuaciones observado en el conjunto de entrenamiento. Asimismo, $P_{0|0}$ puede inicializarse como la covarianza empírica de las puntuaciones funcionales de entrenamiento.

Etapla 3: construcción de puntos sigma y predicción

Dado el estado estimado en el instante anterior y su covarianza asociada, se construye un conjunto de puntos sigma según (2.48), (2.49) y (2.50). Estos puntos se propagan a través de la dinámica del estado, obteniendo los puntos sigma predichos según (2.51). A partir de ellos se calculan la media predictiva del estado (2.52) y la covarianza predictiva (2.53).

Etapla 4: predicción de la observación y actualización

Los puntos sigma predichos se transforman mediante la ecuación de observación, obteniendo la media predictiva de la observación (2.55), su covarianza (2.56) y la covarianza cruzada (2.57). Con estas cantidades se define la ganancia de Kalman (2.58). Luego, el estado latente se actualiza mediante (2.59) y su covarianza mediante (2.60).

Etapla 5: reconstrucción funcional

Una vez obtenida la estimación filtrada del estado latente, se obtiene una estimación de las puntuaciones funcionales. En el caso particular en que el estado latente coincide con las puntuaciones, es decir, cuando $d = K$ y $\mathbf{a}_t = \boldsymbol{\xi}_t$, la curva funcional estimada se reconstruye mediante

$$\hat{X}_t^{(K)}(s) = \hat{\mu}_{\text{train}}(s) + \sum_{j=1}^K \hat{a}_{t,j} \hat{\psi}_j(s), \quad (3.14)$$

donde $\hat{\mu}_{\text{train}}$ y $\{\hat{\psi}_j\}_{j=1}^K$ fueron estimadas usando únicamente el conjunto de entrenamiento.

Más generalmente, si las puntuaciones funcionales se obtienen a partir de una función de

observación h , la reconstrucción se realiza usando

$$\widehat{\mathbf{z}}_t = h(\widehat{\mathbf{a}}_t; \widehat{\theta}),$$

y luego proyectando dichas puntuaciones sobre la base FPCA retenida.

Parámetros de implementación del UKF

Para cada conjunto de datos se especifican los siguientes elementos de implementación:

1. **Dimensión del estado.** Se considera un estado latente $\mathbf{a}_t \in \mathbb{R}^d$. En la especificación base se toma $d = K$, donde K corresponde al número de componentes principales funcionales retenidas.
2. **Estado inicial.** La media inicial del estado $\widehat{\mathbf{a}}_{0|0}$ se inicializa usando el primer vector de puntuaciones funcionales observado en el conjunto de entrenamiento, o bien mediante el promedio de las puntuaciones de entrenamiento.
3. **Covarianza inicial.** La matriz $P_{0|0}$ se inicializa como la matriz de covarianza empírica de las puntuaciones funcionales del conjunto de entrenamiento.
4. **Ruido de estado.** La matriz Q representa la covarianza del ruido de estado $\mathbf{w}_t$. Esta matriz puede fijarse, calibrarse o estimarse a partir de los residuos de un modelo dinámico inicial ajustado sobre las puntuaciones de entrenamiento.
5. **Ruido de observación.** La matriz R representa la covarianza del ruido de observación $\mathbf{v}_t$. Esta matriz puede fijarse, calibrarse o estimarse a partir del error de reconstrucción, de la variabilidad residual de las puntuaciones funcionales o mediante un criterio de máxima verosimilitud aproximada.
6. **Parámetros del UKF.** Los parámetros de escalamiento del UKF se denotan por α , β y κ . Estos parámetros determinan la dispersión de los puntos sigma y los pesos asociados al cálculo de medias y covarianzas.
7. **Estimación de parámetros.** El UKF se utiliza para filtrar recursivamente el estado latente suponiendo conocidos los parámetros del modelo. Si los parámetros de g ,

h , Q o R se estiman desde los datos, debe especificarse un criterio adicional, como máxima verosimilitud predictiva aproximada, algoritmos de tipo EM u optimización numérica.

8. **Horizonte de predicción.** Se considera un horizonte de predicción h . En los experimentos de predicción un paso adelante se toma $h = 1$.
9. **Protocolo de entrenamiento y prueba.** Se utiliza una división cronológica entre entrenamiento y prueba, evitando particiones aleatorias. La FPCA y los parámetros iniciales del modelo se ajustan usando exclusivamente el conjunto de entrenamiento, mientras que el conjunto de prueba se emplea únicamente para evaluación predictiva.

Esquema algorítmico

El procedimiento completo puede resumirse de la siguiente manera:

Algorithm 1 Estimación secuencial mediante filtro de Kalman *unscented*

- 1: **Entrada:** puntuaciones observadas $\{\mathbf{z}_t\}_{t=1}^T$, estado inicial $\hat{\mathbf{a}}_{0|0}$, covarianza inicial $P_{0|0}$, funciones g y h , covarianzas Q y R , parámetros UKF α , β y κ
 - 2: **Salida:** estimaciones filtradas $\{\hat{\mathbf{a}}_{t|t}\}_{t=1}^T$
 - 3: **for** $t = 1, \dots, T$ **do**
 - 4: Generar puntos sigma a partir de $\hat{\mathbf{a}}_{t-1|t-1}$ y $P_{t-1|t-1}$ según (2.49)
 - 5: Propagar los puntos sigma a través de la dinámica g según (2.51)
 - 6: Calcular la media predictiva $\hat{\mathbf{a}}_{t|t-1}$ mediante (2.52)
 - 7: Calcular la covarianza predictiva $P_{t|t-1}$ mediante (2.53)
 - 8: Propagar los puntos sigma predichos a través de la función de observación h
 - 9: Calcular la media predictiva de la observación $\hat{\mathbf{z}}_{t|t-1}$ mediante (2.55)
 - 10: Calcular la covarianza predictiva de la observación S_t mediante (2.56)
 - 11: Calcular la covarianza cruzada $P_{az,t}$ mediante (2.57)
 - 12: Calcular la ganancia de Kalman K_t mediante (2.58)
 - 13: Actualizar el estado latente mediante (2.59)
 - 14: Actualizar la covarianza del estado mediante (2.60)
 - 15: **end for**
 - 16: Reconstruir la curva funcional estimada mediante (3.14)
-

3.3.8. Reconstrucción funcional y evaluación

Una vez obtenida la predicción del estado reducido, la curva funcional pronosticada se reconstruye mediante

$$\hat{X}_{t+1}^{(K)}(s) = \mu(s) + \sum_{j=1}^K \hat{\xi}_{t+1,j} \psi_j(s), \quad (3.15)$$

que corresponde al caso particular de la predicción funcional (2.67) para horizonte $h = 1$.

La calidad de la predicción se evalúa comparando la trayectoria reconstruida con la curva observada del periodo siguiente. Desde el punto de vista teórico, el error funcional se interpreta mediante la descomposición (2.68), la cual separa el error de predicción sobre las componentes retenidas del error de truncación asociado a las componentes descartadas. En el caso lineal, la incertidumbre predictiva puede además interpretarse mediante la traza de la covarianza dada en (2.69).

En la implementación empírica se utilizan métricas discretizadas sobre una grilla fina del dominio funcional, en particular el error cuadrático medio (MSE) y el error absoluto medio (MAE). Adicionalmente, se examina la adecuación del modelo mediante el análisis de innovaciones y residuos, en concordancia con (2.41) y (2.63).

3.3.9. Consideraciones computacionales

Desde el punto de vista computacional, el procedimiento combina tres tipos de costos principales.

- **Suavizamiento y FPCA.** El costo proviene de la construcción de la representación funcional y de la descomposición espectral asociada al operador de covarianza (2.10).
- **Propagación del estado reducido.** El costo del modelo dinámico depende de la dimensión reducida K y del número de observaciones temporales disponibles.
- **Filtro de Kalman unscented.** En el UKF, el costo por iteración está dominado por la generación de $2K + 1$ puntos sigma, de acuerdo con (2.49), así como por las operaciones matriciales requeridas para calcular (2.53), (2.56) y (2.60).

En consecuencia, para dimensión reducida fija, el costo total del procedimiento crece aproximadamente de forma lineal con el número de trayectorias observadas, lo que lo hace viable para aplicaciones con series temporales funcionales de tamaño moderado o grande.

Capítulo 4

Experimentos y resultados

4.1. Descripción de los conjuntos de datos

Con el fin de evaluar de manera integral el desempeño del modelo dinámico funcional propuesto, se realizaron experimentos sobre cinco conjuntos de datos reales provenientes de distintos dominios aplicados. Estos conjuntos de datos presentan características heterogéneas en términos de frecuencia temporal, naturaleza de las variables y estructura de dependencia, lo que permite analizar la robustez del modelo bajo diferentes escenarios empíricos.

Los conjuntos de datos utilizados son los siguientes:

- **Gemini Cryptocurrency (ASH/USD):** Serie temporal correspondiente al precio de intercambio de la criptomoneda ASH frente al dólar estadounidense obtenida de la plataforma Gemini. Los datos se registran con frecuencia horaria y contienen información sobre precios y volumen de transacciones.
<https://github.com/thebigshaikh>
- **Household Power Consumption:** Conjunto de datos ampliamente utilizado en estudios de series temporales energéticas, que registra el consumo eléctrico de un hogar residencial en Francia. Las observaciones incluyen variables como potencia activa global, potencia reactiva y diferentes submediciones de consumo eléctrico.

<https://github.com/mkivenson/Household-Power-Consumption>

- **Metro Interstate Traffic Volume:** Datos de volumen de tráfico vehicular registrados en una autopista interestatal en el área metropolitana de Minneapolis–Saint Paul. El conjunto incluye información meteorológica y variables temporales que influyen en el flujo vehicular.

<https://github.com/ManojKumarMaruthi/Regression>

- **Beijing Multi-Site Air Quality:** Serie temporal de calidad del aire registrada en múltiples estaciones de monitoreo en Beijing. Las variables incluyen concentraciones de contaminantes atmosféricos como $PM_{2.5}$, PM_{10} , SO_2 , NO_2 , CO y O_3 , junto con variables meteorológicas.

<https://github.com/Afkerian/Beijing-Multi-Site-Air-Quality-Data-Data-Set>

- **Electricity Transformer Temperature (ETT):** Conjunto de datos utilizado frecuentemente en estudios de predicción temporal, que registra la temperatura del aceite de transformadores eléctricos junto con variables relacionadas con la carga eléctrica. Las observaciones se registran con frecuencia horaria.

<https://github.com/zhouhaoyi/ETDataset>

4.2. Protocolo de entrenamiento y testeo

Para cada conjunto de datos se construyeron observaciones funcionales a partir de agregaciones diarias. Específicamente, las mediciones horarias fueron agrupadas en intervalos de 24 horas para obtener curvas funcionales diarias. Aquellos días con observaciones incompletas fueron descartados, con el objetivo de trabajar con trayectorias definidas sobre una misma malla temporal.

La partición entre entrenamiento y prueba se realizó respetando el orden cronológico de la serie. En particular, aproximadamente el 98 % inicial de las observaciones funcionales se destinó al conjunto de entrenamiento, mientras que el 2 % final se reservó para la evaluación fuera de muestra. Esta estrategia evita el uso de información futura durante la etapa de estimación y reproduce un escenario predictivo más realista.

Una vez definida la partición, las curvas diarias fueron suavizadas mediante una expansión en bases B-spline, con el objetivo de obtener una representación funcional continua de las trayectorias temporales. Posteriormente, se aplicó un procedimiento de reducción de dimensión mediante Análisis de Componentes Principales Funcionales (FPCA).

Para evitar filtración de información, la media funcional, el operador de covarianza, las autofunciones FPCA y el número de componentes principales retenidas se determinaron exclusivamente usando las curvas del conjunto de entrenamiento. De esta manera, el conjunto de prueba no intervino en la construcción de la base funcional reducida ni en la elección de la dimensión del espacio de scores.

Una vez aprendida la representación FPCA en el conjunto de entrenamiento, tanto las curvas de entrenamiento como las curvas de prueba fueron proyectadas sobre la misma base de autofunciones. Así, cada trayectoria funcional quedó representada por un vector de puntajes funcionales asociado a las primeras componentes principales retenidas.

El modelo dinámico funcional se estimó utilizando únicamente los puntajes funcionales del conjunto de entrenamiento. En particular, se empleó un modelo de espacio de estados no lineal basado en el filtro de Kalman *unscented* (UKF), el cual permite realizar inferencia secuencial sobre el estado latente asociado a la dinámica reducida del proceso funcional. Los parámetros del modelo y las matrices de covarianza utilizadas por el filtro se fijaron, calibraron o estimaron empleando exclusivamente información del conjunto de entrenamiento.

La evaluación predictiva se realizó posteriormente sobre el conjunto de prueba, manteniendo fijos todos los elementos aprendidos durante la etapa de entrenamiento: la media funcional, la base FPCA, el número de componentes retenidas y los parámetros del modelo dinámico. Las predicciones generadas en el espacio reducido fueron luego reconstruidas en el espacio funcional para compararlas con las trayectorias observadas.

Esta elección de partición, con aproximadamente un 98 % de observaciones para entrenamiento y un 2 % para prueba, buscó maximizar la información disponible para la estimación de modelos dinámicos funcionales, especialmente considerando el costo computacional del UKF. Al mismo tiempo, al reservar las observaciones finales para evaluación fuera de muestra, se mantiene un esquema de validación temporal coherente con el objetivo de

predicción.

Los experimentos se implementaron en el entorno estadístico **R**, utilizando bibliotecas especializadas para análisis funcional y modelos de espacio de estados.

4.3. Resultados predictivos

El desempeño predictivo del modelo se evaluó utilizando métricas estándar de error de predicción, particularmente el error cuadrático medio (MSE) y el error absoluto medio (MAE). Estas métricas se calcularon tanto en el conjunto de entrenamiento como en el conjunto de prueba con el fin de evaluar la capacidad de generalización del modelo.

Dataset	Modelo	MAE	MSE
Criptomonedas	VAR Dinámico	0.2861548	0.09305971
	FAR(1)	0.1166035	0.02546084
	Kalman Lineal	0.1344761	0.02743918
	f-GARCH	0.3204784	0.12790037
	TV-FAR	0.3744867	0.15541372
	UKF	0.4378532	0.26608178
Consumo Eléctrico	VAR Dinámico	0.4446307	0.2707251
	FAR(1)	0.4446307	0.2707251
	Kalman Lineal	0.4250964	0.2429222
	f-GARCH	0.4149361	0.2332321
	TV-FAR	0.4619715	0.3021380
	UKF	0.4139992	0.2327792
Flujo Vehicular	VAR Dinámico	195.23	96741.25
	FAR(1)	676.27	818277.16
	Kalman Lineal	534.86	583324.17
	f-GARCH	665.24	898800.15
	TV-FAR	217.61	80613.27
	UKF	155.85	110012.55
Polución	VAR Dinámico	58.44409	3449.019
	FAR(1)	62.12302	3892.588
	Kalman Lineal	47.67236	2304.049
	f-GARCH	47.67236	2304.049
	TV-FAR	47.75498	2311.945
	UKF	34.24877	1202.635
Temperatura OT	VAR Dinámico	0.9949796	1.3335765
	FAR(1)	0.4010108	0.2343384
	Kalman Lineal	0.3926599	0.2158717
	f-GARCH	0.3924427	0.2234410
	TV-FAR	0.4410330	0.3178926
	UKF	0.8368458	0.8897734

Cuadro 4.1: Resultados de MAE y MSE para distintos modelos en cinco datasets

Como se muestra en la Tabla 3.1, el desempeño predictivo de los modelos considerados varía dependiendo de la naturaleza dinámica de cada conjunto de datos. En general, los resultados evidencian diferencias importantes entre enfoques lineales, no lineales y funcionales, incluyendo el modelo VAR dinámico, el filtro de Kalman lineal, el filtro de Kalman no lineal basado en la transformación *unscented* (UKF), y modelos funcionales como FAR, TV-FAR y f-GARCH.

En el conjunto de datos correspondiente a la temperatura del aceite del transformador (Temperatura OT), En temperatura del aceite del transformador, los resultados favorecen modelos lineales o parsimoniosos. El filtro de Kalman lineal obtiene el menor MSE y f-GARCH el menor MAE, mientras que UKF presenta un error considerablemente mayor. Esto sugiere que, para este conjunto de datos, la estructura dominante puede estar suficientemente descrita por una dinámica lineal persistente y por heterocedasticidad condicional, sin requerir una formulación no lineal más flexible.

Para el conjunto de datos de polución atmosférica, el filtro UKF presenta el menor error de predicción en ambas métricas consideradas, superando tanto a los modelos lineales como a los funcionales. En particular, se observa una reducción sustancial del MSE en comparación con el modelo VAR dinámico, el filtro de Kalman lineal y modelos como FAR y TV-FAR. Este comportamiento indica que la dinámica de las concentraciones de contaminantes presenta relaciones no lineales relevantes que son capturadas de manera más efectiva mediante el esquema de estimación no lineal del UKF.

En flujo vehicular, el UKF obtiene el menor MAE, lo que sugiere mejor desempeño promedio absoluto. Sin embargo, TV-FAR y VAR dinámico obtiene el menor MSE, lo que indica menor penalización de errores grandes. Por tanto, la conclusión depende de la métrica: UKF parece reducir el error típico, mientras que TV-FAR parece controlar mejor errores extremos. En contraste, el filtro de Kalman lineal y el modelo FAR presentan errores considerablemente mayores, lo que evidencia dificultades para capturar la complejidad y variabilidad del sistema.

En consumo eléctrico, el UKF obtiene el menor MAE y MSE, aunque la diferencia respecto de f-GARCH es pequeña. Por tanto, los resultados sugieren una ventaja moderada del UKF, no una superioridad concluyente. Estos resultados sugieren que modelos capaces de

capturar no linealidades o heterocedasticidad pueden ser adecuados para este conjunto de datos.

Finalmente, para el conjunto de criptomonedas, los resultados favorecen claramente a modelos parsimoniosos. FAR(1) alcanza los menores valores de MAE y MSE, seguido por el filtro de Kalman lineal. En contraste, el UKF presenta el mayor error, lo que sugiere que la flexibilidad no lineal no aporta beneficios predictivos en este caso y puede amplificar variabilidad asociada a ruido o episodios extremos.

4.3.1. Conjunto de las criptomonedas

El análisis del conjunto de datos de criptomonedas sugiere la presencia de una dinámica latente altamente persistente y próxima al umbral de inestabilidad, lo que impone dificultades relevantes para su modelación mediante enfoques tradicionales. Como se observa en la Figura 4.2, el primer componente principal ($PC1$), asociado al nivel del precio, exhibe una trayectoria que converge hacia valores cercanos a uno. Esta configuración es compatible con un comportamiento próximo a raíz unitaria y permite inferir un alto grado de persistencia temporal en la serie, en el sentido de que la dinámica presente depende de manera marcada de su historia reciente. Por su parte, el segundo componente principal ($PC2$) presenta oscilaciones más abruptas, lo que sugiere variaciones en la forma de la curva intradía y la presencia de componentes dinámicas adicionales asociadas a la actividad del mercado.

Desde la perspectiva de la estabilidad, la Figura 4.4 muestra que el radio espectral del operador dinámico A_t alcanza e incluso supera el valor crítico de uno hacia el final del periodo de estudio. Este resultado es consistente con un régimen cercano a la inestabilidad o explosividad local, en el cual los choques dejan de disiparse con rapidez y pueden amplificarse temporalmente. En la misma figura, la evolución de los residuos al cuadrado muestra agrupamiento temporal de la variabilidad, lo que constituye evidencia empírica de *clusters* de volatilidad y, en consecuencia, de heterocedasticidad condicional en la serie.

En términos de desempeño predictivo, la Figura 4.1 muestra que el modelo FAR(1) obtiene el mejor ajuste relativo a la trayectoria observada, seguido por el filtro de Kalman lineal.

Este resultado sugiere que la estructura dominante del proceso puede ser capturada de manera adecuada mediante modelos lineales y relativamente parsimoniosos. En contraste, el filtro de Kalman no lineal basado en la transformación *unscented* (UKF) presenta el peor desempeño comparativo, generando predicciones con oscilaciones de magnitud superior a la observada en la serie real. Esta discrepancia sugiere que, en este caso, la incorporación de no linealidad no mejora la capacidad predictiva y podría estar amplificando componentes atribuibles principalmente a ruido o variabilidad no estructural.

Los diagnósticos de innovaciones, presentados en la Figura 4.3, refuerzan esta interpretación. En particular, la función de autocorrelación (ACF) indica que, más allá del primer rezago, los residuos son compatibles con un comportamiento cercano a ruido blanco, lo que sugiere que la mayor parte de la dependencia temporal ha sido absorbida por los modelos ajustados. No obstante, el histograma y el gráfico Q-Q evidencian desviaciones sistemáticas respecto a la normalidad, particularmente en las colas, lo que es consistente con la presencia de observaciones extremas o episodios de alta volatilidad, rasgo frecuente en series financieras. En consecuencia, la hipótesis gaussiana resulta insuficiente para describir completamente la distribución empírica de las innovaciones.

En este contexto, aunque el modelo f-GARCH no alcanza el mejor desempeño en términos de error medio, sí proporciona una descripción más adecuada de la dinámica de la volatilidad, particularmente en los intervalos de mayor incertidumbre identificados en la Figura 4.4. Por otra parte, el modelo VAR dinámico presenta un desempeño inferior al de enfoques más simples, lo que sugiere que la incorporación de una estructura multivariada dependiente del tiempo no aporta ganancias sustantivas en este conjunto de datos.

En conjunto, la evidencia empírica indica que la dinámica del precio de la criptomonedas está dominada por una fuerte persistencia y por episodios de volatilidad elevada, lo que favorece el uso de modelos funcionales parsimoniosos, como FAR(1), y de formulaciones lineales en espacio de estados. En contraste, modelos más flexibles, como el UKF o TV-FAR, no muestran ventajas predictivas en este caso y tienden a introducir variabilidad adicional en la reconstrucción. Por consiguiente, los resultados sugieren que, para este conjunto de datos, la parsimonia estructural y la adecuada representación funcional predominan sobre la incorporación de no linealidades adicionales.




Figura 4.1: Comparación de las predicciones obtenidas mediante los 6 modelos frente a la curva observada del precio ASH/USD.




Figura 4.2: Evolución temporal de los coeficientes dinámicos asociados a los componentes principales del modelo para el dataset de criptomonedas.





Figura 4.3: Diagnóstico de innovaciones del modelo para el dataset de criptomonedas. Se muestran el ACF, el histograma y el gráfico Q-Q de los residuos.



(a) Evolución del radio espectral del operador dinámico A_t .

(b) Evolución de la volatilidad condicional de los residuos.

Figura 4.4: Dinámica temporal del sistema para el dataset de criptomonedas: radio espectral y volatilidad condicional.

4.3.2. Conjunto de electricidad

El análisis del conjunto de datos de consumo eléctrico sugiere la presencia de una dinámica latente compleja, caracterizada por la interacción entre persistencia temporal, heterocedasticidad y posibles componentes no lineales. Como se observa en la Figura 4.5, todos los modelos reproducen la estructura general de la curva de consumo; sin embargo, se registran diferencias relevantes en su capacidad para ajustarse a los máximos y mínimos locales de la serie. En particular, se observa una tendencia sistemática a subestimar los

picos de consumo, especialmente en periodos de alta demanda, lo que es consistente con la presencia de observaciones extremas o cambios bruscos de nivel que no son capturados adecuadamente por formulaciones lineales simples.

Desde la perspectiva de la estabilidad, la Figura 4.8 muestra que el radio espectral del operador dinámico se aproxima en distintos intervalos al valor crítico de uno. Este comportamiento es compatible con un régimen de alta persistencia, en el cual los efectos de perturbaciones externas, tales como variaciones climáticas o cambios en los patrones de consumo, se disipan lentamente. En la misma figura, la evolución temporal de los residuos al cuadrado presenta agrupamiento de la variabilidad, lo que constituye evidencia empírica de *clusters* de volatilidad y, por tanto, de heterocedasticidad condicional. Este rasgo favorece el uso de modelos como f-GARCH, cuya formulación incorpora explícitamente la dinámica de la varianza condicional.

La evolución de los coeficientes dinámicos, presentada en la Figura 4.6, aporta información adicional sobre la estructura del estado latente. El primer componente principal ($PC1$), asociado al nivel general de consumo, presenta una trayectoria relativamente estable con oscilaciones suaves, mientras que los componentes de orden superior ($PC2$ y $PC3$) exhiben una mayor variabilidad, particularmente en los periodos iniciales, seguida de una fase de mayor estabilización. Este patrón sugiere que la incertidumbre sobre la forma de la curva de consumo es más elevada al inicio del periodo analizado y disminuye a medida que la dinámica subyacente se vuelve más regular.

Los diagnósticos de innovaciones del modelo, mostrados en la Figura 4.7, refuerzan esta interpretación. En particular, el histograma y el gráfico Q-Q muestran desviaciones sistemáticas respecto a la normalidad, especialmente en las colas, lo que resulta consistente con la presencia de eventos extremos en el consumo. Asimismo, la función de autocorrelación (ACF) revela dependencia temporal residual en ciertos rezagos, lo que sugiere que modelos lineales simples, como VAR o FAR(1), no logran absorber completamente la estructura dinámica del sistema.

En este contexto, el filtro de Kalman no lineal basado en la transformación *unscented* (UKF) presenta el mejor desempeño predictivo, alcanzando los menores valores de MAE y MSE. Como se aprecia en la Figura 4.5, este modelo reproduce con mayor precisión tanto

el nivel como la forma de la serie, particularmente en presencia de cambios abruptos. Este resultado es consistente con la hipótesis de que la dinámica del estado reducido incluye relaciones no lineales que no son capturadas adecuadamente por aproximaciones estrictamente lineales. En comparación, el filtro de Kalman lineal y los modelos funcionales clásicos presentan un desempeño ligeramente inferior, mientras que formulaciones más rígidas, como VAR dinámico o TV-FAR, muestran menor capacidad de adaptación frente a una estructura que varía en el tiempo.

En conjunto, la evidencia empírica indica que el consumo eléctrico corresponde a un proceso dinámico caracterizado por alta persistencia, heterocedasticidad y desviaciones respecto a la normalidad. Bajo estas condiciones, el uso de modelos que permitan capturar simultáneamente la dinámica de la media y parte de la complejidad de la incertidumbre resulta metodológicamente adecuado, destacando el desempeño del UKF en la modelación de la trayectoria latente y la utilidad de f-GARCH en la descripción de la volatilidad condicional.




Figura 4.5: Comparación de las predicciones obtenidas mediante los 6 modelos propuestos frente a la curva observada del consumo en KW.




Figura 4.6: Evolución temporal de los coeficientes dinámicos asociados a los componentes principales del modelo para el dataset de criptomonedas.





Figura 4.7: Diagnóstico de innovaciones del modelo para el dataset de criptomonedas. Se muestran el ACF, el histograma y el gráfico Q-Q de los residuos.



(a) Evolución del radio espectral del operador dinámico A_t .

(b) Evolución de la volatilidad condicional de los residuos.

Figura 4.8: Dinámica temporal del sistema para el dataset de consumo eléctrico: radio espectral y volatilidad condicional.

4.3.3. Conjunto de flujo vehicular

El análisis del conjunto de datos de flujo vehicular sugiere la presencia de una dinámica latente altamente estructurada, pero con variabilidad temporal significativa. Como se observa en la Figura 4.9, la curva observada del volumen de tráfico presenta un patrón intradía claramente bimodal, con un máximo matutino asociado a la hora punta de la mañana y un segundo pico, de mayor magnitud y duración, durante la tarde. Esta configuración indica que la estructura dominante del proceso no se reduce únicamente al nivel medio de la serie, sino también a la forma de la curva y a sus variaciones locales en intensidad.

La evolución temporal de esta estructura se aprecia con mayor detalle en la Figura 4.10, donde los coeficientes dinámicos asociados a los componentes principales permiten descomponer la dinámica del sistema. En particular, el primer componente principal ($PC1$), asociado al nivel general de tráfico, presenta una trayectoria relativamente estable con fluctuaciones puntuales, lo que sugiere cambios en el volumen agregado de vehículos. Por su parte, el segundo componente principal ($PC2$) exhibe mayor variabilidad, capturando modificaciones en la forma de la curva intradía, especialmente en la relación entre los picos de la mañana y de la tarde. En conjunto, estos resultados son consistentes con una estructura promedio estable, pero con una localización e intensidad de los máximos que varían apreciablemente entre días.

Desde la perspectiva de la estabilidad y la incertidumbre del sistema, la Figura 4.12 muestra que el radio espectral del operador dinámico se mantiene en un rango compatible con estabilidad, aunque próximo a zonas de alta persistencia. Este comportamiento sugiere que los choques se disipan, pero no necesariamente de manera inmediata. En la misma figura, la evolución de los residuos al cuadrado presenta agrupamiento temporal de la variabilidad, lo que constituye evidencia empírica de *clusters* de volatilidad, con periodos claramente diferenciados de alta y baja incertidumbre. Esta configuración es consistente con la influencia de factores exógenos que modifican los patrones habituales de tráfico, tales como condiciones climáticas, eventos extraordinarios o variaciones estacionales.

Los diagnósticos de innovaciones del modelo, presentados en la Figura 4.11, permiten evaluar la adecuación dinámica del enfoque adoptado. En particular, los residuos se concentran en torno a cero sin evidencia clara de sesgo sistemático, mientras que la función de autocorrelación (ACF) indica que la mayor parte de la dependencia temporal ha sido absorbida por el modelo. No obstante, el gráfico Q-Q muestra desviaciones respecto a la normalidad en las colas, lo que resulta consistente con la presencia de observaciones extremas asociadas a caídas o incrementos abruptos en el flujo vehicular. Tales episodios son, por su naturaleza, difíciles de anticipar mediante modelos puramente gaussianos.

En este contexto, el filtro de Kalman no lineal basado en la transformación *unscented* (UKF) presenta el mejor desempeño predictivo, tal como se aprecia en la Figura 4.9, donde las predicciones reproducen con mayor precisión tanto la forma bimodal como las variaciones locales de la serie. Este resultado es consistente con la hipótesis de que la dinámica del estado reducido incluye relaciones no lineales, particularmente en la evolución del componente *PC2*, el cual gobierna cambios complejos en la forma de la curva intradía. En comparación, modelos lineales como el filtro de Kalman estándar presentan errores de mayor magnitud, lo que sugiere menor capacidad de adaptación frente a fluctuaciones locales del sistema.

Finalmente, la comparación de las métricas de error refuerza estas observaciones: los mejores desempeños corresponden al UKF y al VAR dinámico, lo que sugiere que la dependencia temporal de corto plazo desempeña un papel central en este conjunto de datos. En contraste, modelos más parsimoniosos, como FAR(1), o modelos orientados a la volatilidad, como f-GARCH, resultan menos adecuados para capturar la rápida evolución

y la no linealidad de la dinámica de la media. En conjunto, la evidencia empírica indica que el flujo vehicular corresponde a un sistema en el que interactúan una estructura determinística intradía, variabilidad temporal significativa y componentes no lineales, por lo que el uso de modelos dinámicos más flexibles resulta metodológicamente apropiado.




Figura 4.9: Comparación de las predicciones obtenidas mediante los 6 modelos propuestos frente a la curva observada de volumen de vehículos.




Figura 4.10: Evolución temporal de los coeficientes dinámicos asociados a los componentes principales del modelo para el dataset de flujo vehicular.





Figura 4.11: Diagnóstico de innovaciones del modelo para el dataset de flujo vehicular. Se muestran el ACF, el histograma y el gráfico Q-Q de los residuos.



(a) Evolución del radio espectral del operador dinámico A_t .

(b) Evolución de la volatilidad condicional de los residuos.

Figura 4.12: Dinámica temporal del sistema para el dataset de flujo vehicular: radio espectral y volatilidad condicional.

4.3.4. Conjunto de polución

El análisis del conjunto de datos de polución atmosférica sugiere que la dinámica de la concentración de material particulado fino ($PM_{2,5}$) está caracterizada por alta persistencia temporal, heterocedasticidad y componentes no lineales relevantes. Como se observa en la Figura 4.13, la serie presenta un patrón diario bien definido, con máximos asociados a intervalos de mayor actividad antropogénica, lo que es consistente con la existencia de ciclos intradía en la evolución del contaminante.

Desde la perspectiva de la estabilidad, la Figura 4.16 muestra que el radio espectral del operador dinámico se mantiene de manera sistemática por debajo de uno. Este resultado es compatible con un régimen estable, aunque altamente persistente, en el cual los efectos de perturbaciones externas se disipan lentamente. En la misma figura, la evolución de los residuos al cuadrado presenta agrupamiento temporal de la variabilidad, lo que constituye evidencia empírica de *clusters* de volatilidad y, en consecuencia, de heterocedasticidad condicional.

En este contexto, el filtro de Kalman no lineal basado en la transformación *unscented* (UKF) presenta el mejor desempeño predictivo, reproduciendo con mayor precisión tanto el nivel como la forma de la serie observada, tal como se aprecia en la Figura 4.13. Este resultado es consistente con la presencia de relaciones no lineales en la dinámica del estado reducido, las cuales no son capturadas adecuadamente por el filtro de Kalman lineal ni por modelos como VAR o FAR(1), cuyos ajustes tienden a sobreestimar sistemáticamente la trayectoria observada.

El análisis del estado latente, mostrado en la Figura 4.14, indica que el primer componente principal (*PC1*) concentra una estructura de fondo relativamente estable, mientras que los componentes de orden superior reflejan ajustes de corto plazo y variaciones locales en la forma de la curva. Esta descomposición sugiere que la dinámica del proceso combina una componente dominante persistente con fluctuaciones de menor escala temporal.

Por otra parte, los diagnósticos de innovaciones presentados en la Figura 4.15 muestran desviaciones respecto a la normalidad, particularmente en las colas, junto con evidencia de dependencia temporal remanente. Este comportamiento es consistente con la presencia de observaciones extremas y con una estructura dinámica que no puede describirse completamente mediante supuestos gaussianos estándar.

En conjunto, la evidencia empírica indica que la serie de $PM_{2,5}$ presenta una combinación de persistencia, heterocedasticidad y no linealidad, bajo la cual el UKF ofrece una representación más adecuada de la dinámica latente y una mejora sustantiva en precisión predictiva respecto a los modelos lineales y funcionales clásicos.




Figura 4.13: Comparación de las predicciones obtenidas mediante el modelo VAR dinámico, el filtro de Kalman lineal y el UKF frente a la curva observada de concentración de $PM_{2,5}$




Figura 4.14: Evolución temporal de los coeficientes dinámicos asociados a los componentes principales del modelo para el dataset de polución.





Figura 4.15: Diagnóstico de innovaciones del modelo para el dataset de polución. Se muestran el ACF, el histograma y el gráfico Q-Q de los residuos.



(a) Evolución del radio espectral del operador dinámico A_t .

(b) Evolución de la volatilidad condicional de los residuos.

Figura 4.16: Dinámica temporal del sistema para el dataset de material particulado 2.5 : radio espectral y volatilidad condicional.

4.3.5. Conjunto de temperatura OT

El análisis del desempeño predictivo en el conjunto de datos de temperatura del aceite del transformador sugiere una jerarquía relativamente definida entre los modelos considerados, caracterizada por una competencia estrecha entre enfoques funcionales y formulaciones lineales en espacio de estados. Como se observa en la Figura 4.17, los modelos f-GARCH y Kalman lineal presentan un ajuste más próximo a la curva observada que el resto de los métodos. En particular, el modelo f-GARCH alcanza el menor error absoluto medio ($MAE = 0.3924$), lo que lo posiciona como el mejor en términos de discrepancia promedio.

Este resultado es consistente con la presencia de heterocedasticidad condicional, en un contexto donde la varianza de los errores no permanece constante en el tiempo. Muy próximo a este desempeño se encuentra el filtro de Kalman lineal ($MAE = 0.3926$), cuya estructura recursiva permite actualizar el estado de manera eficiente frente a cambios graduales en el nivel de la serie. Por su parte, el modelo FAR(1) también presenta un desempeño competitivo ($MAE = 0.4010$), lo que sugiere que una parte importante de la dinámica del proceso puede describirse a partir de la forma funcional observada en el periodo inmediatamente anterior.

Desde la perspectiva dinámica, los gráficos asociados permiten caracterizar con mayor precisión la naturaleza del proceso subyacente. En la Figura 4.20 se observa que el radio espectral del operador dinámico se mantiene cercano a uno a lo largo del tiempo. Este comportamiento es compatible con un régimen de alta persistencia, próximo al umbral de estabilidad, en el cual los choques se disipan lentamente. En la misma figura, la evolución de los residuos al cuadrado presenta agrupamiento temporal de la variabilidad, lo que constituye evidencia empírica de *clusters* de volatilidad y, por tanto, de heterocedasticidad condicional. Esta característica resulta coherente con el buen desempeño relativo del modelo f-GARCH, cuya formulación está diseñada precisamente para capturar la dinámica de la varianza condicional.

Adicionalmente, la Figura 4.18 muestra que los coeficientes dinámicos asociados al primer componente principal ($PC1$) se estabilizan en valores elevados y próximos a uno, lo que es consistente con una dinámica de fuerte persistencia en el componente dominante del proceso. En contraste, el segundo componente principal ($PC2$) presenta mayor variabilidad temporal, sugiriendo que su contribución se concentra principalmente en ajustes de corto plazo y en cambios locales en la curvatura de las trayectorias.

En contraste con los modelos anteriores, el filtro de Kalman no lineal basado en la transformación *unscented* (UKF) presenta el peor desempeño relativo ($MAE = 0.836$; $MSE = 0.889$). Como se aprecia en la Figura 4.17, sus predicciones introducen oscilaciones de magnitud superior a la observada en la serie real y se alejan sistemáticamente de la trayectoria empírica. Este patrón sugiere que la incorporación de no linealidades en el espacio de estados no produce ganancias predictivas en este contexto y, por el contrario, puede amplificar componentes atribuibles a ruido o variabilidad no estructural. A dife-

rencia del filtro de Kalman lineal, cuya dinámica induce una evolución más suave del estado, el UKF muestra una sensibilidad mayor frente a las innovaciones, lo que deteriora su precisión predictiva.

Los diagnósticos de innovaciones refuerzan esta interpretación. En la Figura 4.19 se observan desviaciones respecto a la normalidad, particularmente en las colas, tanto en el histograma como en el gráfico Q-Q. Asimismo, la función de autocorrelación indica que el rezago uno permanece significativo, lo que sugiere la existencia de dependencia temporal residual de corto plazo. En este contexto, el desempeño inferior del modelo VAR dinámico indica que la incorporación de una estructura multivariada dependiente del tiempo no aporta mejoras sustantivas frente a formulaciones más parsimoniosas, como FAR(1), o frente a modelos que capturan de manera explícita la heterocedasticidad, como f-GARCH.

En conjunto, la evidencia empírica indica que la serie de temperatura del aceite evoluciona en un régimen de alta persistencia, próximo al umbral de estabilidad, y con heterocedasticidad condicional relevante. Bajo estas condiciones, los resultados comparativos sugieren que modelos esencialmente lineales o parsimoniosos, como el filtro de Kalman lineal y FAR(1), así como modelos orientados a la dinámica de la varianza, como f-GARCH, resultan más adecuados que formulaciones no lineales más flexibles como el UKF. En consecuencia, para este conjunto de datos, la parsimonia estructural y la modelación explícita de la volatilidad parecen desempeñar un papel más relevante que la incorporación de no linealidades adicionales.




Figura 4.17: Comparación de las predicciones obtenidas mediante los 6 modelos frente a la curva observada de temperatura de aceite




Figura 4.18: Evolución temporal de los coeficientes dinámicos asociados a los componentes principales del modelo para el dataset de temperatura del aceite OT.





Figura 4.19: Diagnóstico de innovaciones del modelo para el dataset de polución. Se muestran el ACF, el histograma y el gráfico Q-Q de los residuos.



(a) Evolución del radio espectral del operador dinámico A_t .

(b) Evolución de la volatilidad condicional de los residuos.

Figura 4.20: Dinámica temporal del sistema para el dataset de temperatura: radio espectral y volatilidad condicional.

4.4. Experimento 1: Detección de cambio estructural bajo distintas intensidades

En este experimento se evaluó el desempeño del filtro de Kalman *unscented* (UKF) en un entorno controlado mediante la simulación de datos funcionales con un cambio estructural en el operador dinámico. Se generaron $T = 500$ trayectorias funcionales, cada una observada en una malla de $m = 24$ puntos, y representadas mediante una base ortonormal de dimensión $K = 2$. La dinámica de los coeficientes latentes $\xi_t \in \mathbb{R}^2$ fue modelada mediante un proceso autorregresivo de orden 1 con un quiebre estructural en $t = 250$.

Con el fin de analizar la sensibilidad del filtro frente a la magnitud del cambio, se consideraron dos configuraciones del operador dinámico. En ambos casos, el régimen inicial está dado por un operador estable y diagonal

$$A_1 = \begin{pmatrix} 0,8 & 0,0 \\ 0,0 & 0,8 \end{pmatrix},$$

mientras que el segundo régimen varía en intensidad. En una primera configuración, el cambio introduce dependencia cruzada moderada entre componentes. En una segunda configuración, más exigente, el operador

$$A_2 = \begin{pmatrix} -0,5 & 0,9 \\ -0,9 & -0,5 \end{pmatrix}$$

genera una dinámica oscilatoria con inversión de signo y fuerte acoplamiento, produciendo trayectorias significativamente más inestables.

El filtro UKF fue implementado bajo una especificación incorrecta, asumiendo que la dinámica del sistema permanece gobernada por A_1 en todo momento. Para compensar esta mala especificación, se incorporó un mecanismo adaptativo en la covarianza del ruido de proceso, definida como

$$Q_t = Q_{\text{base}} \left(1 + c \cdot \overline{\varepsilon_t^2} \right),$$

donde $\overline{\varepsilon_t^2}$ corresponde a la energía promedio de los residuos en una ventana móvil, y c es un factor de amplificación.

Los resultados muestran que el comportamiento del filtro depende críticamente de la intensidad del cambio estructural. En el caso de un cambio moderado, el UKF logra adaptarse parcialmente mediante el incremento de la incertidumbre, permitiendo detectar la ruptura aunque con cierto retardo temporal. En contraste, bajo un cambio agresivo, los residuos crecen de manera explosiva y los tests estadísticos (CUSUM y Chow) rechazan con alta significancia la hipótesis de estabilidad. El algoritmo PELT detecta el quiebre en torno a $t \approx 298$, evidenciando nuevamente un desfase respecto al cambio real.

Desde el punto de vista dinámico, mientras que en el escenario moderado el filtro mantiene cierta capacidad de seguimiento, en el caso agresivo se observa una pérdida completa

de estabilidad. La propagación de los puntos sigma bajo un operador incorrecto induce divergencia en los estados estimados, y el mecanismo adaptativo basado en Q_t resulta insuficiente para corregir el error de especificación. En consecuencia, este experimento evidencia que la detección de cambios estructurales es factible mediante el análisis de residuos, pero la estabilidad del sistema requiere necesariamente la actualización explícita del operador dinámico.

4.5. Experimento 2: Sensibilidad a la Dimensionalidad y a la Representación Funcional

Este experimento evalúa la robustez del modelo propuesto frente a dos fuentes fundamentales de especificación: (i) la elección del número de componentes principales K , y (ii) la selección de la base funcional utilizada en la representación de las curvas. Ambos elementos determinan la calidad de la aproximación funcional y afectan directamente la estabilidad del filtro de Kalman.

Impacto de la Representación Funcional

Se compararon tres bases funcionales: Fourier, B-Splines y Wavelets, evaluando su desempeño en términos de error de reconstrucción de coeficientes (MSE) y la traza de la matriz de covarianza del filtro ($\text{tr}(P)$), utilizada como medida de incertidumbre.

Los resultados evidencian diferencias sustanciales entre representaciones.

En primer lugar, la base de Fourier presenta el mejor desempeño, con un error de reconstrucción extremadamente bajo ($\text{MSE} = 0,013$) y la menor incertidumbre ($\text{tr}(P) = 0,169$). Este comportamiento se explica porque la dinámica simulada posee una estructura intrínsecamente oscilatoria, la cual es capturada de manera eficiente mediante funciones sinusoidales. En consecuencia, el filtro opera en un régimen estable, donde los puntos sigma se concentran en torno a la trayectoria estimada, reflejando alta confianza en el modelo.

Por el contrario, la base de B-Splines muestra un deterioro significativo en desempeño ($\text{MSE} = 0,814$), debido a su naturaleza local. Con un número limitado de funciones base, esta representación no logra capturar adecuadamente la estructura global de la señal, generando pérdida de información relevante. Esta deficiencia se traduce en un aumento de la incertidumbre del filtro ($\text{tr}(P) = 0,518$), reflejando una menor capacidad de predicción.

Finalmente, la representación mediante Wavelets presenta un comportamiento intermedio en términos de error ($\text{MSE} = 0,443$), pero con la mayor incertidumbre ($\text{tr}(P) = 0,586$). Esto se debe a la naturaleza no suave de ciertas bases wavelet (por ejemplo, Haar), que introducen discontinuidades al aproximar funciones suaves. Como consecuencia, el residuo estructural se interpreta como ruido de proceso, inflando la covarianza del sistema y deteriorando la estabilidad del filtro.

En conjunto, estos resultados demuestran que la elección de la base funcional no solo afecta la precisión de reconstrucción, sino también la estabilidad dinámica del sistema estimado.

Impacto de la Dimensionalidad

Se evaluaron tres configuraciones: subestimación ($K = 1$), especificación correcta ($K = 5$) y sobreestimación ($K = 15$).

En el caso de subestimación ($K = 1$), el modelo presenta un error elevado ($\text{MSE} = 0,394$), debido a la incapacidad de capturar la estructura oscilatoria del sistema. Sin embargo, la incertidumbre es artificialmente baja ($\text{tr}(P) = 0,034$), lo que indica un exceso de confianza en una representación incorrecta. Este fenómeno corresponde a un sesgo estructural elevado, donde el modelo ignora componentes relevantes de la señal.

Para $K = 5$, correspondiente a la dimensión real del sistema, se obtiene un equilibrio óptimo entre precisión y estabilidad. El error disminuye significativamente ($\text{MSE} = 0,066$) y la incertidumbre se mantiene en niveles moderados ($\text{tr}(P) = 0,170$). Esta configuración captura adecuadamente la dinámica subyacente sin introducir complejidad innecesaria.

En contraste, la sobreestimación ($K = 15$) produce una leve mejora en el error ($\text{MSE} =$

0,064), pero a costa de un aumento considerable en la incertidumbre ($\text{tr}(P) = 0,510$). Este comportamiento es característico del sobreajuste, donde el modelo comienza a capturar ruido como si fuera señal, lo que deteriora la estabilidad del filtro y aumenta el riesgo de inestabilidad numérica.

Los resultados permiten identificar un trade-off fundamental entre sesgo y varianza:

- La subestimación introduce alto sesgo y pérdida de información estructural.
- La sobreestimación incrementa la varianza y reduce la estabilidad del sistema.

Desde la perspectiva del filtrado, la subestimación compromete la capacidad predictiva, mientras que la sobreestimación afecta la robustez y estabilidad del algoritmo.

El desempeño del filtro Unscented Kalman está fuertemente influenciado por la calidad de la representación funcional. En escenarios de subestimación, el filtro converge rápidamente pero hacia una solución sesgada. En cambio, en escenarios de sobreestimación, los puntos sigma se dispersan excesivamente, generando trayectorias erráticas y aumentando la sensibilidad a perturbaciones.

Estos resultados muestran que el UKF es robusto a cierta mala especificación, pero su desempeño óptimo depende críticamente de una adecuada elección tanto de la base funcional como de la dimensión del espacio reducido.

El experimento demuestra que la selección conjunta de la base funcional y la dimensionalidad es un elemento crítico en modelos de espacio de estados funcionales. En particular, una representación alineada con la estructura de la señal (como Fourier en procesos oscilatorios) y una elección adecuada de K permiten alcanzar un equilibrio óptimo entre precisión, estabilidad y robustez.




Figura 4.21: Gráficos del experimento 2 respecto de la dimensionalidad

4.6. Experimento 3: Robustez del UKF ante violaciones de gaussianidad

Este experimento evalúa la robustez del filtro de Kalman *unscented* (UKF) frente a la violación del supuesto de gaussianidad en los ruidos de proceso. El UKF, al igual que el filtro de Kalman clásico, se deriva bajo la hipótesis de que las perturbaciones siguen distribuciones normales. Para analizar el impacto de relajar este supuesto, se introduce un cambio en la distribución del ruido hacia una t -Student con 5 grados de libertad (t_5), la cual presenta colas pesadas y, por tanto, una mayor probabilidad de generar valores atípicos.

En una primera etapa, se considera un escenario de contaminación distribuida, donde el sistema evoluciona con ruido gaussiano para $t < 300$ y con ruido t_5 para $t \geq 300$. Este diseño permite evaluar si el filtro mantiene estabilidad ante la aparición frecuente de observaciones extremas. Los resultados muestran que, tras el cambio de distribución, los residuos presentan picos más pronunciados, evidenciando la presencia de outliers. No obstante, la variabilidad global de los residuos se mantiene acotada y el filtro continúa siguiendo adecuadamente la dinámica del sistema.

Un resultado particularmente relevante es que el error cuadrático medio en la fase con ruido t -Student no aumenta, e incluso resulta levemente inferior al de la fase gaussiana. Aunque este comportamiento puede parecer contra-intuitivo, tiene una explicación técnica. Por una parte, el escalamiento aplicado a la distribución t_5 asegura una varianza comparable a la gaussiana, lo que limita el impacto promedio de los outliers. Por otra, el UKF, al ser un estimador de mínimo error cuadrático medio, presenta una robustez inherente frente a perturbaciones con media cero, siempre que la dinámica del sistema esté correctamente especificada. Este resultado sugiere que el filtro es capaz de absorber desviaciones moderadas de la normalidad sin deteriorar significativamente su desempeño.

El análisis mediante gráficos Q-Q confirma la violación del supuesto de gaussianidad. Mientras que en la fase inicial los residuos se alinean con la recta teórica, en la fase con ruido t -Student se observan desviaciones claras en las colas, lo que evidencia una mayor frecuencia de valores extremos. Adicionalmente, si se considera la estimación del operador dinámico mediante ventanas deslizantes, estos outliers introducen fluctuaciones temporales en los parámetros estimados, incrementando su volatilidad.

En una segunda etapa, se analiza un escenario más adverso mediante la inyección de outliers puntuales de gran magnitud en las observaciones. A diferencia del caso anterior, donde la contaminación es distribuida, aquí los eventos son esporádicos pero altamente disruptivos. Los resultados evidencian un fenómeno de respuesta impulsiva del filtro, donde cada outlier induce un desplazamiento abrupto en la estimación del estado. Sin embargo, inmediatamente después de cada perturbación, el sistema retorna rápidamente a su trayectoria base, lo que indica estabilidad asintótica.

Este comportamiento puede interpretarse como un compromiso entre sensibilidad y estabilidad. Por un lado, el filtro no es completamente robusto en el sentido estricto, ya que responde activamente a los valores atípicos en lugar de ignorarlos. Por otro, demuestra una alta resiliencia, al no propagar el error en el tiempo ni divergir tras los shocks. Este fenómeno, descrito como un efecto de “latigazo”, refleja que el filtro es capaz de absorber perturbaciones extremas de forma transitoria.

Finalmente, el análisis de la energía de los residuos muestra picos pronunciados en los instantes de ataque, lo que sugiere que el filtro detecta eficazmente la presencia de ano-

malías. En aplicaciones prácticas, este comportamiento podría ser aprovechado como un mecanismo de detección de fallos o eventos anómalos.

En conjunto, los resultados indican que el UKF es robusto frente a desviaciones distribucionales moderadas, pero vulnerable a outliers extremos en términos de precisión instantánea. No obstante, su capacidad de recuperación evita la inestabilidad global del sistema. Esto sugiere que, en entornos con alta probabilidad de observaciones atípicas, resulta conveniente complementar el filtro con técnicas robustas que limiten la influencia de errores extremos.

4.7. Conclusiones

Los resultados obtenidos a partir de los experimentos controlados y del análisis empírico sobre múltiples datasets permiten establecer una caracterización integral del desempeño del filtro de Kalman *unscented* (UKF) y de los modelos funcionales en contextos dinámicos complejos.

En primer lugar, los experimentos de simulación evidencian que el desempeño del UKF está fuertemente condicionado por la correcta especificación del sistema. En particular, se observa que el filtro es capaz de adaptarse a perturbaciones moderadas mediante mecanismos internos de ajuste de incertidumbre, pero presenta limitaciones importantes ante cambios estructurales severos, errores en la representación funcional y presencia de outliers extremos. Estos resultados muestran que la robustez del UKF no es absoluta, sino que depende críticamente de la calidad de la modelación subyacente.

En segundo lugar, el análisis empírico sobre los cinco datasets confirma y extiende estos hallazgos en escenarios reales. En sistemas caracterizados por alta persistencia y estructuras funcionales estables, como las criptomonedas y la temperatura del aceite, los modelos más simples, como FAR(1) y el filtro de Kalman lineal presentan el mejor desempeño, lo que indica que la parsimonia es suficiente para capturar la dinámica dominante. En contraste, en sistemas con mayor complejidad estructural, como el flujo vehicular y la polución atmosférica, donde existen no linealidades y cambios en la forma de la señal, el UKF logra ventajas significativas al adaptarse a estas dinámicas no lineales.

Adicionalmente, en datasets como el consumo eléctrico, donde coexisten persistencia, heterocedasticidad y no linealidades moderadas, ningún modelo individual resulta completamente dominante. En estos casos, se observa que la combinación de enfoques —como el uso de modelos de volatilidad tipo f-GARCH junto con filtros dinámicos— permite capturar de manera más adecuada tanto la media como la incertidumbre del sistema.

Un resultado transversal, consistente tanto en simulación como en datos reales, es la relevancia de la representación funcional y de la dimensionalidad del sistema. Una mala elección de base o de número de componentes principales puede inducir sesgos o inestabilidad, afectando directamente el desempeño del filtro. Asimismo, la presencia sistemática de heterocedasticidad y colas pesadas en los residuos evidencia que los supuestos gaussianos son frecuentemente violados en la práctica, lo que limita el alcance de los modelos clásicos y justifica el uso de enfoques más flexibles.

En conjunto, los resultados permiten concluir que no existe un modelo universalmente óptimo, sino que el desempeño depende de la interacción entre tres elementos fundamentales: la estructura dinámica del sistema, la calidad de la representación funcional y la naturaleza estadística del ruido. En este sentido, el UKF destaca como una herramienta poderosa para modelar no linealidades, pero su uso debe ser cuidadosamente justificado, ya que puede sobreajustar el ruido en sistemas donde la dinámica es esencialmente lineal o altamente persistente.

Finalmente, esta investigación sugiere que el enfoque más adecuado para el modelamiento de series funcionales dinámicas no consiste en la adopción de un único modelo, sino en una estrategia adaptativa basada en diagnóstico previo. La selección del modelo debe considerar propiedades como estabilidad, persistencia, no linealidad y estructura de la varianza, permitiendo combinar herramientas de manera coherente según las características del problema. De esta forma, es posible alcanzar un equilibrio entre precisión, interpretabilidad y robustez en la predicción de sistemas complejos.

Capítulo 5

Conclusiones

En esta tesis se estudió el problema de modelar y predecir series temporales funcionales mediante una formulación de espacio de estados construida sobre una representación reducida del proceso. El enfoque adoptado combina herramientas de análisis funcional de datos, reducción de dimensión vía componentes principales funcionales y un esquema de inferencia recursiva basado en el filtro de Kalman *unscented*. Esta combinación permitió formular un marco coherente para describir la evolución temporal de trayectorias funcionales a través de un estado reducido de dimensión finita.

Desde el punto de vista teórico, el trabajo mostró que la representación de las trayectorias en una base funcional apropiada permite trasladar el problema desde un espacio de Hilbert infinito-dimensional a un contexto multivariado de dimensión reducida. En particular, el FPCA aparece como una herramienta fundamental, pues proporciona una base ortonormal empírica adaptada a la estructura de covarianza del proceso y, al mismo tiempo, una representación óptima en media cuadrática dentro de la clase de aproximaciones truncadas. De este modo, las puntuaciones funcionales retenidas pueden interpretarse como las variables de estado sobre las cuales se construye la modelación dinámica posterior.

Sobre esta base, se desarrolló una metodología en la cual la dinámica temporal se modela en el espacio reducido de puntuaciones y la inferencia del estado se realiza de manera secuencial. El interés principal de esta formulación radica en que permite separar conceptualmente la evolución latente del sistema de la variabilidad observacional, incorporando

además una herramienta recursiva para actualizar estimaciones y pronósticos a medida que se dispone de nueva información. En el caso no lineal, el uso del UKF permite extender el marco lineal-gaussiano clásico sin recurrir a linealizaciones explícitas del sistema.

Los resultados experimentales obtenidos en conjuntos de datos reales muestran que el desempeño del enfoque propuesto depende de la naturaleza dinámica del proceso observado. En los casos de polución atmosférica, consumo eléctrico y flujo vehicular, el UKF exhibe un comportamiento competitivo e incluso superior al de varios métodos de referencia, lo que sugiere que en estos escenarios la incorporación de una dinámica no lineal en el espacio reducido resulta apropiada. En particular, la mejora observada en el conjunto de polución indica que el modelo es capaz de capturar relaciones dinámicas que no son descritas adecuadamente por aproximaciones lineales más rígidas.

Cabe señalar que las métricas utilizadas para evaluar el desempeño predictivo, como el MAE y el MSE, deben interpretarse con cautela al comparar resultados entre conjuntos de datos distintos. Estas métricas dependen directamente de la escala de la variable analizada, por lo que sus valores no son necesariamente comparables de forma directa entre dominios. Por ejemplo, los errores asociados al flujo vehicular tienden a ser naturalmente mayores que aquellos observados en series de criptomonedas o temperatura OT, debido a las diferencias en las unidades de medición y en la magnitud típica de las observaciones. En consecuencia, las comparaciones basadas en MAE y MSE son más apropiadas dentro de un mismo conjunto de datos y entre modelos evaluados bajo la misma escala, pero no deben interpretarse como una comparación absoluta de dificultad predictiva entre datasets.

No obstante, la evidencia empírica también muestra que el uso de un modelo no lineal no implica una mejora sistemática del desempeño predictivo. En los conjuntos de criptomonedas y temperatura OT, los mejores resultados se obtienen con métodos más simples, como FAR(1), Kalman lineal o f-GARCH. Esta observación sugiere que, cuando la dinámica dominante puede describirse de manera suficientemente adecuada mediante una estructura lineal o parsimoniosa, la introducción de no linealidad adicional puede traducirse en una complejidad innecesaria y en una pérdida de precisión predictiva. Por consiguiente, la principal conclusión empírica del trabajo no es que el UKF domine universalmente a los métodos clásicos, sino que su utilidad depende de la estructura efectiva del proceso

funcional analizado.

Los experimentos de simulación permitieron complementar esta lectura empírica al estudiar el comportamiento del método bajo escenarios controlados de especificación. En particular, se analizó la sensibilidad del procedimiento frente a cambios estructurales, a elecciones inadecuadas de la dimensión funcional y a desviaciones de gaussianidad. Estos experimentos muestran que el desempeño del modelo depende de forma crítica tanto de la calidad de la representación reducida como de la especificación de la dinámica latente. En especial, la elección del número de componentes retenidas constituye un compromiso entre fidelidad de representación y estabilidad numérica, mientras que la presencia de perturbaciones extremas o cambios no modelados puede afectar de manera importante la calidad de las estimaciones secuenciales.

A partir de estos resultados, pueden destacarse tres conclusiones generales. En primer lugar, la etapa de reducción de dimensión no es un procedimiento auxiliar, sino una parte estructural del método, ya que condiciona tanto la representación funcional como el comportamiento dinámico posterior. En segundo lugar, la formulación de espacio de estados proporciona una ventaja conceptual relevante al permitir una distinción explícita entre estado latente y observación. En tercer lugar, la incorporación de un filtro no lineal como el UKF es pertinente cuando la dinámica del estado reducido presenta complejidad suficiente para justificarlo, pero no constituye una mejora automática en todo escenario.

El trabajo presenta, sin embargo, ciertas limitaciones. La primera de ellas es que el análisis se realiza sobre una representación truncada de dimensión fija, por lo que la elección de la base y del número de componentes retenidas influye directamente en los resultados. La segunda es que la implementación del UKF se lleva a cabo en un espacio reducido de dimensión baja, lo cual favorece la viabilidad computacional, pero puede restringir la capacidad del modelo para capturar modos de variación adicionales. La tercera es que la metodología no incorpora de manera explícita variables exógenas ni mecanismos más generales de cambio de régimen, que podrían ser relevantes en algunos de los dominios considerados. Adicionalmente, la evaluación cuantitativa se basa principalmente en métricas dependientes de escala, como MAE y MSE, lo que limita la comparación directa del desempeño entre conjuntos de datos con unidades y magnitudes distintas.

Estas limitaciones sugieren varias direcciones de trabajo futuro. Una primera línea consiste en desarrollar formulaciones de espacio de estados funcionales con dinámica explícitamente variante en el tiempo o con cambios de régimen. Una segunda posibilidad es incorporar modelos no gaussianos o filtros secuenciales más generales que permitan una mayor robustez frente a colas pesadas y outliers. Asimismo, sería natural considerar la inclusión de variables exógenas dentro del estado reducido o en la ecuación de observación. Otra extensión de interés consiste en estudiar esquemas híbridos que preserven la interpretabilidad funcional, pero incorporen mecanismos de aprendizaje más flexibles para la dinámica del sistema. Finalmente, sería conveniente incluir métricas normalizadas de desempeño predictivo, tales como errores relativos, RMSE normalizado, MASE o medidas porcentuales cuando sean apropiadas, con el fin de facilitar comparaciones más equilibradas entre conjuntos de datos con escalas y unidades de medición diferentes.

En síntesis, esta tesis muestra que la combinación de representación funcional, reducción de dimensión e inferencia recursiva en espacio de estados constituye un marco metodológico pertinente para el análisis predictivo de series temporales funcionales. Sin embargo, los resultados también muestran que la incorporación de no linealidad mediante UKF debe justificarse empíricamente caso a caso, pues modelos más parsimoniosos pueden presentar igual o mejor desempeño cuando la dinámica reducida es predominantemente lineal, persistente o dominada por heterocedasticidad. Además, la interpretación comparativa de los errores debe considerar la escala propia de cada conjunto de datos, por lo que el uso de métricas normalizadas constituye una extensión natural para futuros análisis.

Bibliografía

- Aue, A. and Horváth, L. (2013). Structural breaks in functional time series. *Journal of Multivariate Analysis*.
- Aue, A., Norinho, D. D., and Hörmann, S. (2015). On the prediction of stationary functional time series. *Journal of the American Statistical Association*, 110(509):378–392.
- Bosq, D. (2000). *Linear Processes in Function Spaces: Theory and Applications*, volume 149 of *Lecture Notes in Statistics*. Springer, New York.
- Cerovecki, C. and Sørensen, S. (2019). Functional garch models: The quasi-likelihood approach and its applications. *Journal of Econometrics*, 209(1):263–281.
- Durbin, J. and Koopman, S. J. (2012). *Time Series Analysis by State Space Methods*. Oxford University Press.
- Ferraty, F. and Vieu, P. (2006). *Nonparametric Functional Data Analysis*. Springer.
- Hays, S., Shen, H., and Huang, J. Z. (2012). Functional dynamic factor models with application to yield curve forecasting. *The Annals of Applied Statistics*.
- Hörmann, S., Kidziński, Ł., and Hallin, M. (2015). Dynamic functional principal components. *Journal of the Royal Statistical Society: Series B*, 77(2):319–348.
- Horváth, L. and Kokoszka, P. (2012). *Inference for Functional Data with Applications*. Springer.
- Hsing, T. and Eubank, R. (2015). *Theoretical Foundations of Functional Data Analysis, with an Introduction to Linear Operators*. Wiley.
- Hyndman, R. J., Ahmed, R., Athanasopoulos, G., and Shang, H. L. (2011). Optimal combination forecasts for hierarchical time series. *Computational Statistics Data Analysis*.

- Hyndman, R. J. and Ullah, M. S. (2007). Robust forecasting of mortality and fertility rates: A functional data approach. *Computational Statistics & Data Analysis*, 51(10):4942–4956.
- Hörmann, S. and Kokoszka, P. (2012). *Functional Time Series*. Springer Series in Statistics. Springer, New York.
- Julier, S. J. and Uhlmann, J. K. (1997). A new extension of the kalman filter to non-linear systems. In *Proceedings of AeroSense: The 11th International Symposium on Aerospace/Defense Sensing, Simulation and Controls*.
- Kalman, R. E. (1960). A new approach to linear filtering and prediction problems. *Journal of Basic Engineering*, 82(1):35–45.
- Kokoszka, P. and Reimherr, M. (2017). *Introduction to Functional Data Analysis*. CRC Press.
- Lim, B., Arik, S. O., Loeff, N., and Pfister, T. (2021). Temporal fusion transformers for interpretable multi-horizon time series forecasting. *International Journal of Forecasting*.
- Lütkepohl, H. (2005). *New Introduction to Multiple Time Series Analysis*. Springer.
- Mallat, S. (2008). *A Wavelet Tour of Signal Processing: The Sparse Way*. Academic Press, 3 edition.
- Nagbe, K., Cugliari, J., and Jacques, J. (2018). Short-term electricity demand forecasting using a functional state space model. *Energies*, 11(5):1120.
- Ramsay, J. O., Hooker, G., and Graves, S. (2009). *Functional Data Analysis with R and MATLAB*. Springer.
- Ramsay, J. O. and Silverman, B. W. (2005). *Functional Data Analysis*. Springer, 2nd edition.
- Rasmussen, C. E. and Williams, C. K. I. (2006). *Gaussian Processes for Machine Learning*. MIT Press.
- Rauch, H. E., Tung, F., and Striebel, C. T. (1965). Maximum likelihood estimates of linear dynamic systems. *AIAA Journal*, 3(8):1445–1450.

- Särkkä, S. (2007). On unscented kalman filtering for state estimation of continuous-time nonlinear systems. *IEEE Transactions on Automatic Control*, 52(9):1631–1641.
- Särkkä, S. (2013). *Bayesian Filtering and Smoothing*. Cambridge University Press.
- Shumway, R. H. and Stoffer, D. S. (2017). *Time Series Analysis and Its Applications*. Springer.
- Simon, D. (2006). *Optimal State Estimation: Kalman, H Infinity, and Nonlinear Approaches*. Wiley.
- Strang, G. and Nguyen, T. (1996). *Wavelets and Filter Banks*. Wellesley-Cambridge Press.
- Vaswani, A. e. a. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*.
- Wan, E. A. and van der Merwe, R. (2000). The unscented kalman filter for nonlinear estimation. In *Proceedings of the IEEE Adaptive Systems for Signal Processing, Communications, and Control Symposium*.
- West, M. and Harrison, J. (1997). *Bayesian Forecasting and Dynamic Models*. Springer, 2 edition.
- Xu, M., Zhu, L., and Müller, H.-G. (2017). Varying coefficient functional autoregressive model with application to forecasting of electricity demand. *Journal of Multivariate Analysis*, 153:139–155.

Apéndice A

Código computacional

A.1. Código base para los dataset

A continuación se presenta un script representativo del procedimiento implementado en esta tesis. El código incluye la construcción de curvas funcionales, suavizamiento mediante bases B-spline, reducción de dimensión vía FPCA, ajuste de modelos dinámicos en el espacio reducido y evaluación predictiva sobre el conjunto de datos de criptomonedas, se replica de la misma manera con pequeñas modificaciones para el resto de datasets.

```
1 # =====
2 # 1. CARGA DE LIBRERAS Y DATOS
3 # =====
4 library(fda)
5 library(dplyr)
6 library(tidyr)
7 library(lubridate)
8 library(vars)
9 library(dlm)
10
11 ruta <-
12     "https://raw.githubusercontent.com/.../Gemini_ASHUSD_1h.csv"
13 datos <- read.csv(ruta, skip = 1)
```

```

14 df_curvas <- datos %>%
15   mutate(dt = as.POSIXct(date, format="%Y-%m-%d %H:%M:%S"),
16          fecha_dia = as.Date(dt),
17          hora = hour(dt)) %>%
18   arrange(dt) %>%
19   group_by(fecha_dia, hora) %>%
20   summarise(Precio = mean(close, na.rm = TRUE), .groups = "drop")
21   %>%
22   group_by(fecha_dia) %>%
23   filter(n() == 24) %>%
24   ungroup() %>%
25   pivot_wider(names_from = fecha_dia, values_from = Precio) %>%
26   arrange(hora)
27
28 matriz_puntos <- as.matrix(df_curvas[, -1])
29 n_dias <- ncol(matriz_puntos)
30 horas <- 0:23
31 rango <- c(0, 23)
32
33 # =====
34 # 2. FDA Y PROYECCIONES (B-SPLINES)
35 # =====
36 base_bspline <- create.bspline.basis(rangeval = rango, nbasis = 15)
37 ash_fd <- smooth.basis(argvals = horas, y = matriz_puntos,
38                        fdParobj = base_bspline)$fd
39 ash_pca <- pca.fd(ash_fd, nharm = 5)
40 xi_all <- ash_pca$scores
41 xi <- ash_pca$scores[, 1:2]
42
43 # =====
44 # 3. EJECUCI N DE LOS 6 MODELOS
45 # =====
46
47 # --- A. VAR Din mico ---

```

```

46 mod_var <- VAR(xi[1:(n_dias-1)], ], p = 1, type = "none")
47 p_var <- predict(mod_var, n.ahead = 1)$fcst
48 xi_hat_var <- c(p_var$y1[1,1], p_var$y2[1,1])
49 curva_var <- ash_pca$meanfd + (xi_hat_var[1] *
    ash_pca$harmonics[1]) + (xi_hat_var[2] * ash_pca$harmonics[2])
50
51 # --- B. Kalman Lineal ---
52 y_obs_k <- xi[2:n_dias, 1]; x_reg_k <- xi[1:(n_dias-1), ]
53 build_k <- function(p) dlmModReg(x_reg_k, addInt=F, dV=exp(p[1]),
    dW=exp(p[2:3]))
54 fit_k <- dlmMLE(y_obs_k, parm=c(0,0,0), build=build_k)
55 filtro <- dlmFilter(y_obs_k, build_k(fit_k$par))
56 p_sl_k <- sum(filtro$m[nrow(filtro$m), ] * xi[n_dias, ])
57 curva_kal <- ash_pca$meanfd + (p_sl_k * ash_pca$harmonics[1])
58
59 # --- C. UKF ---
60 mean_xi <- apply(xi, 2, mean); sd_xi <- apply(xi, 2, sd); xi_n <-
    scale(xi)
61 L <- 2; alpha <- 0.01; beta <- 2; kappa <- 0; lambda <- alpha^2 *
    (L + kappa) - L
62 wm <- c(lambda/(L+lambda), rep(1/(2*(L+lambda)), 2*L)); wc <- wm;
    wc[1] <- wc[1]+(1-alpha^2+beta)
63 x_h <- matrix(0, n_dias, L); x_h[1,] <- xi_n[1,]; P <- diag(0.01,
    L); Q <- diag(0.0001, L); R <- 0.05
64 for (t in 2:n_dias) {
65     chol_P <- tryCatch(chol((L+lambda)*P), error=function(e)
        diag(0.01, L))
66     sig <- rbind(x_h[t-1,], sweep(chol_P, 1, x_h[t-1,], "+"),
        sweep(-chol_P, 1, x_h[t-1,], "+"))
67     x_p <- colSums(wm*sig); P_p <- Q
68     for (i in 1:5) { d <- sig[i,]-x_p; P_p <- P_p + wc[i]*(d*%t(d))
        }
69     z_o <- xi_n[t,1]; z_s <- sig[,1]; z_h <- sum(wm*z_s); P_zz <- R
        + sum(wc*(z_s-z_h)^2); P_xz <- matrix(0, L, 1)

```

```

70   for (i in 1:5) { P_xz <- P_xz + wc[i]*(sig[i,]-x_p)*(z_s[i]-z_h)
      }
71   K_g <- P_xz/P_zz; x_h[t,] <- x_p + as.vector(K_g*(z_o-z_h)); P
      <- P_p - (K_g%*%t(K_g))*P_zz
72 }
73 xi_ukf_f <- x_h[n_dias,]*sd_xi + mean_xi
74 curva_ukf <- ash_pca$meanfd + (xi_ukf_f[1]*ash_pca$harmonics[1]) +
      (xi_ukf_f[2]*ash_pca$harmonics[2])
75
76 # --- D. FAR(1) ---
77 S_ayer <- xi_all[1:(n_dias-1), ]; S_hoy <- xi_all[2:n_dias, ]
78 beta_far <- solve(t(S_ayer) %*% S_ayer) %*% t(S_ayer) %*% S_hoy
79 p_scores_far <- xi_all[n_dias, ] %*% beta_far
80 curva_far <- ash_pca$meanfd; for(i in 1:5) curva_far <- curva_far
      + (p_scores_far[i] * ash_pca$harmonics[i])
81
82 # --- E. TV-FAR (Time-Varying FAR) ---
83 ventana <- 30
84 S_ayer_tv <- xi_all[(n_dias-ventana):(n_dias-1), ]
85 S_hoy_tv <- xi_all[(n_dias-ventana+1):n_dias, ]
86 beta_tv <- solve(t(S_ayer_tv) %*% S_ayer_tv) %*% t(S_ayer_tv) %*%
      S_hoy_tv
87 p_scores_tv <- xi_all[n_dias, ] %*% beta_tv
88 curva_tvfar <- ash_pca$meanfd; for(i in 1:5) curva_tvfar <-
      curva_tvfar + (p_scores_tv[i] * ash_pca$harmonics[i])
89
90 # --- F. f-GARCH ---
91 residuos_all <- S_hoy - (S_ayer %*% beta_far)
92
93 estimar_h <- function(res) {
94   n <- length(res)
95   h <- numeric(n)
96   h[1] <- var(res)
97   omega <- 0.05 * var(res)

```

```

98   alpha <- 0.1
99   beta_g <- 0.8
100  for (i in 2:n) {
101    h[i] <- omega + alpha * (res[i-1]^2) + beta_g * h[i-1]
102  }
103  return(tail(h, 1))
104 }
105
106 h_next <- apply(residuos_all, 2, estimar_h)
107 volatilidad_f <- sqrt(h_next)
108 curva_fgarch <- curva_far - (0.5 * volatilidad_f[1] *
109   ash_pca$harmonics[1])
110 # =====
111 # 4. TABLA DE METRICAS
112 # =====
113 grilla <- seq(0, 23, length.out = 200)
114 y_real <- as.vector(eval.fd(grilla, ash_fd[n_dias]))
115
116 preds <- list(
117   VAR = as.vector(eval.fd(grilla, curva_var)),
118   Kalman = as.vector(eval.fd(grilla, curva_kal)),
119   UKF = as.vector(eval.fd(grilla, curva_ukf)),
120   FAR = as.vector(eval.fd(grilla, curva_far)),
121   TV_FAR = as.vector(eval.fd(grilla, curva_tvfar)),
122   f_GARCH = as.vector(eval.fd(grilla, curva_fgarch))
123 )
124
125 metricas <- data.frame(
126   Modelo = c("VAR Dinámico", "Kalman Lineal", "UKF", "FAR(1)",
127     "TV-FAR", "f-GARCH"),
128   MAE = sapply(preds, function(x) mean(abs(y_real - x))),
129   MSE = sapply(preds, function(x) mean((y_real - x)^2))
130 )

```

```
130  
131 print(metricas[order(metricas$MAE), ])
```

Listing A.1: Script representativo del pipeline experimental en R.